

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

FACULTAD DE CIENCIAS E INGENIERÍA



“Traducción automática neuronal Shiwilu–Castellano”

Tesis para obtener el título profesional de Ingeniería Informática

AUTOR:

Fabian Prado Infanson

ASESOR:

Mg. Erasmo Gómez

Lima, 26 de Julio del 2025

Resumen

El shiwilu, también conocido como jebero, es una lengua amazónica peruana en situación crítica de amenaza, cuya presencia digital y disponibilidad de recursos bilingües siguen siendo limitadas. Esta tesis aborda dicho problema mediante la propuesta de un sistema de traducción automática neuronal bidireccional entre shiwilu y castellano, orientado a apoyar la documentación, el aprendizaje y el uso cotidiano de la lengua en contextos educativos y comunitarios.

El trabajo se centra en la construcción de una base metodológica y técnica para desarrollar el sistema: recopilación y alineación de un corpus paralelo, definición de criterios de selección y normalización, preparación de recursos de representación semántica, diseño de modelos de traducción y planteamiento de un protocolo de evaluación que combine métricas automáticas con validación participativa. La investigación adopta un enfoque reproducible, trazable y sensible a las particularidades lingüísticas del shiwilu, considerando los desafíos propios de las lenguas de bajo recurso.

Con ello, la tesis busca aportar un recurso tecnológico inicial y una ruta experimental documentada para futuras investigaciones en traducción automática de lenguas originarias.

Índice general

Resumen	1
1 Generalidades	8
1.1 Problemática	8
1.1.1 Árbol de Problemas	11
1.1.2 Causas	11
1.1.3 Consecuencias	12
1.1.4 Problema seleccionado	13
1.2 Objetivos	13
1.2.1 Objetivo general	13
1.2.2 Objetivos específicos	13
1.2.3 Resultados esperados	14
1.2.4 Mapeo de objetivos, resultados y verificación	15
1.3 Métodos y Procedimientos	16
1.3.1 Herramientas:	17
1.3.2 Justificación	17
1.3.3 Detalle	18
1.3.4 Métodos	19
1.3.5 Procedimientos	20
2 Marco Conceptual	21

2.1	Introducción	21
2.2	Desarrollo del marco	21
2.2.1	Procesamiento de Lenguaje Natural (NLP)	21
2.2.2	Lenguas de bajo recursos (LRL)	22
2.2.3	Alineación oración a oración	22
2.2.4	Preprocesamiento y tokenización sub-palabra	23
2.2.5	Aumento de datos (<i>data augmentation</i>)	24
2.2.6	Transfer learning y modelos multilingües	25
2.2.7	Adaptación eficiente (adapters/LoRA)	26
2.2.8	Representaciones vectoriales (embeddings) y minería/filtrado	26
2.2.9	BLEU (Bilingual Evaluation Understudy)	27
2.2.10	chrF (carácter n-gram F-score)	27
2.2.11	BERTScore y COMET	27
3	Estado del Arte	29
3.1	Introducción	29
3.2	Objetivos de revisión	29
3.3	Preguntas de revisión	30
3.4	Estrategia de búsqueda	30
3.4.1	Motores de búsqueda a usar	30
3.4.2	Cadenas de búsqueda a usar	31
3.4.3	Documentos encontrados	34
3.4.4	Criterios de inclusión/exclusión	34
3.5	Formulario de extracción de datos	35

3.6	Resultados de la revisión	36
3.6.1	¿Qué técnicas de generación y ampliación de datos (back-translation, mutación semántica, paraphrasing, pivoting, filtrado por embeddings, etc.) producen mejoras reproducibles en NMT para pares de muy bajos recursos?	36
3.6.2	¿Qué arquitecturas y estrategias de entrenamiento (multilingüe, transfer learning, fine-tuning bidireccional, adapters, few/zero-shot) ofrecen el mejor balance entre rendimiento y coste computacional para un modelo shiwilu↔castellano, y qué baselines son apropiados para la comparación?	39
3.6.3	¿Qué métricas automáticas (BLEU, ChrF++, TER, ¿etc.) y procedimientos de validación combinada (evaluación automática + pruebas participativas con hablantes) son más adecuados y fiables para medir adecuación lingüística y pertinencia cultural en traducciones de lenguas originarias con corpus escaso?	42
3.7	Conclusiones	44
4	Recopilación y preparación inicial del corpus bilingüe	45
4.1	Introducción	45
4.2	Fuentes del corpus bilingüe	45
4.3	Construcción, normalización y auditoría del corpus	48
4.4	Caracterización del corpus preparado	50
4.5	Particiones reproducibles del corpus	52
4.6	Preparación del modelo de embeddings	53
5	Sistema de traducción neuronal SA-BiNLLB	57
5.1	Introducción	57
5.2	Arquitectura general	58

5.3	Datos canónicos para NMT	58
5.4	Filtrado semántico de calidad	59
5.5	Entrenamiento del modelo v_0	60
5.6	Augmentación de datos para v_{1bt}	60
5.7	Resultados experimentales	62
5.8	Evaluación humana	65
5.9	Conclusión del capítulo	65
6	Conclusiones y trabajos futuros	66
6.1	Conclusiones	66
6.2	Trabajos futuros	66
	Referencias	68
A	Anexos	75
	Anexo B: Documento reproducible del proceso de corpus y embeddings	91
	Anexo C: Documento reproducible del sistema NMT SA-BiNLLB	97

Índice de cuadros

1.1	Resultados esperados (mapeo de objetivos, MV e IOV)	15
1.2	Herramientas, métodos y procedimientos a utilizar	17
3.1	Resultados de búsqueda de las cadenas	34
3.2	Resultados luego de aplicar criterios de exclusión	34
3.3	Formulario de extracción de datos	35
4.1	Fuentes bilingües incorporadas al corpus	47
4.2	Etapas reproducibles de preparación del corpus	50
4.3	Resumen del corpus consolidado y auditado	51
4.4	Estadísticas léxicas del corpus auditado	51
4.5	Particiones canónicas del corpus bilingüe (variante x1, semilla 42)	52
4.6	Métricas del modelo de embeddings preparado	54
5.1	Distribución del corpus canónico bidireccional para entrenamiento NMT (variante x1).	59
5.2	Distribución de pares en el conjunto de entrenamiento tras el filtro semántico (variante x1).	60
5.3	Comparación de variantes del sistema sobre el conjunto de prueba (variante x1, 451 pares por dirección). chrF++ es la métrica primaria.	62
5.4	<i>Leaderboard</i> cerrado del ciclo de ablaciones sobre la variante x1 (446 pares por dirección, 892 filas direccionales). chrF++ es la métrica primaria.	63

5.5	Intervalos de confianza bootstrap del 95 % sobre chrF++ reranked, $n = 1000$ re-muestras percentil por dirección. Las predicciones avg vuelven a re-muestrear cada dirección independientemente.	64
A.1	Limitaciones del proyecto	79
A.2	Umbral de riesgo (probabilidad e impacto)	80
A.3	Matriz de riesgos del proyecto	81
A.4	Lista de tareas (EDT)	84
A.5	Cronograma del proyecto	86
A.6	Presupuesto del proyecto	90
A.7	Artefactos reproducibles de construcción del corpus	92
A.8	Criterios documentados para selección y normalización	93
A.9	Archivos canónicos de partición	93
A.10	Evolución experimental del modelo de embeddings	94
A.11	Reportes del modelo de embeddings preparado	96
A.12	Hiperparámetros del adaptador LoRA y del entrenamiento.	98
A.13	Ablación de α en el <i>reranker</i> semántico (modelos v_0 y v_{1bt} , variante x1, conjunto de <i>test</i> , métrica de selección: chrF++ promedio).	100
A.14	Ablación de α para el modelo aumentado v_{1bt} (variante x1).	100
A.15	Análisis rare-token / OOV sobre el bucket de referencias con $\geq 20\%$ palabras raras (variante x1).	104
A.16	Tokens promedio por oración de shiwilu: SP Unigram entrenado en este trabajo vs. el <i>tokenizer</i> multilingüe de NLLB-200 (variante x1).	105
A.17	Pipeline reproducible del sistema NMT SA-BiNLLB.	108

Capítulo 1

Generalidades

1.1 Problemática

El shiwilu, también llamado jebero, es una lengua amazónica peruana de la familia cahuapana que atraviesa un estado crítico de amenaza. El número de hablantes es muy reducido, en su mayoría personas adultas mayores, y la transmisión intergeneracional se encuentra quebrada (Valenzuela, 2018). Aunque en 2016 fue declarada Patrimonio Cultural de la Nación, su presencia en el ecosistema digital sigue siendo mínima, lo que incrementa el riesgo de desplazamiento. Cuando una lengua no encuentra espacios de uso en entornos digitales, su marginación se acelera y disminuye la posibilidad de su aprendizaje y uso cotidiano (Ministerio de Cultura del Perú, 2016; UNESCO, 2023).

En este escenario, un sistema de traducción automática neuronal entre shiwilu y castellano podría convertirse en una herramienta estratégica para documentar, acceder y circular conocimiento bilingüe. No obstante, el desarrollo de un traductor de este tipo enfrenta un cuello de botella inmediato: no existe un corpus paralelo shiwilu–castellano con volumen y diversidad suficientes para entrenar y evaluar modelos con criterios reproducibles. La traducción automática, tanto en su vertiente estadística como neuronal, depende de colecciones amplias de oraciones alineadas; cuando el paralelo es mínimo, la calidad de los modelos cae y los resultados no son comparables entre estudios (Mager & Meza, 2018). En shiwilu, más allá de aportes de documentación, como el diccionario bilingüe con ejemplos de uso, los datos disponibles siguen siendo escasos y dispersos, de modo que no hay baselines ni conjuntos de prueba estables contra los cuales contrastar avances (Valenzuela, 2018). Esta situación contrasta con pares mejor documentados en la región, como quechua–español o shipibo–español, donde ya existen corpus iniciales y

evaluaciones básicas que permiten organizar la investigación (Chuquimamani, 2021; Galarreta, 2017).

El problema abarca también la calidad y la representatividad de los datos. En ausencia de textos variados, el material disponible tiende a concentrarse en narrativas tradicionales o léxico especializado, lo que sesga el dominio temático y deja fuera construcciones frecuentes del uso cotidiano. Con pocos ejemplos, los modelos neuronales sobreajustan y generalizan mal, fenómeno documentado en lenguas indígenas con corpus de apenas miles de oraciones (Mager & Meza, 2018). A ello se suma la distancia tipológica entre shiwilu y castellano: la morfología aglutinante, ciertos patrones estructurales y los alineamientos semánticos no uno a uno complica la alineación y la traducción literal de términos culturalmente marcados; en varios casos no hay equivalencias directas, lo que exige una curación cuidadosa y verificación contextual de las parejas de oración (Ministerio de Cultura del Perú, 2016). Incluso si se reúne un primer conjunto paralelo, la calidad del dato y su adecuación semántica y cultural se vuelven el desafío central.

La dimensión sociolingüística es igualmente ineludible, ya que la construcción de recursos depende del trabajo con hablantes. Dada la escala de la comunidad y la edad de sus miembros, la obtención y validación de paralelos requiere colaboración cercana. En este proyecto, el Grupo Chana ha articulado la recolección de materiales con apoyo del señor Fidel Lomas Chota, hablante competente y autor de relatos en shiwilu, quien ha contribuido con traducciones y validaciones. Su participación garantiza datos de primera mano y criterio cultural para juzgar la aceptabilidad de equivalencias, un aspecto que las métricas automáticas no capturan por sí solas (UNESCO, 2023). La experiencia comparada en náhuatl y guaraní sugiere, además, que sin esta mediación humana los modelos tienden a aprender artefactos del corpus y fallan en variedades o géneros no cubiertos por los datos de entrenamiento (Baladón et al., 2024; Ríos, 2019).

El panorama regional confirma que la base del problema en lenguas de muy bajos recursos es doble: escasez de corpus y ausencia de referencias evaluativas. En quechua sureño, la creación de nuevos conjuntos bilingües a partir de fuentes dispersas fue condición previa para evaluar con métricas estándar y establecer comparaciones significativas; sin ese piso de datos, no era

posible justificar avances ni orientar mejoras (Chuquimamani, 2021). En shipibo–español, un esfuerzo temprano desde el enfoque estadístico mostró el mismo patrón: antes de buscar la mejor arquitectura, era imprescindible contar con un corpus alineado utilizable y un procedimiento reproducible para entrenar y medir (Galarreta, 2017). Estas lecciones sugieren que, en shiwilu, no hay atajos de ingeniería: sin un primer corpus paralelo confiable y criterios de evaluación claros, cualquier intento de traducción neuronal carecerá de base metodológica y relevancia práctica (Meque et al., 2023).

En síntesis, la problemática que aborda esta tesis es multidimensional. En el plano técnico, falta el insumo esencial, el cual es un corpus paralelo validado y por arrastre, faltan líneas de base y protocolos de evaluación adaptados al par shiwilu–castellano. En el plano lingüístico, la asimetría tipológica y la carga cultural de numerosos términos exigen datos cuidadosamente curados y verificación contextual. En el plano social, la escala pequeña y envejecida de la comunidad obliga a que la construcción de recursos sea participativa, pues solo así se asegura que las traducciones sean útiles y respetuosas (UNESCO, 2023). Mantener este conjunto de factores sin atender mantiene al shiwilu fuera del ecosistema digital y limita su aprendizaje, su circulación escrita y su presencia simbólica en la esfera pública.

Este diagnóstico delimita con precisión el núcleo del problema: sin corpus paralelo validado, sin líneas de base y sin un esquema de verificación que combine métricas automáticas con revisión por hablantes, no es posible avanzar con rigor hacia un traductor neuronal shiwilu↔castellano. Por ello, esta investigación asume como punto de partida la construcción y depuración de datos bilingües con apoyo comunitario, junto con la definición de criterios evaluativos reproducibles que permitan situar cualquier resultado en una línea cero clara. Solo sobre ese cimiento será razonable explorar y comparar arquitecturas, estrategias de transferencia y futuros incrementos de datos. Atender esta problemática no solo llena un vacío científico en la traducción automática de lenguas peruanas de muy bajo recurso; también supone un paso concreto para que el shiwilu tenga presencia en la esfera tecnológica contemporánea (UNESCO, 2023; Valenzuela, 2018).

1.1.1 Árbol de Problemas

En la figura 1 se muestra un panorama claro para observar la problemática central, las causas consideradas y consecuencias que generan estas mismas.




Figura 1.1: Árbol de Problemas

1.1.2 Causas

Inexistencia de un corpus paralelo shiwilu–castellano adecuado. Los textos disponibles son escasos, dispersos y con variaciones ortográficas y de dominio que dificultan su aprovechamiento. Falta alineación fiable a nivel de oración, hay ruido (traducciones parciales, glosas, duplicados) y metadatos incompletos. Además, no existen particiones estandarizadas de entrenamiento/validación/prueba que permitan comparaciones justas y reproducibles.

Investigación limitada y falta de baselines adaptados al par shiwilu–castellano. Hay pocos estudios específicos y no se cuenta con líneas base consensuadas (configuraciones mínimas, tokenización/segmentación apropiada o variantes multilingües razonables). Esta carencia impide

medir avances con rigor, aislar el impacto de cada técnica y evitar conclusiones sesgadas por configuraciones ad-hoc.

Falta de métodos comparativos en línea para probar y contrastar modelos NMT. No existe una interfaz accesible que permita evaluar modelos lado a lado, registrar métricas y recopilar ejemplos de uso real de forma ágil. Sin pruebas comparativas en un entorno web, se ralentiza el ciclo de retroalimentación, se dificulta la trazabilidad de cambios y se limita la participación de docentes e integrantes de la comunidad.

Protocolos combinados de validación automatizada y participativa insuficientes. Predomina el uso de métricas automáticas generales que no capturan adecuación, naturalidad ni pertinencia cultural. Faltan guías, instrumentos y criterios para integrar la revisión de hablantes (escalas, rúbricas, taxonomías de error, control de acuerdo inter-anotador), lo que genera evaluaciones incompletas y poco accionables.

1.1.3 Consecuencias

Modelos con precisión insuficiente en usos reales. Las salidas presentan errores léxicos y morfosintácticos, inestabilidad ante variantes ortográficas y pérdida de sentido en dominios no vistos. Esto reduce la confianza de usuarios y docentes, eleva el costo de posesición y limita la adopción del traductor en tareas cotidianas (material educativo, comunicaciones comunitarias, trámites), dejando el sistema como un prototipo poco útil fuera del laboratorio.

Escasez de materiales bilingües para enseñanza y uso práctico. La falta de recursos paralelos limpios y actualizados impide generar textos, ejercicios y guías bilingües con progresión pedagógica. Se restringen las oportunidades de lectura y escritura en shiwilu con apoyo del castellano, y se dificulta producir contenidos para contextos reales (salud, servicios públicos, señalética), perpetuando la dependencia de materiales aislados o desactualizados.

Menor visibilidad digital y dificultad en la revitalización. La baja disponibilidad de herramientas y contenidos en línea reduce la presencia del shiwilu en buscadores, plataformas y aplicaciones, desincentivando la participación de jóvenes y hablantes potenciales. Esto crea un círculo vicioso: menor uso genera menos datos y menos innovación, lo que a su vez limita el

apoyo institucional y la colaboración con otras comunidades y actores tecnológicos.

1.1.4 Problema seleccionado

Dificultad para que nuevos hablantes aprendan, interioricen y usen cotidianamente la lengua shiwilu, por la limitada disponibilidad de recursos bilingües, herramientas y evaluaciones pertinentes.

1.2 Objetivos

1.2.1 Objetivo general

Mejorar la capacidad de nuevos hablantes para aprender e interiorizar la lengua shiwilu mediante el desarrollo de un sistema de traducción automática neuronal shiwilu↔castellano, sustentado en un corpus paralelo, protocolos de evaluación automática-participativa y un prototipo funcional para su uso en contextos reales.

1.2.2 Objetivos específicos

- 1. Recopilar y alinear un corpus paralelo shiwilu–castellano y producir particiones reproducibles para entrenamiento, validación y prueba.**
 - **Alcance de fuentes:** delimitar criterios de inclusión y priorizar materiales comunitarios, educativos y documentales.
 - **Alineación a nivel de oración:** segmentar, normalizar variantes ortográficas y sincronizar pares con apoyo de herramientas.
 - **Reproducibilidad:** definir reglas para train/valid/test, con bitácora del preprocesamiento.
- 2. Implementar y validar un modelo de traducción automática neuronal bidireccional (shiwilu↔castellano).**
 - **Arquitectura y tokenización:** seleccionar un esquema adecuado a bajo recurso y fijar parámetros de segmentación.

- **Control experimental:** documentar configuraciones e hiperparámetros para asegurar replicabilidad.
3. **Definir un protocolo de validación que combine evaluación automática y validación participativa con hablantes para medir adecuación lingüística y pertinencia cultural.**
- **Métricas automáticas:** seleccionar indicadores (p. ej., BLEU/chrF/COMET) y su procedimiento de cálculo.
 - **Evaluación con hablantes:** diseñar instrumentos con rúbricas de adecuación, fluidez y pertinencia cultural.
 - **Confiabilidad:** establecer muestreo, instrucciones de anotación y medición de consistencia entre evaluadores.
4. **Diseñar e implementar un prototipo funcional de traductor automático neuronal que integre el modelo entrenado y facilite su uso y prueba.**
- **Funcionalidad mínima:** ingreso de texto y visualización de resultados de forma simple y accesible.
 - **Pruebas y registro:** habilitar pruebas básicas y registro estructurado de entradas/salidas para análisis.
 - **Integración y despliegue:** empaquetar el modelo y la interfaz en un entorno ejecutable

1.2.3 Resultados esperados

- O1:
 - R1: Corpus paralelo shiwilu–castello ambos correctamente preprocesado y con las características relevantes cantidad de palabras, de sustantivos, etc.
 - R2: Modelo de *embeddings* preparado.

- O2:
 - R3: Modelo de traducción automático shiwilu->castellano entrenado.
 - R4: Modelo de traducción automático castellano->shiwilu entrenado.
- O3:
 - R5: Protocolo de validación documentado (métricas automáticas, instrumentos y rúbricas para hablantes).
- O4:
 - R6: Prototipo funcional ejecutable localmente que integre el modelo NMT y permita pruebas básicas.
 - R7: Documento de proceso para la validación con pruebas de experto.
 - R8: Ejecución del proceso de validación con expertos.

1.2.4 Mapeo de objetivos, resultados y verificación

Para cada uno de los objetivos planteados, se plantearon los siguientes resultados esperados en esta Tabla 1.

Tabla 1.1: Resultados esperados (mapeo de objetivos, MV e IOV)

Objetivo	Resultados asociados	Medio de verificación (MV)	Indicador objetivamente verificable (IOV)
O1: Recopilar y alinear un corpus paralelo shiwilu–castellano y producir particiones reproducibles.	R1: Corpus depurado y alineado. R2: Modelo de <i>embeddings</i> preparado.	MV1: Informe breve de criterios de selección, normalización y alineación aplicadas. MV2: Entregable del modelo de embeddings	IOV1: Procedimiento descrito y aplicado. IOV2: Datos obtenidos del modelo de <i>embeddings</i>

Tabla 1.1 (continuación)

Objetivo	Resultados asociados	Medio de verificación (MV)	Indicador objetivamente verificable (IOV)
O2: Implementar y validar un modelo NMT bidireccional (shiwilu↔castellano).	R3: Modelo shiwilu→castellano R4: Modelo castellano→shiwilu.	MV3: Descripción del pipeline de entrenamiento y configuraciones probadas. MV4: Reporte de evaluación automática en valid/test.	IOV3: Entrenamientos completados en ambas direcciones. IOV4: Métricas BLEU/chrF presentadas.
O3: Definir un protocolo de validación que combine evaluación automática y participativa.	R4: Protocolo de validación documentado (métricas, instrumentos y rúbricas).	MV5: Protocolo que prioriza la evaluación automática (métricas) e incluye una sesión acotada con hablantes.	IOV5: Métricas automáticas reportadas y muestra acotada con hablantes registrada.
O4: Diseñar e implementar un prototipo funcional de traductor NMT que facilite su uso y prueba.	R5: Prototipo funcional ejecutable localmente que integre el modelo NMT y permita pruebas básicas. R7: Documento de proceso para pruebas de experto R8: Proceso de validación con expertos ejecutado.	MV6: Prototipo operativo con guía breve de uso y video corto de demostración.	IOV6: Demostración de traducción de ejemplos y registro de casos de prueba ejecutada (expertos).

1.3 Métodos y Procedimientos

Se describirán las herramientas, métodos, enfoques y procedimientos para lograr los resultados previstos. Todo ello se plantea en la tabla 2.

Tabla 1.2: Herramientas, métodos y procedimientos a utilizar

Resultados Esperados	Herramientas (H), Métodos (M) y Procedimientos (P)
R1: Corpus shiwilu–castellano preprocesado y alineado.	H: Python, regex, tokenizador. M: Limpieza, segmentación, alineación. P: Criterios→limpieza/segmentación→alineación→bitácora.
R2: Modelo de embeddings preparado.	H: Python, E5/Sentence-Transformers (o LASER), FAISS/índice vectorial. M: Embeddings oracionales; similitud y umbral.
R3: NMT shiwilu→castellano entrenado.	H: Python, PyTorch (Transformers) o TensorFlow; SentencePiece. M: Entrenamiento supervisado NMT; subword; evaluación BLEU/chrF. P: Particionar→entrenar→validar→métricas.
R4: NMT castellano→shiwilu entrenado.	H: Python, PyTorch (Transformers) o TensorFlow; SentencePiece. M: Mismo esquema que R3 en dirección inversa. P: Repetir pipeline→consolidar métricas.
R5: Protocolo de validación documentado.	H: Procesador de texto; formularios/hojas. M: Rúbricas (adecuación, fluidez, pertinencia); muestreo.
R6: Prototipo local funcional (UI simple).	H: Python, PyTorch/TensorFlow; Gradio/Streamlit; logs. P: UI→cargar checkpoint→traducir→registrar.
R7: Documento de proceso para pruebas de experto.	M: Plantilla de acta y checklist; versionado. P: Formato→checklist→evidencias→archivo.
R8: Validación con expertos ejecutada (actas).	M: Aplicación del protocolo; consolidación. P: Sesiones→consolidado→síntesis→mejoras.

1.3.1 Herramientas:

1.3.2 Justificación

La selección de herramientas responde a la necesidad de implementar un pipeline compacto y reproducible para traducción automática shiwilu↔castellano en un contexto de bajo recurso. Python se adopta como lenguaje de orquestación por su ecosistema maduro y la facilidad para controlar versiones, semillas y configuraciones a lo largo de todo el proceso.

En la preparación del corpus (R1) se emplean expresiones regulares y un tokenizador básico para limpieza, segmentación y alineación con reglas simples de longitud y puntuación, manteniendo una bitácora que documenta criterios y transformaciones. Para la representación semántica y el

filtrado (R2) se utilizan embeddings oracionales generados con E5/Sentence-Transformers (o LASER) y un índice vectorial FAISS, lo que permite estimar similitudes, fijar umbrales operativos, detectar *outliers* y priorizar pares útiles antes del modelado.

El modelado NMT bidireccional (R3–R4) se realiza con PyTorch o TensorFlow (familia Transformers) y segmentación en subpalabras mediante SentencePiece, a fin de reducir OOV y estabilizar el vocabulario en ambas direcciones. El entrenamiento se conduce bajo control experimental (semillas, *checkpoints* y configuraciones registradas) y se evalúa con métricas reproducibles (BLEU y chrF++), garantizando comparabilidad entre modelos y corridas.

Para la verificación práctica (R6) se implementa un prototipo local con Gradio o Streamlit, con interfaz mínima de entrada, traducción y salida, y registro estructurado de entradas y salidas para análisis posterior. La validación participativa (R5, R7–R8) se instrumenta con formularios y hojas de cálculo, apoyada en rúbricas de adecuación, fluidez y pertinencia cultural, y consolidada mediante actas y resúmenes que facilitan la trazabilidad de hallazgos y acciones de mejora.

En conjunto, estas herramientas sostienen cuatro principios operativos: calidad de datos (regex, tokenizador, embeddings e índice), robustez del modelo (SentencePiece y marcos de Deep learning), evaluación reproducible (BLEU/chrF++) y transferencia a la práctica (prototipo local y validación experta).

1.3.3 Detalle

- **Python:** Orquestación del pipeline de preprocesamiento, entrenamiento, evaluación y prototipado; control de semillas, versiones y configuraciones.
- **Expresiones regulares (regex):** Limpieza y normalización de texto (tildes, signos, espacios, duplicados) previas a la segmentación y alineación; soporte a la bitácora de decisiones.
- **Tokenizador:** Segmentación inicial de oraciones y palabras; generación de conteos (tokens, tipos, OOV) para trazabilidad del corpus paralelo.
- **E5 / Sentence-Transformers (o LASER):** Embeddings oracionales para medir similitud semántica, detectar outliers y priorizar material útil en bajo recurso.

- **FAISS / índice vectorial:** Búsqueda eficiente en el espacio de embeddings y aplicación de umbrales para filtrado y control de calidad.
- **SentencePiece:** Segmentación en subpalabras (BPE/unigram) para reducir OOV y estabilizar el vocabulario en shiwilu↔castellano.
- **PyTorch / TensorFlow (Transformers):** Entrenamiento NMT bidireccional con registro de hiperparámetros, checkpoints y configuraciones reproducibles.
- **sacreBLEU:** Cálculo estandarizado de BLEU en validación y prueba con parámetros fijados para asegurar comparabilidad.
- **chrF++:** Métrica complementaria basada en caracteres y palabras, adecuada para morfología rica en escenarios de bajo recurso.
- **Gradio / Streamlit:** Prototipo local con interfaz mínima (entrada → traducción → salida) y registro estructurado de casos para análisis posterior.
- **Formularios y hojas de cálculo:** Instrumentos para rúbricas, actas y consolidación de resultados en la validación con expertos (componentes cuantitativos y cualitativos).

1.3.4 Métodos

• Data augmentation

Generación de datos sintéticos (p. ej., sinónimos controlados, back-translation, interpolación en el espacio latente) para robustecer el entrenamiento, mejorar la cobertura y mitigar el sobreajuste en bajo recurso.

• Proceso KDD

Marco de descubrimiento de conocimiento que estructura el pipeline en selección, preprocesamiento, transformación y análisis exploratorio, asegurando orden, trazabilidad y criterios reproducibles.

• Tokenización subword (BPE/unigram)

Segmentación en subpalabras con SentencePiece para estabilizar el vocabulario y reducir OOV

en lenguas de bajo recurso, manteniendo compatibilidad en ambas direcciones de traducción.

- **Alineación paralela**

Uso combinado de herramientas automáticas (p. ej., *awesome-align*) y reglas lingüísticas simples (longitud, puntuación) para obtener alineaciones consistentes entre textos fuente y destino.

- **Evaluación A/B con bootstrapping**

Contraste de métricas automáticas (p. ej., BLEU, chrF++) mediante re-muestreo para estimar variabilidad y significancia de diferencias entre configuraciones o modelos.

- **Automatización de pipelines**

Orquestación de entrenamientos, evaluaciones y registros con scripts o DAG ligeros, fijando semillas y configuraciones para garantizar reproducibilidad y auditoría de experimentos.

1.3.5 Procedimientos

- **Revisión humana y refinamiento**

Evaluación muestral por hablantes nativos en coherencia, fluidez y fidelidad; consolidación de medidas descriptivas y ajuste iterativo de reglas de limpieza, alineación y generación sintética.

- **Verificación de calidad léxica (OOV)**

Comparación de vocabularios del corpus original y del sintético para estimar la proporción de tokens fuera de vocabulario; si se supera el umbral definido, se reajustan tokenización, filtrado y estrategias de expansión de datos.

- **Selección de checkpoint y control experimental**

Registro de configuraciones e hiperparámetros; elección del mejor checkpoint según validación; almacenamiento de bitácoras y métricas para comparación entre corridas.

- **Registro estructurado y trazabilidad**

Conservación de entradas y salidas, versiones de datos, semillas y resultados en repositorio organizado, facilitando replicación, auditoría y análisis posterior.

Capítulo 2

Marco Conceptual

2.1 Introducción

A continuación se presenta una síntesis de los fundamentos teóricos necesarios para clarificar los distintos aspectos de la problemática. En este capítulo se incluyen definiciones (por ejemplo, procesamiento de lenguaje natural), los algoritmos principales del aprendizaje automático y las técnicas concretas que se emplearán en la investigación (por ejemplo, back-translation), además de otros conceptos clave que sustentan el estudio. El propósito es ofrecer al lector un marco conceptual claro y coherente que facilite la comprensión de las decisiones metodológicas y la interpretación de los resultados.

2.2 Desarrollo del marco

El objetivo principal del marco conceptual es reunir y definir de forma precisa los conceptos, técnicas y herramientas que se utilizarán en la tesis, de modo que quede explícito el conocimiento necesario para comprender el problema y las soluciones propuestas. Este bloque conceptual proporciona el vocabulario técnico común para el trabajo, articula las nociones que sustentan los procedimientos experimentales y sirve de referencia para la interpretación de los resultados.

2.2.1 Procesamiento de Lenguaje Natural (NLP)

El Procesamiento de Lenguaje Natural (PLN) es la disciplina interdisciplinaria que combina informática, inteligencia artificial y lingüística para permitir que las máquinas analicen, interpreten y generen lenguaje humano de forma automática; abarca tareas que van desde la segmentación y el etiquetado morfosintáctico hasta la representación semántica y la generación de

texto (Chowdhury, 2003).

A nivel conceptual, el PLN transforma texto bruto en representaciones manipulables (tokens, sub-palabras, vectores/embeddings) y aplica modelos estadísticos o neuronales para aprender patrones lingüísticos: las etapas típicas son preprocesamiento → representación → modelado → evaluación. En la última década, los enfoques basados en aprendizaje profundo (p. ej. redes neuronales profundas y arquitecturas de atención Bahdanau et al., 2015) han pasado a ser el centro del PLN por su capacidad para aprender jerarquías de representaciones directamente de los datos (Socher & Manning, 2013).

2.2.2 Lenguas de bajo recursos (LRL)

Las lenguas de muy bajos recursos (Low-Resource Languages, LRL) son aquellas para las cuales existe una cantidad muy limitada de datos digitales, y en particular de corpus paralelos (fuente–meta) suficientes para entrenar modelos estadísticos o neuronales con buen desempeño. Esta condición incluye no solo la escasez numérica de ejemplos paralelos, sino también problemas asociados como dominio sesgado, variación ortográfica, ausencia de anotaciones lingüísticas y poca disponibilidad de textos monolingües de calidad (Koehn & Knowles, 2017; Zoph et al., 2016).

La escasez de datos reduce la capacidad de aprendizaje y la generalización de modelos NMT, incrementa el riesgo de overfitting y disminuye la cobertura léxica y contextual del sistema. Conceptualmente, las LRL requieren estrategias que compensen la falta de paralelo, por ejemplo, transferencia desde modelos preentrenados, aumento de datos o minería de paralelo comparable y una mayor atención a la normalización y validación lingüística para asegurar que los ejemplos disponibles representen adecuadamente las variantes del habla (Artetxe & Schwenk, 2019).

2.2.3 Alineación oración a oración

La alineación oración a oración consiste en emparejar oraciones equivalentes en dos lenguas para convertir colecciones comparables en pares fuente y meta utilizables por sistemas de traducción. En la práctica, este proceso combina heurísticas simples, por ejemplo reglas basadas en la longitud relativa de los segmentos, con métodos estadísticos o neuronales que explotan

señales léxicas, sintácticas y contextuales; asimismo, es habitual complementar las salidas automáticas con reglas lingüísticas o validación humana para reducir el ruido. Las correspondencias resultantes pueden ser uno a uno, uno a muchos o muchos a uno. La calidad de estas alineaciones puede medirse mediante indicadores como la precisión y la tasa de pares falsos, y condiciona directamente la utilidad del corpus: las alineaciones defectuosas introducen ruido que degrada el aprendizaje del modelo, mientras que las alineaciones limpias incrementan la señal supervisada disponible, lo cual es especialmente crítico en pares de muy bajos recursos. Las herramientas automáticas modernas, como los alineadores neuronales que emplean representaciones contextualizadas, facilitan la extracción de paralelo; aun así, en todos los casos es necesario aplicar criterios de filtrado y verificación para garantizar la coherencia temática y la trazabilidad de los pares.

2.2.4 Preprocesamiento y tokenización sub-palabra

El preprocesamiento agrupa las operaciones de limpieza y normalización del texto que convierten el material bruto en unidades coherentes y comparables para el modelado. Conceptualmente incluye la normalización de codificación (por ejemplo, normalización Unicode), la limpieza de ruido (eliminación o corrección de caracteres inválidos, marcas de formato o duplicados), la segmentación en oraciones y la normalización ortográfica mínima (p. ej., manejo de mayúsculas/minúsculas, tratamiento de signos de puntuación y variantes tipográficas). Estas transformaciones tienen por objeto reducir la varianza superficial del corpus y hacer que las señales lingüísticas que aprenden los modelos sean más estables y comparables entre fuentes heterogéneas.

La tokenización sub-palabra es una estrategia que divide las unidades léxicas en fragmentos más pequeños aprendidos a partir del propio corpus, con el fin de reducir el problema de palabras fuera de vocabulario y capturar elementos morfológicos productivos. Técnicamente, los métodos más usados son BPE (Byte Pair Encoding) y los modelos de unigram / SentencePiece, que construyen vocabularios de sub-unidades optimizando una medida de compactación o probabilidad sobre el corpus (Kudo & Richardson, 2018; Sennrich et al., 2016). A nivel conceptual, elegir una tokenización sub-palabra implica un compromiso entre tamaño del vocabulario y gra-

nularidad de las piezas: vocabularios más grandes reducen la fragmentación pero aumentan la dimensionalidad; vocabularios más pequeños incrementan la capacidad de representar formas novedosas mediante composiciones de sub-unidades.

Para pares con variación ortográfica o riqueza morfológica, como el caso shiwilu–castellano, la tokenización sub-palabra facilita que las formas derivadas y las variantes ortográficas compartan representaciones parciales, mejorando la generalización del modelo frente a formas raras. Asimismo, la práctica conceptual aconseja documentar las decisiones de tokenización (tipo de algoritmo y tamaño del vocabulario) porque influyen en la distribución de los tokens y, por ende, en el comportamiento de las métricas de evaluación (Kudo & Richardson, 2018; Sennrich et al., 2016).

2.2.5 Aumento de datos (*data augmentation*)

El aumento de datos agrupa técnicas destinadas a generar ejemplos sintéticos a partir del material disponible para ampliar la cobertura léxica y contextual del conjunto de entrenamiento. Conceptualmente, estas técnicas buscan introducir variación útil que actúe como regularizador del modelo y que permita que patrones raros o formas morfológicas poco frecuentes sean vistos durante el aprendizaje. Entre los métodos más usados en traducción automática se encuentran la retrotraducción (back-translation), el parafraseo, y las operaciones de modificación léxica sencillas como la sustitución de sinónimos o la técnica EDA (Easy Data Augmentation) (Sennrich et al., 2016; Wei & Zou, 2019).

La retrotraducción consiste en entrenar un sistema de traducción en la dirección meta→fuente con datos disponibles y luego traducir grandes cantidades de texto monolingüe en la lengua meta para producir pares sintéticos fuente–meta que se incorporan al entrenamiento. El parafraseo y las operaciones basadas en sinónimos generan alternativas al mismo significado en la lengua fuente o meta, aumentando la diversidad léxica sin requerir nueva anotación humana. Desde un punto de vista teórico, estos procedimientos incrementan la densidad de la señal de entrenamiento y reducen el sobreajuste en escenarios con poco paralelo, aunque su efectividad depende de la calidad del modelo que genera los ejemplos sintéticos y del control del ruido introducido.

No obstante, el aumento de datos implica riesgos conceptuales importantes: la introducción de pares sintéticos de baja calidad puede sesgar al modelo hacia errores sistemáticos, producir efectos de dominio no deseados o reforzar traducciones incorrectas si el generador es débil. Por ello, conceptualmente es crucial aplicar criterios de filtrado y estimación de confianza sobre los ejemplos sintéticos, por ejemplo mediante puntuaciones de calidad automáticas o umbrales de similitud semántica, y considerar la composición equilibrada entre datos auténticos y sintéticos para evitar diluir la señal real.

2.2.6 Transfer learning y modelos multilingües

El *transfer learning* en PLN se refiere al uso de modelos preentrenados o a la transferencia de parámetros aprendidos en una tarea o idioma fuente para mejorar el rendimiento en otra tarea o en un idioma con pocos datos. En el contexto de NMT esto puede materializarse como preentrenamiento en grandes colecciones monolingües o paralelas en idiomas con abundante recurso y posterior ajuste fino (*fine-tuning*) sobre el par objetivo, o bien como entrenamiento multilingüe conjunto donde un único modelo aprende a traducir múltiples idiomas compartiendo representaciones (Zoph et al., 2016). Los modelos multilingües preentrenados (p. ej. mBART, NLLB) explotan señales cruzadas entre lenguas para aprender embeddings y transformaciones transferibles que benefician a los pares de muy bajos recursos al proporcionar una representación inicial más informativa que el entrenamiento desde cero (Y. Liu et al., 2020; NLLB Team et al., 2022).

Conceptualmente, las ventajas de estas estrategias son que reducen la dependencia de grandes *corpus* paralelos para el par objetivo y permiten aprovechar patrones tipológicos o léxico-semánticos compartidos entre idiomas. Sin embargo, la transferencia puede introducir sesgos si los idiomas de preentrenamiento dominan al par objetivo (efecto de *interferencia*), o si los dominios y estilos difieren notablemente; por ello, a nivel conceptual se distingue entre transferencias beneficiosa, cuando hay suficiente semejanza tipológica o forma lingüística compartida y transferencias nocivas, que requieren técnicas de mitigación como muestreo balanceado, re-pesado de idiomas o adaptación focalizada. En resumen, transfer learning y modelos multilingües constituyen una palanca teórica y práctica central para abordar la escasez de datos en

shiwilu–castellano, siempre que se consideren cuidadosamente las condiciones de similitud lingüística y las estrategias para evitar la dominancia de idiomas mayoritarios (Zoph et al., 2016).

2.2.7 Adaptación eficiente (adapters/LoRA)

Las técnicas de adaptación eficiente buscan ajustar modelos preentrenados grandes añadiendo o entrenando un número reducido de parámetros en lugar de actualizar la totalidad del modelo. Los adapters incorporan módulos pequeños entre capas del modelo que se entrenan para la tarea objetivo, manteniendo fijos los pesos base; de este modo se conservan las representaciones generales del preentrenamiento y se reduce el costo de almacenamiento y cómputo para cada adaptación específica (Houlsby et al., 2019). LoRA propone una idea afín desde la perspectiva de factorización de parámetros: en lugar de modificar matrices completas, se aprenden componentes de bajo rango que se suman a las matrices originales, lo que permite una adaptación eficaz con un número significativamente menor de parámetros entrenables (Hu et al., 2022). Conceptualmente, estas técnicas permiten experimentar y desplegar adaptaciones para pares de muy bajos recursos sin incurrir en el coste de reentrenar o almacenar copias completas de modelos muy grandes.

2.2.8 Representaciones vectoriales (embeddings) y minería/filtrado

Los embeddings son vectores numéricos que codifican propiedades léxicas y contextuales de palabras, subpalabras, oraciones o documentos, y sirven como base para medir similitud semántica en espacios continuos. En la práctica se usan embeddings de oraciones (por ejemplo SBERT o modelos E5) para representar segmentos lingüísticos y comparar su proximidad mediante similitud coseno u otras métricas; la minería de paralelo comparable consiste en buscar en grandes colecciones aquellos pares de segmentos cuya proximidad vectorial sugiere traducción o equivalencia, y la indexación mediante motores de búsqueda vectorial como FAISS permite escalar esta operación a corpus extensos. El filtrado posterior con umbrales de similitud o clasificadores de calidad reduce el ruido y mejora la precisión del paralelo extraído, de modo que conceptualmente la combinación embedding+índice vectorial actúa como puente entre textos no alineados y pares útiles para NMT.

2.2.9 BLEU (Bilingual Evaluation Understudy)

Las métricas automáticas constituyen el primer nivel de evaluación de un sistema de traducción y han sido objeto de revisiones sistemáticas que comparan sus fundamentos, supuestos y limitaciones (Lee et al., 2023). BLEU es una métrica automática de evaluación de traducción basada en la coincidencia de n-gramas entre la hipótesis de traducción y una o más referencias. Calcula precisiones modificadas de n-gramas para varios valores de n y combina esas precisiones mediante la media geométrica, aplicando además una penalidad por brevedad para evitar sobrevaloraciones de hipótesis excesivamente cortas; su fórmula formal resume estas componentes en una puntuación entre 0 y 1 generalmente expresada como porcentaje (Papineni et al., 2002). Conceptualmente, BLEU cuantifica la coincidencia léxica y local del orden de tokens, por lo que es sensible a la elección de referencias y no captura directamente sinonimia ni equivalencias reordenadas que no comparten n-gramas con la referencia.

2.2.10 chrF (carácter n-gram F-score)

chrF evalúa la similitud entre hipótesis y referencia a nivel de caracteres mediante n-gramas de caracteres; calcula precisión y recall sobre esos n-gramas y reporta una F-score agregada, pudiendo ponderar recall frente a precisión mediante el parámetro β . Al operar sobre caracteres en lugar de palabras, chrF resulta especialmente sensible a semejanzas morfológicas, variaciones ortográficas y segmentos parciales compartidos entre formas derivadas, aspectos que suelen ser relevantes en lenguas con morfología productiva o en corpus con variación ortográfica; por ello, conceptualmente ofrece ventajas sobre métricas puramente basadas en palabras cuando la coincidencia léxica exacta es una medida limitada (Popović, 2015).

2.2.11 BERTScore y COMET

BERTScore compara tokens de hipótesis y referencia usando embeddings contextuales extraídos de modelos como BERT: para cada token calcula la máxima similitud con tokens de la otra secuencia y a partir de esas similitudes construye medidas de precisión, recall y F1 que reflejan correspondencia semántica token-a-token. COMET, por su parte, es un marco neuronal que en-

trena un regresor para predecir una puntuación de calidad en correlación con juicios humanos, utilizando como entradas la fuente, la hipótesis y opcionalmente la referencia y aprovechando representaciones contextualizadas; conceptualmente estas métricas representan una transición desde medidas de coincidencia léxica hacia evaluadores que capturan similitud contextual y correlación humana, aunque su fiabilidad depende de los datos con que fueron entrenadas y del dominio al que se aplican (Rei et al., [2020](#); Zhang et al., [2020](#)).

Capítulo 3

Estado del Arte

3.1 Introducción

En este capítulo se presenta la revisión sistemática de la literatura relacionada con la traducción automática neuronal (NMT) aplicada a lenguas de bajos recursos. Se abordan enfoques, técnicas y experiencias previas en escenarios similares, con el fin de identificar avances, limitaciones y oportunidades de investigación que sean pertinentes para el caso de estudio de la lengua shiwilu.

3.2 Objetivos de revisión

- Identificación de métodos y estrategias: clasificar y comparar las técnicas más utilizadas en traducción automática neural para lenguas de bajo recursos (back-transition, transfer learning, sistemas encoder-decoder, data augmentation, zero-shot, few-shot, etc.
- Integración de bases de conocimiento externas: revisar modelos híbridos que incorporan ontologías, WordNets o Knowledge Base (KB) en los flujos de pre- y post-procesamiento de MT/NMT, midiendo mejoras en cobertura léxica, desambiguación y coherencia semántica para lenguas indígenas.
- Análisis de métricas de evaluación: sintetizar el funcionamiento de BLEU, ChrF++ y evaluar su sensibilidad a la variabilidad introducida por datos sintéticos, así como protocolos de adaptación y comparación con evaluaciones humanas.

3.3 Preguntas de revisión

- P1. ¿Qué técnicas de generación y ampliación de datos (back-translation, mutación semántica, paraphrasing, pivoting, filtrado por embeddings, etc.) producen mejoras reproducibles en NMT para pares de muy bajos recursos?
- P2. ¿Qué arquitecturas y estrategias de entrenamiento (multilingüe, transfer learning, fine-tuning bidireccional, adapters, few/zero-shot) ofrecen el mejor balance entre rendimiento y coste computacional para un modelo shiwilu↔castellano, y qué baselines son apropiados para la comparación?
- P3. ¿Qué métricas automáticas (BLEU, ChrF++, TER, ¿etc.) y procedimientos de validación combinada (evaluación automática + pruebas participativas con hablantes) son más adecuados y fiables para medir adecuación lingüística y pertinencia cultural en traducciones de lenguas originarias con corpus escaso?

3.4 Estrategia de búsqueda

3.4.1 Motores de búsqueda a usar

Scopus

- Es una base bibliográfica multidisciplinaria que agrega resúmenes y citas de artículos, actas y capítulos revisados por pares.
- Su cobertura y metadatos permiten identificar tendencias, estudios empíricos y comparativas relevantes en NMT y técnicas de aumento de datos.
- Proporciona métricas bibliométricas útiles para priorizar lecturas y fundamentar la selección de trabajos clave.

IEEE Xplore

- Es una biblioteca digital orientada a la ingeniería y las ciencias de la computación con énfasis en documentación experimental y detalles implementaciones.
- Incluye artículos y actas que describen configuraciones experimentales, métricas de rendimiento y optimizaciones prácticas aplicables a sistemas de traducción.
- Ofrece evidencia técnica valiosa para la definición de parámetros experimentales y criterios de evaluación reproducibles.

ACL Anthology

- Es un repositorio especializado en lingüística computacional y procesamiento de lenguaje natural que reúne actas y trabajos de la comunidad NLP (ACL, EMNLP, WMT, LREC, workshops).
- Es importante recalcar que en este repositorio no se puede realizar búsqueda en cadena, entonces amerita ajustarse la búsqueda similar. Entonces esta fuente se usará como un respaldo técnico de las principales dos.
- Contiene investigaciones de vanguardia en NMT, evaluación y recursos para lenguas de bajos recursos, con frecuencia acompañadas de código y datos.

3.4.2 Cadenas de búsqueda a usar

Cadena 1 (C1) – Generación y ampliación de datos sintéticos

El objetivo de esta cadena es recuperar trabajos sobre técnicas de data augmentation aplicadas a NMT (back-translation, paraphrasing, synthetic data, filtering) y estudios que midan su efecto en pares de muy bajo recursos.

Scopus:

TITLE-ABS-KEY(("data augmentation" OR "synthetic data" OR "back-translation"
OR backtranslation OR "paraphrase" OR "paraphrasing" OR "synthetic pivot" OR

"data synthesis" OR "data augmentation techniques") AND ("neural machine translation" OR "NMT" OR "machine translation") AND ("low-resource" OR "low resource" OR "under-resourced" OR "minority language" OR "indigenous" OR "endangered language")) AND NOT("image" OR "images" OR "computer vision" OR "audio" OR "speech") AND (PUBYEAR > 2018 AND PUBYEAR < 2026) AND SUBJAREA(COMP)

IEEE Xplore:

("data augmentation" OR "synthetic data" OR "back-translation" OR backtranslation OR "paraphrase" OR "paraphrasing" OR "synthetic pivot" OR "data synthesis") AND ("neural machine translation" OR "NMT" OR "machine translation") AND ("low-resource" OR "low resource" OR "under-resourced" OR "minority language" OR "indigenous" OR "endangered language")

Cadena 2 (C2) – Arquitecturas y estrategias de entrenamiento para pares muy escasos

El objetivo de esta cadena es recuperar trabajos sobre arquitecturas y estrategias de entrenamiento adecuadas para pares con datos mínimos (transfer learning, fine-tuning bidireccional, modelos multilingües y preentrenados, adapters, enfoques few/zero-shot y técnicas de ajuste de parámetros).

Scopus:

TITLE-ABS-KEY(("transfer learning" OR "fine-tuning" OR "fine tuning" OR "adapters" OR "adapter modules" OR "multilingual" OR "multilingual models" OR "few-shot" OR "few shot" OR "zero-shot" OR "zero shot" OR "pre-trained" OR "pretrained" OR "transformer" OR "mBART" OR "mT5") AND ("neural machine translation" OR "NMT" OR "machine translation") AND ("low-resource" OR "low resource" OR "small dataset" OR "under-resourced" OR "minority language")) AND NOT("image" OR "images" OR "computer vision" OR "audio" OR "speech") AND (PUBYEAR > 2018 AND PUBYEAR < 2026) AND SUBJAREA(COMP)

IEEE Xplore:

("transfer learning" OR "fine-tuning" OR "fine tuning" OR "adapters" OR "multilingual" OR "few-shot" OR "few shot" OR "zero-shot" OR "zero shot" OR "pre-trained" OR "pretrained" OR "transformer") AND ("neural machine translation" OR "NMT" OR "machine translation") AND ("low-resource" OR "low resource" OR "small dataset" OR "under-resourced") AND NOT ("image" OR "images" OR "computer vision" OR "audio" OR "speech")

Cadena 3 (C3) – Evaluación automática y participativa; métricas y protocolos

El objetivo de esta cadena es identificar métricas automáticas y protocolos de evaluación, así como estudios sobre evaluación participativa (human evaluation, adequacy, acceptability, community/participatory evaluation), y trabajos que analicen la sensibilidad de métricas a la presencia de datos sintéticos.

Scopus:

TITLE-ABS-KEY (("BLEU" OR "ChrF" OR "ChrF++" OR "TER" OR "METEOR" OR "automatic evaluation" OR "evaluation metric" OR "evaluation metrics" OR "human evaluation" OR "participatory evaluation" OR "community evaluation" OR "adequacy" OR "acceptability") AND ("machine translation" OR "neural machine translation" OR "NMT") AND ("low-resource" OR "low resource" OR "indigenous" OR "small dataset")) AND NOT ("image" OR "audio" OR "speech") AND (PUBYEAR > 2018 AND PUBYEAR < 2026) AND SUBJAREA(COMP)

IEEE Xplore:

("BLEU" OR "ChrF" OR "ChrF++" OR "TER" OR "METEOR" OR "automatic evaluation" OR "evaluation metric" OR "human evaluation" OR "participatory evaluation" OR "community evaluation" OR "adequacy" OR "acceptability") AND ("machine translation" OR "neural machine translation" OR "NMT") AND ("low-resource" OR "low resource" OR "indigenous" OR "small dataset") AND NOT ("image" OR "audio" OR "speech")

3.4.3 Documentos encontrados

Los resultados encontrados con las cadenas de búsquedas usadas se presentan a continuación en la Tabla 1. Dado que las cadenas devolvían una gran cantidad de artículos, realizó una revisión preliminar de los títulos y resúmenes para filtrar y reducir la muestra utilizando los criterios de inclusión/exclusión, estos resultados son visibles en la Tabla 2.

Tabla 3.1: Resultados de búsqueda de las cadenas

Fuente	C1	C2	C3	Cantidad documentos duplicados
Scopus	225	617	425	340
IEEE Xplore	90	352	123	
Total	315	969	548	

Tabla 3.2: Resultados luego de aplicar criterios de exclusión

Preguntas	Artículos por pregunta
P1	50
P2	45
P3	63

3.4.4 Criterios de inclusión/exclusión

- Para inclusión:
 - Se revisaron artículos publicados entre 2018 y 2025 para asegurar información vigente y actual
 - Investigaciones que detallen el tratamiento de data sintética y otras alternativas para poco corpus de datos
 - Artículos exclusivamente revisados por pares
- Para la exclusión:

- Artículos que solo tienen resumen, es decir con acceso restringido
- Artículos que no se enfoquen en lenguas de bajos recursos o de corpus limitados
- Estudios que hablen de las lenguas de pocos recursos fuera de punto de vista de NMT, sino más enfocado en lingüística
- Publicaciones que podrían ser redundantes, reportes cortos o position papers.

3.5 Formulario de extracción de datos

Se desarrollo un formulario de extracción de datos con campos a evaluar detallado en la Tabla 3, en este caso si el articulo analizado cumplía con responder las preguntas de investigación según los criterios de inclusión y exclusión que se detalló previamente. Para esta tarea si el estudio a analizarse contribuía con el desarrollo de la pregunta, se respondía con un “Sí”, caso contrario “No”.

Tabla 3.3: Formulario de extracción de datos

Campo	Descripción
DOI	Identificador único del documento
Document Title	Título del estudio
Publication Year	Año de publicación
Abstract	Abstracción del documento
Link	Link referencial del DOI para obtener la fuente
Fuente	De qué cadena y de qué motor viene, ej. C1-Scopus, C4-IEEE
¿Qué métodos y protocolos han demostrado ser más efectivos para construir y alinear un corpus paralelo cuando solo se dispone de corpus monolingüe muy limitado (p. ej. textos de un solo autor en shiwilu) y recursos en castellano?	¿El artículo responde a esta pregunta? ¿Sí o No?

Tabla 3.3 (continuación)

Campo	Descripción
¿Qué arquitecturas y estrategias de entrenamiento (multilingüe, transfer learning, fine-tuning bidireccional, adapters, few/zero-shot) ofrecen el mejor balance entre rendimiento y coste computacional para un modelo shiwilu↔castellano, y qué baselines son apropiados para la comparación?	¿El artículo responde a esta pregunta? ¿Sí o no?
¿Qué métricas automáticas (BLEU, ChrF++, TER, ¿etc.) y procedimientos de validación combinada (evaluación automática + pruebas participativas con hablantes) son más adecuados y fiables para medir adecuación lingüística y pertinencia cultural en traducciones de lenguas originarias con corpus escaso?	¿El artículo responde a esta pregunta? ¿Sí o no?

3.6 Resultados de la revisión

3.6.1 ¿Qué técnicas de generación y ampliación de datos (back-translation, mutación semántica, paraphrasing, pivoting, filtrado por embeddings, etc.) producen mejoras reproducibles en NMT para pares de muy bajos recursos?

El principal desafío de la traducción automática neuronal (NMT) en escenarios de muy bajos recursos es la escasez de datos paralelos. Sin suficientes ejemplos de entrenamiento, la calidad de las traducciones se ve seriamente afectada, al punto de que la NMT pura puede ser superada por métodos estadísticos tradicionales. Para enfrentar esta limitación, la literatura reciente ha propuesto múltiples técnicas de generación y ampliación de datos que han demostrado mejoras reproducibles en lenguas con escasa disponibilidad digital. Entre ellas destacan la retrotraducción, la mutación semántica y el parafraseo, el uso de idiomas pivote y la transferencia multilingüe, el filtrado mediante embeddings, así como la augmentación sintáctica y la obtención activa de nuevos datos. Todas estas aproximaciones buscan enriquecer el entrenamiento con datos adi-

cionales tanto reales como sintéticos y han mostrado un impacto consistente en la mejora de la calidad de la traducción.

Una de las técnicas más efectivas es la retrotraducción (back-translation), introducida por Sennrich et al. (2016). El procedimiento consiste en entrenar un modelo inverso con el corpus paralelo reducido y utilizarlo para traducir datos monolingües del idioma meta hacia el idioma fuente, generando pares sintéticos que se incorporan al entrenamiento. Esta estrategia ha reportado mejoras significativas en métricas como BLEU y se ha convertido en práctica estándar en NMT de bajos recursos. Existen variantes más refinadas, como la retrotraducción selectiva de Luo et al. (2019), que prioriza oraciones con vocabulario poco frecuente, logrando incrementos notables en BLEU y reduciendo el tiempo de entrenamiento.

Otra línea de trabajo es el parafraseo y la mutación semántica del corpus. Fadaee et al. (2017) propusieron insertar palabras raras en contextos nuevos, generando ejemplos adicionales para mejorar la cobertura léxica del modelo. El parafraseo automático, ya sea mediante sinónimos, reformulaciones o traducciones de ida y vuelta, también ha demostrado beneficios. Al exponer al sistema a distintas variantes de una misma oración, se fortalece su capacidad de generalización. Aunque los resultados suelen ser más modestos que los obtenidos con retrotraducción, contribuyen de manera consistente a mejorar la robustez de los modelos.

El uso de idiomas pivote y la transferencia multilingüe constituyen otra estrategia importante. Un idioma pivote permite entrenar con corpus paralelo de terceros idiomas o bien realizar traducción en cascada. Talwar y Laasri (2025) mostraron que el hindi como pivote para la traducción nepalí-inglés duplicó el puntaje BLEU frente a un modelo entrenado solo con corpus directo. En un enfoque complementario, la transferencia multilingüe aprovecha modelos previamente entrenados en pares de mayor recurso para inicializar la traducción en lenguas minoritarias. Montoya et al. (2019) experimentaron con español-shipibo utilizando inicializaciones desde diferentes pares de idiomas y alcanzaron mejoras de hasta 12 puntos BLEU, incluso con pivotes tipológicamente distantes. Estos resultados confirman que el tamaño y la calidad del corpus pivot influyen más que la cercanía lingüística, como también señalaron Kocmi y Bojar (2018).

Las técnicas de filtrado y minería de datos basadas en embeddings han mostrado gran utilidad

cuando existen corpus comparables o bilingües ruidosos. Herramientas como LASER permiten identificar oraciones semánticamente equivalentes en diferentes idiomas y extraer corpus paralelo oculto (Artetxe & Schwenk, 2019). Chaudhary et al. (2019) demostraron en el Shared Task de WMT que este enfoque elevó significativamente los resultados en nepalí-inglés y cingalés-inglés al filtrar millones de pares web, conservando únicamente los más consistentes. Además de extraer datos, los embeddings también sirven para depurar traducciones sintéticas, eliminando ejemplos de baja calidad y reforzando la fiabilidad del corpus de entrenamiento.

Otra vertiente prometedora es la augmentación sintáctica. Li et al. (2025) propusieron segmentar oraciones complejas en cláusulas y generar pares adicionales mediante traducción inversa, lo que enriqueció el corpus con ejemplos de menor tamaño pero mayor diversidad estructural. Con este enfoque se lograron mejoras constantes frente a baselines y a otros métodos de augmentación. Estrategias similares como el intercambio de subárboles sintácticos o la recombinación de sujetos y predicados también han demostrado ampliar la cobertura gramatical en lenguas con recursos escasos.

Finalmente, en escenarios de extrema limitación, la recopilación activa de datos se vuelve fundamental. Montoya et al. (2019) ampliaron el corpus español-shipibo con un conjunto de flashcards bilingües que aportó vocabulario diverso y mejoró la cobertura léxica. También implementaron esquemas de aprendizaje activo y crowdsourcing, presentando oraciones en español a hablantes nativos para obtener traducciones verificadas. De manera paralela, Yamamoto et al. (2023) mostraron cómo aprovechar corpus comparables no paralelos mediante un ciclo iterativo de traducción automática y filtrado, generando datos sintéticos útiles incluso sin disponer de textos monolingües extensos en la lengua meta. Estos enfoques resaltan la importancia de combinar la generación de datos con la incorporación de material real recopilado en colaboración con la comunidad.

En conjunto, la evidencia señala que no existe una única solución, sino un conjunto de técnicas complementarias. La retrotraducción explota datos monolingües, el parafraseo introduce variabilidad semántica, los idiomas pivote y la transferencia multilingüe aportan conocimiento desde pares más ricos, los embeddings permiten extraer y filtrar corpus adicionales, y la recopilación

activa añade datos verificados por hablantes. La integración de estas estrategias ha demostrado mejorar sustancialmente la calidad de la traducción, incluso en contextos con recursos extremadamente limitados.

3.6.2 ¿Qué arquitecturas y estrategias de entrenamiento (multilingüe, transfer learning, fine-tuning bidireccional, adapters, few/zero-shot) ofrecen el mejor balance entre rendimiento y coste computacional para un modelo shiwilu↔castellano, y qué baselines son apropiados para la comparación?

La evidencia reciente en traducción de muy bajos recursos indica que el mejor compromiso entre rendimiento y coste no proviene de entrenar modelos desde cero, sino de reutilizar modelos multilingües preentrenados y adaptarlos con técnicas de transferencia eficientes, complementadas por un entrenamiento bilingüe bidireccional y módulos de adaptación livianos. Y. Liu et al. (2020) y trabajos posteriores muestran que, frente a corpus mínimos, la reutilización de representaciones previas y la compartición de parámetros entre lenguas elevan la calidad y reducen el coste computacional. De Silva y Hansadi (2024) aportan análisis comparativos recientes que corroboran este patrón; Sun et al. (2025) ofrecen evidencia adicional sobre la fragilidad y el coste de entrenar transformadores bilingües desde cero con datos escasos.

En la práctica, el NLLB Team et al. (2022) y otros grupos documentan que la adaptación de modelos multilingües preentrenados (p. ej., mBART, mT5 o NLLB; Y. Liu et al., 2020; Xue et al., 2021) con unas pocas centenas o miles de pares paralelos suele superar claramente a los modelos bilingües entrenados desde cero, porque se aprovechan representaciones de alto nivel y patrones de traducción ya aprendidos en múltiples lenguas. Este enfoque evita el coste del preentrenamiento completo si se limita a un fine-tuning supervisado, aunque puede aparecer interferencia negativa entre idiomas alejados. Para mitigar esa interferencia, Chronopoulou et al. (2023) y Houlisby et al. (2019) han mostrado la eficacia de los adapters basados en familias lingüísticas: estos insertan pequeños bloques entrenables y dejan congelado el resto del modelo, aislando la adaptación por grupos de lenguas. Hu et al. (2022) añade que, con igual cantidad de

datos, esta estrategia suele mejorar la adaptación plena, reduce el cómputo y facilita escenarios zero-/few-shot.

El aprendizaje por transferencia continúa siendo el pilar metodológico cuando los datos del par objetivo son exiguos. Kocmi y Bojar (2018) describen el “transfer trivial”, que consiste en inicializar con un par rico y afinar en el par escaso, pero los avances recientes muestran que enriquecer la transferencia con señales léxicas o lingüísticas específicas del idioma minoritario incrementa la ganancia sin elevar en exceso el coste. Maimaiti et al. (2022) destacan que embeddings léxicos preentrenados compartidos entre una lengua padre y la hija mejoran la cobertura de vocabulario poco frecuente sin recurrir a aumentaciones costosas; por su parte, estudios sobre modelado morfológico (Nzeyimana, 2024) indican que la incorporación explícita de información morfológica aporta robustez en lenguas con rica morfología, con ganancias comparables a modelos multilingües a gran escala cuando el paralelo es mínimo.

En contextos como Shiwilu↔Castellano, donde el monolingüe objetivo es casi inexistente y predominan pares paralelos cortos (p. ej., flashcards), esta transferencia “guiada” resulta especialmente ventajosa: permite explotar el español como lengua pivote de alto recurso, añadir conocimiento léxico/morfológico del Shiwilu y evitar ciclos de entrenamiento prolongados (Montoya et al., 2019).

Asimismo, el entrenamiento bilingüe bidireccional con un único modelo (Shiwilu↔Castellano) se ha consolidado como una práctica robusta. Y. Liu et al. (2020) y De Silva y Hansadi (2024) muestran que al mezclar ambas direcciones y señalar el idioma objetivo con un token, cada par paralelo se aprovecha “dos veces”, actuando como regularizador y mejorando la consistencia bilingüe con un coste marginal respecto a mantener dos modelos unidireccionales. Por esto, el bilingüe bidireccional constituye una baseline fuerte y reproducible en pares muy escasos, sobre todo cuando se combina con transferencia o con un preentrenado multilingüe.

Dentro de las estrategias paramétricas y eficientes en cómputo, Houlsby et al. (2019), Hu et al. (2022) y Chronopoulou et al. (2023) han mostrado que los adapters y técnicas afines (p. ej., LoRA) reducen drásticamente los parámetros entrenables y el uso de GPU sin pérdida apreciable de rendimiento frente al fine-tuning completo. Ning et al. (2024) proponen además enfoques

con atención dispersa explícita y PLMs integrados que concentran la capacidad del modelo en componentes informativos, rebajando el coste de inferencia y entrenamiento sin sacrificar calidad. Recientemente, Qorbani et al. (2025) han explorado la especialización por par, por ejemplo, la duplicación y ajuste de neuronas críticas para el par escaso, siendo vía para elevar el rendimiento del par minoritario sin reentrenar el modelo completo ni perjudicar pares ajenos, con un sobre coste computacional controlado. Para Shiwilu, estas técnicas de especialización son prácticas cuando se dispone de un conjunto de validación por par y se busca exprimir un multilingüe grande sin aumentar su huella computacional.

En escenarios few/zero-shot, la evidencia sugiere que una adaptación breve de un modelo grande con muy pocos pares paralelos curados (cientos) puede cerrar gran parte de la brecha a coste mínimo; sin embargo, el zero-shot puro hacia una lengua no vista tiende a ser frágil y normalmente requiere inyección léxica o validación humana para ser utilizable (Y. Liu et al., 2020; NLLB Team et al., 2022). Para Shiwilu, el few-shot fine-tuning sobre mBART/mT5/NLLB con adapters y entrenamiento bidireccional aparece como un punto dulce entre calidad y coste, especialmente si se integra un léxico Shiwilu–español y señales morfológicas.

A la luz de esta evidencia, un diseño recomendado para Shiwilu↔Castellano que maximice rendimiento y minimice costes sería: partir de un baseline bilingüe bidireccional basado en la arquitectura Transformer (Vaswani et al., 2017) entrenado con el paralelo disponible; comparar dicho baseline contra un SMT frase-a-frase como línea histórica de mínima; y pasar luego a fine-tuning de un modelo multilingüe preentrenado (mBART/mT5/NLLB) con adapters específicos. En este último paso conviene incorporar transferencia léxica y morfológica y, cuando proceda, aplicar técnicas de especialización por par (twinning) para afinar sin reentrenar el total. Esta propuesta recoge las prácticas más respaldadas y reproducibles en LRLs: ofrece mejoras significativas frente a los baselines con un coste computacional moderado y controlado.

3.6.3 ¿Qué métricas automáticas (BLEU, ChrF++, TER, ¿etc.) y procedimientos de validación combinada (evaluación automática + pruebas participativas con hablantes) son más adecuados y fiables para medir adecuación lingüística y pertinencia cultural en traducciones de lenguas originarias con corpus escaso?

En traducción automática para lenguas originarias con datos escasos, la evaluación ha ido desplazándose desde el uso exclusivo de métricas clásicas hacia esquemas mixtos que combinan indicadores automáticos y validación humana. BLEU sigue empleándose como referencia comparativa entre sistemas, pero la literatura reciente muestra que su énfasis en coincidencias de n-gramas lo vuelve poco sensible a variación morfológica, paráfrasis y sinónimos, especialmente en contextos de bajo recurso; además, sus valores absolutos pueden resultar poco informativos cuando el conjunto de prueba es pequeño o el dominio es muy específico (Post, 2018; Roy et al., 2024). Por ello, se ha vuelto habitual reportarlo junto con otras métricas que ofrecen señales complementarias sobre la calidad.

Para lenguas con morfología rica, se han privilegiado indicadores a nivel de subcadena y representaciones, pues capturan mejor coincidencias parciales y variación formal. Entre las alternativas contemporáneas, BERTScore aproxima similitud semántica mediante embeddings y suele reflejar mejor la adecuación cuando la traducción válida no coincide palabra por palabra con la referencia (Zhang et al., 2020). En la misma línea, BLEURT aprende a imitar juicios humanos y reduce la dependencia de coincidencias superficiales (Sellam et al., 2020), mientras que COMET integra información de la fuente y la hipótesis para predecir calidad con correlaciones superiores a las métricas n-gram en múltiples escenarios (Rei et al., 2020). Ahora bien, los estudios en lenguas de muy bajo recurso advierten que estas métricas neuronales, usadas en modo generalista, no siempre generalizan de forma óptima a idiomas poco representados; su desempeño mejora cuando se ajustan con anotaciones humanas del mismo entorno lingüístico (Sai et al., 2023; Singh et al., 2024; Wang et al., 2024).

La práctica contemporánea en evaluación de bajos recursos favorece, por tanto, un conjunto cu-

rado de métricas automáticas y no una sola cifra. Un protocolo razonable incluye BLEU como línea de base comparativa, indicadores sensibles a variación formal o semántica como BERTScore y BLEURT, y, cuando sea viable, una versión adaptada por familia o región lingüística de COMET u otra métrica aprendida para elevar la concordancia con juicios nativos (Sai et al., 2023; Wang et al., 2024). Conjuntos de prueba multilingües recientes, como FLORES, han impulsado además prácticas de reporte más cuidadosas en LRLs y variantes de cómputo que respetan particularidades de segmentación y escritura; aun así, persiste la recomendación de interpretar con cautela cualquier puntaje aislado y buscar convergencia entre métricas (NLLB Team et al., 2022; Post, 2018).

Debido a que ninguna métrica automática captura por sí sola matices de pertinencia cultural, la validación combinada con hablantes nativos se consolida como componente indispensable. En evaluaciones a gran escala con expertos se ha visto que marcos sistemáticos de anotación como MQM permiten diagnosticar errores por categorías y que el ranking de sistemas puede diferir sustancialmente del inferido con encuestas rápidas o métricas superficiales; además, ciertas métricas modernas se alinean mejor con juicios expertos cuando han sido contrastadas y afinadas con datos del mismo dominio (Freitag et al., 2021). Para lenguas originarias, diversos proyectos han optado por guías simplificadas inspiradas en MQM o por rúbricas de adecuación, fluidez y sensibilidad cultural acordadas con la comunidad, de modo que la evaluación humana sea sostenible y pertinente al uso real (Sai et al., 2023; Wang et al., 2024).

En el contexto peruano, se dispone de evidencia aplicada en Shipibo-Konibo que ilustra este enfoque iterativo: Montoya et al. (2019) presentan un marco de mejora continua que combina ampliación incremental de datos, transferencia y aprendizaje activo, evaluando el avance con BLEU a nivel palabra y a nivel subpalabra mediante segmentación BPE; paralelamente, incorporan retroalimentación de hablantes a través de un agente conversacional para recolectar nuevas traducciones y ajustar el sistema. Esta experiencia coincide con la pauta observada en LRLs: usar métricas automáticas para seguimiento y comparación controlada, y sostener decisiones de despliegue con revisión humana participativa que verifique adecuación lingüística y pertinencia cultural en los dominios objetivo. En suma, para medir de manera más fiable la calidad en traducciones hacia lenguas originarias de corpus escaso, conviene priorizar un conjunto de

métricas que incluya al menos un indicador semántico moderno junto con la línea base clásica, y articularlo con procedimientos de evaluación con hablantes que garanticen que la traducción diga lo correcto y lo haga como corresponde en su comunidad.

3.7 Conclusiones

El análisis del estado del arte indica que la limitación principal para el desarrollo de un sistema de traducción automática shiwilu↔castellano es la escasez de un corpus paralelo amplio, diverso y con metadatos adecuados. Las mejoras metodológicas, como la adaptación de modelos multilingües preentrenados (por ejemplo, mBART, mT5, NLLB) mediante técnicas de afinamiento eficientes (adapters, LoRA), y el uso controlado de aumento de datos (back-translation, parafraseo), aportan ganancias apreciables en la relación rendimiento-coste, pero no sustituyen la necesidad de datos verificados por hablantes. De igual forma, los métodos de minería y filtrado basados en representaciones (por ejemplo, SBERT o LASER) son herramientas valiosas para extraer pares paralelos de corpus comparables siempre que se apliquen criterios de calidad rigurosos y mecanismos de depuración.

Para la tesis se derivan implicaciones metodológicas claras. En primer lugar, resulta prioritario consolidar y curar un corpus paralelo reproducible con metadatos y trazabilidad que permitan documentación y replicabilidad experimental. En segundo lugar, se recomienda establecer líneas base experimentales reproducibles y aplicar una estrategia combinada que incluya adaptación de modelos multilingües, aumento selectivo de datos y filtrado por embeddings. La evaluación debe integrar métricas automáticas establecidas (por ejemplo, BLEU, ChrF, COMET) y estudios de validación con hablantes mediante rúbricas que midan adecuación, fluidez y pertinencia cultural. Finalmente, todas las etapas experimentales deben acompañarse de prácticas de reproducibilidad que son recomendables para lograr resultados consistentes en distintos entornos de desarrollo.

Capítulo 4

Recopilación y preparación inicial del corpus bilingüe

4.1 Introducción

Este capítulo presenta la construcción del corpus paralelo shiwilu–castellano utilizado en la investigación y la preparación del recurso de *embeddings* que servirá como base para las etapas posteriores de modelado. El trabajo descrito responde al primer objetivo específico, orientado a recopilar y alinear un corpus paralelo, producir particiones reproducibles para entrenamiento, validación y prueba, y dejar preparado un modelo de representación semántica como entregable intermedio.

La organización del capítulo sigue la secuencia metodológica aplicada en el proyecto: primero se describen las fuentes lingüísticas incorporadas; luego se documenta el flujo de extracción, filtrado, unificación, normalización y auditoría; posteriormente se presentan las particiones canónicas; y finalmente se resume la preparación del modelo de *embeddings*. El detalle operativo del pipeline, comandos, archivos y reportes se presenta en el [Anexo B](#), entendido como documento reproducible del proceso y medio de verificación de los resultados asociados al objetivo.

4.2 Fuentes del corpus bilingüe

El corpus se construyó a partir de ocho fuentes complementarias. Pueden agruparse en tres grandes líneas: (i) materiales narrativos publicados o documentados por escrito; (ii) *flashcards* shiwilu–castellano elaboradas y revisadas en colaboración directa con el señor Fidel Lomas Chota, hablante nativo shiwilu; y (iii) una lista de vocabulario nivel-palabra recogida original-

mente en trabajo de campo lingüístico documental.

La primera línea, de carácter narrativo, está formada por dos obras. *VOCES SHIWILU: 400 años de resistencia lingüística en Jebero* es una compilación documental que recopila relatos en shiwilu con su correspondencia en castellano; aporta oraciones de carácter narrativo, mayor variación contextual y estructuras discursivas amplias. *Pidir Llinsercha'su – Los relatos de Fidel* es una colección propia de relatos transcritos por Fidel Lomas Chota; complementa la línea narrativa con un registro distinto y consolidado por el propio hablante.

La segunda línea, de carácter léxico-comunicativo, está integrada por cinco subconjuntos de *flashcards* contruidos en conjunto con el hablante nativo. Todos comparten la lógica de tarjeta bilingüe shiwilu–castellano, pero se diferencian por el contexto y dominio temático que cubren:

- *flashcards2*: base léxico-funcional con frases breves de uso general.
- *flashcards_oraciones*: tarjetas con oraciones completas, útiles para extender la cobertura sintáctica.
- *vs_textos_narrativos*: tarjetas con contexto narrativo (recuperadas a partir de los textos 8–9 de *VOCES SHIWILU*).
- *cotidianas*: tarjetas de expresiones de uso diario.
- *el_principito*: tarjetas resultantes de un esfuerzo paralelo de traducir fragmentos de *El Principito* al shiwilu, conservando la estructura tarjeta a tarjeta.

La tercera línea complementa el corpus con vocabulario nivel-palabra de origen lingüístico-documental. La fuente *extra* se construye a partir del anexo *Lista de palabras utilizadas en el análisis fonológico* de la tesis de licenciatura de Madalengoitia Barúa (2014), recopilada en el marco del Proyecto Cahuapana, proyecto de documentación de las lenguas jebero y chayahuita auspiciado por la National Science Foundation de los Estados Unidos. La lista original fue grabada por Pilar M. Valenzuela en Jeberos el 24 de julio de 2007 con el hablante nativo Meneleo Careajano Chota (nacido el 22 de julio de 1942) y transcrita por la propia autora de la tesis. La lista cubre veinte secciones fonológicas (cuatro vocales y dieciséis consonantes), donde cada

sección ilustra los contextos de aparición de un fonema del jebero mediante ejemplos glosados al castellano. Su incorporación al corpus aporta cobertura léxica de fauna, flora, parentesco y vocabulario cotidiano, particularmente útil para reducir la tasa de palabras fuera de vocabulario en la dirección castellano → shiwilu.

Esta organización es relevante para la trazabilidad del corpus: las dos fuentes narrativas (*VOCES SHIWILU* y *Pidir Llinsercha'su*) aportan estructuras discursivas extensas y diversidad estilística; las cinco fuentes tipo *flashcards* aportan correspondencias léxicas y morfológicas controladas, validadas todas con el mismo hablante nativo; y *extra* aporta cobertura léxica nivel-palabra documentada en trabajo de campo lingüístico previo.

La Tabla 4.1 resume la composición inicial validada después de los procesos de filtrado y extracción. Esta tabla reemplaza los conteos preliminares usados durante etapas anteriores por los valores consolidados del pipeline actual, que ahora cubre las ocho fuentes habilitadas en `config/sources.json`.

Tabla 4.1: Fuentes bilingües incorporadas al corpus

Fuente	Tipo de contenido	Pares válidos	Formato de origen	Uso en el corpus
<i>flashcards2</i> (flashcards base)	Tarjetas bilingües con frases breves, validadas con hablante nativo	2251	Archivo tabular	Base léxica y funcional de expresiones controladas
<i>VOCES SHIWILU</i>	Compilación narrativa publicada: <i>400 años de resistencia lingüística en Jebero</i>	956	PDF convertido a CSV	Línea narrativa principal
<i>flashcards_oraciones</i>	Tarjetas bilingües con oraciones completas, validadas con hablante nativo	669	Archivo tabular	Ampliación sintáctica de las flashcards base
<i>Pidir Llinsercha'su</i> – <i>Los relatos de Fidel</i>	Relatos propios transcritos por Fidel Lomas Chota	562	Archivo tabular	Línea narrativa complementaria
<i>vs_textos_narrativos</i>	Tarjetas con contexto narrativo (textos 8–9 de <i>VOCES SHIWILU</i>)	35	Archivo tabular	Tarjetas de registro narrativo

Tabla 4.1 (continuación)

Fuente	Tipo de contenido	Pares válidos	Formato de origen	Uso en el corpus
<i>cotidianas</i>	Tarjetas de expresiones de uso diario, validadas con hablante nativo	44	Archivo tabular sin cabecera	Tarjetas de registro coloquial y comunicativo
<i>el_principito</i>	Tarjetas resultantes de traducir fragmentos de <i>El Principito</i> al shiwilu	13	Archivo tabular	Contraste con dominio literario traducido
<i>extra</i>	Lista de vocabulario nivel-palabra del anexo fonológico de Madalengoitia Barúa (2014) (Proyecto Cahuapana, NSF)	364	Archivo tabular	Cobertura léxica documental para reducir OOV en castellano → shiwilu
Total unificado	Registros paralelos de las ocho fuentes	4894	CSV consolidado	Base para normalización, auditoría y particiones

La combinación de fuentes responde a una necesidad propia de las lenguas de bajo recurso: aprovechar todo el material disponible sin homogeneizarlo de forma agresiva. Las flashcards y las cotidianas ofrecen control y validación directa; los relatos y los textos narrativos aportan diversidad estilística; *el_principito* agrega un contraste literario controlado. Por ello, el procesamiento posterior se diseñó para conservar trazabilidad por fuente y mantener acceso tanto a las versiones originales como a las normalizadas. Cada fuente atraviesa la etapa 01 de filtrado de forma independiente, lo que permite reportar inclusiones y exclusiones por origen y reproducir el pipeline de extremo a extremo.

4.3 Construcción, normalización y auditoría del corpus

El proceso de preparación se organizó como un pipeline reproducible. Cada etapa generó un archivo de salida y un reporte asociado, de modo que las decisiones de limpieza, exclusión y partición pudieran ser auditadas posteriormente. La Figura 4.1 muestra el flujo general aplicado

desde las fuentes originales hasta las particiones canónicas.




Figura 4.1: Flujo reproducible de construcción del corpus bilingüe

La extracción del PDF de *VOCES SHIWILU: 400 años de resistencia lingüística en Jebero* se realizó con heurísticas conservadoras para identificar ítems numerados y separar segmentos bilingües. El resultado fue un conjunto de 956 pares exportados, de los cuales 867 fueron marcados como casos directos y 89 como casos recuperados mediante una regla de respaldo. Esta distinción permitió conservar información útil sin ocultar los casos que requirieron tratamiento especial.

En paralelo, el filtrado se aplicó por separado a cada una de las ocho fuentes habilitadas. Esta decisión fue necesaria porque, para entrenamiento y evaluación supervisada, cada registro debe contener una entrada en castellano y una entrada en shiwilu, y porque cada fuente tiene su propio esquema de columnas y formato. Tras esta etapa quedaron disponibles 2251 pares de *flashcards2*, 956 de *VOCES SHIWILU*, 669 de *flashcards_oraciones*, 562 de *Pidir Llinsercha'su*, 35 de *vs_textos_narrativos*, 44 de *cotidianas*, 13 de *el_principito* y 364 de *extra*.

A continuación, las ocho fuentes se integraron en un único dataset de 4894 registros con trazabilidad de origen. Sobre este corpus unificado se aplicó una normalización no destructiva: las

columnas originales se conservaron, mientras que las versiones normalizadas se generaron en columnas separadas. Las reglas aplicadas incluyeron normalización Unicode NFC, eliminación de espacios redundantes, ajuste de espacios junto a comas, conversión a minúsculas y eliminación de comillas dobles. Esta estrategia evita perder información lingüística potencialmente relevante, especialmente en una lengua con rasgos morfológicos complejos como el shiwilu.

La Tabla 4.2 resume las etapas principales, sus salidas y los reportes que permiten reproducir o auditar cada paso. El listado completo de rutas se desarrolla en el [Anexo B](#).

Tabla 4.2: Etapas reproducibles de preparación del corpus

Etap	Nombre	Procedimiento aplicado	Salida principal	Reporte de control
00	Extracción PDF	Conversión de relatos bilingües desde PDF hacia registros tabulares	956 pares extraídos	Resumen de extracción
01	Filtrado por fuente	Eliminación, fuente por fuente, de filas sin par bilingüe completo	4894 pares válidos (sumando las 8 fuentes)	Filas removidas por fuente
01b	Unificación	Integración de las 8 fuentes y conservación de metadatos de origen	4894 registros	Resumen de unificación
02	Normalización	Normalización textual no destructiva sobre español y shiwilu	4894 registros normalizados	Log de normalización
03	Auditoría	Revisión de duplicados, conflictos y alertas de longitud o contenido	80 duplicados exactos detectados	Resumen de auditoría
04	Partición	Generación de train, valid y test con semilla fija y grupos	4814 pares incluidos	Manifiesto de preprocesamiento

4.4 Caracterización del corpus preparado

La auditoría permitió describir el corpus tanto en términos cuantitativos como en términos de calidad. El corpus unificado contiene 4894 registros provenientes de las ocho fuentes habilitadas; de ellos, 80 fueron excluidos por duplicación exacta antes de generar las particiones canónicas.

Por tanto, el corpus final utilizado para entrenamiento y evaluación de recursos intermedios quedó compuesto por 4814 pares paralelos.

Tabla 4.3: Resumen del corpus consolidado y auditado

Indicador	Valor	Fuente del valor	Interpretación
Registros unificados	4894	Unificación de fuentes	Total antes de exclusiones finales
Registros incluidos	4814	Manifiesto canónico	Pares usados para particiones y modelos
Registros excluidos	80	Auditoría y manifiesto	Duplicados exactos removidos
Grupos totales	4523	Manifiesto canónico	Agrupación semántica para evitar fuga entre splits
Grupos multi-par	257	Manifiesto canónico	Casos con más de una variante equivalente
Filas con cambios de normalización	4426	Reporte de normalización	Registros afectados por al menos una regla textual
Transformaciones registradas	9026	Reporte de normalización	Cambios trazables aplicados al corpus

Desde el punto de vista léxico, la auditoría muestra una diferencia relevante entre ambas lenguas. El castellano presenta 22 651 tokens y 6220 tipos únicos, mientras que el shiwilu presenta 14 217 tokens y 7412 tipos únicos. Esta mayor proporción de tipos únicos en shiwilu — y, en particular, su *type-token ratio* (TTR) más alto, 0,5213 frente a 0,2746 en castellano — es coherente con la caracterización de la lengua como sistema de alta productividad morfológica; por ello, el preprocesamiento evitó eliminar agresivamente signos o segmentos internos que pudieran formar parte de unidades lingüísticas válidas.

Tabla 4.4: Estadísticas léxicas del corpus auditado

Lengua	Tokens	Tipos únicos	TTR	Hapax
Castellano	22 651	6220	0.2746	4130
Shiwilu	14 217	7412	0.5213	5742

4.5 Particiones reproducibles del corpus

Para asegurar comparabilidad entre experimentos, el corpus final se dividió en particiones de entrenamiento, validación y prueba bajo una proporción 80/10/10 y con semilla fija igual a 42. La división no se realizó únicamente por filas, sino considerando grupos semánticos mediante `group_id`. Esta decisión evita que variantes equivalentes o relaciones uno-a-muchos queden distribuidas entre entrenamiento y prueba, lo cual produciría una estimación artificialmente optimista del desempeño.

Tabla 4.5: Particiones canónicas del corpus bilingüe (variante x1, semilla 42)

Partición	Filas	Grupos	Flashcards (5 fuentes)	VOCES SHIWI- LU	Pidir	Extra	Uso
Entrenamiento	3852	3623	2368	769	464	251	Ajuste de modelos y recursos intermedios
Validación	481	448	316	89	47	29	Selección y control experimental
Prueba	481	452	308	98	42	33	Evaluación final no usada en entrenamiento
Total	4814	4523	2992	956	553	313	Corpus canónico incluido

La columna *Flashcards (5 fuentes)* suma *flashcards2*, *flashcards_oraciones*, *vs_textos_narrativos*, *cotidianas* y *el_principito*, todas validadas con el hablante nativo. La columna *VOCES SHIWI-LU* corresponde a la compilación narrativa publicada (*400 años de resistencia lingüística en Jebero*); *Pidir* corresponde a *Pidir Llinsercha'su – Los relatos de Fidel*; *Extra* corresponde a la lista fonológica de Madalengoitia Barúa (2014). La distribución por fuente individual se reporta en `reports/04_embeddings/preprocessing_x1/preprocess_manifest.json`.

La Figura 4.2 muestra que las tres particiones conservan una composición similar por fuente. Esto resulta importante porque evita que una partición quede dominada por un único tipo de

material y permite evaluar el comportamiento del modelo sobre ejemplos provenientes tanto de flashcards como de textos narrativos.




Figura 4.2: Distribución de fuentes por partición canónica (variante x1)

4.6 Preparación del modelo de embeddings

Además del corpus depurado y particionado, el primer objetivo específico contempla la preparación de un modelo de *embeddings*. En esta tesis, los *embeddings* cumplen una función intermedia: permiten representar pares shiwilu–castellano en un espacio semántico común, medir recuperación bilingüe y disponer de un recurso preparado para análisis posteriores vinculados al modelado de traducción automática neuronal.

El modelo seleccionado como candidato final provisional fue la variante v3 de E5-base bidireccional con minería iterativa de negativos, basada en `intfloat/multilingual-e5-base` y ajustada mediante entrenamiento bidireccional con negativos duros y medios. La selección se realizó sobre la partición canónica de prueba de 448 pares (variante x1, oraciones completas), usando recuperación multi-positiva por `group_id`; es decir, el sistema no exige una única traducción válida cuando existen variantes equivalentes registradas. Las 33 entradas adicionales de vocabulario nivel-palabra del dataset *extra* que también caen en la partición de prueba se reportan por separado en el Anexo B, ya que su carácter atómico (consultas de una sola palabra) las hace inherentemente más exigentes para retrieval que las oraciones completas y comparar ambos regímenes en una sola cifra agregada distorsiona la lectura.

La elección de este candidato no fue directa, sino resultado de una secuencia incremental. Primero se evaluó E5-base sin ajuste fino para establecer un punto de comparación. Luego se entrenó una versión con pérdida *Multiple Negatives Ranking Loss*, lo que permitió adaptar el espacio semántico al par shiwilu–castellano. En una tercera etapa se incorporó minería controlada de

negativos duros y medios, con el fin de enseñar al modelo a distinguir pares semánticamente cercanos pero incorrectos. Finalmente, la variante v3 reutilizó el mejor candidato anterior y aplicó una nueva iteración de minería de negativos, manteniendo entrenamiento bidireccional para mejorar la recuperación en ambos sentidos. Esta progresión se resume técnicamente en el Anexo B.

La Figura 4.3 muestra esta progresión a partir de métricas de recuperación sobre la partición de prueba. Se emplean $R@1$ y MRR porque el propósito del modelo de *embeddings* no es generar traducciones directamente, sino recuperar equivalencias bilingües cercanas dentro de un espacio semántico compartido.




Figura 4.3: Evolución experimental de $R@1$ y MRR en los modelos de embeddings

Tabla 4.6: Métricas del modelo de embeddings preparado

Dirección de recuperación	$R@1$	$R@5$	$R@10$	MRR	Aciertos $R@1$
Castellano → shiwilu	0.8080	0.9420	0.9598	0.8671	362/448
Shiwilu → castellano	0.7857	0.9397	0.9621	0.8547	352/448

La Figura 4.4 compara las métricas finales del candidato v3 en ambas direcciones. Se observa que el modelo mantiene un comportamiento equilibrado: en ambos sentidos supera el umbral

de recuperación top-1 cercano a ocho de cada diez consultas y conserva valores altos de recuperación dentro de los primeros cinco y diez candidatos.




Figura 4.4: Métricas finales de recuperación del modelo de embeddings v3

La Figura 4.5 complementa esta lectura al mostrar la distribución de rangos. La mayor parte de las consultas se ubica en rank 1 y, cuando el primer resultado no coincide con la referencia esperada, el par correcto suele permanecer entre los primeros candidatos. Por ello, el modelo queda preparado como entregable de *embeddings* y como insumo para las fases posteriores de integración y evaluación con NMT. Los reportes de entrenamiento, recuperación, minería de negativos y congelamiento del candidato se documentan en el [Anexo B](#).




Figura 4.5: Distribución de rangos del modelo de embeddings v3

Como resultado de este capítulo, la tesis dispone de un corpus paralelo consolidado de 4814 pares útiles provenientes de ocho fuentes bilingües complementarias, particiones reproducibles para experimentación y un modelo de *embeddings* bilingüe evaluado en ambas direcciones.

Estos elementos constituyen la base empírica sobre la cual se apoyan las siguientes etapas de modelado y validación.

Capítulo 5

Sistema de traducción neuronal

SA-BiNLLB

5.1 Introducción

A partir del corpus paralelo shiwilu–castellano consolidado en el Capítulo 4 y del modelo de *embeddings* bilingüe congelado en ese mismo capítulo, este capítulo describe el sistema de traducción automática neuronal implementado en este trabajo: **SA-BiNLLB** (*Semantic-Aware Bidirectional NLLB*). El nombre resume las tres decisiones de diseño que estructuran al sistema: (i) un *backbone* multilingüe pre-entrenado (NLLB-200) adaptado al par shiwilu–castellano mediante una capa LoRA bidireccional liviana; (ii) la reutilización del modelo de *embeddings* bilingüe en tres puntos del pipeline (filtrado de datos, reranking de hipótesis y filtrado de pares sintéticos por consistencia), lo cual da el carácter *semantic-aware* al sistema; y (iii) una capa de aumentación de datos cuya admisión se decide a través del mismo evaluador semántico, evitando así la circularidad de que el modelo NMT valide sus propios datos sintéticos.

La organización del capítulo sigue el camino del sistema en producción: primero se presenta la arquitectura general; luego, los conjuntos de datos canónicos derivados del corpus; después, las dos etapas de filtrado y entrenamiento que producen el modelo v_0 ; a continuación, la augmentación que produce el modelo v_{1bt} ; y finalmente los resultados experimentales y el protocolo de evaluación humana. Los detalles operativos de hiperparámetros, fórmulas, configuraciones, ablaciones completas y reportes auxiliares se presentan en el [Anexo C](#), entendido como documento reproducible del sistema y medio de verificación de los resultados.

5.2 Arquitectura general

El sistema se compone de tres bloques que operan secuencialmente. El primero es el *backbone* de traducción: facebook/nllb-200-distilled-600M, un modelo NMT multilingüe que cubre más de 200 lenguas. NLLB-200 no incluye al shiwilu en su inventario, por lo que se extiende su *tokenizer* para registrar la lengua como shw_Latn y se inicializa la fila correspondiente de *embeddings* desde tres lenguas indígenas sudamericanas tipológica y geográficamente cercanas (quechua de Ayacucho, aymara y guaraní); de esta manera el shiwilu parte con un sesgo morfológico y prosódico razonable en lugar de una inicialización aleatoria.

El segundo bloque es la adaptación al par. Sobre el *backbone* congelado se entrena un único *adapter* LoRA bidireccional, cuyas filas direccionales spa→shw y shw→spa se mezclan en el mismo conjunto de entrenamiento. Esta elección se justifica por la cantidad de datos disponibles: con un corpus de pocos miles de pares paralelos no se justifica entrenar dos adaptadores independientes ni desbloquear el *backbone* completo; LoRA permite ajustar el dominio sin destruir las representaciones pre-entrenadas y manteniendo el costo computacional dentro del presupuesto de una sola GPU.

El tercer bloque es el reutilizador semántico. El modelo de *embeddings* bilingüe v3 congelado en el Capítulo 4 se incorpora al sistema NMT en tres puntos: como filtro de calidad sobre el conjunto de entrenamiento (Sección 5.4), como filtro de consistencia sobre los pares sintéticos generados por backtranslation (Sección 5.6) y como reranker de las hipótesis devueltas por la búsqueda en haz (Sección 5.7). Es esta triple reutilización lo que justifica el nombre *semantic-aware*: el sistema NMT no opera en aislamiento sino acoplado a un evaluador semántico independiente y reutilizable. Los hiperparámetros exactos de cada bloque (rangos, tasas, fórmulas, umbrales) se desarrollan en el Anexo C, secciones A y A.

5.3 Datos canónicos para NMT

Las particiones canónicas del corpus bilingüe (Capítulo 4) se reescriben en formato direccional para alimentar el entrenamiento bidireccional. Cada par paralelo del corpus se replica como

dos filas: una con dirección shw→spa y otra con dirección spa→shw, cada una conservando su `pair_id` y su `group_id` originales. La preservación del `group_id` garantiza que ninguna agrupación semántica cruce las fronteras de *train*, *valid* y *test*; esta integridad evaluativa fue establecida en la fase previa y no se altera. La distribución resultante se muestra en el Cuadro 5.1: los 4501 pares de la variante x1 producen 9002 filas direccionales, que conservan la proporción 80/10/10 del corpus original.

Tabla 5.1: Distribución del corpus canónico bidireccional para entrenamiento NMT (variante x1).

Split	Pares (entrada)	Filas shw→spa	Filas spa→shw	Total
train	3600	3600	3600	7200
valid	450	450	450	900
test	451	451	451	902
Total	4501	4501	4501	9002

5.4 Filtrado semántico de calidad

Antes de entrenar el modelo NMT, el conjunto de entrenamiento direccional pasa por un filtro semántico que descarta pares cuya correspondencia bilingüe no es plausible. El filtro utiliza el modelo de *embeddings* v3 congelado para puntuar la similitud coseno entre la fuente y el destino de cada par; aquellos cuya similitud queda por debajo de un umbral inferior se descartan, los que caen entre dos umbrales se conservan pero quedan marcados para revisión, y los que superan el umbral superior se aceptan sin observaciones. La decisión se toma a nivel de `pair_id` (no por dirección), de manera que las dos filas direccionales de un mismo par compartan etiqueta. Los conjuntos de validación y prueba se puntúan pero no se modifican, para preservar la base de comparación.

El Cuadro 5.2 muestra la distribución de pares aceptados, marcados y descartados sobre el conjunto de entrenamiento de la variante x1. Sobre los pares aceptados se construyen además dos índices FAISS (Johnson et al., 2019) en el espacio de *embeddings* (uno por idioma) que se reutilizan más adelante en la augmentación por minería bilingüe. Los umbrales numéricos, la configuración del modelo de *embeddings* y la especificación de los índices FAISS se desarrollan

en el Anexo C, secciones A y A.

Tabla 5.2: Distribución de pares en el conjunto de entrenamiento tras el filtro semántico (variante x1).

Bucket (pares)	Aceptados	Marcados	Removidos
Conteo	3478	122	0

5.5 Entrenamiento del modelo v_0

El modelo base v_0 se entrena sobre el conjunto direccional filtrado, con una única pasada de fine-tuning del *adapter* LoRA bidireccional. La selección del mejor punto de control durante el entrenamiento se realiza sobre la métrica chrF++ promediada entre las dos direcciones (*eval_avg_chrf*) calculada sobre el conjunto de validación al final de cada época; el sistema conserva el checkpoint con mejor desempeño y descarta los demás. El presupuesto de entrenamiento es de veinte épocas, suficiente para que el modelo alcance una meseta de validación con margen para el sobre-entrenamiento que la selección por mejor checkpoint absorbe automáticamente.

La configuración exacta del optimizador, la tasa de aprendizaje, la programación, la precisión, el tamaño de *batch* efectivo, las longitudes máximas de secuencia y los parámetros de generación se desarrollan en el Anexo C, sección A.

5.6 Augmentación de datos para v_{1bt}

Tras estabilizar v_0 , el sistema explora cuatro fuentes complementarias de datos sintéticos para producir un modelo aumentado v_{1bt} . El criterio común a las cuatro es que la admisión de cualquier par sintético al conjunto de entrenamiento se decide a través del modelo de *embeddings* v3 congelado, no del propio modelo NMT; esta separación evita la circularidad de que el modelo valide sus propios errores.

1. **Backtranslation desde monolingüe shiwilu.** Se extrae un conjunto de oraciones shiwilu sin par paralelo, se traducen al castellano con v_0 y se filtran por similitud semántica cross-

lingual contra la fuente. La aplicación se restringe a la dirección shw→spa porque generar shiwilu sintético desde fuentes españolas con un modelo aún imperfecto en esa dirección contaminaría el *target*, efecto reportado por Edunov et al. (2018). En la práctica este conjunto resultó pequeño (76 oraciones extraídas del PDF de *VOCES SHIWILU*), por lo que su contribución se complementa con el siguiente ítem.

2. **Round-trip backtranslation con filtro de consistencia monolingüe.** Para aprovechar las fuentes monolingües abundantes en castellano (FLORES, OPUS-100, Wikipedia) sin renunciar a la calidad, se traduce cada oración española real al shiwilu con v_0 y se vuelve a traducir al castellano por la dirección inversa; se conserva únicamente el par sintético cuando el castellano recuperado es semánticamente consistente con el original, lo cual se mide con el modelo de *embeddings* v3 sobre los dos textos en castellano. La condición monolingüe permite usar un umbral más estricto que el filtro cross-lingual del ítem anterior y produce pares más confiables. El esquema soporta iteraciones sucesivas: a partir de la primera iteración el modelo generador deja de ser v_0 y pasa a ser el último v_{kbt} entrenado.
3. **Minería bilingüe basada en *embeddings*.** Se utilizan los índices FAISS construidos durante el filtrado para identificar pares shiwilu–castellano con vecindad recíproca y similitud por encima de un umbral. Esta fuente captura paráfrasis cruzadas que el corpus paralelo no había emparejado explícitamente.
4. **Variantes morfológicas controladas.** Sobre el inventario de sufijos minado durante la fase de *embeddings* se generan variantes morfológicas para revisión por lingüista. Sin validación humana estas filas se mantienen fuera del entrenamiento por defecto.

El modelo aumentado v_{1bt} se entrena sobre la unión del conjunto paralelo filtrado con los conjuntos sintéticos aceptados de los ítems 1 a 3. Para reflejar la confiabilidad heterogénea de las distintas fuentes, la pérdida pondera cada fila según su origen (las filas reales pesan más que las sintéticas), y la capacidad del adaptador LoRA se incrementa moderadamente respecto de v_0 para absorber el corpus ampliado sin saturarse. Las fórmulas matemáticas de cada fuente, los

umbrales numéricos, el mapa de pesos por origen y la derivación de la pérdida ponderada se desarrollan en el Anexo C, secciones A y A.

5.7 Resultados experimentales

La evaluación final compara cuatro variantes del sistema sobre el conjunto de prueba: el modelo base v_0 y el modelo aumentado v_{1bt} , cada uno en sus variantes con *baseline* (toma directamente la mejor hipótesis del decodificador) y con *reranking* semántico (reordena las cinco mejores hipótesis combinando la probabilidad del modelo con la similitud coseno fuente–candidato producida por el modelo de *embeddings* v3). Las métricas reportadas son BLEU, chrF++ y COMET, calculadas por dirección de traducción. Se adopta chrF++ como métrica primaria por su mayor robustez en lenguas morfológicamente ricas y de bajos recursos; BLEU se reporta como métrica secundaria estándar y COMET con el caveat explícito de que su entrenamiento subyacente no incluye al shiwilu, por lo cual sus valores absolutos son indicativos.

Tabla 5.3: Comparación de variantes del sistema sobre el conjunto de prueba (variante x1, 451 pares por dirección). chrF++ es la métrica primaria.

Variante	shw→spa				spa→shw			
	chrF++	BLEU	BERTScore	COMET	chrF++	BLEU	BERTScore	COMET
nllb_bidi_lora_v0_xl	22.84	6.74	0.903	0.599	24.82	3.65	0.872	0.657
nllb_bidi_lora_v0_xl+rerank	24.68	8.40	0.905	0.613	26.20	3.81	0.875	0.671
nllb_bidi_lora_v1_bt_xl	30.07	14.01	0.913	0.648	32.76	5.50	0.888	0.709
nllb_bidi_lora_v1_bt_xl+rerank	31.20	14.91	0.914	0.656	33.85	5.20	0.893	0.723

El Cuadro 5.3 consolida los resultados. Tres lecturas resumen lo observado:

Efecto del corpus. Pasar de la variante main (3204 pares) a la variante x1 (4501 pares) duplica BLEU en ambas direcciones y agrega entre cuatro y cinco puntos de chrF++. Este resultado confirma que en el régimen low-resource el rendimiento es muy sensible a la cantidad de datos paralelos disponibles, incluso por encima de cualquier mejora arquitectónica que pueda aportar el sistema.

Efecto del reranking semántico. Sobre cada modelo el reranking aporta entre uno y dos puntos adicionales de chrF++. El aporte es positivo incluso cuando la combinación lineal apoya

completamente al modelo de *embeddings* ($\alpha = 0$), lo cual confirma que el evaluador semántico no introduce ruido. La ablación completa del coeficiente α y los puntos óptimos por modelo se desarrollan en el Anexo C, sección A.

Efecto de la augmentación. El modelo v_{1bt} , entrenado con el corpus paralelo más los pares sintéticos aceptados por el filtro semántico, supera consistentemente a v_0 en ambas direcciones y en las tres métricas. La ganancia es más pronunciada en BLEU (porque la augmentación introduce variabilidad léxica que el modelo aprende a producir) y se mantiene tras el reranking, lo cual indica que ambos mecanismos aportan información complementaria.

Ablaciones del optimizador y la arquitectura del adaptador. Sobre el modelo v_{1bt} se ejecutaron cuatro ablaciones adicionales que aíslan la contribución de mejoras recientes en el espacio de adaptadores PEFT y de fuentes monolingües: $v_{2.0}$ reemplaza LoRA por DoRA (S.-Y. Liu et al., 2024) manteniendo el resto del pipeline, $v_{2.1}$ suma LoRA+ (Hayou et al., 2024) a DoRA, $v_{2.1b}$ aplica LoRA+ sobre LoRA estándar (sin DoRA), y $v_{2.2}$ toma a $v_{2.1b}$ como modelo generador y le suma una ronda de *round-trip backtranslation* con un *pool* monolingüe español tomado de Wikipedia. El Cuadro 5.4 consolida las seis variantes en una tabla única; el Cuadro 5.5 reporta los intervalos de confianza bootstrap del 95 % sobre las predicciones reranked ($n = 1000$ re-muestreos por dirección).

Tabla 5.4: *Leaderboard* cerrado del ciclo de ablaciones sobre la variante x1 (446 pares por dirección, 892 filas direccionales). chrF++ es la métrica primaria.

Variante	Baseline			Reranked (mejor α)		
	shw→spa	spa→shw	avg	shw→spa	spa→shw	avg
v_0	23.58	26.44	25.01	25.16	28.06	26.61
v_{1bt} (+BT OPUS)	29.01	32.69	30.85	29.91	34.36	32.14
$v_{2.0}$ DoRA	29.37	33.30	31.34	30.82	34.35	32.58
$v_{2.1}$ DoRA+LoRA+	40.68	46.96	43.82	41.05	47.54	44.30
$v_{2.1b}$ LoRA+ ★	40.34	46.74	43.54	42.42	47.56	44.99
$v_{2.2}$ +BT iter1 (Wikipedia)	29.67	32.48	31.08	30.72	33.94	32.33

Tres lecturas adicionales emergen del Cuadro 5.4 y del Cuadro 5.5. Primero, LoRA+ aislado ($v_{2.1b}$) es el ganador del ciclo con avg chrF++ reranked = 44.99 (IC 95 % [43.17, 46.96]), un salto

Tabla 5.5: Intervalos de confianza bootstrap del 95 % sobre chrF++ reranked, $n = 1000$ re-muestréos percentil por dirección. Las predicciones avg vuelven a re-muestrear cada dirección independientemente.

Variante (reranked)	shw→spa chrF++ [IC 95%]	spa→shw chrF++ [IC 95%]	avg chrF++ [IC 95%]
v_0	25.16 [23.07, 27.47]	28.06 [26.56, 29.74]	26.61 [25.33, 27.88]
v_{1bt} (+BT OPUS)	29.91 [27.55, 32.35]	34.36 [32.42, 36.69]	32.14 [30.63, 33.80]
$v_{2,0}$ DoRA	30.82 [28.44, 33.12]	34.35 [32.54, 36.59]	32.58 [31.02, 34.25]
$v_{2,1}$ DoRA+LoRA+	41.05 [38.34, 43.56]	47.54 [45.36, 49.95]	44.30 [42.49, 46.12]
$v_{2,1b}$ LoRA+ ★	42.42 [39.65, 44.94]	47.56 [45.02, 50.27]	44.99 [43.17, 46.96]
$v_{2,2}$ +BT iter1 (Wikipedia)	30.72 [28.41, 33.07]	33.94 [31.87, 36.26]	32.33 [30.82, 33.94]

de $\approx 12,8$ puntos chrF++ sobre v_{1bt} ; el incremento es estadísticamente claro porque los intervalos de confianza no se traslapan. Segundo, DoRA aislado ($v_{2,0}$) no se distingue estadísticamente de v_{1bt} (32,58 vs 32,14, IC 95 % traslapados), y la combinación DoRA+LoRA+ ($v_{2,1}$, 44,30) cae dentro del IC del propio LoRA+ aislado, de modo que DoRA no paga su costo computacional adicional con este corpus. Tercero, $v_{2,2}$ regresa el modelo a ≈ 32 chrF++: la *backtranslation* desde Wikipedia (registro enciclopédico, vocabulario externo al corpus de *flashcards* y narrativas comunitarias) introduce pares sintéticos cuya distribución de dominio inunda la señal limpia de LoRA+, confirmando empíricamente que en *low-resource* la coincidencia de dominio prima sobre el volumen del pool monolingüe.

Por estas tres lecturas el ciclo de tesis cierra con $v_{2,1b}$ LoRA+ como sistema enviado. Los detalles operativos de DoRA, LoRA+ y la generación del pool monolingüe iterativo se documentan en el Anexo C, sección A.

Adicionalmente, un análisis morfológicamente sensible mide chrF++ sobre el subconjunto de oraciones cuya referencia contiene una alta proporción de palabras raras en el corpus de entrenamiento, así como la tasa de recuperación de palabras estrictamente *out-of-vocabulary*. El reranking mantiene su ventaja sobre este régimen *rare-heavy*, aunque la tasa de recuperación OOV es uniformemente baja, lo cual motiva una de las líneas de trabajo futuro (Sección 6.2). El detalle por bucket morfológico y la calibración de la capa de confiabilidad por predicción se desarrollan en el Anexo C, secciones A y A.

5.8 Evaluación humana

Adicionalmente al barrido cuantitativo, el sistema reproduce un protocolo de evaluación humana cuya plantilla se prepara automáticamente. El protocolo toma una muestra aleatoria estratificada de cien ítems por dirección balanceada por origen (qué fuente bilingüe del corpus generó el par) y por longitud de la fuente; las hipótesis de los cuatro sistemas (v_0 y v_{1bt} , cada uno en variantes *baseline* y *reranked*) se anonimizan con un mapeo aleatorio letra→sistema persistido por separado, de manera que el revisor califica sin saber qué letra corresponde a qué configuración. Cada ítem recibe puntajes en una escala 1–5 sobre tres ejes: adecuación (preservación del sentido), fluidez (gramaticalidad y naturalidad) y pertinencia cultural (registro idiomáticamente correcto).

La planilla queda generada y lista para ser ejecutada por hablantes nativos del shiwilu. Los archivos producidos (la planilla en formato CSV y la clave de des-anonimización en formato JSON) y la especificación operativa del muestreo se documentan en el Anexo C, sección A.

5.9 Conclusión del capítulo

El sistema SA-BiNLLB articula las tres decisiones de diseño anunciadas al inicio del capítulo: NLLB-200 distilled como *backbone* multilingüe pre-entrenado, un único *adapter* LoRA bidireccional que ajusta el modelo al par shiwilu–castellano, y la reutilización del modelo de *embeddings* bilingüe v3 congelado como evaluador semántico independiente que filtra el corpus de entrenamiento, modera la admisión de pares sintéticos y reordena las hipótesis del decodificador. La evaluación cuantitativa muestra que la combinación de un corpus mayor (variante x1), una augmentación cuya admisión la decide el evaluador semántico (v_{1bt}), el optimizador LoRA+ con tasas de aprendizaje asimétricas $B/A = 16$ sobre LoRA estándar ($v_{2.1b}$) y el reranking semántico produce el campeón enviado del ciclo (avg chrF++ = 44,99, IC 95 % [43,17, 46,96]) con un margen estadísticamente claro sobre v_{1bt} . La evaluación humana queda preparada como entregable adicional para el cierre con hablantes nativos. El detalle operativo del sistema — hiperparámetros, fórmulas, umbrales, ablaciones completas y desviaciones documentadas frente al plan original — se consigna en el Anexo C.

Capítulo 6

Conclusiones y trabajos futuros

6.1 Conclusiones

6.2 Trabajos futuros

Cinco líneas de mejora quedan documentadas como ampliación natural de SA-BiNLLB. Cada una se evaluó durante el ciclo actual y se descartó por costo–beneficio o por restricción de tiempo del cronograma de tesis, no por falta de viabilidad.

Arquitectura *Two-Adapter* LoRA+ con rangos asimétricos. La opción más prometedora identificada al cierre del ciclo, y la que se cita explícitamente como continuación inmediata. Consiste en entrenar dos adaptadores LoRA+ independientes, uno por dirección, con rangos asimétricos: $\text{spa} \rightarrow \text{shw}$ con $r = 64$ y $\alpha = 128$ (la dirección morfológicamente más difícil recibe más capacidad) y $\text{shw} \rightarrow \text{spa}$ con $r = 32$ y $\alpha = 64$. El soporte de código está integrado (`30_train_lora.py --direction {spa2shw,shw2spa}; 40_evaluate.py --checkpoint-spa2shw ...--checkpoint-shw2spa ...`), de modo que la inversión adicional es exclusivamente computacional ($\approx 5\text{--}6$ h sobre el hardware actual). La hipótesis a validar es que la separación por dirección reduce la interferencia entre ambas tareas y cierra la brecha residual entre las dos direcciones que se observa en el Cuadro 5.4.

***Stochastic Weight Averaging* sobre el ganador.** Promediar los pesos de los últimos 3 a 5 *checkpoints* del modelo ganador (Izmailov et al., 2018) suele aportar entre +0,3 y +0,8 chrF++ adicionales en regímenes de bajos recursos a través de regularización implícita. Es barato (≈ 30 min, sin entrenamiento adicional), ortogonal a la arquitectura del adaptador, y aplicable tanto a $v_{2.1b}$ como al ganador del experimento Two-Adapter.

Iterative backtranslation con corpus monolingüe controlado por dominio. La regresión observada en $v_{2.2}$ (Wikipedia) confirma que en *low-resource* la calidad del pool monolingüe se rige por la coincidencia de dominio, no por su tamaño. La línea futura es curar un pool combinado de Tatoeba, *News-commentary* hispanoamericano y narrativas comunitarias (10–30 k frases), filtrarlo con el SBERT v_3 congelado contra el Shiwilu existente para preservar la distribución del corpus original, y aplicar iteraciones sucesivas de *round-trip backtranslation* (Edunov et al., 2018; Hoang et al., 2018) con criterio de detención sobre validación.

Corpus monolingüe español controlado por dominio. El sistema actual omite la dirección $\text{spa} \rightarrow \text{shw}$ en *backtranslation* clásica precisamente para no contaminar el *target* con Shiwilu sintético generado por un modelo aún imperfecto en esa dirección. Curar 10–30 k frases en Español cercanas al dominio de *flashcards* y textos comunitarios, filtrarlas con el SBERT v_3 congelado contra el Shiwilu existente y usarlas como *seeds* para BT $\text{spa} \rightarrow \text{shw}$ con un $v_{2.1b}$ ya estable es la línea natural complementaria a la iteración descrita arriba.

Focal loss para preservación de *rare-tokens*. El análisis morfológicamente sensible documentado en el Anexo C, sección A, muestra que la *OOV recovery rate* es uniformemente baja: el decoder casi no copia palabras shiwilu OOV cuando aparecen en la fuente. *Focal loss* con $\gamma \approx 2$ sobre los *token-ids* más raros sesgaría al modelo a preservarlos. Es ortogonal al pesado por origen documentado en el Anexo C, sección A, y se puede combinar con él, pero requiere reescribir `compute_loss` para conocer la frecuencia de cada *token-target* en *train*.

Referencias

- Artetxe, M., & Schwenk, H. (2019). Massively Multilingual Sentence Embeddings for Zero-Shot Cross-Lingual Transfer and Beyond. *Transactions of the Association for Computational Linguistics*, 7, 597-610. https://doi.org/10.1162/tacl_a_00288
- Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural Machine Translation by Jointly Learning to Align and Translate. *3rd International Conference on Learning Representations (ICLR 2015)*. <https://arxiv.org/abs/1409.0473>
- Baladón, A., Lucas, A., & Pardiñas, V. (2024). *Generación de datos sintéticos para traducción automática entre español y guaraní* [Tesis de grado]. Universidad de la República.
- Chaudhary, V., Tang, Y., Guzmán, F., Schwenk, H., & Koehn, P. (2019). Low-Resource Corpus Filtering Using Multilingual Sentence Embeddings. *Proceedings of the Fourth Conference on Machine Translation (Volume 3: Shared Task Papers, Day 2)*, 261-266. <https://doi.org/10.18653/v1/W19-5435>
- Chowdhury, G. G. (2003). Natural Language Processing. *Annual Review of Information Science and Technology*, 37(1), 51-89. <https://doi.org/10.1002/aris.1440370103>
- Chronopoulou, A., Stojanovski, D., Fraser, A., & Birch, A. (2023). Language Family Adapters for Low-Resource Machine Translation with a Large-Scale Multilingual Model. *Findings of the Association for Computational Linguistics: ACL 2023*.
- Chuquimamani, M. (2021). *Minería web de textos en quechua sureño para traducción automática* [Tesis de licenciatura]. Pontificia Universidad Católica del Perú.
- De Silva, D. I., & Hansadi, D. G. P. (2024). Advancing Machine Translation: A Comparative Analysis of Evolving Technologies. *Proceedings of the 15th International Conference on Computing Communication and Networking Technologies (ICCCNT)*.
- Edunov, S., Ott, M., Auli, M., & Grangier, D. (2018). Understanding Back-Translation at Scale. *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 489-500. <https://doi.org/10.18653/v1/D18-1045>

- Fadaee, M., Bisazza, A., & Monz, C. (2017). Data Augmentation for Low-Resource Neural Machine Translation. En R. Barzilay & M.-Y. Kan (Eds.), *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)* (pp. 567-573). Association for Computational Linguistics. <https://doi.org/10.18653/v1/P17-2090>
- Freitag, M., Foster, G., Grangier, D., Ratnakar, V., Tan, Q., & Macherey, W. (2021). Experts, Errors, and Context: A Large-Scale Study of Human Evaluation for Machine Translation. *Transactions of the Association for Computational Linguistics*, 9, 1460-1474.
- Galarreta, A.-P. (2017). *Generación de corpus paralelos para un traductor estadístico entre shipibo-konibo y español* [Tesis de maestría]. Pontificia Universidad Católica del Perú.
- Hayou, S., Ghosh, N., & Yu, B. (2024). LoRA+: Efficient Low Rank Adaptation of Large Models. <https://arxiv.org/abs/2402.12354>
- Hoang, V. C. D., Koehn, P., Haffari, G., & Cohn, T. (2018). Iterative Back-Translation for Neural Machine Translation. *Proceedings of the 2nd Workshop on Neural Machine Translation and Generation*, 18-24. <https://doi.org/10.18653/v1/W18-2703>
- Houlsby, N., Giurgiu, A., Jastrzebski, S., Morrone, B., De Laroussilhe, Q., Gesmundo, A., Attariyan, M., & Gelly, S. (2019). Parameter-Efficient Transfer Learning for NLP. *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-Rank Adaptation of Large Language Models. *Proceedings of the International Conference on Learning Representations (ICLR 2022)*. <https://arxiv.org/abs/2106.09685>
- Izmailov, P., Podoprikin, D., Garipov, T., Vetrov, D., & Wilson, A. G. (2018). Averaging Weights Leads to Wider Optima and Better Generalization. *Proceedings of the Thirty-Fourth Conference on Uncertainty in Artificial Intelligence (UAI)*. <http://auai.org/uai2018/proceedings/papers/313.pdf>
- Johnson, J., Douze, M., & Jégou, H. (2019). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3), 535-547. <https://doi.org/10.1109/TBDATA.2019.2921572>
- Kocmi, T., & Bojar, O. (2018). Trivial Transfer Learning for Low-Resource Neural Machine Translation. En O. Bojar, R. Chatterjee, C. Federmann, M. Fishel, Y. Graham, B. Haddow,

- M. Huck, A. J. Yepes, P. Koehn, C. Monz, M. Negri, A. N        , M. Neves, M. Post, L. Specia, M. Turchi & K. Verspoor (Eds.), *Proceedings of the Third Conference on Machine Translation: Research Papers* (pp. 244-252). Association for Computational Linguistics. <https://doi.org/10.18653/v1/W18-6325>
- Koehn, P., & Knowles, R. (2017). Six Challenges for Neural Machine Translation. *Proceedings of the First Workshop on Neural Machine Translation*, 28-39. <https://doi.org/10.18653/v1/W17-3204>
- Kudo, T., & Richardson, J. (2018). SentencePiece: A Simple and Language Independent Sub-word Tokenizer and Detokenizer for Neural Text Processing. *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 66-71. <https://doi.org/10.18653/v1/D18-2012>
- Lee, S., Lee, J., Moon, H., Park, C., Seo, J., & Lim, H. (2023). A Survey on Evaluation Metrics for Machine Translation. *Mathematics*, 11(4), 1006.
- Li, F., Shao, M., Yan, H., & Chi, C. (2025). A Clause-Based Data Augmentation Method for Low-Resource Neural Machine Translation. *IEEE Access*, 13, 62567-62576. <https://doi.org/10.1109/ACCESS.2025.3555742>
- Liu, S.-Y., Wang, C.-Y., Yin, H., Molchanov, P., Wang, Y.-C. F., Cheng, K.-T., & Chen, M.-H. (2024). DoRA: Weight-Decomposed Low-Rank Adaptation. *Proceedings of the 41st International Conference on Machine Learning (ICML)*. <https://arxiv.org/abs/2402.09353>
- Liu, Y., Gu, J., Goyal, N., Li, X., Edunov, S., Ghazvininejad, M., Lewis, M., & Zettlemoyer, L. (2020). Multilingual Denoising Pre-training for Neural Machine Translation. *Transactions of the Association for Computational Linguistics*, 8, 726-742. https://doi.org/10.1162/tacl_a_00343
- Luo, D., Shi, S., Su, R., & Huang, H. (2019). Data Augmentation Under Scarce Condition for Neural Machine Translation. *Proceedings of the 2019 IEEE 6th International Conference on Cloud Computing and Intelligence Systems (CCIS)*, 36-40. <https://doi.org/10.1109/CCIS48116.2019.9073698>

- Madalengoitia Barúa, M. G. (2014). *Bosquejo fonológico de la lengua Jebero (shiwilu)* [Tesis de licenciatura]. Pontificia Universidad Católica del Perú. <http://hdl.handle.net/20.500.12404/5251>
- Mager, J. M., & Meza, I. V. (2018). Hacia la traducción automática de las lenguas indígenas de México. *Proceedings of Digital Humanities 2018*.
- Maimaiti, M., Liu, Y., Luan, H., & Sun, M. (2022). Enriching the Transfer Learning with Pre-trained Lexicon Embedding for Low-Resource Neural Machine Translation. *Tsinghua Science and Technology*, 27(1), 150-163. <https://doi.org/10.26599/TST.2020.9010029>
- Meque, A. G. M., Angel, J., Sidorov, G., & Gelbukh, A. (2023). Traducción automática entre lenguas indígenas de México y el español. *Research in Computing Science*, 152(9), 329-337.
- Ministerio de Cultura del Perú. (2016). Resolución Viceministerial N.º 073-2016-VMPCIC-MC: Declaran Patrimonio Cultural de la Nación a la lengua shiwilu.
- Montoya, H. E. G., Rojas, K. D. R., & Oncevay, A. (2019). A Continuous Improvement Framework of Machine Translation for Shipibo-Konibo. En A. Karakanta, A. K. Ojha, C.-H. Liu, J. Washington, N. Oco, S. M. Lakew, V. Malykh & X. Zhao (Eds.), *Proceedings of the 2nd Workshop on Technologies for MT of Low Resource Languages* (pp. 17-23). European Association for Machine Translation. <https://aclanthology.org/W19-6804/>
- Ning, T., Xie, X., & Zhang, J. (2024). Research on Low-Resource Neural Machine Translation Methods Based on Explicit Sparse Attention and Pre-trained Language Model. *Proceedings of the 2024 IEEE 12th International Conference on Computer Science and Network Technology (ICCSNT)*, 103-107. <https://doi.org/10.1109/ICCSNT62291.2024.10776704>
- NLLB Team, Costa-jussà, M. R., Cross, J., Çelebi, O., Elbayad, M., Heafield, K., Heffernan, K., Kalbassi, E., Lam, J., Licht, D., Maillard, J., Sun, A., Wang, S., Wenzek, G., Youngblood, A., Akula, B., Barrault, L., Mejia Gonzalez, G., Hansanti, P., ... Wang, J. (2022). No Language Left Behind: Scaling Human-Centered Machine Translation. *arXiv preprint arXiv:2207.04672*. <https://arxiv.org/abs/2207.04672>
- Nzeyimana, A. (2024). Low-Resource Neural Machine Translation with Morphological Modeling. *arXiv preprint arXiv:2404.02392*. <https://doi.org/10.48550/arXiv.2404.02392>

- Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: A Method for Automatic Evaluation of Machine Translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL 2002)*, 311-318. <https://aclanthology.org/P02-1040.pdf>
- Popović, M. (2015). chrF: Character N-gram F-Score for Automatic MT Evaluation. *Proceedings of the Tenth Workshop on Statistical Machine Translation (WMT 2015)*. <https://aclanthology.org/W15-3049.pdf>
- Post, M. (2018). A Call for Clarity in Reporting BLEU Scores. *Proceedings of the Third Conference on Machine Translation (WMT 2018)*, 186-191.
- Qorbani, A., Ramezani, R., Baraani, A., & Kazemi, A. (2025). Multilingual Neural Machine Translation for Low-Resource Languages by Twinning Important Nodes. *Neurocomputing*, 634, 129890. <https://doi.org/10.1016/j.neucom.2025.129890>
- Rei, R., Stewart, C., Farinha, A., & Lavie, A. (2020). COMET: A Neural Framework for MT Evaluation. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP 2020)*, 2685-2702. <https://doi.org/10.48550/arXiv.2009.09025>
- Ríos, J. C. (2019). *Traducción automática náhuatl-español: variables que influyen en la calidad de la traducción* [Tesis de maestría]. Universidad Nacional Autónoma de México.
- Roy, A., Purkayastha, B. S., Devi, C. S., & Paul, S. (2024). A Neural Based Bidirectional MT System to Investigate the Performance of the Low Resource Language Pair English-Nepali. *INFOCOMP Journal of Computer Science*, 23(1). <https://infocomp.dcc.ufla.br/index.php/infocomp/article/view/3361>
- Sai, A. B., Dixit, T., Nagarajan, V., Kunchukuttan, A., Kumar, P., Khapra, M. M., & Dabre, R. (2023). IndicMT Eval: A Dataset to Meta-Evaluate Machine Translation Metrics for Indian Languages. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL 2023), Long Papers*, 14210-14228.
- Sellam, T., Das, D., & Parikh, A. (2020). BLEURT: Learning Robust Metrics for Text Generation. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL 2020)*, 7881-7892. <https://doi.org/10.48550/arXiv.2004.04696>
- Sennrich, R., Haddow, B., & Birch, A. (2016). Improving Neural Machine Translation Models with Monolingual Data. En K. Erk & N. A. Smith (Eds.), *Proceedings of the 54th*

- Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 86-96). Association for Computational Linguistics. <https://doi.org/10.18653/v1/P16-1009>
- Singh, A., Sai, A. B., Dabre, R., Puduppully, R., Kunchukuttan, A., & Khapra, M. M. (2024). How Good Is Zero-Shot MT Evaluation for Low Resource Indian Languages? *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL 2024), Short Papers*, 640-649.
- Socher, R., & Manning, C. D. (2013). Deep Learning for NLP (Without Magic). En J. Lin & K. Erk (Eds.), *NAACL HLT 2013 Tutorial Abstracts* (pp. 1-3). Association for Computational Linguistics. <https://aclanthology.org/N13-4001/>
- Sun et al. (2025). Bilingual Transformer Training from Scratch in Low-Resource Settings (referencia por verificar) [Referencia citada en el cuerpo; pendiente de verificación bibliográfica].
- Talwar, A., & Laasri, J. (2025). Pivot Language for Low-Resource Machine Translation. <https://doi.org/10.48550/arXiv.2505.14553>
- UNESCO. (2023). El empoderamiento digital impulsa el Decenio Internacional de las Lenguas Indígenas. <https://www.unesco.org/es/articles/el-empoderamiento-digital-impulsa-el-decenio-internacional-de-las-lenguas-indigenas>
- Valenzuela, P. M. (2018). Shiwilu (Jebero). *International Journal of American Linguistics*, 84(S1), S19-S24.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*. <https://arxiv.org/abs/1706.03762>
- Wang, J., Adelani, D. I., Agrawal, S., Masiak, M., Rei, R., et al. (2024). AfriMTE and AfriCOMET: Enhancing COMET to Embrace Under-Resourced African Languages. *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL 2024), Long Papers*.
- Wei, J., & Zou, K. (2019). EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks. *Proceedings of the 2019 Conference on Empirical Methods*

- in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 6382-6388. <https://doi.org/10.18653/v1/D19-1670>
- Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A., & Raffel, C. (2021). mT5: A Massively Multilingual Pre-trained Text-to-Text Transformer. *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 483-498. <https://doi.org/10.18653/v1/2021.naacl-main.41>
- Yamamoto, Y., Akiba, T., & Tsukada, H. (2023). Training Neural Machine Translation Models by Using an Entire Comparable Corpus. *Proceedings of the 2023 10th International Conference on Advanced Informatics: Concept, Theory and Application (ICAICTA)*, 1-5. <https://doi.org/10.1109/ICAICTA59291.2023.10390174>
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). BERTScore: Evaluating Text Generation with BERT. *International Conference on Learning Representations (ICLR 2020)*. <https://doi.org/10.48550/arXiv.1904.09675>
- Zoph, B., Yuret, D., May, J., & Knight, K. (2016). Transfer Learning for Low-Resource Neural Machine Translation. *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1568-1575. <https://doi.org/10.18653/v1/D16-1163>

Apéndice A

Anexos

Los anexos deben ser referenciados desde el documento. Por ejemplo, debe existir un párrafo donde se diga que determinada información puede ser vista en el Anexo X

Los anexos pueden numerarse con letras o número de acuerdo con su preferencia.

Anexo A: Plan de Proyecto

Justificación

El presente proyecto surge de la necesidad urgente de crear soluciones tecnológicas que ayuden a preservar, enseñar y usar de forma cotidiana las lenguas originarias en peligro de extinción, en particular el shiwilu. Esta lengua enfrenta una seria amenaza debido a la escasez de recursos digitales, corpus lingüísticos y herramientas de traducción automática, lo que limita su documentación, aprendizaje y revitalización. Frente a ello, la investigación busca cerrar la brecha entre el conocimiento existente y su aplicación práctica en entornos educativos y tecnológicos.

El objetivo central es diseñar e implementar un sistema de traducción automática neuronal bidireccional entre shiwilu y castellano, basado en la creación de un corpus paralelo depurado y en protocolos de evaluación que combinan métricas automáticas con validación por hablantes. Este enfoque se apoya en los avances del aprendizaje profundo y del procesamiento del lenguaje natural en contextos de bajo recurso, adaptando modelos y arquitecturas a las particularidades lingüísticas del shiwilu para garantizar resultados técnicamente sólidos y culturalmente pertinentes.

El proyecto tendrá impacto en tres niveles: académico, al generar recursos reproducibles para futuras investigaciones; tecnológico, al demostrar la viabilidad de un traductor neuronal en esce-

narios con pocos datos; y social, al fortalecer los esfuerzos de revitalización lingüística mediante una herramienta accesible para docentes y comunidades. En conjunto, esta propuesta representa un aporte técnico y humano que une la innovación con el compromiso cultural, reafirmando el papel de la ingeniería al servicio de la diversidad lingüística.

Viabilidad

El presente proyecto es viable desde los puntos de vista técnico, metodológico, institucional y económico, dado que se sustenta en recursos accesibles, herramientas de libre uso y un plan de ejecución compatible con los plazos y capacidades de un proyecto académico universitario. La naturaleza tecnológica, documental y experimental de la investigación permite alcanzar los objetivos propuestos mediante procedimientos reproducibles y verificables, sin requerir infraestructura especializada ni financiamiento externo significativo. En otras palabras, es una iniciativa que se sostiene sobre bases sólidas y realistas, donde la precisión técnica y la sensatez operativa caminan de la mano.

Desde la perspectiva técnica, la viabilidad se respalda en el uso de plataformas y librerías de código abierto ampliamente reconocidas en el ámbito del aprendizaje profundo y el procesamiento del lenguaje natural. Cada experimento puede documentarse, replicarse y compararse, lo que refuerza la confiabilidad del proceso. Además, la implementación puede realizarse en entornos locales o en plataformas de cómputo en la nube de bajo costo, demostrando que la innovación no siempre requiere grandes presupuestos, sino ingenio y método. El flujo de trabajo, desde la construcción del corpus hasta la evaluación del modelo y la integración del prototipo, ha sido cuidadosamente diseñado para ser completamente reproducible y versionado, garantizando transparencia y continuidad.

En el plano metodológico, la investigación sigue un enfoque estructurado que combina ingeniería de datos, aprendizaje automático y evaluación lingüística. Las fases avanzan con orden lógico: recopilación y alineación del corpus paralelo shiwilu–castellano, entrenamiento y comparación de modelos neuronales bidireccionales, validación automática y participativa, e integración del prototipo funcional de traducción. Cada etapa cuenta con indicadores objetivos y entregables definidos, asegurando coherencia entre los objetivos y los resultados. El registro

sistemático de parámetros e hiperparámetros no solo aporta rigor científico, sino también una brújula para futuras réplicas y mejoras.

La viabilidad institucional del proyecto se ve reforzada por su alineación con las competencias formativas del programa de Ingeniería Informática y con los lineamientos de investigación aplicada de la Facultad de Ciencias e Ingeniería. Además, cuenta con la guía de un asesor especializado en inteligencia artificial y procesamiento de lenguaje natural, y con el respaldo metodológico del curso de tesis. A ello se suma el apoyo del Grupo Chana, comprometido con la revitalización del idioma shiwilu, y del señor Fidel Lomas Chota, hablante nativo y colaborador en proyectos lingüísticos, cuya participación garantiza la pertinencia cultural y la autenticidad del enfoque. La colaboración entre el conocimiento técnico y la sabiduría viva de la lengua convierte este proyecto en un puente entre la academia y la comunidad.

Finalmente, desde una perspectiva económica y temporal, el proyecto resulta plenamente realizable dentro del periodo académico establecido. El uso exclusivo de software libre elimina costos por licencias, y los requerimientos de equipamiento se limitan a equipos personales de desarrollo. Los gastos asociados a la validación lingüística son mínimos y responden a la logística de coordinación con los colaboradores. El cronograma propuesto contempla tiempos razonables y mecanismos de control de avance que aseguran el cumplimiento integral de los objetivos en el marco del semestre. En conjunto, todos estos factores confirman que la propuesta no solo es viable en teoría, sino también en práctica: un ejemplo concreto de cómo la tecnología, bien dirigida, puede ponerse al servicio del conocimiento y la preservación cultural.

Alcance

El presente proyecto comprende el diseño, desarrollo y validación de un sistema de traducción automática neuronal bidireccional entre el idioma shiwilu y el castellano, orientado a fortalecer el aprendizaje y la preservación de la lengua. El trabajo abarca desde la recopilación y preparación de datos lingüísticos hasta la implementación de un prototipo funcional que permita realizar pruebas básicas de traducción. La ejecución se enmarca dentro del curso *Proyecto de Fin de Carrera I*, con una planificación que incluye actividades de gestión, modelado y validación lingüística en colaboración con hablantes nativos.

El alcance técnico incluye la construcción de un corpus paralelo shiwilu–castellano alineado y depurado, el desarrollo de modelos neuronales de traducción bajo un esquema reproducible y la elaboración de un prototipo local ejecutable para la demostración del sistema. Asimismo, se contempla la definición de un protocolo de validación participativa, que combina métricas automáticas con la evaluación cualitativa de hablantes, asegurando tanto la calidad lingüística como la pertinencia cultural del modelo. Durante el proceso, se llevará a cabo también la recolección paralela de *flashcards* junto al Grupo Chana y el señor Fidel Lomas Chota, con el fin de fortalecer el acervo léxico y los ejemplos de uso del idioma, sin que dicha actividad altere las particiones experimentales del corpus principal.

Quedan fuera del alcance del presente proyecto la implementación de una interfaz web o aplicación móvil de acceso público, la integración con servicios en línea de traducción, el entrenamiento de modelos multilingües a gran escala y la evaluación extendida en dominios distintos al educativo y comunitario. Estos aspectos se consideran líneas futuras de trabajo, una vez concluida la validación del prototipo y la consolidación del corpus paralelo.

Limitaciones

Las limitaciones del proyecto constituyen los condicionantes que restringen su planificación, ejecución y alcance operativo. Estas se derivan tanto del contexto académico en el que se desarrolla la investigación como de los recursos y alcances definidos para el periodo de tesis. Su reconocimiento permite establecer expectativas realistas respecto de los resultados y definir futuras líneas de mejora.

En primer lugar, el proyecto presenta **limitaciones temporales** propias del marco académico en el que se ejecuta. El cronograma se encuentra delimitado por la duración de un semestre universitario, lo que restringe la posibilidad de realizar múltiples iteraciones de entrenamiento y evaluación del modelo. En consecuencia, el tiempo disponible para afinar los hiperparámetros, optimizar el rendimiento y explorar variantes arquitectónicas del modelo de traducción automática es limitado, priorizándose la obtención de un sistema funcional y evaluado dentro del periodo establecido.

Asimismo, se identifican **limitaciones técnicas y de recursos** vinculadas al uso de equipamiento personal y entornos gratuitos de cómputo en la nube, como Google Colab o Kaggle. Estas plataformas, si bien son adecuadas para fines experimentales, imponen restricciones en capacidad de procesamiento, memoria y tiempo de ejecución, lo que puede afectar la cantidad de experimentos concurrentes o la profundidad de los entrenamientos. Pese a ello, el diseño modular y reproducible del proyecto permite mitigar estos efectos dentro del alcance académico propuesto.

En cuanto a los **datos disponibles**, el corpus paralelo shiwilu–castellano presenta un tamaño moderado y una diversidad temática acotada, derivada de la limitada disponibilidad de materiales bilingües y de la complejidad del proceso de alineación. Esto condiciona la generalización del modelo a dominios no representados y refuerza la necesidad de considerar esta versión como una base inicial susceptible de ampliación en futuros trabajos.

El proyecto también enfrenta **limitaciones de alcance funcional**, dado que el producto final consistirá en un prototipo ejecutable localmente, orientado a la demostración de la viabilidad técnica y lingüística del sistema. No se contempla el despliegue web ni la integración con plataformas externas, ya que el objetivo principal es validar la factibilidad del enfoque propuesto. De igual modo, las limitaciones de validación participativa derivan de la disponibilidad restringida de hablantes shiwilu; si bien se cuenta con la colaboración del Grupo Chana y del señor Fidel Lomas Chota, hablante nativo, la muestra para la evaluación lingüística será representativa pero acotada, centrada en garantizar pertinencia cultural más que amplitud estadística.

Estas limitaciones, resumidas en la tabla siguiente, no comprometen la validez del proyecto, sino que definen su marco operativo y orientan las posibilidades de mejora y expansión futura.

Tabla A.1: Limitaciones del proyecto

Tipo de limitación	Descripción	Impacto en el proyecto
Tiempo	El plazo de ejecución está restringido al semestre académico, lo que limita el número de iteraciones de prueba, ajuste y validación del modelo.	Menor margen para el <i>fine-tuning</i> progresivo y la experimentación con múltiples configuraciones de red.

Tabla A.1 (continuación)

Tipo de limitación	Descripción	Impacto en el proyecto
Recursos técnicos	El desarrollo se realiza con equipos personales y entornos gratuitos/ <i>low cost</i> de cómputo (Google Colab, Kaggle)	Entrenamientos más lentos y reducción en la cantidad de experimentos simultáneos.
Corpus	El corpus paralelo shiwilu–castellano posee volumen y variedad temática limitados, dependientes de fuentes disponibles y validación lingüística.	Restricción en la capacidad del modelo para generalizar a otros dominios o estilos discursivos.
Herramientas	Se emplean únicamente librerías y herramientas de código abierto, sin uso de software comercial especializado.	Limitación en la integración con sistemas avanzados de evaluación o despliegue profesional.
Alcance funcional	El entregable final es un prototipo local de traducción automática, sin despliegue web ni integración con servicios externos.	Enfoca los resultados en validación académica, no en uso público o masivo.
Validación participativa	La evaluación lingüística depende de la disponibilidad del Grupo Chana y del señor Fidel Lomas Chota, hablante nativo colaborador.	Muestra limitada de validación, centrada en la adecuación cultural más que en la cobertura estadística.

Identificación de los riesgos del proyecto

En la presente sección se identifican los riesgos que podrían afectar el desarrollo del proyecto de tesis. Para ello, se emplea el umbral de riesgo mostrado en la Tabla X Anexo A, que permite medir la probabilidad, el impacto y la severidad como el producto de ambos.

A continuación del mismo, la Tabla X2 Anexo A presenta la matriz de riesgos con la calificación de severidad correspondiente.

Tabla A.2: Umbral de riesgo (probabilidad e impacto)

Probabilidad	Impacto Bajo (1)	Impacto Moderado (2)	Impacto Alto (3)
Si ocurre (5)	5	10	15
Probable (4)	4	8	12

Tabla A.2 (continuación)

Probabilidad	Impacto Bajo (1)	Impacto Moderado (2)	Impacto Alto (3)
Posible (3)	3	6	9
Improbable (2)	2	4	6
No ocurre (1)	1	2	3

Tabla A.3: Matriz de riesgos del proyecto


Descripción del riesgo	Síntomas	P	I	S	Mitigación	Contingencia
Interrupción o limitación del acceso a entornos de cómputo (Colab/Kaggle) durante el entrenamiento.	Sesiones finalizadas abruptamente, pérdida de progreso o tiempo de cómputo.	4	3	12	Guardar checkpoints automáticos y dividir los entrenamientos por etapas.	Reentrenar con subconjuntos reducidos o migrar temporalmente a otra plataforma gratuita.
Corpus paralelo reducido o con ruido en las alineaciones shiwilu–castellano.	Resultados inconsistentes, bajo puntaje BLEU o traducciones inestables.	3	3	9	Aplicar filtros automáticos de similitud, revisión muestral y limpieza manual.	Reprocesar corpus y ajustar criterios de alineación.
Resultados del modelo inferiores a los baselines esperados.	Estancamiento de métricas, sobreajuste o traducciones incoherentes.	3	2	6	Realizar <i>fine-tuning</i> gradual, control de semillas y ajuste de hiperparámetros.	Revertir al baseline y analizar logs para reajustar parámetros.
Disponibilidad limitada de hablantes para validación participativa.	Retrasos en sesiones de validación o muestra reducida.	3	3	9	Coordinar con anticipación con el Grupo Chana y el señor Fidel Lomas Chota; emplear instrumentos asincrónicos.	Sustituir por revisión lingüística parcial o sesiones virtuales.

Tabla A.3 (continuación)

Descripción del riesgo	Síntomas	P	I	S	Mitigación	Contingencia
Falta de tiempo para afinar y mejorar el modelo (<i>fine-tuning</i>).	Cronograma ajustado, tareas de entrenamiento solapadas con documentación.	4	3	12	Priorizar configuraciones reproducibles y registrar resultados intermedios.	Reducir variantes de modelo y enfocar esfuerzos en documentación y análisis.
Pérdida o inconsistencia de datos durante el preprocesamiento o entrenamiento.	Archivos corruptos o datos desalineados.	2	3	6	Implementar control de versiones y respaldos en la nube.	Restaurar desde <i>backups</i> verificados y repetir el procesamiento afectado.
Desviación del alcance del proyecto o incorporación de tareas no previstas.	Retrasos o sobrecarga de trabajo académico.	3	2	6	Control semanal de avance y revisión de cambios con el asesor.	Replanificar cronograma priorizando entregables críticos.

En la siguiente matriz se describen los riesgos identificados, sus síntomas, probabilidad (P), impacto (I) y severidad (S). Las medidas de mitigación corresponden a acciones preventivas destinadas a reducir la probabilidad de ocurrencia, mientras que las contingencias establecen las estrategias de respuesta planificadas para asegurar la continuidad del proyecto en caso de que alguno de los riesgos se materialice.

Estructura de descomposición del trabajo (EDT)



La Estructura de Descomposición del Trabajo (EDT) constituye una representación jerárquica que organiza las actividades del proyecto en componentes manejables y verificables. En el caso del presente trabajo, la EDT se divide en dos secciones principales: la Gestión del Proyecto, que comprende las tareas administrativas, académicas y de seguimiento vinculadas al curso de Proyecto de Fin de Carrera 1, y la Gestión del Producto, que abarca las fases técnicas orientadas al desarrollo del sistema de traducción automática neuronal bidireccional shiwilu–castellano.

La primera sección contempla los entregables establecidos en el curso (E1, E2 y E3), las reuniones periódicas con el asesor, el control de riesgos y avances, así como la composición final del documento de tesis. Por su parte, la gestión del producto comprende la recolección y preparación del corpus bilingüe, el modelado y entrenamiento del sistema de traducción, la validación lingüística participativa con hablantes nativos y el desarrollo del prototipo funcional. De manera complementaria, se incluye la recolección paralela de *flashcards* junto al señor Fidel Lomas, orientada al fortalecimiento del vocabulario y la base de datos lingüística.

El EDT permite visualizar de forma clara la relación entre los objetivos específicos, las fases técnicas y los entregables académicos del proyecto, garantizando la trazabilidad entre las acti-

vidades, el cronograma y los resultados esperados.

Lista de tareas

Tabla A.4: Lista de tareas (EDT)

EDT	Nombre de la tarea	Duración (días)	Esfuerzo (h-persona)	Costo estimado (S/.)	Método de verificación y validación
1.1.1	Avance del cronograma y envío inicial	7	8	80	Revisión del cronograma inicial y validación con asesor
1.1.2	E1 – Plan de Proyecto	19	20	200	Entrega revisada y aprobada / asesor
1.1.3	E2 – Marco conceptual y estado del arte	27	28	280	Retroalimentación del asesor y validación del profesor del curso
1.1.4	E3 – Plan de proyecto y correcciones finales	36	32	320	Revisión del asesor y calificación final del curso
1.2	Reuniones con asesor de tesis	84	13	130	Correos de confirmación de reunión semanal
1.3	Control y seguimiento del proyecto	60	25	90	Bitácora de avances y reportes de progreso
1.4	Composición del documento de tesis	45	40	400	Revisión de formato PUCP y observaciones resueltas
2.1.1	Definición de fuentes y criterios de inclusión	10	12	100	Lista validada y aprobada por asesor
2.1.2	Limpieza y alineación del corpus	20	28	6	Comparación con corpus original y bitácora de preprocesamiento
2.1.3	Generación de particiones reproducibles	5	10	20	Scripts reproducibles y revisión de semillas

Tabla A.4 (continuación)

EDT	Nombre de la tarea	Duración (días)	Esfuerzo (h-persona)	Costo estimado (S/.)	Método de verificación y validación
2.1.4	Recolección paralela con hablante (flashcards)	84	25	250	Validación lingüística con hablante (Grupo Chana / Fidel Lomas Chota)
2.2.1	Definición de arquitectura y tokenización	10	20	45	Configuración aprobada y reproducible
2.2.2	Implementación y análisis de <i>embeddings</i>	6	20	45	Reporte técnico y comparación de resultados
2.2.3	Entrenamiento y pruebas del modelo	12	60	220	Registro de métricas y logs de entrenamiento
2.2.4	Optimización final del sistema	5	25	50	Evaluación de desempeño final del modelo
2.3.1	Diseño de instrumentos de validación	3	12	25	Aprobación del instrumento por asesor
2.3.2	Sesiones con hablantes y revisión lingüística	5	15	30	Rúbricas completadas y observaciones registradas
2.3.3	Análisis de resultados y observaciones	4	15	30	Informe consolidado con tablas y conclusiones
2.4.1	Diseño de la interfaz local	10	18	80	Prueba funcional en entorno local
2.4.2	Integración del modelo al prototipo	6	25	50	Verificación de inferencias correctas
2.4.3	Pruebas de funcionamiento y registro de resultados	5	20	40	Registro de casos de prueba y evidencias
2.4.4	Documentación final y demo	4	15	30	Presentación y revisión del prototipo

Cronograma del proyecto

Tabla A.5: Cronograma del proyecto

EDT	Nombre de la tarea	Fecha de inicio	Fecha de fin	Duración planificada (días)	Dependencias
1	Gestión del proyecto	19/08/2025	19/11/2025	—	—
1.1	Entregables del curso de Tesis 1 (PFC1)	19/08/2025	19/11/2025	—	—
	Avance del cronograma y envío inicial	19/08/2025	25/08/2025	7	—
	E1 – Plan de Proyecto	27/08/2025	15/09/2025	20	1.1
	E2 – Marco conceptual y estado del arte	17/09/2025	13/10/2025	27	1.1
	E3 – Plan de proyecto y correcciones finales	15/10/2025	19/11/2025	36	1.1
1.2	Reuniones con el asesor de tesis	23/08/2025	15/11/2025	84	Paralelo a todas las tareas
1.4	Composición y edición del documento de tesis	19/08/2025	19/11/2025	93	Paralelo a todo el proyecto
2	Gestión del producto	17/02/2026	05/07/2026	—	—
2.1	Recolección y preparación del corpus	17/02/2026	27/03/2026	—	—
2.1.1	Definición de fuentes y criterios de inclusión	17/02/2026	28/02/2026	10	—
2.1.2	Limpieza y alineación del corpus	02/03/2026	20/03/2026	20	2.1.1
2.1.3	Generación de particiones reproducibles	23/03/2026	27/03/2026	5	2.1.2

Tabla A.5 (continuación)

EDT	Nombre de la tarea	Fecha de inicio	Fecha de fin	Duración planificada (días)	Dependencias
2.1.4	Recolección paralela con hablante (flashcards)	17/02/2026	10/05/2026	84	Paralela
2.2	Desarrollo del modelo de traducción	30/03/2026	13/05/2026	—	2.1.3
2.2.1	Definición de arquitectura y tokenización	30/03/2026	10/04/2026	10	2.1.3
2.2.2	Implementación y análisis de embeddings	13/04/2026	20/04/2026	6	2.2.1
2.2.3	Entrenamiento y pruebas del modelo	21/04/2026	06/05/2026	12	2.2.2
2.2.4	Optimización final del sistema	07/05/2026	13/05/2026	5	2.2.3
2.3	Validación lingüística participativa	14/05/2026	30/05/2026	—	2.2.4
2.3.1	Diseño de instrumentos de validación	14/05/2026	16/05/2026	3	2.2.4
2.3.2	Sesiones con hablantes y revisión lingüística	18/05/2026	24/05/2026	5	2.3.1
2.3.3	Análisis de resultados y observaciones	25/05/2026	30/05/2026	4	2.3.2
2.4	Desarrollo del prototipo funcional	01/06/2026	05/07/2026	—	2.3.3
2.4.1	Diseño de la interfaz local	01/06/2026	12/06/2026	10	2.3.3
2.4.2	Integración del modelo al prototipo	15/06/2026	22/06/2026	6	2.4.1
2.4.3	Pruebas de funcionamiento y registro de resultados	23/06/2026	29/06/2026	5	2.4.2

Tabla A.5 (continuación)

EDT	Nombre de la tarea	Fecha de inicio	Fecha de fin	Duración planificada (días)	Dependencias
2.4.4	Documentación final y demo	30/06/2026	05/07/2026	4	2.4.3

- Lista de recursos

- Personas involucradas y necesidades de capacitación

- * Tesista: Fabian Fernando Prado Infanson

- * Asesor: Mg. Héctor Erasmo Gomez Montoya

- * Colaboradores:

- Fidel Lomas Chota: hablante nativo shiwilu, colaborador en la elaboración de flashcards y validación participativa.

- * Necesidad de Capacitación:

- Las actividades a realizar el proyecto en el proyecto de fin de carrera se encuentran dentro del ámbito de la Ingeniería Informática y están respaldadas por los conocimientos adquiridas en cursos electivos de la especialización en Inteligencia Artificial. No se requiere capacitación adicional, aunque se reforzará el aprendizaje autodirigido mediante la revisión bibliográfica técnica actualizada sobre NMT.

- Materiales requeridos para el proyecto

- * Electricidad

- * Servicio de internet

- * Acceso a bibliografía y repositorios digitales (IEEXplore, arXiv, Github).

- Estándares utilizados en el proyecto

- * ISO/IEC 29110-5-1-2 – Gestión de proyectos para Very Small Entities (VSE).

- * Directrices éticas para la recolección y tratamiento de datos lingüísticos (basadas en ACL Ethics 2023).
 - * Normas institucionales PUCP para la elaboración de trabajos de fin de carrera.
 - * Principios FAIR de gestión y reutilización de datos (Findable, Accessible, Interoperable, Reusable).
- Equipamiento requerido
 - * Computadora personal con procesador Intel i7, 32 GB RAM y GPU RTX 5060 TI 16GB.
 - Herramientas requeridas
 - * Python, PyTorch, Hugging Face Transformers y SentencePiece.
 - * Google Colab Pro / Kaggle como entornos de cómputo.
- Costeo del Proyecto

« Debe desarrollar un análisis de costos que incluya siempre:

- costos por el equipo humano
- costos por utilización de equipamiento (usar el concepto de depreciación)
- costos por utilización de software, usar el concepto de TCO (Total cost of ownership) o amortización
- Debe tener claro que costo es un concepto distinto al de gasto

A continuación, se presenta una plantilla mínima genérica que puede ser usada de base para establecer un presupuesto. Para los proyectos de curso es suficiente un solo nivel de partida.

Tabla A.6: Presupuesto del proyecto

Ítem	Descripción	Unidad	Cantidad	Valor unidad (S/.)	Monto parcial (S/.)	Monto total (S/.)
0	Costo total del proyecto	-	-	-	-	13665.00
1	Tesista	-	-	-	-	4600.00
1.1	Fabian Prado Infanson	Hora	460	10	4600	-
2	Otros participantes	-	-	-	-	2240.00
2.1	Mg. H. Erasmo Gómez Montoya (Asesor académico)	Hora	37	20	740	-
2.2	Fidel Lomas Chota	Hora	100	15	1500	-
3	Materiales e insumos	-	-	-	-	1625.00
3.1	Electricidad	Mes	9	25	225	-
3.2	Servicio de internet	Mes	9	100	900	-
3.3	Google Colab Pro	Mes	5	100	500	-
4	Equipamiento y software	-	-	-	-	5200.00
4.1	Computadora personal	Unidad	1	5000	5000	-
4.2	Microsoft Office Suite	Anual	1	200	200	-

Anexo B: Documento reproducible del proceso de corpus y embeddings

Este anexo reúne la documentación operativa que respalda los medios de verificación del primer objetivo específico. En particular, funciona como informe reproducible de criterios de selección, normalización y alineación aplicadas, y como referencia del entregable del modelo de *embeddings*. El propósito no es reemplazar la explicación metodológica del capítulo 4, sino dejar trazabilidad suficiente para revisar, replicar o auditar el proceso.

B.1 Alcance del documento

El proceso documentado comprende dos entregables:

- Corpus paralelo shiwilu–castellano depurado, alineado y particionado.
- Modelo de *embeddings* preparado y evaluado en ambas direcciones.

La fuente de verdad para los conteos y decisiones corresponde a los archivos generados por el pipeline del repositorio. Los valores principales (variante x1, ocho fuentes habilitadas) son: 4894 registros unificados, 4814 registros incluidos en las particiones canónicas, 80 duplicados exactos excluidos, 4523 grupos totales y 257 grupos multi-par.

B.2 Pipeline reproducible del corpus

La Tabla [A.7](#) resume las etapas ejecutadas, los scripts base, las salidas y los reportes de verificación. Las rutas se presentan de forma relativa al directorio raíz del proyecto.

Tabla A.7: Artefactos reproducibles de construcción del corpus

Etap	Script base	Entrada principal	Salida principal	Reporte
00	scripts/00_extraer_dataset_pdf.py	data/raw/II_TEXTOS_SHIWILU.pdf	data/intermediate/00_pdf/dataset_extraido_pdf.csv	reports/00_pdf/summary.json
01	scripts/01_filtrar_dataset.py	data/raw/flashcards2.csv	data/intermediate/01_filtrado/dataset_filtrado.csv	reports/01_filtrado/rows_removed.csv
01b	scripts/01b_unificar_fuentes.py	config/sources.json	data/intermediate/01b_unificado/dataset_unificado.csv	reports/01b_unificado/summary.json
02	scripts/02_depurar_dataset.py	data/intermediate/01b_unificado/dataset_unificado.csv	data/intermediate/02_normalizado/dataset_normalizado.csv	reports/02_normalizacion/summary.json
03	scripts/03_auditar_dataset.py	data/intermediate/02_normalizado/dataset_normalizado.csv	data/processed/03_pre_embeddings/dataset_pre_embeddings.csv	reports/03_auditoria/summary.json
04	src/embeddings/preprocess_embeddings.py	data/processed/03_pre_embeddings/dataset_pre_embeddings.csv	data/processed/04_splits/	reports/04_embeddings/preprocessing/preprocess_manifest.json

B.3 Criterios de selección y normalización

Los criterios aplicados fueron conservadores para evitar eliminar información lingüística útil del shiwilu. La selección mantuvo únicamente pares bilingües completos, preservó la fuente de cada registro y excluyó solo duplicados exactos en el cierre canónico. La normalización se aplicó de forma no destructiva: las columnas originales se conservaron y las versiones procesadas se almacenaron por separado.

Tabla A.8: Criterios documentados para selección y normalización

Criterio	Aplicación	Justificación
Par bilingüe completo	Se conservaron registros con español y shiwilu válidos	Evitar ejemplos incompletos en entrenamiento y evaluación
Trazabilidad por fuente	Se mantuvo el origen flashcards o PDF	Permitir análisis por procedencia del dato
Normalización Unicode NFC	Se estandarizó la representación de caracteres	Reducir variación técnica no lingüística
Espacios y formato	Se aplicaron <i>trim</i> , colapso de espacios y ajuste de coma-espacio	Homogeneizar superficie textual sin alterar contenido
Minúsculas	Se redujo variación por capitalización	Estabilizar vocabulario en un corpus pequeño
Apóstrofes internos	Se preservaron en shiwilu	Evitar romper formas potencialmente relevantes
Puntuación	No se eliminó agresivamente	Reducir riesgo de pérdida morfológica o funcional
Agrupación por <code>group_id</code>	Se agruparon variantes equivalentes antes del split	Evitar fuga de datos entre entrenamiento y prueba

B.4 Particiones canónicas

El archivo `reports/04_embeddings/preprocessing/preprocess_manifest.json` registra la semilla, las proporciones y los conteos finales. La semilla usada fue 42 y las proporciones fueron 80% entrenamiento, 10% validación y 10% prueba. El hash SHA-256 del archivo de entrada canónico fue:

1f6f8f252c47addd44d47eee96570c3db2199dc94522dd04f2e8cb88075654a9

Tabla A.9: Archivos canónicos de partición

Partición	JSONL	CSV	Uso
Entrenamiento	<code>data/processed/04_splits/train.jsonl</code>	<code>data/processed/04_splits/train.csv</code>	Ajuste de modelos

Tabla A.9 (continuación)

Partición	JSONL	CSV	Uso
Validación	data/processed/04_splits/valid.jsonl	data/processed/04_splits/valid.csv	Selección y control
Prueba	data/processed/04_splits/test.jsonl	data/processed/04_splits/test.csv	Evaluación final

También se generó data/processed/04_splits/all_text_for_sp.txt, usado como corpus textual consolidado para procesos posteriores de tokenización o segmentación sub-palabra.

B.5 Entregable del modelo de embeddings

El modelo de *embeddings* preparado quedó registrado como:

models/sentence_transformers/v3_iterative_hn_e5_base_bidirectional

La selección se realizó mediante una progresión experimental. Se partió de modelos E5 sin ajuste fino, que sirvieron como líneas base. Luego se adaptaron al corpus shiwilu–castellano con una pérdida contrastiva. Posteriormente se incorporaron negativos duros y medios para mejorar la discriminación entre pares cercanos, se migró de E5-small a E5-base, se probó entrenamiento bidireccional y finalmente se aplicó una iteración adicional de minería sobre el mejor candidato previo. La Tabla A.10 resume esta secuencia, indicando la hipótesis de cada variante y la decisión tomada a partir de sus resultados.

Tabla A.10: Evolución experimental del modelo de embeddings

Variante	Hipótesis o motivo	Resultado observado	Decisión
E5-small sin ajuste	Medir el desempeño de un modelo multilingüe preentrenado sin adaptación al corpus	R@1=0.0966; recuperación insuficiente	Aplicar fine-tuning contrastivo
v1 E5-small	Verificar si los pares positivos adaptan el espacio semántico	R@1=0.5109; mejora fuerte frente al baseline	Explorar negativos difíciles

Tabla A.10 (continuación)

Variante	Hipótesis o motivo	Resultado observado	Decisión
v2 hard-only	Probar si solo los negativos duros mejoran la discriminación	$R@1=0.5421$; mejora moderada	Combinar negativos duros y medios
v2 hard/medium	Evaluar si los negativos medios estabilizan el aprendizaje	$R@1=0.5670$; mejora mayor que hard-only	Migrar a una base de mayor capacidad
E5-base sin ajuste	Comprobar si una base más grande mejora sin ajuste	$R@1=0.1059$; sigue bajo sin adaptación	Ajustar E5-base con el corpus
v1 E5-base	Repetir fine-tuning contrastivo con mayor capacidad	$R@1=0.6480$; supera a E5-small	Usar E5-base como línea principal
v1 E5-base bidireccional	Evitar favorecer una sola dirección de recuperación	$R@1=0.6573 / 0.6760$	Mantener evaluación bidireccional
v2 E5-base	Combinar E5-base con negativos controlados	$R@1=0.7134 / 0.7165$	Probar entrenamiento bidireccional con negativos
v2 E5-base bidireccional	Unir hard/medium negatives y entrenamiento bidireccional	$R@1=0.7508 / 0.7788$	Usarlo como base para minería iterativa
v3 iterativo bidireccional	Minar nuevos negativos desde el mejor candidato previo	$R@1=0.7882 / 0.7913$	Seleccionarlo como modelo preparado

El entrenamiento final partió del candidato anterior `models/sentence_transformers/v2_hn_controlled_e5_base_bidireccional`, se ejecutó durante 2 épocas, con *batch size* 16, tasa de aprendizaje 5×10^{-6} , temperatura 0.05 y entrenamiento bidireccional. La pérdida registrada fue una entropía cruzada estilo MNRL con negativos explícitos. La minería de negativos produjo 3997 filas negativas, con 2526 casos medios y 1471 casos duros. La Figura A.1 muestra la composición de estos negativos.

Las figuras anteriores representan la evolución del desempeño de recuperación entre candidatos ya entrenados. No corresponden a curvas internas de pérdida de entrenamiento, porque los experimentos de Sentence Transformers no conservaron una serie histórica de pérdida por épo-




Figura A.1: Composición de negativos usados en la iteración v3

ca o paso. Para futuras corridas, se recomienda habilitar logging a TensorBoard o persistir un archivo CSV o `trainer_state.json` con pérdida de entrenamiento y validación por época.

Tabla A.11: Reportes del modelo de embeddings preparado

Reporte	Ruta	Contenido
Entrenamiento	reports/04_embeddings/v3_iterative_hn_e5_base_bidirectional/v3_iterative_hn_e5_base_bidirectional_training.json	Configuración, minería y métricas finales
Recuperación castellano–shiwilu	reports/04_embeddings/experiments/v3_iterative_hn_e5_base_bidirectional/v3_iterative_hn_e5_base_bidirectional_esp_to_shi_retrieval.json	R@1, R@5, R@10, MRR y distribución de rangos
Recuperación shiwilu–castellano	reports/04_embeddings/experiments/v3_iterative_hn_e5_base_bidirectional/v3_iterative_hn_e5_base_bidirectional_shi_to_esp_retrieval.json	R@1, R@5, R@10, MRR y distribución de rangos

Tabla A.11 (continuación)

Reporte	Ruta	Contenido
Congelamiento del candidato	reports/04_embeddings/ experiments/v3_iterative_hn_ e5_base_bidirectional/v3_ iterative_hn_e5_base_ bidirectional_freeze_metadata. json	Rutas finales, manifiesto y decisión de cierre
Script de figuras	scripts/generate_embedding_ figures.py	Generación reproducible de gráficas desde reportes JSON
Resumen tabular de métricas	thesis/latex/figuras/generated/ embedding_metrics_summary. csv	Métricas, hipótesis, resultados y decisiones por variante

La decisión registrada para este candidato fue `candidate_final_embedding_model`. Por tanto, el modelo queda como entregable del resultado R2 y como insumo listo para integración o evaluación con etapas posteriores de traducción automática neuronal.

Anexo C: Documento reproducible del sistema NMT SA-BiNLLB

Este anexo documenta los detalles técnicos, hiperparámetros, fórmulas y rutas de configuración del sistema de traducción neuronal SA-BiNLLB descrito en el Capítulo 5. Su organización es paralela a la del Anexo B: cada subsección amplía un aspecto que en el cuerpo del capítulo se mantiene en tono narrativo, de modo que el lector que requiera reproducir o auditar el sistema disponga aquí de la especificación operativa completa.

C.1 Hiperparámetros del modelo y del entrenamiento

El modelo base es `facebook/nllb-200-distilled-600M`. La adaptación al par shiwilu–castellano se realiza con un único *adapter* LoRA bidireccional cuyos hiperparámetros se resumen en el Cuadro A.12.

Tabla A.12: Hiperparámetros del adaptador LoRA y del entrenamiento.

Parámetro	v_0	v_{1bt}	Comentario
LoRA r	16	32	Aumentado en v_{1bt} para absorber el corpus aumentado sin saturación
LoRA α	32	64	Mantiene la razón $\alpha/r = 2$
LoRA <i>dropout</i>	0,05	0,05	—
<i>Target modules</i>	q_proj, v_proj	ídem	Foco en proyecciones de atención
<i>Bias</i>	none	none	—
<i>Task type</i>	SEQ_2_SEQ_LM	ídem	—
Parámetros entrenables	$\sim 2,36$ M ($\sim 0,38\%$)	$\sim 4,72$ M ($\sim 0,76\%$)	Sobre 619 M de parámetros totales
<i>Learning rate</i>	2×10^{-4}	ídem	AdamW, programación cosenoidal
<i>Warm-up ratio</i>	0,1	0,1	—
<i>Weight decay</i>	0,01	0,01	—
Label smoothing	0,1	0,1	Reformulado por fila cuando hay pesos (ver C.7)
<i>Batch</i> entrenamiento	8	8	Por dispositivo
<i>Gradient accumulation</i>	4	4	<i>Batch</i> efectivo: 32
<i>Batch</i> validación	8	8	—
Épocas	20	20	Selección por mejor <i>eval_avg_chrf</i>
Precisión	fp16 (CUDA)	fp16 / bf16	bf16 disponible vía <code>--bf16</code>
Longitud máx. fuente	128 <i>tokens</i>	128	—
Longitud máx. destino	128 <i>tokens</i>	128	—
Generación intra-loop	beam=4	beam=4	Costo acotado
Generación final	beam=5	beam=5	Para inferencia y <i>reranking</i>

C.2 Extensión del tokenizer NLLB para Shiwili

NLLB-200 no incluye Shiwili en su inventario de lenguas. La extensión del *tokenizer* registra shw_Latn como un *special token* adicional, actualiza los mapas `lang_code_to_id` e `id_to_lang_code`,

y, por compatibilidad con tareas multitarea, registra también las etiquetas estilo T5 <2shw> y <2spa>. La fila de *embeddings* correspondiente al nuevo identificador se inicializa como la media (en float32) de las filas asociadas a tres lenguas indígenas sudamericanas que NLLB sí soporta: quy_Latn (Quechua de Ayacucho), ayr_Latn (Aymara) y grn_Latn (Guarani). La elección responde a contigüidad geográfica, propiedades fonológicas y prosódicas compatibles con el shiwilu de la familia cahuapana, y disponibilidad efectiva de cobertura de subpalabras en NLLB.

La actualización se realiza in-place sobre el modelo redimensionado (`model.resize_token_embeddings`), respetando el atado de pesos entre *input embeddings* y *lm head* cuando aplica. La rutina se encuentra en `src/nmt/training/model_setup.py`.

C.3 Filtrado semántico: configuración y umbrales

El filtro semántico utiliza el modelo congelado `v3_iterative_hn_e5_base_bidirectional_xl` para puntuar la similitud coseno entre fuente y destino de cada par paralelo. Por convención de E5, los textos se prefijan con `query:` y `passage:` respectivamente antes de la codificación. La normalización L2 se aplica antes de calcular el coseno, equivalente a producto interno con vectores unitarios.

Los umbrales se declaran en `config/nmt/filter.yaml`: `score < 0,45` descarta la pareja, `0,45 ≤ score ≤ 0,60` la marca como *flagged* (queda en el corpus pero se reporta), `score > 0,60` la acepta sin marca. La decisión se calcula a nivel de `pair_id` (no por dirección) para garantizar que ambas filas direccionales de un mismo par compartan etiqueta. El filtro se aplica únicamente al *train*; *valid* y *test* reciben el puntaje pero no se modifican.

C.4 Construcción de los índices FAISS

Sobre los pares aceptados se construyen dos índices FAISS (Johnson et al., 2019) de tipo `IndexFlatIP` con dimensión 768 (uno por idioma) y vectores L2-normalizados, lo que vuelve el producto interno equivalente al coseno. Cada índice se acompaña de un parquet de metadatos con `pair_id`, `group_id`, texto y posición. Los índices se utilizan en (a) la fase de aumentación por minería bilingüe (Sección C.6, ítem 3) y (b) la detección opcional de duplicados cercanos: pares con

$IP \geq 0,98$ se reportan como casi-duplicados pero no se eliminan automáticamente.

C.5 Reranking semántico: fórmula y ablación

El *reranker* opera sobre las $K = 5$ hipótesis del decodificador con haz de cinco. Para cada candidato c_i se calcula:

- $p_{\text{trad}}(c_i) = \text{softmax}_K(\text{sequence_score}(c_i))$: probabilidad relativa entre los K candidatos.
- $\cos(s, c_i) = \langle \mathbf{e}(s), \mathbf{e}(c_i) \rangle$, con $\mathbf{e}$ producido por el modelo de *embeddings* congelado y normalizado L2.

El puntaje final es la combinación lineal $\text{final}(c_i) = \alpha \cdot p_{\text{trad}}(c_i) + (1 - \alpha) \cdot \cos(s, c_i)$ y la hipótesis seleccionada es $\arg \max_i \text{final}(c_i)$. El barrido de ablación se efectúa sobre $\alpha \in \{0,0, 0,3, 0,5, 0,7, 1,0\}$ usando chrF++ promediada entre direcciones como métrica de selección. El Cuadro A.13 consolida la ablación para los modelos v_0 y v_{1bt} sobre la variante x1.

Tabla A.13: Ablación de α en el *reranker* semántico (modelos v_0 y v_{1bt} , variante x1, conjunto de *test*, métrica de selección: chrF++ promedio).

α (translation)	avg chrF++	avg BLEU
0.00	25.41	5.78
0.30	25.51	5.97
0.50	25.57	6.02
0.70	25.44	6.11
1.00	23.83	5.20

Tabla A.14: Ablación de α para el modelo aumentado v_{1bt} (variante x1).

α (translation)	avg chrF++	avg BLEU
0.00	31.99	8.42
0.30	32.34	9.67
0.50	32.42	10.02
0.70	32.52	10.05
1.00	31.41	9.75

El óptimo observado es $\alpha = 0,5$ para v_0 y $\alpha = 0,7$ para v_{1bt} . La forma de U invertida de las curvas indica que ambas señales (p_{trad} y $\cos$) aportan información complementaria sin redundancia destructiva.

C.6 Augmentación: especificación matemática de cada fuente

(1) Backtranslation desde monolingüe Shiwilu. Sea M_{shw} el conjunto de oraciones shiwilu sin par paralelo (extraídas del PDF de *VOCES SHIWILU*). Para cada $t \in M_{\text{shw}}$ se genera $\hat{s} = v_0^{\text{shw} \rightarrow \text{spa}}(t)$ con haz de cinco. Se calcula $\cos(t, \hat{s})$ usando el modelo de *embeddings* congelado y se aceptan las parejas con $\cos \geq 0,60$. El conjunto aceptado se acota al doble del tamaño del corpus paralelo ($\text{cap_x} = 2$). Cada par aceptado produce dos filas direccionales con $\text{origin_source} = \text{backtranslation_v0}$.

(2) Round-trip backtranslation desde monolingüe Español. Sea M_{spa} un conjunto de oraciones españolas (FLORES-101 spa_Latn, OPUS-100, Wikipedia es). Para cada $s \in M_{\text{spa}}$ se calcula $\hat{t} = v_0^{\text{spa} \rightarrow \text{shw}}(s)$ y luego $\hat{s} = v_0^{\text{shw} \rightarrow \text{spa}}(\hat{t})$. Se mide $\cos(s, \hat{s})$ (consistencia *monolingüe* en español) con el modelo de *embeddings* congelado y se aceptan parejas con $\cos \geq 0,70$ (umbral más estricto que el cross-lingual del ítem 1, justificado por la naturaleza intra-lengua de la comparación). Cada par aceptado $(s, \hat{t})$ produce dos filas direccionales con $\text{origin_source} = \text{backtranslation_roundtrip_v0}$, almacenadas en `train_bt_roundtrip[_iterN].csv`. El esquema soporta iteraciones sucesivas: a partir de iteración 1 el modelo generador deja de ser v_0 y pasa a ser el último v_{kbt} entrenado.

(3) Minería bilingüe basada en embeddings. Sobre los índices FAISS de la Sección C.4, para cada oración shiwilu del corpus aceptado se obtienen los $k = 5$ vecinos más cercanos en el espacio español, y viceversa. Se conservan únicamente las parejas con vecindad recíproca (mutual top- k) y producto interno $\text{IP} > 0,65$. Esta fuente captura paráfrasis cruzadas que el corpus paralelo no había emparejado explícitamente. Cada par aceptado produce dos filas direccionales con $\text{origin_source} = \text{mined_v3_sbert}$.

(4) Variantes morfológicas controladas. Sobre el inventario de sufijos minado en la fase de *embeddings*, se generan variantes morfológicas (sustitución de sufijos compatibles) para revi-

sión por lingüista. Sin validación humana, estas filas se marcan como `manual_review_required` y se mantienen fuera del entrenamiento por defecto. La activación es opcional vía `--include-morph` y `--emit-csv-anyway`.

C.7 Pesado por origen de la pérdida (Enhancement #4)

Las filas sintéticas tienen confiabilidad heterogénea respecto del paralelo real. Se introduce un mapa de pesos por origen, `DEFAULT_WEIGHT_MAP`:

Origen	Peso w
flashcards (paralelo real)	1,0
pdf_textos (paralelo real)	1,0
mined_v3_sbert (minería bilingüe)	0,5
backtranslation_v0 (BT shiwillu)	0,3
backtranslation_roundtrip_v0 (BT round-trip español)	0,3
morphological_variant (morfología)	0,3

El *collator* extrae el peso de cada *feature* antes del `DataCollatorForSeq2Seq` y lo re-attacha al *batch* como tensor $[B]$. La pérdida se calcula con una variante de *label-smoothing* replicada a nivel *per-row*: para logits $\ell \in \mathbb{R}^{B \times T \times V}$, *labels* $y \in \{1, \dots, V, -100\}^{B \times T}$ y suavizado ϵ ,

$$\mathcal{L} = \frac{\sum_{b,t} w_b \cdot [(1 - \epsilon) \text{NLL}(\ell_{b,t}, y_{b,t}) + \epsilon \overline{-\log p}(\ell_{b,t})] \mathbb{I}[y_{b,t} \neq -100]}{\sum_{b,t} w_b \cdot \mathbb{I}[y_{b,t} \neq -100]}$$

Una fila con $w = 0,3$ contribuye así el 30 % de sus *tokens* válidos al promedio. Esta ruta se activa exclusivamente en v_{1bt} y subsecuentes; el modelo v_0 original mantiene la pérdida estándar de Hugging Face. Implementación en `src/nmt/training/train_lora.py::_weighted_smoothed_ce`.

C.8 Configuración de inferencia

La inferencia (script `scripts/nmt/40_evaluate.py`) usa los siguientes parámetros, declarados en `config/nmt/inference.yaml`:

- `num_beams = 5`
- `num_return_sequences = 5` (necesario para *reranking* y top-K JSONL)
- `length_penalty` y `no_repeat_ngram_size` con valores por defecto del *generation config* de NLLB
- `generation_max_length = 128`
- `forced_bos_token_id` establecido al *lang code* del idioma destino antes de cada llamada

C.9 Bandas de confianza por predicción

Cada predicción persiste tres campos adicionales en `*_predictions.jsonl`: `confidence_score`, `confidence` $\in \{\text{low}, \text{medium}, \text{high}\}$, `confidence_components`.

- **Sin reranker:** `confidence_score` = $\exp(\text{top-1 sequence_score})$, una probabilidad geométrica por *token* sobre la mejor hipótesis.
- **Con reranker:** `confidence_score` = puntaje *final* combinado descrito en C.5.

Los umbrales se calibraron sobre el conjunto de *test* de v_0 : rango observado $[0,20, 0,79]$, mediana 0,41 en *baseline*; rango $[0,10, 0,48]$, mediana 0,28 con *reranker* $\alpha = 0,7$. Se fija `low_to_med` = 0,40, `med_to_high` = 0,55 para la familia *baseline*. La distribución resultante por banda se persiste en `meta.confidence` de cada `*_metrics.json`. Esta señal no pretende ser una probabilidad calibrada sino un indicador suave para consumidores aguas abajo (por ejemplo, herramientas de pre-llenado de *flashcards*).

C.10 Análisis morfológicamente sensible (rare-token y OOV)

Para complementar la métrica corpus-level se reporta chrF++ por *bucket* de fracción de palabras raras en la referencia (frecuencia en *train* < 5) y la tasa de recuperación de palabras OOV (jamás vistas en *train*) que aparecen verbatim en la hipótesis. El *bucket* de mayor interés es “ $\geq 20\%$ raras”, que aísla las oraciones morfológicamente densas. El Cuadro A.15 resume el comportamiento en las cuatro variantes de la versión x1; el *reranker* mantiene su ventaja sobre el régimen *rare-heavy*, aunque la *OOV recovery rate* es uniformemente baja ($\sim 5\%$). Esta observación motiva la línea de trabajo futuro sobre *focal loss* (Sección 6.2).

Tabla A.15: Análisis rare-token / OOV sobre el bucket de referencias con $\geq 20\%$ palabras raras (variante x1).

Variante	shw→spa		spa→shw		Promedio	
	chrF++ raras	OOV rec.	chrF++ raras	OOV rec.	chrF++ raras	OOV rec.
nllb_bidi_lora_v0_x1	—	—	—	—	—	—
nllb_bidi_lora_v0_x1+rerank	—	—	—	—	—	—
nllb_bidi_lora_v1_bt_x1	—	—	—	—	—	—
nllb_bidi_lora_v1_bt_x1+rerank	—	—	—	—	—	—

C.11 SentencePiece como artefacto analítico

El *tokenizer* de tiempo de ejecución es siempre el de NLLB. No obstante, el plan de trabajo prescribe entrenar un *SentencePiece Unigram* sobre el corpus consolidado (vocab = 8000, *character coverage* = 1,0) como artefacto analítico para (i) sustentar la elección de un *tokenizer* compatible con la morfología aglutinante del shiwilu, y (ii) compararlo con la tokenización de NLLB sobre el mismo conjunto. Con ~ 5 k oraciones de entrenamiento, la cobertura efectiva del vocabulario es de aproximadamente 4 k piezas (umbral natural marcado por SentencePiece). El comportamiento sobre shiwilu se resume en el Cuadro A.16: SP unigram produce 10,88 *tokens* promedio frente a 13,18 de NLLB, lo cual confirma que la tokenización entrenada localmente es más compacta para shiwilu. Esta evidencia respalda la elección *conceptual* de un *tokenizer* aglutinante-amigable, aunque en runtime se conserve el de NLLB por compatibilidad con los pesos pre-entrenados.

Tabla A.16: Tokens promedio por oración de shiwilu: SP Unigram entrenado en este trabajo vs. el *tokenizer* multilingüe de NLLB-200 (variante x1).

Tokenizador	Tokens / frase	Tokens / palabra	Vocab efectivo	Frases más cortas
SP Unigram (este trabajo)	10.88	3.42	5293	38/50
NLLB-200	13.18	4.14	256 000	1/50
Empate	—	—	—	11/50

C.12 Protocolo de evaluación humana

El protocolo, implementado por `scripts/nmt/71_human_eval_template.py`, se ejecuta con los parámetros: `--per-direction 100, --seed 2026`, comparando los cuatro sistemas (v_0 y v_{1bt} , cada uno en variantes *baseline* y *reranked*) sobre el conjunto de *test*. El muestreo es estratificado por origen (*flashcards* vs *pdf_textos* vs otras fuentes) y por *bucket* de longitud (corto ≤ 5 , medio ≤ 12 , largo > 12 palabras).

Las hipótesis se anonimizan con un mapeo aleatorio letra $\rightarrow$ sistema (A, B, C, D), persistido en `reports/05_nmt/evaluation_xl/human_eval_anon_key.json`. La planilla resultante `human_eval_template.csv` contiene, por fila, la fuente, la referencia, las cuatro hipótesis anonimizadas y tres celdas vacías para que el revisor consigne puntajes 1–5 en las dimensiones de adecuación, fluidez y pertinencia cultural.

C.13 Reproducibilidad y desviaciones documentadas

El *stack* de NMT vive en un entorno aislado `.venv-nmt` con los pines exactos de `requirements/nmt.txt`. Las desviaciones formales respecto del plan original son:

- Python 3.12 (no 3.11) para alinearse con `pyproject.toml`.
- PyTorch 2.7.1 con *wheels* `cu128` (no 2.5.1) por el soporte de la arquitectura Blackwell (*compute capability* 12.0) presente en la GPU disponible (RTX 5060 Ti).
- Subida coordinada de `transformers 4.55.0`, `accelerate 1.8.1`, `peft 0.16.0` para mantener compatibilidad con la versión de PyTorch.

- `sentence-transformers` $\geq 5.4.1$ (no 4.1.0): el *checkpoint* congelado del capítulo anterior se serializó con las rutas de módulo introducidas en 5.4.x y no es cargable por la familia 4.x.
- Cota superior `numpy` < 2 requerida por COMET 2.2.4.
- Cota `setuptools` < 81 requerida porque `torchmetrics` (dependencia transitiva de COMET) aún importa `pkg_resources`, removido en 81+.

Adicionalmente, `torch.compile` no se utiliza en este pipeline porque depende de Triton, sólo disponible en Linux. Cada desviación se justifica por una restricción concreta de *hardware* o de cadena de dependencias y se ha registrado en el encabezado de `requirements/nmt.txt` y en el archivo `plan.md` de seguimiento.

C.14 Ablaciones del optimizador y arquitectura del adaptador

Sobre la base v_{1bt} descrita en el Capítulo 5, sección 5.7, el ciclo final de experimentación incorporó cuatro ablaciones que aíslan la contribución de tres familias de mejoras: una arquitectura alternativa del adaptador PEFT (DoRA), una modificación del optimizador (LoRA+), su combinación, y una ronda adicional de *round-trip backtranslation* con *pool* monolingüe extra-dominio.

DoRA (Decomposed Low-Rank Adaptation). En lugar del producto $\Delta W = BA$ clásico de LoRA, DoRA descompone la actualización del peso adaptado como $\Delta W = m \cdot \frac{V+BA}{\|V+BA\|_c}$, donde el factor de magnitud m y la dirección normalizada se entrenan por separado (S.-Y. Liu et al., 2024). La hipótesis de DoRA es que separar magnitud y dirección produce dinámicas de aprendizaje más cercanas al *full fine-tuning*. Implementación: PEFT 0.16.0 nativa vía `LoraConfig(use_dora=True)`; conmutador CLI `--use-dora` en `30_train_lora.py`.

LoRA+. Aplica una tasa de aprendizaje asimétrica a las dos matrices del producto BA : $\eta_B = \lambda \cdot \eta_A$ con $\lambda = 16$ según el valor recomendado por los autores para modelos pre-entrenados grandes (Hayou et al., 2024). La justificación es que, dado que B se inicializa en cero y A sigue una distribución no trivial, mantener tasas iguales mantiene a B en un régimen efectivamente inactivo du-

rante demasiados pasos. Implementación: optimizador construido vía `peft.optimizers.create_loraplus_` conmutador CLI `--loraplus-lr-ratio 16.0`.

Round-trip backtranslation iterativa (iter 1). La extensión natural de la *backtranslation* de v_{1bt} usando $v_{2.1b}$ como generador, sobre un *pool* monolingüe español tomado de Wikipedia en español (corpus extraído con `60b_roundtrip_bt.py --source wikipedia`). El criterio de admisión sintética es el mismo del Anexo A: filtro cosenoidal monolingüe contra el SBERT v_3 congelado con umbral $\tau = 0,70$.

El Cuadro 5.4 consolida las seis variantes ordenadas por avg chrF++ reranked; el Cuadro 5.5 reporta los intervalos de confianza bootstrap del 95 % con $n = 1000$ re-muestreos por dirección, computados sobre las predicciones reranked. Las lecturas operativas son:

- **LoRA+ aislado es el ganador.** $v_{2.1b}$ alcanza avg chrF++ = 44,99 con IC 95 % [43,17, 46,96], sin solapamiento con el IC de v_{1bt} ([30,63, 33,80]). El salto de $\approx 12,8$ puntos es la mejora más grande del ciclo y es estadísticamente clara.
- **DoRA aislado no se distingue de v_{1bt} .** $v_{2.0}$ reporta avg chrF++ = 32,58 con IC [31,02, 34,25], que se traslapa con [30,63, 33,80]. En este tamaño de corpus DoRA no paga su sobrecarga computacional.
- **DoRA+LoRA+ no mejora sobre LoRA+ aislado.** $v_{2.1}$ reporta 44,30 con IC [42,49, 46,12], cuyo IC se traslapa fuertemente con el de $v_{2.1b}$. La señal dominante del ciclo proviene del optimizador, no de la descomposición del adaptador.
- **La calidad del *pool* monolingüe rige sobre su volumen.** $v_{2.2}$ regresa a ≈ 32 chrF++, eliminando casi por completo la ganancia de LoRA+. El cambio de *pool* (de OPUS-100, registro conversacional/web alineado con el corpus paralelo, a Wikipedia, registro enciclopédico) introduce vocabulario y longitudes ajenas que el filtro semántico no logra absorber porque el evaluador SBERT v_3 está calibrado sobre la distribución del corpus original; el resultado es coherente con la literatura de *domain-aware backtranslation* y se cita como justificación para el ítem de trabajo futuro sobre corpus monolingüe controlado por dominio.

Los hiperparámetros finales adoptados en $v_{2.1b}$ son los listados en la Sección A, con dos diferencias respecto del entrenamiento de v_{1bt} : (i) el optimizador es construido vía `create_loraplus_optimizer` con $\lambda = 16$, y (ii) la precisión es bf16 (no fp16) por su mayor estabilidad numérica en presencia de tasas de aprendizaje asimétricas. El rango LoRA permanece en $r = 32$, $\alpha = 64$; el resto de la configuración es idéntico.

C.15 Tabla de scripts y reportes generados

El Cuadro A.17 enumera los scripts del pipeline NMT, las salidas principales y los reportes de control que permiten reproducir o auditar cada fase.

Tabla A.17: Pipeline reproducible del sistema NMT SA-BiNLLB.

Fase	Script base	Salida principal	Reporte de control
10	scripts/nmt/10_canonicalize_dataset.py	data/processed/05_nmt_canonical[_xl]/^{\train, valid, test\}.csv	reports/05_nmt/preprocessing[_xl]/canonical_manifest.json
20	scripts/nmt/20_semantic_filter.py	data/processed/06_nmt_filtered[_xl]/train_{accepted, flagged, removed\}.csv	reports/05_nmt/preprocessing[_xl]/semantic_filter.json
21	scripts/nmt/21_build_faiss.py	data/processed/06_nmt_filtered[_xl]/faiss_{shw, spa\}.index + meta parquet	reports/05_nmt/preprocessing[_xl]/faiss_index.json
22	scripts/nmt/22_train_sentencepiece.py	models/nmt/sentencepiece/sp_unigram_8k.model	reports/05_nmt/preprocessing[_xl]/sentencepiece_stats.json
30	scripts/nmt/30_train_lora.py	models/nmt/nllb_bidi_lora_v0[_xl]/	reports/05_nmt/training[_xl]/<run>^{\summary, training_log\}.json
40	scripts/nmt/40_evaluate.py	reports/05_nmt/evaluation[_xl]/<run>/test_predictions[_topk].jsonl	reports/05_nmt/evaluation[_xl]/<run>/test_metrics.json
41	scripts/nmt/41_rare_token_eval.py	—	reports/05_nmt/evaluation[_xl]/<run>/rare_token_analysis[_reranked].json

Tabla A.17 (continuación)

Fase	Script base	Salida principal	Reporte de control
50	scripts/nmt/50_rerank.py	reports/05_nmt/ reranking[_xl]/<run> /test_predictions_ reranked.jsonl	reports/05_nmt/ reranking[_xl]/<run>^\n {test_metrics_reranked, ablation\\}.json
60	scripts/nmt/60_ backtranslate.py	data/processed/07_nmt_ augmented[_xl]^\n{mono_ shw.txt,train_bt.csv\\}	reports/05_nmt/ augmentation[_xl]^\n {mono_extraction, backtranslation\\}.json
60b	scripts/nmt/60b_roundtrip_ bt.py	data/processed/07_nmt_ augmented[_xl]/train_bt_ roundtrip[_iterN].csv	reports/05_nmt/ augmentation[_xl] /backtranslation_ roundtrip.json
61	scripts/nmt/61_mine_pairs. py	data/processed/07_nmt_ augmented[_xl]/train_ mined.csv	reports/05_nmt/ augmentation[_xl] /mining.json
62	scripts/nmt/62_morph_ variants.py	data/processed/07_nmt_ augmented[_xl]/train_ morph.csv (opcional)	reports/05_nmt/ augmentation[_xl] /morph_variants.json
63	scripts/nmt/63_train_with_ augmented.py	models/nmt/nllb_bidi_ lora_v1_bt[_xl]/	reports/05_nmt/ training[_xl]/<run>^\n {summary,training_log\\}. json
70	scripts/nmt/70_compare_ runs.py	reports/05_nmt/ evaluation[_xl] /comparison_<v0>_vs_ <v1>.md	ídem
71	scripts/nmt/71_human_ eval_template.py	reports/05_nmt/ evaluation[_xl]/human_ eval_template.csv	human_eval_anon_key. json
72	scripts/nmt/72_leaderboard. py	reports/05_nmt/ evaluation[_xl] /leaderboard.\\{md,json\\}	—
73	scripts/nmt/73_bootstrap_ci. py	reports/05_nmt/ evaluation[_xl]/<run> /bootstrap_ci.json	reports/05_nmt/ evaluation[_xl] /bootstrap_ci_summary. md
74	scripts/nmt/74_thesis_ tables_phase6.py	thesis/latex/figuras/ generated/nmt_ \\{leaderboard,bootstrap_ ci,rare_token_full\\}[_xl] .tex	—

Tabla A.17 (continuación)

Fase	Script base	Salida principal	Reporte de control
—	scripts/generate_nmt_tables.py	thesis/latex/figuras/ generated/nmt_*.tex	—