

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

FACULTAD DE CIENCIAS E INGENIERÍA



“Traducción automática neuronal Shiwilu–Castellano”

Tesis para obtener el título profesional de Ingeniería Informática

AUTOR:

Fabian Prado Infanson

ASESOR:

Mg. Erasmo Gómez

Lima, 15 de mayo de 2026

Resumen

El shiwilu, también conocido como jebero, es una lengua amazónica peruana en situación crítica de amenaza, cuya presencia digital y disponibilidad de recursos bilingües siguen siendo limitadas. Esta tesis aborda dicho problema mediante la propuesta de un sistema de traducción automática neuronal bidireccional entre shiwilu y castellano, orientado a apoyar la documentación, el aprendizaje y el uso cotidiano de la lengua en contextos educativos y comunitarios.

El trabajo se centra en la construcción de una base metodológica y técnica para desarrollar el sistema: recopilación y alineación de un corpus paralelo, definición de criterios de selección y normalización, preparación de recursos de representación semántica, diseño de modelos de traducción, aplicación de un protocolo de evaluación que combina métricas automáticas con validación participativa e implementación de un prototipo funcional ejecutable que integra el modelo entrenado. La investigación adopta un enfoque reproducible, trazable y sensible a las particularidades lingüísticas del shiwilu, considerando los desafíos propios de las lenguas de bajo recurso.

La primera ejecución participativa se realizó con Fidel Lomas Chota, uno de los principales exponentes y preservadores contemporáneos del shiwilu vinculados al proyecto, sobre 100 traducciones balanceadas por dirección. Los resultados humanos fueron favorables: 80 % de traducciones aceptadas, 20 % corregibles y 0 % rechazadas. Con ello, la tesis aporta un recurso tecnológico inicial, una evidencia humana trazable y una ruta experimental documentada para futuras investigaciones en traducción automática de lenguas originarias.

Índice general

Resumen	1
1 Generalidades	11
1.1 Problemática	11
1.1.1 Árbol de Problemas	14
1.1.2 Causas	14
1.1.3 Consecuencias	15
1.1.4 Problema seleccionado	16
1.2 Objetivos	16
1.2.1 Objetivo general	16
1.2.2 Objetivos específicos	16
1.2.3 Resultados esperados	18
1.2.4 Mapeo de objetivos, resultados y verificación	18
1.3 Métodos y Procedimientos	20
1.3.1 Herramientas	20
1.3.2 Justificación	20
1.3.3 Detalle	21
1.3.4 Métodos	22
1.3.5 Procedimientos	23
2 Marco Conceptual	25

2.1	Introducción	25
2.2	Desarrollo del marco	25
2.2.1	Procesamiento de Lenguaje Natural (NLP)	25
2.2.2	Lenguas de muy bajos recursos (LRL)	26
2.2.3	Alineación oración a oración	26
2.2.4	Preprocesamiento y tokenización en subpalabras	27
2.2.5	Aumento de datos (<i>data augmentation</i>)	28
2.2.6	Transfer learning y modelos multilingües	29
2.2.7	Adaptación eficiente (adapters/LoRA)	30
2.2.8	Representaciones vectoriales (embeddings) y minería/filtrado	30
2.2.9	BLEU (Bilingual Evaluation Understudy)	31
2.2.10	chrF (carácter n-gram F-score)	31
2.2.11	BERTScore y COMET	32
3	Estado del Arte	33
3.1	Introducción	33
3.2	Objetivos de revisión	33
3.3	Preguntas de revisión	34
3.4	Estrategia de búsqueda	34
3.4.1	Motores de búsqueda utilizados	34
3.4.2	Cadenas de búsqueda utilizadas	35
3.4.3	Documentos encontrados	37
3.4.4	Criterios de inclusión/exclusión	38
3.5	Formulario de extracción de datos	39

3.6	Resultados de la revisión	40
3.6.1	P1. Generación y ampliación de datos	40
3.6.2	P2. Arquitecturas, entrenamiento y baselines	42
3.6.3	P3. Métricas y validación con hablantes	45
3.7	Conclusiones	47
4	Recopilación y preparación inicial del corpus bilingüe	49
4.1	Introducción	49
4.2	Resultados alcanzados	49
4.2.1	R1: corpus paralelo depurado, alineado y particionado	50
4.2.2	Fuentes del corpus bilingüe	50
4.2.3	Construcción, normalización y auditoría del corpus	53
4.2.4	Caracterización del corpus preparado	55
4.2.5	Particiones reproducibles del corpus	56
4.2.6	R2: recurso de embeddings bilingüe preparado y evaluado	58
4.3	Discusión	61
5	Sistema de traducción neuronal SA-BiNLLB	63
5.1	Introducción	63
5.2	Resultados alcanzados	64
5.2.1	Arquitectura general	64
5.2.2	Datos canónicos para NMT	65
5.2.3	Filtrado semántico de calidad	66
5.2.4	Entrenamiento del modelo v_0	67
5.2.5	Augmentación de datos para v_{1bt}	67

5.2.6	Evaluación automática y ablaciones	69
5.2.7	Análisis cualitativo estratificado	73
5.3	Discusión	76
5.4	Conclusión del capítulo	77
6	Protocolo de validación automática y participativa	78
6.1	Introducción	78
6.2	Resultados alcanzados	79
6.2.1	Primera ejecución de la validación participativa	81
6.2.2	Instrumento complementario de preferencia pareada	83
6.3	Discusión	84
6.4	Conclusión del capítulo	85
7	Prototipo funcional del traductor automático	86
7.1	Introducción	86
7.2	Resultados alcanzados	87
7.2.1	Arquitectura del prototipo	87
7.2.2	Funcionalidad de la interfaz	88
7.2.3	Registro estructurado de uso	90
7.2.4	Integración y despliegue	91
7.2.5	Demostración y casos de prueba	91
7.3	Discusión	92
7.4	Conclusión del capítulo	93
8	Conclusiones y trabajos futuros	94

8.1 Conclusiones	94
8.2 Trabajos futuros	96
Referencias	99
A Anexos	106
Anexo B: Documento reproducible del proceso de corpus y embeddings	121
Anexo C: Documento reproducible del sistema NMT SA-BiNLLB	126
Anexo D: Prototipo funcional de traducción	141
Anexo E: Validación participativa del sistema	144

Índice de cuadros

1.1	Resultados esperados (mapeo de objetivos, MV e IOV)	19
1.2	Herramientas, métodos y procedimientos a utilizar	20
3.1	Resultados de búsqueda de las cadenas	38
3.2	Resultados luego de aplicar criterios de exclusión	38
3.3	Formulario de extracción de datos	39
4.1	Fuentes bilingües incorporadas al corpus	52
4.2	Etapas reproducibles de preparación del corpus	54
4.3	Resumen del corpus consolidado y auditado	55
4.4	Estadísticas léxicas del corpus auditado	56
4.5	Particiones canónicas del corpus bilingüe (variante x1, semilla 42)	57
4.6	Métricas del modelo de embeddings preparado	59
5.1	Distribución del corpus canónico bidireccional para entrenamiento NMT (variante x1).	66
5.2	Distribución de pares en el conjunto de entrenamiento tras el filtro semántico (variante x1).	67
5.3	Comparación de variantes del sistema sobre el conjunto de prueba (variante x1, 451 pares por dirección). chrF++ es la métrica primaria.	69
5.4	<i>Leaderboard</i> final de ablaciones sobre la variante x1 (446 pares por dirección, 892 filas direccionales). chrF++ es la métrica primaria; BLEU y COMET se reportan como métricas complementarias.	71

5.5	Métricas reranked por dirección sobre el conjunto de prueba de la variante x1. La separación evita que el promedio oculte diferencias entre traducir hacia castellano y traducir hacia shiwilu.	72
5.6	Intervalos de confianza bootstrap del 95 % sobre chrF++ reranked y métricas complementarias promedio. BLEU y COMET se muestran como puntos sin intervalo de confianza.	73
5.7	Distribución de las salidas de $v_{2.1b}$ reranked por banda de puntaje por oración (conjunto de prueba x1, 446 oraciones por dirección).	75
6.1	Estado de los componentes del protocolo de validación.	80
6.2	Resultados agregados de la primera validación participativa.	82
6.3	Ejemplos representativos de correcciones en la validación participativa.	83
7.1	Información que el prototipo conserva en el registro de uso por cada traducción.	90
7.2	Casos de prueba de demostración en ambas direcciones, tomados del conjunto de prueba de la variante x1, en los que la salida del prototipo coincide con la traducción de referencia (modelo $v_{2.1b}$ con reranking, $\alpha = 0,7$).	92
7.3	Estado de los componentes del prototipo funcional.	92
A.1	Limitaciones del proyecto	111
A.2	Umbral de riesgo (probabilidad e impacto)	111
A.3	Matriz de riesgos del proyecto	112
A.4	Lista de tareas (EDT)	114
A.5	Cronograma del proyecto	116
A.6	Presupuesto del proyecto	119
A.7	Evidencia documental de construcción del corpus	121
A.8	Criterios documentados para selección y normalización	122

A.9	Función de las particiones canónicas	123
A.10	Evolución experimental del modelo de embeddings	124
A.11	Reportes del modelo de embeddings preparado	126
A.12	Hiperparámetros del adaptador LoRA y del entrenamiento.	127
A.13	Ablación de α en el <i>reranker</i> semántico (modelos v_0 y v_{1bt} , variante x1, conjunto de <i>test</i> , métrica de selección: chrF++ promedio).	129
A.14	Ablación de α para el modelo aumentado v_{1bt} (variante x1).	130
A.15	Análisis rare-token / OOV sobre el bucket de referencias con $\geq 20\%$ palabras raras para las variantes reranked (variante x1).	133
A.16	Tokens promedio por oración de shiwilu: SP Unigram entrenado en este trabajo vs. el <i>tokenizer</i> multilingüe de NLLB-200 (variante x1).	134
A.17	Evidencias del protocolo de evaluación humana	134
A.18	Pipeline reproducible del sistema NMT SA-BiNLLB.	139
A.19	Componentes funcionales del prototipo	141
A.20	Evidencias digitales de la validación participativa	144
A.21	Síntesis de la validación participativa del sistema.	146
A.22	Correcciones representativas registradas por el revisor.	146

Índice de figuras

1.1	Árbol de Problemas	14
4.1	Flujo reproducible de construcción del corpus bilingüe	53
4.2	Distribución de fuentes por partición canónica (variante x1)	57
4.3	Evolución experimental de R@1 y MRR en los modelos de embeddings	59
4.4	Métricas finales de recuperación del modelo de embeddings v3	59
4.5	Proyección PCA del espacio vectorial bilingüe del modelo de embeddings v3	60
4.6	Distribución de rangos del modelo de embeddings v3	61
5.1	Arquitectura de entrenamiento e inferencia del modelo final SA-BiNLLB $v_{2.1b}$	65
5.2	Evolución del entrenamiento de $v_{2.1b}$ LoRA+ en la variante x1: pérdida de entrenamiento, pérdida de validación y chrF++ de validación por dirección.	74
7.1	Arquitectura del prototipo funcional: capa de interfaz sobre el sistema SA-BiNLLB $v_{2.1b}$ congelado.	87
7.2	Interfaz del prototipo funcional: traducción castellano→shiwilu con el modelo $v_{2.1b}$ y reranking semántico.	89
A.1	Estructura de descomposición del trabajo	114
A.2	Composición de negativos usados en la iteración v3	125
A.3	Comparación de chrF++ promedio en validación durante el entrenamiento de v_0 , v_{1bt} y $v_{2.1b}$ LoRA+.	138

Capítulo 1

Generalidades

1.1 Problemática

El shiwilu, también llamado jebero, es una lengua amazónica peruana de la familia cahuapana que atraviesa un estado crítico de amenaza. El número de hablantes es muy reducido, en su mayoría personas adultas mayores, y la transmisión intergeneracional se encuentra quebrada (Valenzuela, 2018). Aunque en 2016 fue declarada Patrimonio Cultural de la Nación, su presencia en el ecosistema digital sigue siendo mínima, lo que incrementa el riesgo de desplazamiento. Cuando una lengua no encuentra espacios de uso en entornos digitales, su marginación se acelera y disminuye la posibilidad de su aprendizaje y uso cotidiano (Ministerio de Cultura del Perú, 2016; UNESCO, 2023).

En este escenario, un sistema de traducción automática neuronal entre shiwilu y castellano podría convertirse en una herramienta estratégica para documentar, consultar y circular conocimiento bilingüe. Sin embargo, el desarrollo de un traductor de este tipo enfrenta un cuello de botella inmediato: no existe un corpus paralelo shiwilu–castellano con volumen y diversidad suficientes para entrenar y evaluar modelos con criterios reproducibles. La traducción automática, tanto en su vertiente estadística como neuronal, depende de colecciones amplias de oraciones alineadas; cuando el paralelo es mínimo, la calidad de los modelos cae y los resultados no son comparables entre estudios (Mager & Meza, 2018). En shiwilu, más allá de aportes de documentación, como el diccionario bilingüe con ejemplos de uso, los datos disponibles siguen siendo escasos y dispersos. Por ello, aún no se cuenta con baselines ni conjuntos de prueba estables contra los cuales contrastar avances (Valenzuela, 2018). Esta situación contrasta con pares mejor documentados en la región, como quechua–español o shipibo–español, donde ya existen corpus

iniciales y evaluaciones básicas que permiten organizar la investigación (Chuquimamani, 2021; Galarreta, 2017).

El problema no se limita al volumen del corpus; también involucra la calidad y la representatividad de los datos. En ausencia de textos variados, el material disponible tiende a concentrarse en narrativas tradicionales o léxico especializado, lo que sesga el dominio temático y deja fuera construcciones frecuentes del uso cotidiano. Con pocos ejemplos, los modelos neuronales tienden a sobreajustar y generalizar mal, fenómeno documentado en lenguas indígenas con corpus de apenas miles de oraciones (Mager & Meza, 2018). A ello se suma la distancia tipológica entre shiwilu y castellano: la morfología aglutinante, ciertos patrones estructurales y los alineamientos semánticos no uno a uno complican la alineación y la traducción literal de términos culturalmente marcados. En varios casos no hay equivalencias directas, por lo que se requiere curación cuidadosa y verificación contextual de las parejas de oración (Ministerio de Cultura del Perú, 2016). Incluso si se reúne un primer conjunto paralelo, la calidad del dato y su adecuación semántica y cultural siguen siendo el desafío central.

La dimensión sociolingüística también es central, porque la construcción de recursos depende del trabajo con hablantes. Dada la escala de la comunidad y la edad de sus miembros, la obtención y validación de paralelos requiere colaboración cercana. En este proyecto, el Grupo Chana ha articulado la recolección de materiales con apoyo del señor Fidel Lomas Chota, hablante competente, autor de relatos y uno de los principales preservadores contemporáneos del shiwilu vinculados al proyecto, quien ha contribuido con traducciones y validaciones. Su participación aporta datos de primera mano y criterio cultural para juzgar la aceptabilidad de equivalencias, un aspecto que las métricas automáticas no capturan por sí solas (UNESCO, 2023). La experiencia comparada en náhuatl y guaraní sugiere, además, que sin esta mediación humana los modelos tienden a aprender artefactos del corpus y fallan en variedades o géneros no cubiertos por los datos de entrenamiento (Baladón et al., 2024; Ríos, 2019).

El panorama regional confirma que la base del problema en lenguas de muy bajos recursos es doble: escasez de corpus y ausencia de referencias evaluativas. En quechua sureño, la creación de nuevos conjuntos bilingües a partir de fuentes dispersas fue condición previa para evaluar

con métricas estándar y establecer comparaciones significativas; sin ese piso de datos, no era posible justificar avances ni orientar mejoras (Chuquimamani, 2021). En shipibo–español, un esfuerzo temprano desde el enfoque estadístico mostró el mismo patrón: antes de buscar la mejor arquitectura, era imprescindible contar con un corpus alineado utilizable y un procedimiento reproducible para entrenar y medir (Galarreta, 2017). Estas lecciones sugieren que, en shiwilu, no hay atajos de ingeniería: sin un primer corpus paralelo confiable y criterios de evaluación claros, cualquier intento de traducción neuronal carecerá de base metodológica y relevancia práctica (Meque et al., 2023).


En síntesis, la problemática que aborda esta tesis es multidimensional. En el plano técnico, falta el insumo esencial: un corpus paralelo validado; como consecuencia, faltan baselines y protocolos de evaluación adaptados al par shiwilu–castellano. En el plano lingüístico, la asimetría tipológica y la carga cultural de numerosos términos exigen datos cuidadosamente curados y verificación contextual. En el plano social, la escala pequeña y envejecida de la comunidad exige que la construcción de recursos sea participativa, pues solo así se puede procurar que las traducciones sean útiles y respetuosas (UNESCO, 2023). Si estos factores no se atienden, el shiwilu seguirá teniendo poca presencia en el ecosistema digital, con efectos sobre su aprendizaje, su circulación escrita y su presencia simbólica en la esfera pública.

Este diagnóstico delimita el núcleo del problema: sin corpus paralelo validado, sin baselines y sin un esquema de verificación que combine métricas automáticas con revisión por hablantes, no es posible avanzar con rigor hacia un traductor neuronal shiwilu↔castellano. Por ello, esta investigación toma como punto de partida la construcción y depuración de datos bilingües con apoyo comunitario, junto con la definición de criterios evaluativos reproducibles que permitan situar cualquier resultado en un baseline claro. Solo sobre ese cimiento resulta razonable explorar y comparar arquitecturas, estrategias de transferencia y futuros incrementos de datos. Atender esta problemática no solo cubre un vacío científico en la traducción automática de lenguas peruanas de muy bajo recurso; también supone un paso concreto para que el shiwilu tenga presencia en la esfera tecnológica contemporánea (UNESCO, 2023; Valenzuela, 2018).

1.1.1 Árbol de Problemas

La Figura 1.1 resume la problemática central, las causas consideradas y las consecuencias asociadas.

Figura 1.1: Árbol de Problemas



1.1.2 Causas

Las causas y consecuencias siguientes sintetizan el diagnóstico sociolingüístico y técnico presentado en la problemática: la condición crítica del shiwilu y su baja presencia digital (UNESCO, 2023; Valenzuela, 2018), junto con la escasez de recursos paralelos y la necesidad de evaluación reproducible en traducción automática de bajo recurso (Koehn & Knowles, 2017; Mager & Meza, 2018).

Inexistencia de un corpus paralelo shiwilu–castellano adecuado. Los textos disponibles son escasos, dispersos y con variaciones ortográficas y de dominio que dificultan su aprovechamiento. Falta alineación fiable a nivel de oración, hay ruido (traducciones parciales, glosas, duplicados) y metadatos incompletos. Además, no existen particiones estandarizadas de entre-

namiento/validación/prueba que permitan comparaciones justas y reproducibles.

Investigación limitada y falta de baselines adaptados al par shiwilu–castellano. Hay pocos estudios específicos y no se cuenta con baselines consensuados (configuraciones mínimas, tokenización/segmentación apropiada o variantes multilingües razonables). Esta carencia impide medir avances con rigor, aislar el impacto de cada técnica y evitar conclusiones sesgadas por configuraciones ad-hoc.

Falta de métodos comparativos en línea para probar y contrastar modelos NMT. No existe una interfaz accesible que permita evaluar modelos lado a lado, registrar métricas y recopilar ejemplos de uso real de forma ágil. Sin pruebas comparativas en un entorno web, se ralentiza el ciclo de retroalimentación, se dificulta la trazabilidad de cambios y se limita la participación de docentes e integrantes de la comunidad.

Protocolos combinados de validación automatizada y participativa insuficientes. Predomina el uso de métricas automáticas generales que no capturan adecuación, naturalidad ni pertinencia cultural. Faltan guías, instrumentos y criterios para integrar la revisión de hablantes (escalas, rúbricas, taxonomías de error, control de acuerdo inter-anotador), lo que genera evaluaciones incompletas y poco accionables.

1.1.3 Consecuencias

Modelos con precisión insuficiente en usos reales. Las salidas presentan errores léxicos y morfosintácticos, inestabilidad ante variantes ortográficas y pérdida de sentido en dominios no vistos. Esto reduce la confianza de usuarios y docentes, eleva el costo de posesición y limita la adopción del traductor en tareas cotidianas (material educativo, comunicaciones comunitarias, trámites), dejando el sistema como un prototipo poco útil fuera del laboratorio.

Escasez de materiales bilingües para enseñanza y uso práctico. La falta de recursos paralelos limpios y actualizados impide generar textos, ejercicios y guías bilingües con progresión pedagógica. Se restringen las oportunidades de lectura y escritura en shiwilu con apoyo del castellano, y se dificulta producir contenidos para contextos reales (salud, servicios públicos, señalética), perpetuando la dependencia de materiales aislados o desactualizados.

Menor visibilidad digital y dificultad en la revitalización. La baja disponibilidad de herramientas y contenidos en línea reduce la presencia del shiwilu en buscadores, plataformas y aplicaciones, desincentivando la participación de jóvenes y hablantes potenciales. Esto crea un círculo vicioso: menor uso genera menos datos y menos innovación, lo que a su vez limita el apoyo institucional y la colaboración con otras comunidades y actores tecnológicos.

1.1.4 Problema seleccionado

Dificultad para que nuevos hablantes aprendan, interioricen y usen cotidianamente la lengua shiwilu, por la limitada disponibilidad de recursos bilingües, herramientas y evaluaciones pertinentes.

1.2 Objetivos

1.2.1 Objetivo general

Mejorar la capacidad de nuevos hablantes para aprender e interiorizar la lengua shiwilu mediante el desarrollo de un sistema de traducción automática neuronal shiwilu↔castellano, sustentado en un corpus paralelo, protocolos de evaluación automática-participativa y un prototipo funcional para su uso en contextos reales.

1.2.2 Objetivos específicos

- 1. Recopilar y alinear un corpus paralelo shiwilu–castellano y producir particiones reproducibles para entrenamiento, validación y prueba.**
- **Alcance de fuentes:** delimitar criterios de inclusión y priorizar materiales comunitarios, educativos y documentales.
 - **Alineación a nivel de oración:** segmentar, normalizar variantes ortográficas y sincronizar pares con apoyo de herramientas.
 - **Reproducibilidad:** definir reglas para train/valid/test, con bitácora del preprocesamiento.

2. **Implementar y validar un modelo de traducción automática neuronal bidireccional (shiwilu↔castellano).**

- **Arquitectura y tokenización:** seleccionar un esquema adecuado a bajo recurso y fijar parámetros de segmentación.
- **Control experimental:** documentar configuraciones e hiperparámetros para asegurar replicabilidad.

3. **Definir y aplicar una primera ejecución de un protocolo de validación que combine evaluación automática y validación participativa con hablantes para medir adecuación lingüística y pertinencia cultural.**

- **Métricas automáticas:** seleccionar indicadores (p. ej., BLEU/chrF/COMET) y su procedimiento de cálculo.
- **Evaluación con hablantes:** diseñar instrumentos con rúbricas de adecuación, fluidez y pertinencia cultural.
- **Confiabilidad:** establecer muestreo, instrucciones de anotación y medición de consistencia entre evaluadores.

4. **Diseñar e implementar un prototipo funcional de traductor automático neuronal que integre el modelo entrenado y facilite su uso y prueba.**

- **Funcionalidad mínima:** ingreso de texto y visualización de resultados de forma simple y accesible.
- **Pruebas y registro:** habilitar pruebas básicas y registro estructurado de entradas/salidas para análisis.
- **Integración y despliegue:** empaquetar el modelo y la interfaz en un entorno ejecutable

1.2.3 Resultados esperados

- O1:
 - R1: Corpus paralelo shiwilu–castellano depurado, alineado, caracterizado y particionado reproduciblemente.
 - R2: Modelo de *embeddings* preparado.
- O2:
 - R3: Modelo de traducción automático shiwilu->castellano entrenado.
 - R4: Modelo de traducción automático castellano->shiwilu entrenado.
- O3:
 - R5: Protocolo de validación documentado y aplicado en una primera ejecución participativa (métricas automáticas, instrumentos, rúbricas y resultados humanos agregados).
- O4:
 - R6: Prototipo funcional ejecutable localmente que integra el modelo NMT y permite pruebas básicas con registro estructurado de entradas y salidas.
 - R7: Documento de proceso para la validación con pruebas de experto.
 - R8: Ejecución inicial del proceso de validación con revisor competente y consolidación de resultados humanos agregados.

1.2.4 Mapeo de objetivos, resultados y verificación

Para cada uno de los objetivos planteados, se plantearon los siguientes resultados esperados en esta Tabla 1.

Tabla 1.1: Resultados esperados (mapeo de objetivos, MV e IOV)

Objetivo	Resultados asociados	Medio de verificación (MV)	Indicador objetivamente verificable (IOV)
O1: Recopilar y alinear un corpus paralelo shiwilu–castellano y producir particiones reproducibles.	R1: Corpus depurado y alineado. R2: Modelo de <i>embeddings</i> preparado.	MV1: Informe breve de criterios de selección, normalización y alineación aplicadas. MV2: Entregable del modelo de embeddings	IOV1: Procedimiento descrito y aplicado. IOV2: Datos obtenidos del modelo de <i>embeddings</i>
O2: Implementar y validar un modelo NMT bidireccional (shiwilu↔castellano).	R3: Modelo shiwilu→castellano R4: Modelo castellano→shiwilu.	MV3: Descripción del pipeline de entrenamiento y configuraciones probadas. MV4: Reporte de evaluación automática en valid/test. MV5: Protocolo documentado que integra evaluación automática, muestreo participativo, rúbrica, plantilla de revisión y resultados humanos consolidados.	IOV3: Entrenamientos completados en ambas direcciones. IOV4: Métricas BLEU/chrF presentadas.
O3: Definir y aplicar una primera ejecución de un protocolo de validación que combine evaluación automática y participativa.	R5: Protocolo de validación documentado y aplicado en una primera ejecución participativa (métricas, instrumentos, rúbricas y resultados humanos agregados).		IOV5: Métricas automáticas reportadas, muestra acotada revisada y promedios humanos por dirección consolidados.
O4: Diseñar e implementar un prototipo funcional de traductor NMT que facilite su uso y prueba.	R6: Prototipo funcional ejecutable localmente que integra el modelo NMT y permite pruebas básicas con registro estructurado de entradas y salidas. R7: Documento de proceso para pruebas de experto R8: Proceso de validación con experto ejecutado inicialmente y documentado como evidencia reproducible.	MV6: Prototipo operativo (interfaz web ejecutable localmente) con guía breve de uso y registro estructurado de uso.	IOV6: Demostración de traducción de ejemplos en ambas direcciones, registro de casos de prueba ejecutado y evidencia de la primera validación participativa.

1.3 Métodos y Procedimientos

A continuación se describen las herramientas, métodos, enfoques y procedimientos previstos para alcanzar los resultados del proyecto. La síntesis se presenta en la Tabla 1.2.

Tabla 1.2: Herramientas, métodos y procedimientos a utilizar

Resultados Esperados	Herramientas (H), Métodos (M) y Procedimientos (P)
R1: Corpus shiwilu–castellano preprocesado y alineado.	H: Python, regex, tokenizador. M: Limpieza, segmentación, alineación. P: Criterios→limpieza/segmentación→alineación→bitácora.
R2: Modelo de embeddings preparado.	H: Python, E5/Sentence-Transformers (o LASER), FAISS/índice vectorial. M: Embeddings oracionales; similitud y umbral.
R3: NMT shiwilu→castellano entrenado.	H: Python, PyTorch (Transformers) o TensorFlow; SentencePiece. M: Entrenamiento supervisado NMT; subword; evaluación BLEU/chrF.
R4: NMT castellano→shiwilu entrenado.	P: Particionar→entrenar→validar→métricas. H: Python, PyTorch (Transformers) o TensorFlow; SentencePiece. M: Mismo esquema que R3 en dirección inversa.
R5: Protocolo de validación documentado y aplicado inicialmente.	P: Repetir pipeline→consolidar métricas. H: Procesador de texto; formularios/hojas. M: Rúbricas (sentido, naturalidad, decisión); muestreo balanceado; consolidación de resultados.
R6: Prototipo local funcional implementado (UI simple).	H: Python, PyTorch; Gradio; logs. P: UI→cargar checkpoint→traducir→registrar.
R7: Documento de proceso para pruebas de experto.	M: Plantilla de acta y checklist; versionado. P: Formato→checklist→evidencias→archivo.
R8: Validación con experto ejecutada inicialmente.	M: Aplicación del protocolo; consolidación de puntajes y observaciones. P: Revisión→consolidado→síntesis→mejoras.

1.3.1 Herramientas

1.3.2 Justificación

La selección de herramientas responde a la necesidad de implementar un flujo compacto y reproducible para traducción automática shiwilu↔castellano en un contexto de bajo recurso. Python se adopta como lenguaje de orquestación por su ecosistema maduro y por la facilidad que ofrece

para controlar versiones, semillas y configuraciones a lo largo del proceso.

En la preparación del corpus (R1) se emplean expresiones regulares y un tokenizador básico para limpieza, segmentación y alineación con reglas simples de longitud y puntuación, manteniendo una bitácora que documenta criterios y transformaciones. Para la representación semántica y el filtrado (R2) se utilizan *embeddings* oracionales generados con modelos de la familia E5/Sentence-Transformers (Reimers & Gurevych, 2019; L. Wang et al., 2022) y un índice vectorial FAISS (Johnson et al., 2019), lo que permite estimar similitudes, fijar umbrales operativos, detectar *outliers* y priorizar pares útiles antes del modelado.

El modelado NMT bidireccional (R3–R4) se realiza con marcos de aprendizaje profundo de la familia Transformers y segmentación en subpalabras mediante SentencePiece, con el objetivo de reducir OOV y estabilizar el vocabulario en ambas direcciones (Kudo & Richardson, 2018). El entrenamiento se conduce bajo control experimental (semillas, *checkpoints* y configuraciones registradas) y se evalúa con métricas reproducibles (BLEU y chrF++), de modo que los modelos y corridas puedan compararse de forma consistente (Papineni et al., 2002; Popović, 2015).

Para la verificación práctica (R6) se implementó un prototipo local con Gradio, con interfaz mínima de entrada, traducción y salida, y registro estructurado de entradas y salidas para análisis posterior. La validación participativa se define en R5 como protocolo, formularios y hojas de cálculo, apoyada en rúbricas de sentido, naturalidad y decisión; su primera ejecución con revisor competente y la consolidación de resultados asociados a R7–R8 quedan incorporadas como evidencia del proyecto.

En conjunto, estas herramientas sostienen cuatro principios operativos: calidad de datos (regex, tokenizador, embeddings e índice), robustez del modelo (SentencePiece y marcos de aprendizaje profundo), evaluación reproducible (BLEU/chrF++) y proyección práctica del sistema (prototipo local y validación experta).

1.3.3 Detalle

– **Python:** Orquestación del pipeline de preprocesamiento, entrenamiento, evaluación y prototipado; control de semillas, versiones y configuraciones.

- **Expresiones regulares (regex):** Limpieza y normalización de texto (tildes, signos, espacios, duplicados) previas a la segmentación y alineación; soporte a la bitácora de decisiones.
- **Tokenizador:** Segmentación inicial de oraciones y palabras; generación de conteos (tokens, tipos, OOV) para trazabilidad del corpus paralelo.
- **E5 / Sentence-Transformers (o LASER):** Embeddings oracionales para medir similitud semántica, detectar outliers y priorizar material útil en bajo recurso.
- **FAISS / índice vectorial:** Búsqueda eficiente en el espacio de embeddings y aplicación de umbrales para filtrado y control de calidad.
- **SentencePiece:** Segmentación en subpalabras (BPE/unigram) para reducir OOV y estabilizar el vocabulario en shiwilu↔castellano.
- **PyTorch / TensorFlow (Transformers):** Entrenamiento NMT bidireccional con registro de hiperparámetros, checkpoints y configuraciones reproducibles.
- **sacreBLEU:** Cálculo estandarizado de BLEU en validación y prueba con parámetros fijados para asegurar comparabilidad.
- **chrF++:** Métrica complementaria basada en caracteres y palabras, adecuada para morfología rica en escenarios de bajo recurso.
- **Gradio / Streamlit:** Prototipo local con interfaz mínima (entrada → traducción → salida) y registro estructurado de casos para análisis posterior.
- **Formularios y hojas de cálculo:** Instrumentos para rúbricas, actas y consolidación de resultados en la validación con expertos (componentes cuantitativos y cualitativos).

1.3.4 Métodos

• Data augmentation

Generación de datos sintéticos (p. ej., sinónimos controlados, back-translation, interpolación en el espacio latente) para robustecer el entrenamiento, mejorar la cobertura y mitigar el sobreajuste en bajo recurso.

- **Proceso KDD**

Marco de descubrimiento de conocimiento que estructura el pipeline en selección, preprocesamiento, transformación y análisis exploratorio, asegurando orden, trazabilidad y criterios reproducibles.

- **Tokenización subword (BPE/unigram)**

Segmentación en subpalabras con SentencePiece para estabilizar el vocabulario y reducir OOV en lenguas de bajo recurso, manteniendo compatibilidad en ambas direcciones de traducción.

- **Alineación paralela**

Uso combinado de herramientas automáticas (p. ej., *awesome-align*) y reglas lingüísticas simples (longitud, puntuación) para obtener alineaciones consistentes entre textos fuente y destino.

- **Evaluación A/B con bootstrapping**

Contraste de métricas automáticas (p. ej., BLEU, chrF++) mediante re-muestreo para estimar variabilidad y significancia de diferencias entre configuraciones o modelos.

- **Automatización de pipelines**

Orquestación de entrenamientos, evaluaciones y registros con scripts o DAG ligeros, fijando semillas y configuraciones para garantizar reproducibilidad y auditoría de experimentos.

1.3.5 Procedimientos

- **Revisión humana y refinamiento**

Evaluación muestral por hablantes nativos en coherencia, fluidez y fidelidad; consolidación de medidas descriptivas y ajuste iterativo de reglas de limpieza, alineación y generación sintética.

- **Verificación de calidad léxica (OOV)**

Comparación de vocabularios del corpus original y del sintético para estimar la proporción de tokens fuera de vocabulario; si se supera el umbral definido, se reajustan tokenización, filtrado y estrategias de expansión de datos.

- **Selección de checkpoint y control experimental**

Registro de configuraciones e hiperparámetros; elección del mejor checkpoint según validación; almacenamiento de bitácoras y métricas para comparación entre corridas.

- **Registro estructurado y trazabilidad**

Conservación de entradas y salidas, versiones de datos, semillas y resultados en repositorio organizado, facilitando replicación, auditoría y análisis posterior.

Capítulo 2

Marco Conceptual

2.1 Introducción

A continuación se presenta una síntesis de los fundamentos teóricos necesarios para comprender la problemática y las decisiones metodológicas de la tesis. El capítulo reúne conceptos de procesamiento de lenguaje natural, traducción automática neuronal, lenguas de bajo recurso, tokenización, aumento de datos, transferencia, adaptación eficiente, representaciones vectoriales y métricas de evaluación. El propósito es ofrecer un marco conceptual claro, suficiente para seguir el desarrollo experimental y la interpretación de los resultados.

2.2 Desarrollo del marco

El objetivo principal del marco conceptual es reunir y definir de forma precisa los conceptos, técnicas y herramientas que se utilizarán en la tesis, de modo que quede explícito el conocimiento necesario para comprender el problema y las soluciones propuestas. Este bloque conceptual proporciona el vocabulario técnico común para el trabajo, articula las nociones que sustentan los procedimientos experimentales y sirve de referencia para la interpretación de los resultados.

2.2.1 Procesamiento de Lenguaje Natural (NLP)

El Procesamiento de Lenguaje Natural (PLN) es la disciplina interdisciplinaria que combina informática, inteligencia artificial y lingüística para permitir que las máquinas analicen, interpreten y generen lenguaje humano de forma automática; abarca tareas que van desde la segmentación y el etiquetado morfosintáctico hasta la representación semántica y la generación de texto (Chowdhury, 2003).

A nivel conceptual, el PLN transforma texto bruto en representaciones manipulables (tokens, subpalabras, vectores/embeddings) y aplica modelos estadísticos o neuronales para aprender patrones lingüísticos: las etapas típicas son preprocesamiento → representación → modelado → evaluación. En la última década, los enfoques basados en aprendizaje profundo (p. ej. redes neuronales profundas y arquitecturas de atención Bahdanau et al., 2015) han pasado a ser el centro del PLN por su capacidad para aprender jerarquías de representaciones directamente de los datos (Socher & Manning, 2013).

2.2.2 Lenguas de muy bajos recursos (LRL)

Las lenguas de muy bajos recursos (Low-Resource Languages, LRL) son aquellas para las cuales existe una cantidad muy limitada de datos digitales, y en particular de corpus paralelos (fuente–meta) suficientes para entrenar modelos estadísticos o neuronales con buen desempeño. Esta condición incluye no solo la escasez numérica de ejemplos paralelos, sino también problemas asociados como dominio sesgado, variación ortográfica, ausencia de anotaciones lingüísticas y poca disponibilidad de textos monolingües de calidad (Koehn & Knowles, 2017; Zoph et al., 2016).

La escasez de datos reduce la capacidad de aprendizaje y la generalización de modelos NMT, incrementa el riesgo de overfitting y disminuye la cobertura léxica y contextual del sistema. Conceptualmente, las LRL requieren estrategias que compensen la falta de paralelo, por ejemplo, transferencia desde modelos preentrenados, aumento de datos o minería de paralelo comparable y una mayor atención a la normalización y validación lingüística para asegurar que los ejemplos disponibles representen adecuadamente las variantes del habla (Artetxe & Schwenk, 2019).

2.2.3 Alineación oración a oración

La alineación oración a oración consiste en emparejar oraciones equivalentes en dos lenguas para convertir colecciones comparables en pares fuente y meta utilizables por sistemas de traducción. En la práctica, este proceso combina heurísticas simples, por ejemplo reglas basadas en la longitud relativa de los segmentos, con métodos estadísticos o neuronales que explotan señales léxicas, sintácticas y contextuales (Gale & Church, 1993). Asimismo, es habitual com-

plementar las salidas automáticas con reglas lingüísticas o validación humana para reducir el ruido. Las correspondencias resultantes pueden ser uno a uno, uno a muchos o muchos a uno. La calidad de estas alineaciones puede medirse mediante indicadores como la precisión y la tasa de pares falsos, y condiciona directamente la utilidad del corpus: las alineaciones defectuosas introducen ruido que degrada el aprendizaje del modelo, mientras que las alineaciones limpias incrementan la señal supervisada disponible, lo cual es especialmente crítico en pares de muy bajos recursos. Las herramientas automáticas modernas, como los alineadores neuronales que emplean representaciones contextualizadas, facilitan la extracción de paralelo; aun así, en todos los casos es necesario aplicar criterios de filtrado y verificación para garantizar la coherencia temática y la trazabilidad de los pares (Artetxe & Schwenk, 2019; Koehn & Knowles, 2017).

2.2.4 Preprocesamiento y tokenización en subpalabras

El preprocesamiento agrupa las operaciones de limpieza y normalización del texto que convierten el material bruto en unidades coherentes y comparables para el modelado. Conceptualmente incluye la normalización de codificación (por ejemplo, normalización Unicode), la limpieza de ruido (eliminación o corrección de caracteres inválidos, marcas de formato o duplicados), la segmentación en oraciones y la normalización ortográfica mínima (p. ej., manejo de mayúsculas/minúsculas, tratamiento de signos de puntuación y variantes tipográficas). Estas transformaciones tienen por objeto reducir la varianza superficial del corpus y hacer que las señales lingüísticas que aprenden los modelos sean más estables y comparables entre fuentes heterogéneas (Koehn & Knowles, 2017; Kudo & Richardson, 2018).

La tokenización en subpalabras divide las unidades léxicas en fragmentos más pequeños aprendidos a partir del propio corpus, con el fin de reducir el problema de palabras fuera de vocabulario y capturar elementos morfológicos productivos. Técnicamente, los métodos más usados son BPE (Byte Pair Encoding) y los modelos de unigram / SentencePiece, que construyen vocabularios de subunidades optimizando una medida de compactación o probabilidad sobre el corpus (Kudo & Richardson, 2018; Sennrich et al., 2016). A nivel conceptual, elegir una tokenización en subpalabras implica un compromiso entre tamaño del vocabulario y granularidad de las piezas: vocabularios más grandes reducen la fragmentación pero aumentan la dimensiona-

lidad; vocabularios más pequeños incrementan la capacidad de representar formas novedosas mediante composiciones de subunidades.

Para pares con variación ortográfica o riqueza morfológica, como el caso shiwilu–castellano, la tokenización en subpalabras facilita que las formas derivadas y las variantes ortográficas compartan representaciones parciales, mejorando la generalización del modelo frente a formas raras. Asimismo, conviene documentar las decisiones de tokenización (tipo de algoritmo y tamaño del vocabulario) porque influyen en la distribución de los tokens y, por ende, en el comportamiento de las métricas de evaluación (Kudo & Richardson, 2018; Sennrich et al., 2016).

2.2.5 Aumento de datos (*data augmentation*)

El aumento de datos agrupa técnicas destinadas a generar ejemplos sintéticos a partir del material disponible para ampliar la cobertura léxica y contextual del conjunto de entrenamiento. Conceptualmente, estas técnicas buscan introducir variación útil que actúe como regularizador del modelo y que permita que patrones raros o formas morfológicas poco frecuentes sean vistos durante el aprendizaje. Entre los métodos más usados en traducción automática se encuentran la retrotraducción (back-translation), el parafraseo y las operaciones de modificación léxica sencillas, como la sustitución de sinónimos o la técnica EDA (Easy Data Augmentation) (Sennrich et al., 2016; Wei & Zou, 2019).

La retrotraducción consiste en entrenar un sistema de traducción en la dirección meta→fuente con datos disponibles y luego traducir grandes cantidades de texto monolingüe en la lengua meta para producir pares sintéticos fuente–meta que se incorporan al entrenamiento (Edunov et al., 2018; Sennrich et al., 2016). El parafraseo y las operaciones basadas en sinónimos generan alternativas al mismo significado en la lengua fuente o meta, aumentando la diversidad léxica sin requerir nueva anotación humana (Wei & Zou, 2019). Desde un punto de vista teórico, estos procedimientos incrementan la densidad de la señal de entrenamiento y reducen el sobreajuste en escenarios con poco paralelo, aunque su efectividad depende de la calidad del modelo que genera los ejemplos sintéticos y del control del ruido introducido.

No obstante, el aumento de datos implica riesgos conceptuales importantes: la introducción

de pares sintéticos de baja calidad puede sesgar al modelo hacia errores sistemáticos, producir efectos de dominio no deseados o reforzar traducciones incorrectas si el generador es débil. Por ello, conceptualmente es crucial aplicar criterios de filtrado y estimación de confianza sobre los ejemplos sintéticos, por ejemplo mediante puntuaciones de calidad automáticas o umbrales de similitud semántica, y considerar la composición equilibrada entre datos auténticos y sintéticos para evitar diluir la señal real (Edunov et al., 2018; Fadaee et al., 2017).

2.2.6 Transfer learning y modelos multilingües

El *transfer learning* en PLN se refiere al uso de modelos preentrenados o a la transferencia de parámetros aprendidos en una tarea o idioma fuente para mejorar el rendimiento en otra tarea o en un idioma con pocos datos. En el contexto de NMT esto puede materializarse como preentrenamiento en grandes colecciones monolingües o paralelas en idiomas con abundante recurso y posterior ajuste fino (fine-tuning) sobre el par objetivo, o bien como entrenamiento multilingüe conjunto donde un único modelo aprende a traducir múltiples idiomas compartiendo representaciones (Zoph et al., 2016). Los modelos multilingües preentrenados (p. ej. mBART, NLLB) explotan señales cruzadas entre lenguas para aprender embeddings y transformaciones transferibles que benefician a los pares de muy bajos recursos al proporcionar una representación inicial más informativa que el entrenamiento desde cero (Y. Liu et al., 2020; NLLB Team et al., 2022).

Estas estrategias reducen la dependencia de grandes *corpus* paralelos para el par objetivo y permiten aprovechar patrones tipológicos o léxico-semánticos compartidos entre idiomas. Sin embargo, la transferencia también puede introducir sesgos si los idiomas de preentrenamiento dominan al par objetivo, fenómeno conocido como *interferencia*, o si los dominios y estilos difieren notablemente. Por ello, conviene distinguir entre transferencia beneficiosa, cuando existe suficiente semejanza tipológica o alguna forma lingüística compartida, y transferencia nociva, cuando el conocimiento transferido introduce ruido o favorece patrones ajenos al par objetivo. En resumen, transfer learning y modelos multilingües constituyen una palanca teórica y práctica central para abordar la escasez de datos en shiwilu–castellano, siempre que se consideren cuidadosamente las condiciones de similitud lingüística y las estrategias para evitar la dominancia

de idiomas mayoritarios (Zoph et al., 2016).

2.2.7 Adaptación eficiente (adapters/LoRA)

Las técnicas de adaptación eficiente buscan ajustar modelos preentrenados grandes añadiendo o entrenando un número reducido de parámetros en lugar de actualizar la totalidad del modelo. Los *adapters* incorporan módulos pequeños entre capas del modelo que se entrenan para la tarea objetivo, manteniendo fijos los pesos base; de este modo se conservan las representaciones generales del preentrenamiento y se reduce el costo de almacenamiento y cómputo para cada adaptación específica (Houlsby et al., 2019). LoRA propone una idea afín desde la perspectiva de factorización de parámetros: en lugar de modificar matrices completas, se aprenden componentes de bajo rango que se suman a las matrices originales, lo que permite una adaptación eficaz con un número significativamente menor de parámetros entrenables (Hu et al., 2022). Conceptualmente, estas técnicas permiten experimentar y desplegar adaptaciones para pares de muy bajos recursos sin incurrir en el coste de reentrenar o almacenar copias completas de modelos muy grandes.

2.2.8 Representaciones vectoriales (embeddings) y minería/filtrado

Los *embeddings* son vectores numéricos que codifican propiedades léxicas y contextuales de palabras, subpalabras, oraciones o documentos, y sirven como base para medir similitud semántica en espacios continuos. En la práctica se usan *embeddings* de oraciones (por ejemplo SBERT o modelos E5) para representar segmentos lingüísticos y comparar su proximidad mediante similitud coseno u otras métricas (Reimers & Gurevych, 2019; L. Wang et al., 2022). La minería de paralelo comparable consiste en buscar en grandes colecciones aquellos pares de segmentos cuya proximidad vectorial sugiere traducción o equivalencia, y la indexación mediante motores de búsqueda vectorial como FAISS permite escalar esta operación a corpus extensos (Artetxe & Schwenk, 2019; Johnson et al., 2019). El filtrado posterior con umbrales de similitud o clasificadores de calidad reduce el ruido y mejora la precisión del paralelo extraído, de modo que conceptualmente la combinación *embedding*+índice vectorial actúa como puente entre textos no alineados y pares útiles para NMT.

2.2.9 BLEU (Bilingual Evaluation Understudy)

Las métricas automáticas constituyen el primer nivel de evaluación de un sistema de traducción y han sido objeto de revisiones sistemáticas que comparan sus fundamentos, supuestos y limitaciones (Lee et al., 2023). BLEU es una métrica automática de evaluación de traducción basada en la coincidencia de n-gramas entre la hipótesis de traducción y una o más referencias. Calcula precisiones modificadas de n-gramas para varios valores de n y combina esas precisiones mediante la media geométrica, aplicando además una penalidad por brevedad para evitar sobrevaloraciones de hipótesis excesivamente cortas; su fórmula formal resume estas componentes en una puntuación entre 0 y 1 generalmente expresada como porcentaje (Papineni et al., 2002). Conceptualmente, BLEU cuantifica la coincidencia léxica y local del orden de tokens, por lo que es sensible a la elección de referencias y no captura directamente sinonimia ni equivalencias reordenadas que no comparten n-gramas con la referencia.

2.2.10 chrF (carácter n-gram F-score)

chrF evalúa la similitud entre hipótesis y referencia a nivel de caracteres mediante n-gramas de caracteres; calcula precisión y recall sobre esos n-gramas y reporta una F-score agregada, pudiendo ponderar recall frente a precisión mediante el parámetro β . Su variante chrF++ incorpora además n-gramas de palabras, lo que añade una señal léxica complementaria sin abandonar la sensibilidad a la forma. Al operar principalmente sobre caracteres, chrF resulta especialmente sensible a semejanzas morfológicas, variaciones ortográficas y segmentos parciales compartidos entre formas derivadas, aspectos que suelen ser relevantes en lenguas con morfología productiva o en corpus con variación ortográfica; por ello, conceptualmente ofrece ventajas sobre métricas puramente basadas en palabras cuando la coincidencia léxica exacta es una medida limitada (Popović, 2015). Esta diferencia tiene una consecuencia práctica para un par como shiwilu–castellano: al traducir hacia el shiwilu, lengua aglutinante, BLEU penaliza con dureza cada palabra cuya forma plena no coincide token a token, por lo que puede subestimar avances reales; chrF++, al puntuar coincidencias parciales de caracteres, conserva señal en esos casos. En cambio, al traducir hacia el castellano BLEU recupera su utilidad como indicador estándar,

dado que el destino no presenta la misma densidad morfológica.

2.2.11 BERTScore y COMET

BERTScore compara tokens de hipótesis y referencia usando embeddings contextuales extraídos de modelos como BERT. Para cada token calcula la máxima similitud con tokens de la otra secuencia y, a partir de esas similitudes, construye medidas de precisión, recall y F1 que reflejan correspondencia semántica token-a-token.

COMET, por su parte, es un marco neuronal que entrena un regresor para predecir una puntuación de calidad en correlación con juicios humanos, utilizando como entradas la fuente, la hipótesis y opcionalmente la referencia. En conjunto, estas métricas representan una transición desde medidas de coincidencia léxica hacia evaluadores que capturan similitud contextual y correlación humana, aunque su fiabilidad depende de los datos con que fueron entrenadas y del dominio al que se aplican (Rei et al., [2020](#); Zhang et al., [2020](#)).

Capítulo 3

Estado del Arte

3.1 Introducción

En este capítulo se presenta la revisión de literatura relacionada con la traducción automática neuronal (NMT) aplicada a lenguas de bajos recursos. Se revisan enfoques, técnicas y experiencias previas en escenarios similares, con el fin de identificar avances, limitaciones y oportunidades de investigación pertinentes para el caso de la lengua shiwilu.

3.2 Objetivos de revisión

- Identificación de métodos y estrategias: clasificar y comparar las técnicas más utilizadas en traducción automática neuronal para lenguas de bajos recursos (back-translation, transfer learning, sistemas encoder-decoder, data augmentation, zero-shot, few-shot, etc.).
- Integración de bases de conocimiento externas: revisar modelos híbridos que incorporan ontologías, WordNets o Knowledge Base (KB) en los flujos de pre- y post-procesamiento de MT/NMT, considerando posibles mejoras en cobertura léxica, desambiguación y coherencia semántica para lenguas indígenas.
- Análisis de métricas de evaluación: sintetizar el funcionamiento de BLEU y chrF++, evaluar su sensibilidad ante la variabilidad introducida por datos sintéticos, y revisar protocolos de comparación con evaluaciones humanas.

3.3 Preguntas de revisión

- P1. ¿Qué técnicas de generación y ampliación de datos (back-translation, mutación semántica, paraphrasing, pivoting, filtrado por embeddings, etc.) producen mejoras reproducibles en NMT para pares de muy bajos recursos?
- P2. ¿Qué arquitecturas y estrategias de entrenamiento (multilingüe, transfer learning, fine-tuning bidireccional, adapters, few/zero-shot) ofrecen el mejor balance entre rendimiento y coste computacional para un modelo shiwilu $\leftrightarrow$ castellano, y qué baselines son apropiados para la comparación?
- P3. ¿Qué métricas automáticas (BLEU, chrF++, TER u otras) y procedimientos de validación combinada (evaluación automática + pruebas participativas con hablantes) son más adecuados y fiables para medir adecuación lingüística y pertinencia cultural en traducciones de lenguas originarias con corpus escaso?

3.4 Estrategia de búsqueda

3.4.1 Motores de búsqueda utilizados

Scopus

- Es una base bibliográfica multidisciplinaria que agrega resúmenes y citas de artículos, actas y capítulos revisados por pares.
- Su cobertura y metadatos permiten identificar tendencias, estudios empíricos y comparativas relevantes en NMT y técnicas de aumento de datos.
- Proporciona métricas bibliométricas útiles para priorizar lecturas y fundamentar la selección de trabajos clave.

IEEE Xplore

- Es una biblioteca digital orientada a la ingeniería y las ciencias de la computación, con énfasis en documentación experimental y detalles de implementación.
- Incluye artículos y actas que describen configuraciones experimentales, métricas de rendimiento y optimizaciones prácticas aplicables a sistemas de traducción.
- Ofrece evidencia técnica valiosa para la definición de parámetros experimentales y criterios de evaluación reproducibles.

ACL Anthology

- Es un repositorio especializado en lingüística computacional y procesamiento de lenguaje natural que reúne actas y trabajos de la comunidad NLP (ACL, EMNLP, WMT, LREC, workshops).
- En este repositorio no siempre es posible reproducir las cadenas de búsqueda con la misma sintaxis usada en Scopus o IEEE Xplore; por ello, la consulta se ajusta manualmente y se usa como respaldo técnico de las dos fuentes principales.
- Contiene investigaciones de vanguardia en NMT, evaluación y recursos para lenguas de bajos recursos, con frecuencia acompañadas de código y datos.

3.4.2 Cadenas de búsqueda utilizadas

Cadena 1 (C1) – Generación y ampliación de datos sintéticos

El objetivo de esta cadena es recuperar trabajos sobre técnicas de data augmentation aplicadas a NMT (back-translation, paraphrasing, synthetic data, filtering) y estudios que midan su efecto en pares de muy bajos recursos.

Scopus:

TITLE-ABS-KEY(("data augmentation" OR "synthetic data" OR "back-translation" OR backtranslation OR "paraphrase" OR "paraphrasing" OR "synthetic pivot" OR "data synthesis" OR "data augmentation techniques") AND ("neural machine translation" OR

"NMT" OR "machine translation") AND ("low-resource" OR "low resource" OR "under-resourced" OR "minority language" OR "indigenous" OR "endangered language")) AND NOT("image" OR "images" OR "computer vision" OR "audio" OR "speech") AND (PUBYEAR > 2018 AND PUBYEAR < 2026) AND SUBJAREA(COMP)

IEEE Xplore:

("data augmentation" OR "synthetic data" OR "back-translation" OR backtranslation OR "paraphrase" OR "paraphrasing" OR "synthetic pivot" OR "data synthesis") AND ("neural machine translation" OR "NMT" OR "machine translation") AND ("low-resource" OR "low resource" OR "under-resourced" OR "minority language" OR "indigenous" OR "endangered language")

Cadena 2 (C2) – Arquitecturas y estrategias de entrenamiento para pares muy escasos

El objetivo de esta cadena es recuperar trabajos sobre arquitecturas y estrategias de entrenamiento adecuadas para pares con datos mínimos (transfer learning, fine-tuning bidireccional, modelos multilingües y preentrenados, adapters, enfoques few/zero-shot y técnicas de ajuste de parámetros).

Scopus:

TITLE-ABS-KEY(("transfer learning" OR "fine-tuning" OR "fine tuning" OR "adapters" OR "adapter modules" OR "multilingual" OR "multilingual models" OR "few-shot" OR "few shot" OR "zero-shot" OR "zero shot" OR "pre-trained" OR "pretrained" OR "transformer" OR "mBART" OR "mT5") AND ("neural machine translation" OR "NMT" OR "machine translation") AND ("low-resource" OR "low resource" OR "small dataset" OR "under-resourced" OR "minority language")) AND NOT("image" OR "images" OR "computer vision" OR "audio" OR "speech") AND (PUBYEAR > 2018 AND PUBYEAR < 2026) AND SUBJAREA(COMP)

IEEE Xplore:

("transfer learning" OR "fine-tuning" OR "fine tuning" OR "adapters" OR "multilingual" OR "few-shot" OR "few shot" OR "zero-shot" OR "zero shot" OR "pre-trained" OR "pre-

trained" OR "transformer") AND ("neural machine translation" OR "NMT" OR "machine translation") AND ("low-resource" OR "low resource" OR "small dataset" OR "under-resourced") AND NOT ("image" OR "images" OR "computer vision" OR "audio" OR "speech")

Cadena 3 (C3) – Evaluación automática y participativa; métricas y protocolos

El objetivo de esta cadena es identificar métricas automáticas y protocolos de evaluación, así como estudios sobre evaluación participativa (human evaluation, adequacy, acceptability, community/participatory evaluation), y trabajos que analicen la sensibilidad de métricas a la presencia de datos sintéticos.

Scopus:

TITLE-ABS-KEY (("BLEU" OR "ChrF" OR "ChrF++" OR "TER" OR "METEOR" OR "automatic evaluation" OR "evaluation metric" OR "evaluation metrics" OR "human evaluation" OR "participatory evaluation" OR "community evaluation" OR "adequacy" OR "acceptability")) AND ("machine translation" OR "neural machine translation" OR "NMT") AND ("low-resource" OR "low resource" OR "indigenous" OR "small dataset")) AND NOT ("image" OR "audio" OR "speech") AND (PUBYEAR > 2018 AND PUBYEAR < 2026) AND SUBJAREA(COMP)

IEEE Xplore:

("BLEU" OR "ChrF" OR "ChrF++" OR "TER" OR "METEOR" OR "automatic evaluation" OR "evaluation metric" OR "human evaluation" OR "participatory evaluation" OR "community evaluation" OR "adequacy" OR "acceptability") AND ("machine translation" OR "neural machine translation" OR "NMT") AND ("low-resource" OR "low resource" OR "indigenous" OR "small dataset") AND NOT ("image" OR "audio" OR "speech")

3.4.3 Documentos encontrados

Los resultados obtenidos con las cadenas de búsqueda se presentan en la Tabla 3.1. Dado que las consultas devolvieron una cantidad amplia de artículos, se realizó una revisión preliminar

de títulos y resúmenes para reducir la muestra mediante los criterios de inclusión y exclusión. El resultado de ese filtrado se resume en la Tabla 3.2.

Tabla 3.1: Resultados de búsqueda de las cadenas

Fuente	C1	C2	C3	Cantidad documentos duplicados
Scopus	225	617	425	340
IEEE Xplore	90	352	123	
Total	315	969	548	

Tabla 3.2: Resultados luego de aplicar criterios de exclusión

Preguntas	Artículos por pregunta
P1	50
P2	45
P3	63

3.4.4 Criterios de inclusión/exclusión

- Para inclusión:
 - Artículos publicados entre 2018 y 2025, para asegurar información vigente y actual.
 - Investigaciones que detallen el tratamiento de datos sintéticos y otras alternativas para escenarios con corpus reducido.
 - Artículos revisados por pares.
- Para la exclusión:
 - Artículos con acceso restringido únicamente al resumen.
 - Artículos que no se enfoquen en lenguas de bajos recursos o corpus limitados.
 - Estudios sobre lenguas de pocos recursos abordados desde una perspectiva exclusivamente lingüística y no desde NMT.
 - Publicaciones redundantes, reportes cortos o *position papers*.

3.5 Formulario de extracción de datos

Se desarrolló un formulario de extracción de datos para registrar la información básica de cada estudio y evaluar si respondía a las preguntas de investigación. Los campos se detallan en la Tabla 3.3. Para cada pregunta, se marcó “Sí” cuando el artículo aportaba evidencia directa y “No” cuando no contribuía de forma suficiente al análisis.

Tabla 3.3: Formulario de extracción de datos

Campo	Descripción
DOI	Identificador único del documento
Document Title	Título del estudio
Publication Year	Año de publicación
Abstract	Resumen del documento
Link	Enlace referencial del DOI o fuente consultada
Fuente	Cadena y motor de búsqueda de origen, por ejemplo C1-Scopus o C2-IEEE
¿Qué técnicas de generación y ampliación de datos (back-translation, mutación semántica, paraphrasing, pivoting, filtrado por embeddings, etc.) producen mejoras reproducibles en NMT para pares de muy bajos recursos?	¿El artículo responde a esta pregunta? ¿Sí o no?
¿Qué arquitecturas y estrategias de entrenamiento (multilingüe, transfer learning, fine-tuning bidireccional, adapters, few/zero-shot) ofrecen el mejor balance entre rendimiento y coste computacional para un modelo shiwilu↔castellano, y qué baselines son apropiados para la comparación?	¿El artículo responde a esta pregunta? ¿Sí o no?
¿Qué métricas automáticas (BLEU, chrF++, TER u otras) y procedimientos de validación combinada (evaluación automática + pruebas participativas con hablantes) son más adecuados y fiables para medir adecuación lingüística y pertinencia cultural en traducciones de lenguas originarias con corpus escaso?	¿El artículo responde a esta pregunta? ¿Sí o no?

3.6 Resultados de la revisión

3.6.1 P1. Generación y ampliación de datos

Pregunta de revisión: ¿Qué técnicas de generación y ampliación de datos (back-translation, mutación semántica, paraphrasing, pivoting, filtrado por embeddings, etc.) producen mejoras reproducibles en NMT para pares de muy bajos recursos?

El principal desafío de la traducción automática neuronal (NMT) en escenarios de muy bajos recursos es la escasez de datos paralelos. Sin suficientes ejemplos de entrenamiento, la calidad de las traducciones se ve afectada y, en algunos casos, la NMT pura puede ser superada por métodos estadísticos tradicionales. Para enfrentar esta limitación, la literatura reciente ha propuesto técnicas de generación y ampliación de datos que reportan mejoras en lenguas con baja disponibilidad digital. Entre ellas destacan la retrotraducción, la mutación semántica y el parafraseo, el uso de idiomas pivote y la transferencia multilingüe, el filtrado mediante embeddings, así como la aumentación sintáctica y la obtención activa de nuevos datos. Todas estas aproximaciones buscan enriquecer el entrenamiento con datos adicionales, reales o sintéticos, aunque su efecto depende de la calidad del material generado y de su cercanía con el dominio de uso.

Una de las técnicas más utilizadas es la retrotraducción (back-translation), introducida por Sennrich et al. (2016). El procedimiento consiste en entrenar un modelo inverso con el corpus paralelo reducido y utilizarlo para traducir datos monolingües del idioma meta hacia el idioma fuente, generando pares sintéticos que luego se incorporan al entrenamiento. Esta estrategia ha reportado mejoras en métricas como BLEU y se ha convertido en una práctica frecuente en NMT de bajos recursos. Existen variantes más refinadas, como la retrotraducción selectiva de Luo et al. (2019), que prioriza oraciones con vocabulario poco frecuente, con incrementos en BLEU y reducción del tiempo de entrenamiento.

Otra línea de trabajo es el parafraseo y la mutación semántica del corpus. Fadaee et al. (2017) propusieron insertar palabras raras en contextos nuevos, generando ejemplos adicionales para mejorar la cobertura léxica del modelo. El parafraseo automático, ya sea mediante sinónimos, reformulaciones o traducciones de ida y vuelta, también puede aportar variabilidad útil. Al ex-

poner al sistema a distintas versiones de una misma oración, se fortalece su capacidad de generalización. Aunque los resultados suelen ser más modestos que los obtenidos con retrotraducción, estas técnicas contribuyen a mejorar la robustez de los modelos.

El uso de idiomas pivote y la transferencia multilingüe constituye otra estrategia relevante. Un idioma pivote permite entrenar con corpus paralelo de terceros idiomas o realizar traducción en cascada. Talwar y Laasri (2025) mostraron que el hindi como pivote para la traducción nepalí–inglés duplicó el puntaje BLEU frente a un modelo entrenado solo con corpus directo. En un enfoque complementario, la transferencia multilingüe aprovecha modelos previamente entrenados en pares de mayor recurso para inicializar la traducción en lenguas minoritarias. Montoya et al. (2019) experimentaron con español–shipibo utilizando inicializaciones desde diferentes pares de idiomas y alcanzaron mejoras de hasta 12 puntos BLEU, incluso con pivotes tipológicamente distantes. Estos resultados sugieren que el tamaño y la calidad del corpus pivote pueden pesar tanto como la cercanía lingüística, como también señalaron Kocmi y Bojar (2018).

Las técnicas de filtrado y minería de datos basadas en embeddings son útiles cuando existen corpus comparables o bilingües ruidosos. Herramientas como LASER permiten identificar oraciones semánticamente equivalentes en diferentes idiomas y extraer corpus paralelo oculto (Artetxe & Schwenk, 2019). Chaudhary et al. (2019) demostraron en el Shared Task de WMT que este enfoque elevó los resultados en nepalí–inglés y cingalés–inglés al filtrar millones de pares web y conservar los más consistentes. Además de extraer datos, los embeddings también sirven para depurar traducciones sintéticas, eliminar ejemplos de baja calidad y reforzar la fiabilidad del corpus de entrenamiento.

Otra vertiente prometedora es la aumentación sintáctica. Li et al. (2025) propusieron segmentar oraciones complejas en cláusulas y generar pares adicionales mediante traducción inversa, lo que enriqueció el corpus con ejemplos de menor tamaño pero mayor diversidad estructural. Con este enfoque se lograron mejoras frente a baselines y otros métodos de aumentación. Estrategias similares, como el intercambio de subárboles sintácticos o la recombinación de sujetos y predicados, también han demostrado ampliar la cobertura gramatical en lenguas con recursos escasos.

Finalmente, en escenarios de extrema limitación, la recopilación activa de datos se vuelve fundamental. Montoya et al. (2019) ampliaron el corpus español–shipibo con un conjunto de flashcards bilingües que aportó vocabulario diverso y mejoró la cobertura léxica. También implementaron esquemas de aprendizaje activo y crowdsourcing, presentando oraciones en español a hablantes nativos para obtener traducciones verificadas. De manera paralela, Yamamoto et al. (2023) mostraron cómo aprovechar corpus comparables no paralelos mediante un ciclo iterativo de traducción automática y filtrado, generando datos sintéticos útiles incluso sin textos monolingües extensos en la lengua meta. Estos enfoques resaltan la importancia de combinar la generación de datos con material real recopilado en colaboración con la comunidad.

En conjunto, la evidencia señala que no existe una única solución, sino un conjunto de técnicas complementarias. La retrotraducción explota datos monolingües, el parafraseo introduce variabilidad semántica, los idiomas pivote y la transferencia multilingüe aportan conocimiento desde pares más ricos, los *embeddings* permiten extraer y filtrar corpus adicionales, y la recopilación activa añade datos verificados por hablantes. La combinación de estas estrategias puede mejorar la calidad de la traducción, incluso en contextos con recursos extremadamente limitados, siempre que se controle el ruido y la pertinencia del dominio.

3.6.2 P2. Arquitecturas, entrenamiento y baselines

Pregunta de revisión: ¿Qué arquitecturas y estrategias de entrenamiento (multilingüe, transfer learning, fine-tuning bidireccional, adapters, few/zero-shot) ofrecen el mejor balance entre rendimiento y coste computacional para un modelo shiwilu↔castellano, y qué baselines son apropiados para la comparación?

La evidencia reciente en traducción de muy bajos recursos indica que el mejor compromiso entre rendimiento y coste suele venir de reutilizar modelos multilingües preentrenados y adaptarlos con técnicas de transferencia eficientes, en lugar de entrenar modelos desde cero. Este enfoque puede complementarse con entrenamiento bilingüe bidireccional y módulos de adaptación livianos. Y. Liu et al. (2020) y trabajos posteriores muestran que, frente a corpus mínimos, la reutilización de representaciones previas y la compartición de parámetros entre lenguas elevan la calidad y reducen el coste computacional. De Silva y Hansadi (2024) aportan análisis

comparativos recientes que corroboran este patrón; de forma complementaria, NLLB muestra que el escalamiento multilingüe y el control de datos son centrales para cubrir lenguas con recursos limitados sin entrenar un sistema aislado desde cero para cada par (NLLB Team et al., 2022).

En la práctica, NLLB Team et al. (2022) y otros trabajos documentan que la adaptación de modelos multilingües preentrenados (p. ej., mBART, mT5 o NLLB; Y. Liu et al., 2020; Xue et al., 2021) con unas pocas centenas o miles de pares paralelos suele superar a los modelos bilingües entrenados desde cero, porque aprovecha representaciones de alto nivel y patrones de traducción ya aprendidos en múltiples lenguas. Este enfoque evita el coste del preentrenamiento completo si se limita a un fine-tuning supervisado, aunque puede aparecer interferencia negativa entre idiomas alejados. Para mitigar esa interferencia, Chronopoulou et al. (2023) y Houlsby et al. (2019) han mostrado la eficacia de los adapters basados en familias lingüísticas: estos insertan pequeños bloques entrenables y dejan congelado el resto del modelo, aislando la adaptación por grupos de lenguas. Hu et al. (2022) añade que, con igual cantidad de datos, esta estrategia puede competir con la adaptación plena, reducir el cómputo y facilitar escenarios zero-/few-shot.

El aprendizaje por transferencia continúa siendo el pilar metodológico cuando los datos del par objetivo son exiguos. Kocmi y Bojar (2018) describen el “transfer trivial”, que consiste en inicializar con un par rico y afinar en el par escaso, pero los avances recientes muestran que enriquecer la transferencia con señales léxicas o lingüísticas específicas del idioma minoritario incrementa la ganancia sin elevar en exceso el coste. Maimaiti et al. (2022) destacan que embeddings léxicos preentrenados compartidos entre una lengua padre y la hija mejoran la cobertura de vocabulario poco frecuente sin recurrir a aumentaciones costosas; por su parte, estudios sobre modelado morfológico (Nzeyimana, 2024) indican que la incorporación explícita de información morfológica aporta robustez en lenguas con rica morfología, con ganancias comparables a modelos multilingües a gran escala cuando el paralelo es mínimo.

En contextos como shiwilu↔castellano, donde el monolingüe objetivo es casi inexistente y predominan pares paralelos cortos (p. ej., flashcards), esta transferencia “guiada” resulta especialmente útil: permite aprovechar el castellano como lengua de alto recurso, añadir conocimiento

léxico/morfológico del shiwilu y evitar ciclos de entrenamiento prolongados (Montoya et al., 2019).

Asimismo, el entrenamiento bilingüe bidireccional con un único modelo (shiwilu↔castellano) se ha consolidado como una práctica robusta. Y. Liu et al. (2020) y De Silva y Hansadi (2024) muestran que, al mezclar ambas direcciones y señalar el idioma objetivo con un token, cada par paralelo se aprovecha en las dos direcciones, lo que actúa como regularizador y mejora la consistencia bilingüe con un coste marginal frente a mantener dos modelos unidireccionales. Por ello, el modelo bilingüe bidireccional constituye un baseline fuerte y reproducible en pares muy escasos, sobre todo cuando se combina con transferencia o con un preentrenado multilingüe.

Dentro de las estrategias paramétricas y eficientes en cómputo, Houlsby et al. (2019), Hu et al. (2022) y Chronopoulou et al. (2023) han mostrado que los adapters y técnicas afines (p. ej., LoRA) reducen de manera importante los parámetros entrenables y el uso de GPU sin una pérdida apreciable de rendimiento frente al fine-tuning completo. Ning et al. (2024) proponen además enfoques con atención dispersa explícita y PLMs integrados que concentran la capacidad del modelo en componentes informativos, rebajando el coste de inferencia y entrenamiento sin sacrificar calidad. Recientemente, Qorbani et al. (2025) han explorado la especialización por par, por ejemplo, la duplicación y ajuste de neuronas críticas para el par escaso, como vía para elevar el rendimiento del par minoritario sin reentrenar el modelo completo ni perjudicar pares ajenos. Para shiwilu, estas técnicas de especialización son prácticas cuando se dispone de un conjunto de validación por par y se busca aprovechar un modelo multilingüe grande sin aumentar demasiado su huella computacional.

En escenarios few/zero-shot, la evidencia sugiere que una adaptación breve de un modelo grande con muy pocos pares paralelos curados (cientos) puede reducir gran parte de la brecha con un coste bajo; sin embargo, el zero-shot puro hacia una lengua no vista tiende a ser frágil y normalmente requiere inyección léxica o validación humana para ser utilizable (Y. Liu et al., 2020; NLLB Team et al., 2022). Para shiwilu, el few-shot fine-tuning sobre mBART/mT5/NLLB con adapters y entrenamiento bidireccional aparece como un equilibrio razonable entre calidad y coste, especialmente si se integra un léxico shiwilu–castellano y señales morfológicas.

A la luz de esta evidencia, un diseño recomendado para shiwilu↔castellano que busque equilibrar rendimiento y coste sería: partir de un baseline bilingüe bidireccional basado en la arquitectura Transformer (Vaswani et al., 2017) entrenado con el paralelo disponible; comparar dicho baseline contra un SMT frase-a-frase como referencia histórica mínima; y pasar luego al fine-tuning de un modelo multilingüe preentrenado (mBART/mT5/NLLB) con adapters específicos. En este último paso conviene incorporar transferencia léxica y morfológica y, cuando proceda, aplicar técnicas de especialización por par (twinning) para afinar sin reentrenar el modelo completo. Esta propuesta recoge prácticas respaldadas y reproducibles en LRLs: ofrece mejoras frente a baselines con un coste computacional moderado y controlado.

3.6.3 P3. Métricas y validación con hablantes

Pregunta de revisión: ¿Qué métricas automáticas (BLEU, chrF++, TER u otras) y procedimientos de validación combinada (evaluación automática + pruebas participativas con hablantes) son más adecuados y fiables para medir adecuación lingüística y pertinencia cultural en traducciones de lenguas originarias con corpus escaso?

En traducción automática para lenguas originarias con datos escasos, la evaluación ha ido desplazándose desde el uso exclusivo de métricas clásicas hacia esquemas mixtos que combinan indicadores automáticos y validación humana. BLEU sigue empleándose como referencia comparativa entre sistemas, pero la literatura reciente muestra que su énfasis en coincidencias de n-gramas lo vuelve poco sensible a variación morfológica, paráfrasis y sinónimos, especialmente en contextos de bajo recurso. Además, sus valores absolutos pueden resultar poco informativos cuando el conjunto de prueba es pequeño o el dominio es muy específico (Post, 2018; Roy et al., 2024). Por ello, se ha vuelto habitual reportarlo junto con otras métricas que ofrezcan señales complementarias sobre la calidad.

Para lenguas con morfología rica, se han privilegiado indicadores a nivel de subcadena y representaciones, pues capturan mejor coincidencias parciales y variación formal. Entre las alternativas contemporáneas, BERTScore aproxima similitud semántica mediante embeddings y suele reflejar mejor la adecuación cuando la traducción válida no coincide palabra por palabra con la referencia (Zhang et al., 2020). En la misma línea, BLEURT aprende a imitar juicios

humanos y reduce la dependencia de coincidencias superficiales (Sellam et al., 2020), mientras que COMET integra información de la fuente y la hipótesis para predecir calidad con correlaciones superiores a las métricas n-gram en múltiples escenarios (Rei et al., 2020). Ahora bien, los estudios en lenguas de muy bajo recurso advierten que estas métricas neuronales, usadas en modo generalista, no siempre generalizan de forma óptima a idiomas poco representados; su desempeño mejora cuando se ajustan con anotaciones humanas del mismo entorno lingüístico (Sai et al., 2023; J. Wang et al., 2024).

La práctica contemporánea en evaluación de bajos recursos favorece, por tanto, un conjunto curado de métricas automáticas y no una sola cifra. Un protocolo razonable incluye BLEU como baseline comparativo, indicadores sensibles a variación formal o semántica como BERTScore y BLEURT, y, cuando sea viable, una versión adaptada por familia o región lingüística de COMET u otra métrica aprendida para elevar la concordancia con juicios nativos (Sai et al., 2023; J. Wang et al., 2024). Conjuntos de prueba multilingües recientes, como FLORES, han impulsado además prácticas de reporte más cuidadosas en LRLs y variantes de cómputo que respetan particularidades de segmentación y escritura. Aun así, cualquier puntaje aislado debe interpretarse con cautela y contrastarse con otras señales (NLLB Team et al., 2022; Post, 2018).

Debido a que ninguna métrica automática captura por sí sola matices de pertinencia cultural, la validación combinada con hablantes nativos se vuelve un componente indispensable. En evaluaciones a gran escala con expertos se ha visto que marcos sistemáticos de anotación como MQM permiten diagnosticar errores por categorías y que el ranking de sistemas puede diferir del inferido con encuestas rápidas o métricas superficiales. Además, ciertas métricas modernas se alinean mejor con juicios expertos cuando han sido contrastadas y afinadas con datos del mismo dominio (Freitag et al., 2021). Para lenguas originarias, diversos proyectos han optado por guías simplificadas inspiradas en MQM o por rúbricas de adecuación, fluidez y sensibilidad cultural acordadas con la comunidad, de modo que la evaluación humana sea sostenible y pertinente al uso real (Sai et al., 2023; J. Wang et al., 2024).

En el contexto peruano, se dispone de evidencia aplicada en Shipibo-Konibo que ilustra este enfoque iterativo: Montoya et al. (2019) presentan un marco de mejora continua que combina

ampliación incremental de datos, transferencia y aprendizaje activo, evaluando el avance con BLEU a nivel palabra y a nivel subpalabra mediante segmentación BPE. Paralelamente, incorporan retroalimentación de hablantes a través de un agente conversacional para recolectar nuevas traducciones y ajustar el sistema. Esta experiencia coincide con la pauta observada en LRLs: usar métricas automáticas para seguimiento y comparación controlada, y sostener decisiones de despliegue con revisión humana participativa que verifique adecuación lingüística y pertinencia cultural en los dominios objetivo. En suma, para medir de manera más fiable la calidad en traducciones hacia lenguas originarias de corpus escaso, conviene priorizar un conjunto de métricas que incluya al menos un indicador semántico moderno junto con el baseline clásico, y articularlo con procedimientos de evaluación con hablantes que verifiquen si la traducción conserva el sentido y resulta aceptable para su comunidad de uso.

3.7 Conclusiones

El análisis del estado del arte indica que la limitación principal para el desarrollo de un sistema de traducción automática shiwilu↔castellano es la escasez de un corpus paralelo amplio, diverso y con metadatos adecuados. Las mejoras metodológicas, como la adaptación de modelos multilingües preentrenados (por ejemplo, mBART, mT5, NLLB) mediante técnicas de afinamiento eficientes (adapters, LoRA), aportan ganancias apreciables en la relación rendimiento-coste (Hu et al., 2022; Y. Liu et al., 2020). El uso controlado de aumento de datos (back-translation, parafraseo) amplía la cobertura, pero no sustituye la necesidad de datos verificados por hablantes (Montoya et al., 2019; Sennrich et al., 2016). De igual forma, los métodos de minería y filtrado basados en representaciones (por ejemplo, SBERT o LASER) son herramientas valiosas para extraer pares paralelos de corpus comparables siempre que se apliquen criterios de calidad rigurosos y mecanismos de depuración (Artetxe & Schwenk, 2019; Reimers & Gurevych, 2019).

Para la tesis se derivan implicaciones metodológicas claras. En primer lugar, resulta prioritario consolidar y curar un corpus paralelo reproducible con metadatos y trazabilidad que permitan documentación y replicabilidad experimental. En segundo lugar, se recomienda establecer base-lines experimentales reproducibles y aplicar una estrategia combinada que incluya adaptación de modelos multilingües, aumento selectivo de datos y filtrado por *embeddings*. La evaluación

debe integrar métricas automáticas establecidas, como BLEU, chrF++ y COMET (Papineni et al., 2002; Rei et al., 2020), junto con estudios de validación con hablantes mediante rúbricas que midan adecuación, fluidez y pertinencia cultural (Freitag et al., 2021; Post, 2018). Finalmente, todas las etapas experimentales deben acompañarse de prácticas de reproducibilidad para obtener resultados consistentes y comparables en distintos entornos de desarrollo.

Capítulo 4

Recopilación y preparación inicial del corpus bilingüe

4.1 Introducción

Este capítulo presenta la construcción del corpus paralelo shiwilu–castellano utilizado en la investigación y la preparación del recurso de *embeddings* que se emplea como soporte semántico para el modelado posterior. El trabajo descrito responde al primer objetivo específico, orientado a recopilar y alinear un corpus paralelo, producir particiones reproducibles para entrenamiento, validación y prueba, y dejar preparado un recurso de representación semántica como entregable intermedio. Por ello, el capítulo se concentra en los insumos verificables sobre los que se construye y evalúa el modelo de traducción.

La organización del capítulo sigue la secuencia metodológica aplicada en el proyecto: primero se describen las fuentes lingüísticas incorporadas; luego se documenta el flujo de extracción, filtrado, unificación, normalización y auditoría; posteriormente se presentan las particiones canónicas; y finalmente se resume la preparación del modelo de *embeddings*. La evidencia documental y la trazabilidad técnica del proceso se presentan en el [Anexo B](#), entendido como medio de verificación de los resultados asociados al objetivo.

4.2 Resultados alcanzados

Los resultados de este capítulo se agrupan en dos entregables verificables. El primero es el corpus paralelo depurado, alineado y particionado (R1); el segundo es el recurso de *embeddings* bilingüe preparado y evaluado (R2). En ambos casos, el [Anexo B](#) explica qué evidencia sostiene

cada entregable y conserva, en segundo plano, las referencias técnicas necesarias para auditar o reproducir el proceso.

4.2.1 R1: corpus paralelo depurado, alineado y particionado

Este resultado comprende la consolidación de las fuentes bilingües, su normalización no destructiva, la auditoría de duplicados y la generación de particiones reproducibles. El propósito de R1 no es solo reunir ejemplos shiwilu–castellano, sino dejar un corpus estable, trazable por fuente y adecuado para los experimentos posteriores.

4.2.2 Fuentes del corpus bilingüe

El corpus se construyó a partir de ocho fuentes complementarias. Pueden agruparse en tres grandes líneas: (i) materiales narrativos publicados o documentados por escrito; (ii) *flashcards* shiwilu–castellano elaboradas y revisadas en colaboración directa con el señor Fidel Lomas Chota, hablante nativo shiwilu; y (iii) una lista de vocabulario nivel-palabra recogida originalmente en trabajo de campo lingüístico documental.

La primera línea, de carácter narrativo, está formada por dos obras. *VOCES SHIWILU: 400 años de resistencia lingüística en Jebero* es una compilación documental que recopila relatos en shiwilu con su correspondencia en castellano; aporta oraciones de carácter narrativo, mayor variación contextual y estructuras discursivas amplias. *Pidir Llinsercha 'su – Los relatos de Fidel* es una colección propia de relatos transcritos por Fidel Lomas Chota; complementa la línea narrativa con un registro distinto y consolidado por el propio hablante.

La segunda línea, de carácter léxico-comunicativo, está integrada por cinco subconjuntos de *flashcards* contruidos en conjunto con el hablante nativo. Todos comparten la lógica de tarjeta bilingüe shiwilu–castellano, pero se diferencian por el contexto y dominio temático que cubren:

- *flashcards2*: base léxico-funcional con frases breves de uso general.
- *flashcards_oraciones*: tarjetas con oraciones completas, útiles para extender la cobertura sintáctica.

- *vs_textos_narrativos*: tarjetas con contexto narrativo (recuperadas a partir de los textos 8–9 de *VOCES SHIWILU*).
- *cotidianas*: tarjetas de expresiones de uso diario.
- *el_principito*: tarjetas resultantes de un esfuerzo paralelo de traducir fragmentos de *El Principito* al shiwilu, conservando la estructura tarjeta a tarjeta.

La tercera línea complementa el corpus con vocabulario nivel-palabra de origen lingüístico-documental. La fuente *extra* se construye a partir del anexo *Lista de palabras utilizadas en el análisis fonológico* de la tesis de licenciatura de Madalengoitia Barúa (2014), recopilada en el marco del Proyecto Cahuapana, proyecto de documentación de las lenguas jebero y chayahuita auspiciado por la National Science Foundation de los Estados Unidos. La lista original fue grabada por Pilar M. Valenzuela en Jeberos el 24 de julio de 2007 con el hablante nativo Meneleo Careajano Chota (nacido el 22 de julio de 1942) y transcrita por la propia autora de la tesis. La lista cubre veinte secciones fonológicas (cuatro vocales y dieciséis consonantes), donde cada sección ilustra los contextos de aparición de un fonema del jebero mediante ejemplos glosados al castellano. Su incorporación al corpus aporta cobertura léxica de fauna, flora, parentesco y vocabulario cotidiano, particularmente útil para reducir la tasa de palabras fuera de vocabulario en la dirección castellano → shiwilu.

Esta organización es relevante para la trazabilidad del corpus: las dos fuentes narrativas (*VOCES SHIWILU* y *Pidir Llinsercha 'su*) aportan estructuras discursivas extensas y diversidad estilística; las cinco fuentes tipo *flashcards* aportan correspondencias léxicas y morfológicas controladas, validadas todas con el mismo hablante nativo; y *extra* aporta cobertura léxica nivel-palabra documentada en trabajo de campo lingüístico previo.

La Tabla 4.1 resume la composición inicial validada después de los procesos de filtrado y extracción. Esta tabla reemplaza los conteos preliminares usados durante etapas anteriores por los valores consolidados del proceso actual, que ahora cubre las ocho fuentes habilitadas en `config/sources.json`.

Tabla 4.1: Fuentes bilingües incorporadas al corpus

Fuente	Tipo de contenido	Pares válidos	Formato de origen	Uso en el corpus
<i>flashcards2</i> (flashcards base)	Tarjetas bilingües con frases breves, validadas con hablante nativo	2251	Archivo tabular	Base léxica y funcional de expresiones controladas
<i>VOCES SHIWILU</i>	Compilación narrativa publicada: <i>400 años de resistencia lingüística en Jebero</i>	956	PDF convertido a CSV	Línea narrativa principal
<i>flashcards_oraciones</i>	Tarjetas bilingües con oraciones completas, validadas con hablante nativo	669	Archivo tabular	Ampliación sintáctica de las flashcards base
<i>Pidir Llinsercha 'su – Los relatos de Fidel</i>	Relatos propios transcritos por Fidel Lomas Chota	562	Archivo tabular	Línea narrativa complementaria
<i>vs_textos_narrativos</i>	Tarjetas con contexto narrativo (textos 8–9 de <i>VOCES SHIWILU</i>)	35	Archivo tabular	Tarjetas de registro narrativo
<i>cotidianas</i>	Tarjetas de expresiones de uso diario, validadas con hablante nativo	44	Archivo tabular sin cabecera	Tarjetas de registro coloquial y comunicativo
<i>el_principito</i>	Tarjetas resultantes de traducir fragmentos de <i>El Principito</i> al shiwilu	13	Archivo tabular	Contraste con dominio literario traducido
<i>extra</i>	Lista de vocabulario nivel-palabra del anexo fonológico de Madalengoitia Barúa (2014) (Proyecto Cahuapana, NSF)	364	Archivo tabular	Cobertura léxica documental para reducir OOV en castellano → shiwilu
Total unificado	Registros paralelos de las ocho fuentes	4894	CSV consolidado	Base para normalización, auditoría y particiones


La combinación de fuentes responde a una necesidad propia de las lenguas de bajo recurso: aprovechar todo el material disponible sin homogeneizarlo de forma agresiva, preservando metadatos y trazabilidad para sostener comparaciones reproducibles (Koehn & Knowles, 2017; Mager & Meza, 2018). Las flashcards y las cotidianas ofrecen control y validación directa; los relatos y los textos narrativos aportan diversidad estilística; *el_principito* agrega un contras-

te literario controlado; y *extra* amplía la cobertura de vocabulario, aunque por su formato de palabras aisladas se analiza con cuidado en las etapas posteriores. Por ello, el procesamiento posterior se diseñó para conservar el origen de cada registro y mantener acceso tanto a las versiones originales como a las normalizadas. Cada fuente atraviesa la etapa 01 de filtrado de forma independiente, lo que permite reportar inclusiones y exclusiones por origen y reproducir el flujo completo.

4.2.3 Construcción, normalización y auditoría del corpus

El proceso de preparación se organizó como un flujo reproducible. Cada etapa generó un archivo de salida y un reporte asociado, de modo que las decisiones de limpieza, exclusión y partición pudieran revisarse posteriormente. La Figura 4.1 muestra el recorrido general aplicado desde las fuentes originales hasta las particiones canónicas.

Figura 4.1: Flujo reproducible de construcción del corpus bilingüe



La extracción del PDF de *VOCES SHIWILU: 400 años de resistencia lingüística en Jebero* se realizó con heurísticas conservadoras para identificar ítems numerados y separar segmentos bilingües. El resultado fue un conjunto de 956 pares exportados, de los cuales 867 fueron marcados como casos directos y 89 como casos recuperados mediante una regla de respaldo. Esta

distinción permitió conservar información útil sin ocultar los casos que requirieron tratamiento especial.

En paralelo, el filtrado se aplicó por separado a cada una de las ocho fuentes habilitadas. Esta decisión fue necesaria porque, para entrenamiento y evaluación supervisada, cada registro debe contener una entrada en castellano y una entrada en shiwilu, y porque cada fuente tiene su propio esquema de columnas y formato. Tras esta etapa quedaron disponibles 2251 pares de *flashcards2*, 956 de *VOCES SHIWILU*, 669 de *flashcards_oraciones*, 562 de *Pidir Llinsercha 'su*, 35 de *vs_textos_narrativos*, 44 de *cotidianas*, 13 de *el_principito* y 364 de *extra*.

A continuación, las ocho fuentes se integraron en un único dataset de 4894 registros con trazabilidad de origen. Sobre este corpus unificado se aplicó una normalización no destructiva: las columnas originales se conservaron, mientras que las versiones normalizadas se generaron en columnas separadas. Las reglas aplicadas incluyeron normalización Unicode NFC, eliminación de espacios redundantes, ajuste de espacios junto a comas, conversión a minúsculas y eliminación de comillas dobles. Esta estrategia evita perder información lingüística potencialmente relevante, especialmente en una lengua con rasgos morfológicos complejos como el shiwilu.

La Tabla 4.2 resume las etapas principales, sus salidas y los reportes que permiten reproducir o auditar cada paso. El Anexo B presenta esa trazabilidad como respaldo documental del corpus, no como requisito para comprender el resultado.

Tabla 4.2: Etapas reproducibles de preparación del corpus

Etapas	Nombre	Procedimiento aplicado	Salida principal	Reporte de control
00	Extracción PDF	Conversión de relatos bilingües desde PDF hacia registros tabulares	956 pares extraídos	Resumen de extracción
01	Filtrado por fuente	Eliminación, fuente por fuente, de filas sin par bilingüe completo	4894 pares válidos (sumando las 8 fuentes)	Filas removidas por fuente
01b	Unificación	Integración de las 8 fuentes y conservación de metadatos de origen	4894 registros	Resumen de unificación

Tabla 4.2 (continuación)

Etap	Nombre	Procedimiento aplicado	Salida principal	Reporte de control
02	Normalización	Normalización textual no destructiva sobre español y shiwilu	4894 registros normalizados	Log de normalización
03	Auditoría	Revisión de duplicados, conflictos y alertas de longitud o contenido	80 duplicados exactos detectados	Resumen de auditoría
04	Partición	Generación de train, valid y test con semilla fija y grupos	4814 pares incluidos	Manifiesto de preprocesamiento

4.2.4 Caracterización del corpus preparado

La auditoría permitió describir el corpus tanto en términos cuantitativos como en términos de calidad. El corpus unificado contiene 4894 registros provenientes de las ocho fuentes habilitadas; de ellos, 80 fueron excluidos por duplicación exacta antes de generar las particiones canónicas. Por tanto, el corpus final auditado quedó compuesto por 4814 pares paralelos.

Dentro de ese total conviene distinguir dos niveles de uso. El corpus auditado completo contiene 4814 pares, incluyendo registros oracionales y vocabulario nivel-palabra. Para los experimentos NMT del capítulo siguiente se utiliza el subconjunto oracional de 4501 pares, mientras que los 313 registros de vocabulario atómico de la fuente *extra* se conservan como recurso léxico y se reportan por separado cuando corresponde. Esta separación evita mezclar en una misma evaluación ejemplos de naturaleza distinta.

Tabla 4.3: Resumen del corpus consolidado y auditado

Indicador	Valor	Fuente del valor	Interpretación
Registros unificados	4894	Unificación de fuentes	Total antes de exclusiones finales
Registros incluidos	4814	Manifiesto canónico	Pares usados para particiones y modelos
Registros excluidos	80	Auditoría y manifiesto	Duplicados exactos removidos

Tabla 4.3 (continuación)

Indicador	Valor	Fuente del valor	Interpretación
Grupos totales	4523	Manifiesto canónico	Agrupación semántica para evitar fuga entre splits
Grupos multi-par	257	Manifiesto canónico	Casos con más de una variante equivalente
Filas con cambios de normalización	4426	Reporte de normalización	Registros afectados por al menos una regla textual
Transformaciones registradas	9026	Reporte de normalización	Cambios trazables aplicados al corpus

Desde el punto de vista léxico, la auditoría muestra una diferencia relevante entre ambas lenguas. El castellano presenta 22 651 tokens y 6220 tipos únicos, mientras que el shiwilu presenta 14 217 tokens y 7412 tipos únicos. Esta mayor proporción de tipos únicos en shiwilu — y, en particular, su *type-token ratio* (TTR) más alto, 0,5213 frente a 0,2746 en castellano — es coherente con la caracterización de la lengua como sistema de alta productividad morfológica; por ello, el preprocesamiento evitó eliminar agresivamente signos o segmentos internos que pudieran formar parte de unidades lingüísticas válidas.

Tabla 4.4: Estadísticas léxicas del corpus auditado

Lengua	Tokens	Tipos únicos	TTR	Hapax
Castellano	22 651	6220	0.2746	4130
Shiwilu	14 217	7412	0.5213	5742

4.2.5 Particiones reproducibles del corpus


Para asegurar comparabilidad entre experimentos, el corpus final se dividió en particiones de entrenamiento, validación y prueba bajo una proporción 80/10/10 y con semilla fija igual a 42. La división no se realizó únicamente por filas, sino considerando grupos semánticos mediante `group_id`. Esta decisión evita que variantes equivalentes o relaciones uno-a-muchos queden distribuidas entre entrenamiento y prueba, lo cual produciría una estimación artificialmente optimista del desempeño.

Tabla 4.5: Particiones canónicas del corpus bilingüe (variante x1, semilla 42)

Partición	Filas	Grupos	Flashcards (5 fuentes)	VOCES SHIWI- LU	Pidir	Extra	Uso
Entrenamiento	3852	3623	2368	769	464	251	Ajuste de modelos y recursos intermedios
Validación	481	448	316	89	47	29	Selección y control experimental
Prueba	481	452	308	98	42	33	Evaluación final no usada en entrenamiento
Total	4814	4523	2992	956	553	313	Corpus canónico incluido

La columna *Flashcards (5 fuentes)* suma *flashcards2*, *flashcards_oraciones*, *vs_textos_narrativos*, *cotidianas* y *el_principito*, todas validadas con el hablante nativo. La columna *VOCES SHIWILU* corresponde a la compilación narrativa publicada (*400 años de resistencia lingüística en Jebero*); *Pidir* corresponde a *Pidir Llinsercha'su – Los relatos de Fidel*; *Extra* corresponde a la lista fonológica de Madalengoitia Barúa (2014). Esta última fuente aporta vocabulario útil para cobertura léxica, pero no tiene el mismo comportamiento que las oraciones completas en tareas de recuperación o traducción. La distribución por fuente individual se reporta en `reports/04_embeddings/preprocessing_x1/preprocess_manifest.json`.

La Figura 4.2 muestra que las tres particiones conservan una composición similar por fuente. Esto resulta importante porque evita que una partición quede dominada por un único tipo de material y permite evaluar el comportamiento del modelo sobre ejemplos provenientes tanto de flashcards como de textos narrativos.

Figura 4.2: Distribución de fuentes por partición canónica (variante x1)

Una vez fijado el corpus y sus particiones, el siguiente paso fue preparar una representación semántica bilingüe que permitiera medir cercanía entre pares shiwilu–castellano y apoyar las etapas posteriores del sistema NMT.

4.2.6 R2: recurso de embeddings bilingüe preparado y evaluado

Además del corpus depurado y particionado, el primer objetivo específico contempla la preparación de un modelo de *embeddings*. En esta tesis, los *embeddings* cumplen una función intermedia: permiten representar pares shiwilu–castellano en un espacio semántico común, medir recuperación bilingüe y aportar una señal independiente para el filtrado, la comparación y el reordenamiento de hipótesis en el sistema NMT.

El modelo preparado como entregable R2 fue la variante v3 de E5-base bidireccional con minería iterativa de negativos, basada en `intfloat/multilingual-e5-base` y ajustada mediante entrenamiento bidireccional con negativos duros y medios. La selección se realizó sobre la partición canónica de prueba de 448 pares (variante x1, oraciones completas), usando recuperación multi-positiva por `group_id`; es decir, el sistema no exige una única traducción válida cuando existen variantes equivalentes registradas. Las 33 entradas adicionales de vocabulario nivel-palabra del dataset *extra* que también caen en la partición de prueba se reportan por separado en el Anexo B, ya que su carácter atómico (consultas de una sola palabra) las hace más exigentes para recuperación que las oraciones completas y comparar ambos regímenes en una sola cifra agregada distorsiona la lectura.

La elección de este candidato no fue directa, sino resultado de una secuencia incremental. Primero se evaluó E5-base sin ajuste fino para establecer un punto de comparación. Luego se entrenó una versión con pérdida *Multiple Negatives Ranking Loss*, lo que permitió adaptar el espacio semántico al par shiwilu–castellano. En una tercera etapa se incorporó minería controlada de negativos duros y medios, con el fin de enseñar al modelo a distinguir pares semánticamente cercanos pero incorrectos. Finalmente, la variante v3 reutilizó el mejor candidato anterior y aplicó una nueva iteración de minería de negativos, manteniendo entrenamiento bidireccional para mejorar la recuperación en ambos sentidos. Esta progresión se resume técnicamente en el [Anexo B](#).

La Figura 4.3 muestra esta progresión a partir de métricas de recuperación sobre la partición de prueba. Se emplean $R@1$ y MRR porque el propósito del modelo de *embeddings* no es generar traducciones directamente, sino recuperar equivalencias bilingües cercanas dentro de un espacio semántico compartido.

Figura 4.3: Evolución experimental de $R@1$ y MRR en los modelos de embeddings





Tabla 4.6: Métricas del modelo de embeddings preparado

Dirección de recuperación	$R@1$	$R@5$	$R@10$	MRR	Aciertos $R@1$
Castellano → shiwilu	0.8080	0.9420	0.9598	0.8671	362/448
Shiwilu → castellano	0.7857	0.9397	0.9621	0.8547	352/448


La Figura 4.4 compara las métricas finales del candidato v3 en ambas direcciones. Se observa que el modelo mantiene un comportamiento equilibrado: en ambos sentidos supera el umbral de recuperación top-1 cercano a ocho de cada diez consultas y conserva valores altos de recuperación dentro de los primeros cinco y diez candidatos.

Figura 4.4: Métricas finales de recuperación del modelo de embeddings v3




La Figura 4.5 representa los pares completos de la partición de prueba en el espacio vectorial del modelo v3, proyectados a dos dimensiones mediante PCA. Cada línea une una oración castellana con su contraparte shiwilu; por tanto, la figura no sustituye las métricas de recuperación, pero permite inspeccionar visualmente que ambas lenguas quedan ubicadas en vecindarios semánticos compartidos.

Figura 4.5: Proyección PCA del espacio vectorial bilingüe del modelo de embeddings v3



La Figura 4.6 complementa esta lectura al mostrar la distribución de rangos. La mayor parte de las consultas se ubica en rank 1 y, cuando el primer resultado no coincide con la referencia esperada, el par correcto suele permanecer entre los primeros candidatos. Por ello, el modelo queda preparado como entregable de *embeddings* y como insumo semántico para el sistema NMT descrito en el capítulo siguiente. Los reportes de entrenamiento, recuperación, minería de negativos y congelamiento del candidato se documentan en el [Anexo B](#).

Figura 4.6: Distribución de rangos del modelo de embeddings v3



4.3 Discusión

Los resultados del capítulo muestran que el primer obstáculo del par shiwilu–castellano no es solamente la escasez de datos, sino la necesidad de convertir fuentes heterogéneas en un recurso comparable, auditable y reutilizable. El corpus final de 4814 pares no elimina la condición de bajo recurso, pero establece una base empírica más estable que las colecciones dispersas iniciales: conserva trazabilidad por fuente, separa versiones originales y normalizadas, excluye duplicados exactos y fija particiones de entrenamiento, validación y prueba que pueden ser reutilizadas por experimentos posteriores.

La caracterización léxica confirma además que el shiwilu presenta una densidad morfológica mayor que el castellano dentro del corpus, reflejada en una proporción más alta de tipos únicos y hapax. Esta observación es coherente con la descripción lingüística del shiwilu (Valenzuela, 2018) y justifica dos decisiones metodológicas: evitar una normalización destructiva que borre información morfológica, y preparar un modelo de *embeddings* capaz de operar como recurso semántico auxiliar. En línea con la literatura de lenguas de bajo recurso, el valor principal del recurso no se limita al volumen absoluto, sino a su control, trazabilidad y posibilidad de comparación experimental (Artetxe & Schwenk, 2019; Koehn & Knowles, 2017).

El modelo de *embeddings* v3 ofrece una señal sólida para recuperación bilingüe en ambas direcciones, con $R@1$ cercano a ocho de cada diez consultas sobre oraciones completas. Este resultado cumple el IOV asociado a R2 porque el recurso no solo queda entrenado, sino medido

con particiones fijas y reportes reproducibles. Su desempeño debe interpretarse dentro del alcance del recurso: el modelo de *embeddings* no genera traducciones, sino que ofrece una señal de cercanía semántica útil para recuperación, filtrado y apoyo al sistema NMT. Los ítems de vocabulario atómico se reportan por separado porque responden a un régimen de recuperación distinto al de las oraciones completas.

En conjunto, el capítulo cumple el OE1 mediante dos resultados verificables: R1, un corpus paralelo consolidado, depurado y particionado; y R2, un recurso de *embeddings* bilingüe preparado y evaluado. La contribución no está solo en el volumen reunido, sino en haber convertido materiales heterogéneos en un recurso ordenado, comparable y listo para experimentación. Con ello, el capítulo deja cerrado el insumo central del proyecto: un corpus paralelo controlado y una representación semántica bilingüe que alimentan el sistema NMT del capítulo siguiente. El [Anexo B](#) contiene los medios de verificación que permiten reproducir el proceso, revisar criterios de inclusión y normalización, consultar manifiestos de partición y auditar las métricas del modelo de representación.

Capítulo 5

Sistema de traducción neuronal

SA-BiNLLB

5.1 Introducción

A partir del corpus paralelo shiwilu–castellano consolidado en el Capítulo 4 y del modelo de *embeddings* bilingüe congelado en ese mismo capítulo, este capítulo describe el sistema de traducción automática neuronal implementado y evaluado en este trabajo: **SA-BiNLLB** (*Semantic-Aware Bidirectional NLLB*). El capítulo se concentra en el modelo NMT, sus datos de entrenamiento, sus variantes y sus métricas automáticas; el protocolo participativo se desarrolla como componente metodológico propio en el capítulo siguiente. El nombre resume tres decisiones de diseño: (i) un *backbone* multilingüe pre-entrenado (NLLB-200) adaptado al par shiwilu–castellano mediante una capa LoRA bidireccional liviana; (ii) la reutilización del modelo de *embeddings* bilingüe en tres puntos del pipeline (filtrado de datos, reranking de hipótesis y filtrado de pares sintéticos por consistencia), lo cual da el carácter *semantic-aware* al sistema; y (iii) una capa de aumentación de datos cuya admisión se decide a través del mismo evaluador semántico, evitando así la circularidad de que el modelo NMT valide sus propios datos sintéticos.

La organización del capítulo sigue el flujo experimental del modelo: primero se presenta la arquitectura general; luego, los conjuntos de datos canónicos derivados del corpus; después, las etapas de filtrado y entrenamiento que producen el modelo v_0 ; a continuación, la augmentación que produce el modelo v_{1bt} ; y finalmente los resultados experimentales y las ablaciones que llevan a la variante seleccionada. Los detalles operativos de hiperparámetros, fórmulas,

configuraciones y reportes auxiliares se presentan en el [Anexo C](#), entendido como documento reproducible del sistema y medio de verificación de los resultados.

5.2 Resultados alcanzados


Este capítulo reporta los resultados asociados al segundo objetivo específico: implementar y evaluar un sistema de traducción automática neuronal bidireccional para el par shiwilu–castellano. Los entregables centrales son R3, el sistema shiwilu→castellano, y R4, el sistema castellano→shiwilu, ambos implementados dentro de una arquitectura única SA-BiNLLB y medidos con el mismo protocolo automático sobre particiones fijas. Esta evidencia cuantitativa permite comparar variantes, seleccionar el modelo con mejor desempeño y establecer la base técnica que será retomada por el protocolo del Capítulo 6. El [Anexo C](#) funciona como medio de verificación reproducible de hiperparámetros, scripts, métricas, ablaciones, intervalos de confianza y análisis de rare-token.

5.2.1 Arquitectura general

El sistema se compone de tres bloques que operan secuencialmente. El primero es el *backbone* de traducción: facebook/nllb-200-distilled-600M, un modelo NMT multilingüe que cubre más de 200 lenguas. NLLB-200 no incluye al shiwilu en su inventario, por lo que se extiende su *tokenizer* para registrar la lengua como shw_Latn y se inicializa la fila correspondiente de *embeddings* desde tres lenguas indígenas sudamericanas tipológica y geográficamente cercanas (quechua de Ayacucho, aymara y guaraní); de esta manera el shiwilu parte con un sesgo morfológico y prosódico razonable en lugar de una inicialización aleatoria.

El segundo bloque es la adaptación al par. Sobre el *backbone* congelado se entrena un único *adapter* LoRA bidireccional, cuyas filas direccionales spa→shw y shw→spa se mezclan en el mismo conjunto de entrenamiento. Esta elección se justifica por la cantidad de datos disponibles: con un corpus de pocos miles de pares paralelos no se justifica entrenar dos adaptadores independientes ni desbloquear el *backbone* completo; LoRA permite ajustar el dominio sin destruir las representaciones pre-entrenadas y manteniendo el costo computacional dentro del presupuesto

Figura 5.1: Arquitectura de entrenamiento e inferencia del modelo final SA-BiNLLB $v_{2.1b}$



de una sola GPU.

El tercer bloque corresponde al componente de apoyo semántico. El modelo de *embeddings* bilingüe v3 congelado en el Capítulo 4 no traduce directamente, pero aporta una señal independiente para tres decisiones del sistema NMT: filtrar pares de entrenamiento (Sección 5.2.3), revisar la consistencia de pares sintéticos generados por backtranslation (Sección 5.2.5) y reordenar las hipótesis devueltas por la búsqueda en haz (Sección 5.2.6). Es esta triple reutilización lo que justifica el nombre *semantic-aware*: el sistema NMT no opera en aislamiento, sino apoyado en un evaluador semántico independiente y reutilizable. Los hiperparámetros exactos de cada bloque (rangos, tasas, fórmulas, umbrales) se desarrollan en el Anexo C, secciones A y A.

5.2.2 Datos canónicos para NMT

Las particiones canónicas del corpus bilingüe (Capítulo 4) se reescriben en formato direccional para alimentar el entrenamiento bidireccional. Cada par paralelo del corpus se replica como dos filas: una con dirección shw→spa y otra con dirección spa→shw, cada una conservando su pair_id y su group_id originales. La preservación del group_id garantiza que ninguna agrupa-

ción semántica cruce las fronteras de *train*, *valid* y *test*; esta integridad evaluativa fue establecida en la fase previa y no se altera. La distribución resultante se muestra en el Cuadro 5.1: los 4501 pares de la variante x1 producen 9002 filas direccionales, que conservan la proporción 80/10/10 del corpus original.

Tabla 5.1: Distribución del corpus canónico bidireccional para entrenamiento NMT (variante x1).

Split	Pares (entrada)	Filas shw→spa	Filas spa→shw	Total
train	3923	3923	3923	7846
valid	445	445	445	890
test	446	446	446	892
Total	4814	4814	4814	9628

5.2.3 Filtrado semántico de calidad

Antes de entrenar el modelo NMT, el conjunto de entrenamiento direccional pasa por un filtro semántico que descarta pares cuya correspondencia bilingüe no es plausible. El filtro utiliza el modelo de *embeddings* v3 congelado para puntuar la similitud coseno entre la fuente y el destino de cada par; aquellos cuya similitud queda por debajo de un umbral inferior se descartan, los que caen entre dos umbrales se conservan pero quedan marcados para revisión, y los que superan el umbral superior se aceptan sin observaciones. La decisión se toma a nivel de *pair_id* (no por dirección), de manera que las dos filas direccionales de un mismo par compartan etiqueta. Los conjuntos de validación y prueba se puntúan pero no se modifican, para preservar la base de comparación.

El Cuadro 5.2 muestra la distribución de pares aceptados, marcados y descartados sobre el conjunto de entrenamiento de la variante x1. Sobre los pares aceptados se construyen además dos índices FAISS (Johnson et al., 2019) en el espacio de *embeddings* (uno por idioma) que se reutilizan más adelante en la augmentación por minería bilingüe. Los umbrales numéricos, la configuración del modelo de *embeddings* y la especificación de los índices FAISS se desarrollan en el Anexo C, secciones A y A.

Tabla 5.2: Distribución de pares en el conjunto de entrenamiento tras el filtro semántico (variante x1).

Bucket (pares)	Aceptados	Marcados	Removidos
Conteo	3615	304	4

5.2.4 Entrenamiento del modelo v_0

El modelo base v_0 se entrena sobre el conjunto direccional filtrado, con una única pasada de fine-tuning del *adapter* LoRA bidireccional. La selección del mejor punto de control durante el entrenamiento se realiza sobre la métrica chrF++ promediada entre las dos direcciones (*eval_avg_chrf*) calculada sobre el conjunto de validación al final de cada época; el sistema conserva el checkpoint con mejor desempeño y descarta los demás. El presupuesto de entrenamiento es de veinte épocas, suficiente para que el modelo alcance una meseta de validación con margen para el sobre-entrenamiento que la selección por mejor checkpoint absorbe automáticamente.

La configuración exacta del optimizador, la tasa de aprendizaje, la programación, la precisión, el tamaño de *batch* efectivo, las longitudes máximas de secuencia y los parámetros de generación se desarrollan en el Anexo C, sección A.

5.2.5 Augmentación de datos para v_{1bt}

Tras estabilizar v_0 , el sistema explora cuatro fuentes complementarias de datos sintéticos para producir un modelo aumentado v_{1bt} . El criterio común a las cuatro es que la admisión de cualquier par sintético al conjunto de entrenamiento se decide a través del modelo de *embeddings* v3 congelado, no del propio modelo NMT; esta separación evita la circularidad de que el modelo valide sus propios errores.

1. **Backtranslation desde monolingüe shiwilu.** Se extrae un conjunto de oraciones shiwilu sin par paralelo, se traducen al castellano con v_0 y se filtran por similitud semántica cross-lingual contra la fuente. La aplicación se restringe a la dirección shw→spa porque generar shiwilu sintético desde fuentes españolas con un modelo aún imperfecto en esa dirección

contaminaría el *target*, efecto reportado por Edunov et al. (2018). En la práctica este conjunto resultó pequeño (76 oraciones extraídas del PDF de *VOCES SHIWILU*), por lo que su contribución se complementa con el siguiente ítem.

2. **Round-trip backtranslation con filtro de consistencia monolingüe.** Para aprovechar las fuentes monolingües abundantes en castellano (FLORES, OPUS-100, Wikipedia) sin renunciar a la calidad, se traduce cada oración española real al shiwilu con v_0 y se vuelve a traducir al castellano por la dirección inversa; se conserva únicamente el par sintético cuando el castellano recuperado es semánticamente consistente con el original, lo cual se mide con el modelo de *embeddings* v3 sobre los dos textos en castellano. La condición monolingüe permite usar un umbral más estricto que el filtro cross-lingual del ítem anterior y produce pares más confiables. El esquema soporta iteraciones sucesivas: a partir de la primera iteración el modelo generador deja de ser v_0 y pasa a ser el último v_{kbt} entrenado.
3. **Minería bilingüe basada en *embeddings*.** Se utilizan los índices FAISS construidos durante el filtrado para identificar pares shiwilu–castellano con vecindad recíproca y similitud por encima de un umbral. Esta fuente captura paráfrasis cruzadas que el corpus paralelo no había emparejado explícitamente.
4. **Variantes morfológicas controladas.** Sobre el inventario de sufijos minado durante la fase de *embeddings* se generan variantes morfológicas para revisión por lingüista. Sin validación humana estas filas se mantienen fuera del entrenamiento por defecto.

El modelo aumentado v_{1bt} se entrena sobre la unión del conjunto paralelo filtrado con los conjuntos sintéticos aceptados de los ítems 1 a 3. Para reflejar la confiabilidad heterogénea de las distintas fuentes, la pérdida pondera cada fila según su origen (las filas reales pesan más que las sintéticas), y la capacidad del adaptador LoRA se incrementa moderadamente respecto de v_0 para absorber el corpus ampliado sin saturarse. Las fórmulas matemáticas de cada fuente, los umbrales numéricos, el mapa de pesos por origen y la derivación de la pérdida ponderada se desarrollan en el Anexo C, secciones A y A.

5.2.6 Evaluación automática y ablaciones

La evaluación final compara cuatro variantes del sistema sobre el conjunto de prueba: el modelo base v_0 y el modelo aumentado v_{1bt} , cada uno en sus variantes con *baseline* (toma directamente la mejor hipótesis del decodificador) y con *reranking* semántico (reordena las cinco mejores hipótesis combinando la probabilidad del modelo con la similitud coseno fuente–candidato producida por el modelo de *embeddings* v3). Las métricas reportadas son BLEU, chrF++ y COMET, calculadas por dirección de traducción. Se adopta chrF++ como métrica primaria por su mayor robustez en lenguas morfológicamente ricas y de bajos recursos; BLEU se reporta como métrica secundaria estándar y COMET con el caveat explícito de que su entrenamiento subyacente no incluye al shiwilu, por lo cual sus valores absolutos son indicativos. Aunque chrF++ se conserva como criterio primario para comparar y seleccionar modelos, cada dirección se lee con la métrica que mejor la refleja: BLEU es el indicador de cabecera más informativo en shw→spa (salida en castellano), mientras que chrF++ es el más fiable en spa→shw (salida en shiwilu), donde BLEU subestima la calidad por la densidad morfológica del idioma destino.

Tabla 5.3: Comparación de variantes del sistema sobre el conjunto de prueba (variante x1, 451 pares por dirección). chrF++ es la métrica primaria.

Variante	shw→spa				spa→shw			
	chrF++	BLEU	BERTScore	COMET	chrF++	BLEU	BERTScore	COMET
nllb_bidi_lora_v0_xl	23.58	8.50	0.903	0.602	26.44	4.47	0.873	0.664
nllb_bidi_lora_v0_xl+rerank	25.16	9.73	0.904	0.612	28.06	4.61	0.879	0.684
nllb_bidi_lora_v1_bt_xl	29.01	12.03	0.909	0.636	32.69	5.57	0.884	0.700
nllb_bidi_lora_v1_bt_xl+rerank	29.91	12.45	0.910	0.648	34.36	6.69	0.891	0.718

El Cuadro 5.3 consolida los resultados. Tres lecturas resumen lo observado:

Efecto del corpus. Pasar de la variante main (3204 pares) a la variante x1 (4501 pares) duplica BLEU en ambas direcciones y agrega entre cuatro y cinco puntos de chrF++. Este resultado confirma que en el régimen low-resource el rendimiento es muy sensible a la cantidad de datos paralelos disponibles, incluso por encima de cualquier mejora arquitectónica que pueda aportar el sistema.

Efecto del reranking semántico. Sobre cada modelo el reranking aporta entre uno y dos puntos adicionales de chrF++. El aporte es positivo incluso cuando la combinación lineal apoya completamente al modelo de *embeddings* ($\alpha = 0$), lo cual confirma que el evaluador semántico no introduce ruido. La ablación completa del coeficiente α y los puntos óptimos por modelo se desarrollan en el Anexo C, sección A.

Efecto de la augmentación. El modelo v_{1bt} , entrenado con el corpus paralelo más los pares sintéticos aceptados por el filtro semántico, supera consistentemente a v_0 en ambas direcciones y en las tres métricas. La ganancia es más pronunciada en BLEU (porque la augmentación introduce variabilidad léxica que el modelo aprende a producir) y se mantiene tras el reranking, lo cual indica que ambos mecanismos aportan información complementaria.

Ablaciones del optimizador y la arquitectura del adaptador. Sobre el modelo v_{1bt} se ejecutaron cuatro ablaciones adicionales que aíslan la contribución de mejoras recientes en el espacio de adaptadores PEFT y de fuentes monolingües: $v_{2,0}$ reemplaza LoRA por DoRA (S.-Y. Liu et al., 2024) manteniendo el resto del pipeline, $v_{2,1}$ suma LoRA+ (Hayou et al., 2024) a DoRA, $v_{2,1b}$ aplica LoRA+ sobre LoRA estándar (sin DoRA), y $v_{2,2}$ toma a $v_{2,1b}$ como modelo generador y le suma una ronda de *round-trip backtranslation* con un *pool* monolingüe español tomado de Wikipedia. El Cuadro 5.4 consolida las seis variantes en una tabla única con chrF++ como criterio primario y BLEU/COMET como señales complementarias; el Cuadro 5.6 reporta la incertidumbre bootstrap de chrF++ y conserva BLEU/COMET como puntos de contexto.

Además de las métricas finales sobre el conjunto de prueba, se revisó la trayectoria del entrenamiento del modelo seleccionado. La Figura 5.2 muestra que la pérdida de entrenamiento disminuye de forma sostenida y que el chrF++ de validación aumenta hasta estabilizarse hacia las últimas épocas. Esta lectura es útil porque confirma que la selección de $v_{2,1b}$ no se apoya sólo en una medición final, sino también en un proceso de ajuste consistente.

Tres lecturas adicionales emergen de los Cuadros 5.4, 5.5 y 5.6. Primero, LoRA+ aislado ($v_{2,1b}$) es la variante con mejor desempeño, con avg chrF++ reranked = 44.99 (IC 95 % [43.17, 46.96]), BLEU promedio = 18.46 y COMET promedio = 0.752; el salto de $\approx 12,8$ puntos chrF++ sobre v_{1bt} es estadísticamente claro porque los intervalos de confianza no se traslapan. Segundo, el

Tabla 5.4: *Leaderboard* final de ablaciones sobre la variante x1 (446 pares por dirección, 892 filas direccionales). chrF++ es la métrica primaria; BLEU y COMET se reportan como métricas complementarias.

Variante	chrF++ avg			Reranked avg		
	baseline	reranked	Δ	BLEU	COMET	BERT-F1
v_0	25.01	26.61	+1.60	7.17	0.648	0.892
v_{1bt} (+BT OPUS)	30.85	32.14	+1.28	9.57	0.683	0.900
$v_{2.0}$ DoRA	31.34	32.58	+1.25	10.51	0.688	0.901
$v_{2.1}$ DoRA+LoRA+	43.82	44.30	+0.47	18.00	0.745	0.918
$v_{2.1b}$ LoRA+ ★	43.54	44.99	+1.45	18.46	0.752	0.919
$v_{2.2}$ +BT iter1 (Wikipedia)	31.08	32.33	+1.25	10.33	0.687	0.901

desglose direccional muestra que el promedio no debe leerse como rendimiento homogéneo: en la variante seleccionada, la dirección spa→shw alcanza mayor chrF++ (47.56) que shw→spa (42.42), mientras que BLEU es mayor en shw→spa (24.48 frente a 12.45). Esta divergencia confirma la necesidad de reportar ambas direcciones, pues cada métrica reacciona de modo distinto a la morfología, la longitud y la variación léxica del idioma destino. Tercero, DoRA aislado ($v_{2.0}$) no se distingue estadísticamente de v_{1bt} (32,58 vs 32,14, IC 95 % traslapados), y la combinación DoRA+LoRA+ ($v_{2.1}$, 44,30) cae dentro del IC del propio LoRA+ aislado, de modo que DoRA no compensa su costo computacional adicional con este corpus. Finalmente, $v_{2.2}$ regresa el modelo a ≈ 32 chrF++ y también baja en BLEU/COMET respecto de $v_{2.1b}$: la *backtranslation* desde Wikipedia (registro enciclopédico, vocabulario externo al corpus de *flashcards* y narrativas comunitarias) introduce pares sintéticos cuya distribución de dominio debilita la señal limpia de LoRA+, lo que indica que en *low-resource* la coincidencia de dominio pesa más que el volumen del pool monolingüe.

Una lectura complementaria, de carácter interpretativo más que normativo, ayuda a dimensionar la mejora. Como referencia práctica, un BLEU por debajo de 10 —o un chrF++ por debajo de 20— suele indicar salidas dominadas por palabras frecuentes y cortas, cercanas al ruido. Bajo esa óptica, el modelo base v_0 se sitúa en el umbral de ruido en shw→spa (BLEU 9.73) y por debajo en spa→shw (BLEU 4.61), mientras que la variante seleccionada lo supera con holgura

Tabla 5.5: Métricas reranked por dirección sobre el conjunto de prueba de la variante x1. La separación evita que el promedio oculte diferencias entre traducir hacia castellano y traducir hacia shiwilu.

Variante (reranked)	shw→spa		spa→shw	
	chrF++	BLEU	chrF++	BLEU
v_0	25.16	9.73	28.06	4.61
v_{1bt} (+BT OPUS)	29.91	12.45	34.36	6.69
$v_{2.0}$ DoRA	30.82	14.55	34.35	6.46
$v_{2.1}$ DoRA+LoRA+	41.05	23.23	47.54	12.76
$v_{2.1b}$ LoRA+ ★	42.42	24.48	47.56	12.45
$v_{2.2}$ +BT iter1 (Wikipedia)	30.72	14.76	33.94	5.90

(BLEU 24.48 en shw→spa; chrF++ de 42 a 48 en ambas direcciones, muy por encima de 20). El salto, por tanto, no es solo numérico: separa un sistema apenas distinguible del ruido de uno que produce traducción con contenido.

Con base en esta evidencia, $v_{2.1b}$ LoRA+ se selecciona como la variante final del sistema evaluado. Dado que $v_{2.1}$ (DoRA+LoRA+) y $v_{2.1b}$ (LoRA+ solo) no son estadísticamente distinguibles —sus intervalos de confianza se traslapan—, la elección entre ambas se resuelve por parsimonia: $v_{2.1b}$ alcanza el mismo nivel con un adaptador más simple, sin el costo adicional de DoRA. En términos del proyecto, este resultado muestra que el sistema aprovecha de manera efectiva el corpus disponible y mejora con claridad frente a las variantes previas. La ganancia no depende de un único cambio aislado: combina un corpus más amplio, control de calidad sobre datos reales y sintéticos, ajuste eficiente del adaptador y reordenamiento semántico de hipótesis. En el contexto de una lengua de muy bajo recurso como el shiwilu, el desempeño alcanzado constituye un baseline sólido para continuar el desarrollo, precisamente porque se obtiene con un corpus paralelo reducido, de dominio limitado y con alta complejidad morfológica en una de las lenguas. Los detalles operativos de DoRA, LoRA+ y la generación del pool monolingüe

Tabla 5.6: Intervalos de confianza bootstrap del 95 % sobre chrF++ reranked y métricas complementarias promedio. BLEU y COMET se muestran como puntos sin intervalo de confianza.

Variante (reranked)	avg chrF++ [IC 95%]	BLEU avg	COMET avg
v_0	26.61 [25.33, 27.88]	7.17	0.648
v_{1bt} (+BT OPUS)	32.14 [30.63, 33.80]	9.57	0.683
$v_{2.0}$ DoRA	32.58 [31.02, 34.25]	10.51	0.688
$v_{2.1}$ DoRA+LoRA+	44.30 [42.49, 46.12]	18.00	0.745
$v_{2.1b}$ LoRA+ ★	44.99 [43.17, 46.96]	18.46	0.752
$v_{2.2}$ +BT iter1 (Wikipedia)	32.33 [30.82, 33.94]	10.33	0.687

iterativo se documentan en el Anexo C, sección A.

Adicionalmente, un análisis morfológicamente sensible mide chrF++ sobre el subconjunto de oraciones cuya referencia contiene una alta proporción de palabras raras en el corpus de entrenamiento, así como la tasa de recuperación de palabras estrictamente *out-of-vocabulary*. El reranking mantiene su ventaja sobre este régimen *rare-heavy*, aunque la tasa de recuperación OOV es uniformemente baja, lo cual motiva una de las líneas de trabajo futuro (Sección 8.2). El detalle por bucket morfológico y la calibración de la capa de confiabilidad por predicción se desarrollan en el Anexo C, secciones A y A.

5.2.7 Análisis cualitativo estratificado

Las métricas agregadas indican cuánto mejora el sistema, pero no muestran *dónde* acierta o falla. Para complementarlas se realizó un análisis cualitativo estratificado sobre las salidas reranked del modelo seleccionado $v_{2.1b}$: cada oración del conjunto de prueba se puntuó de forma individual y se agrupó en bandas de calidad. La dirección shw→spa se puntúa con BLEU por oración, indicador pertinente cuando la lengua destino es el castellano, y la dirección spa→shw con chrF++ por oración, porque BLEU penaliza en exceso la formación incompleta de palabras enteras en una lengua aglutinante y tiende a ocultar diferencias reales. Los cortes entre bandas siguen un umbral interpretativo de uso frecuente: puntajes de BLEU por debajo de 10, o de chrF++ por debajo de 20, suelen corresponder a salidas en las que solo coinciden palabras muy




Figura 5.2: Evolución del entrenamiento de $v_{2.1b}$ LoRA+ en la variante x1: pérdida de entrenamiento, pérdida de validación y chrF++ de validación por dirección.

frecuentes o cortas (pronombres, preposiciones, signos de puntuación) más que contenido real.

El Cuadro 5.7 muestra que la mayoría de las traducciones supera con holgura ese umbral. En $\text{shw} \rightarrow \text{spa}$, el 70 % de las salidas alcanza $\text{BLEU} \geq 20$ (puntaje medio 53.7) y solo el 17.3 % queda en la banda de ruido; en $\text{spa} \rightarrow \text{shw}$, el 55.2 % alcanza $\text{chrF++} \geq 40$ y apenas el 11.4 % queda por debajo de 20. Vista en detalle, la salida del sistema no es ruido sino traducción mayoritariamente informativa, lo que respalda la lectura cuantitativa de la sección anterior.

La inspección de ejemplos por banda permite caracterizar fortalezas y debilidades. En la banda alta de $\text{shw} \rightarrow \text{spa}$ abundan las coincidencias exactas o casi exactas, sobre todo en oraciones

Tabla 5.7: Distribución de las salidas de $v_{2.1b}$ reranked por banda de puntaje por oración (conjunto de prueba x1, 446 oraciones por dirección).

Dirección (métrica)	Banda	n	%	media
shw→spa (BLEU)	BLEU < 10	77	17.3	5.94
	10 ≤ BLEU < 20	57	12.8	14.21
	BLEU ≥ 20	312	70.0	53.69
spa→shw (chrF++)	chrF++ < 20	51	11.4	13.55
	20 ≤ chrF++ < 40	149	33.4	30.95
	chrF++ ≥ 40	246	55.2	67.41

cortas y frecuentes; por ejemplo, *¿eñupi'na pidek'pen?* se traduce como *¿dónde está tu casa?*, idéntica a la referencia. En la banda de ruido, en cambio, el sistema conserva a menudo el marco sintáctico pero yerra el contenido: *a'ñapalek sukta-shunka' iskun ekkilala* se traduce como *tengo doscientos metros de altura* en lugar de *tengo sesentinueve años* —la estructura *tengo + cantidad* es correcta, aunque el valor numérico no se preserva—, y *iyatulek' wayupi mer'cha'su'* (*me gusta la fruta madura*) se vuelve *detesto beber limpio*, con error de polaridad y de léxico. Estos casos confirman que un BLEU bajo no es arbitrario: señala pérdidas reales de sentido, no meras paráfrasis penalizadas.

En spa→shw, la banda alta es mayoritaria y reproduce la referencia de forma exacta incluso con morfología compleja, como *nosotros no trabajamos en la casa* → *kuda ku'la saka'tapi'ñidek pidek'kek*. La banda intermedia ilustra la asimetría morfológica ya discutida: el sistema acierta los lexemas y resuelve la mayor parte de la forma de la palabra, con desviaciones acotadas en la flexión plena que chrF++ capta parcialmente al operar sobre caracteres. La banda inferior se concentra, de manera previsible, en oraciones largas y con alta proporción de términos fuera de vocabulario, donde la calidad desciende; este comportamiento es coherente con la baja recuperación OOV ya señalada y motiva la capa de bandas de confiabilidad por predicción (Anexo C, sección A) y la línea de trabajo futuro sobre cobertura de vocabulario.

Conviene señalar una limitación del propio análisis: en $\text{spa} \rightarrow \text{shw}$ la salida está en shiwilu, por lo que su revisión fina excede lo que puede juzgarse con rigor sin el apoyo de un hablante nativo. Por ello el examen cualitativo de esta dirección se apoya en chrF++ y en el contraste con la referencia, y deja la valoración lingüística y cultural detallada para el protocolo participativo del Capítulo 6.

5.3 Discusión

Los resultados automáticos indican que la contribución más importante para el par shiwilu–castellano proviene de combinar transferencia multilingüe, adaptación eficiente y control semántico de los datos. NLLB aporta una base multilingüe razonable, LoRA permite ajustar el modelo sin entrenar todos los parámetros, y el modelo de *embeddings* congelado actúa como verificador independiente para filtrar entrenamiento, admitir datos sintéticos y reordenar hipótesis. Esta composición es consistente con la literatura de NMT *low-resource*: cuando el paralelo es limitado, la calidad del dato, el dominio y el control experimental suelen pesar tanto como la arquitectura. En ese marco, la mejora clara y estable sobre las variantes previas permite sostener que SA-BiNLLB constituye una base técnica consistente para el par shiwilu–castellano.

La comparación entre v_0 , v_{1bt} y las variantes posteriores muestra que la augmentación controlada mejora el sistema, pero también que el aumento de volumen no es suficiente por sí mismo. El retroceso de $v_{2.2}$ al usar Wikipedia como pool monolingüe evidencia una limitación central: en lenguas de bajo recurso, un conjunto sintético grande pero alejado del dominio puede introducir ruido más rápido de lo que aporta cobertura (Edunov et al., 2018; Hoang et al., 2018). En cambio, LoRA+ sobre LoRA estándar produce la mejora más clara del conjunto de ablaciones, lo que sugiere que, dentro del presupuesto de datos disponible, la dinámica de optimización del adaptador fue más decisiva que aumentar la complejidad arquitectónica con DoRA (Hayou et al., 2024; Hu et al., 2022).

La evaluación automática cumple el IOV del OE2 porque reporta BLEU, chrF++ y COMET por dirección, compara variantes, incluye reranking, documenta ablaciones y agrega intervalos de confianza bootstrap para la métrica primaria. Estos resultados permiten cerrar la comparación

técnica de los modelos NMT y seleccionar una variante final bajo criterios reproducibles. A partir de esta base cuantitativa, el Capítulo 6 organiza el protocolo de evaluación automática y participativa.

La generalización del sistema debe formularse con prudencia. SA-BiNLLB muestra que un pipeline reproducible con corpus curado, embeddings bilingües, PEFT y reranking puede producir un baseline sólido para una lengua originaria de muy bajo recurso. Sus resultados se interpretan dentro del marco experimental definido: tamaño reducido del corpus, concentración de dominio en flashcards y narrativas, y baja recuperación de términos OOV. En consecuencia, el capítulo establece la base cuantitativa del sistema y enlaza naturalmente con el protocolo de evaluación del capítulo siguiente.

5.4 Conclusión del capítulo

El sistema SA-BiNLLB articula las tres decisiones de diseño anunciadas al inicio del capítulo: NLLB-200 distilled como *backbone* multilingüe pre-entrenado, un único *adapter* LoRA bidireccional que ajusta el modelo al par shiwilu–castellano, y la reutilización del modelo de *embeddings* bilingüe v3 congelado como evaluador semántico independiente que filtra el corpus de entrenamiento, modera la admisión de pares sintéticos y reordena las hipótesis del decodificador. La evaluación cuantitativa muestra que la combinación de un corpus mayor (variante x1), una augmentación cuya admisión la decide el evaluador semántico (v_{1bt}), el optimizador LoRA+ con tasas de aprendizaje asimétricas $B/A = 16$ sobre LoRA estándar ($v_{2.1b}$) y el reranking semántico produce el mejor sistema evaluado (avg chrF++ = 44,99, IC 95 % [43,17, 46,96]) con un margen estadísticamente claro sobre v_{1bt} . Con ello se cumplen R3 y R4 como modelos bidireccionales implementados y evaluados automáticamente. En conjunto, estos resultados dejan seleccionado el modelo que servirá como referencia para el protocolo de evaluación del capítulo siguiente. El detalle operativo del sistema: hiperparámetros, fórmulas, umbrales, ablaciones completas y desviaciones documentadas frente al plan original se consigna en el [Anexo C](#).

Capítulo 6

Protocolo de validación automática y participativa

6.1 Introducción

Este capítulo desarrolla el objetivo específico 3: definir y aplicar una primera ejecución de un protocolo de validación que combine evaluación automática y validación participativa con hablantes para medir adecuación lingüística y pertinencia cultural en el sistema shiwilu↔castellano. El capítulo anterior permitió seleccionar una variante NMT bajo criterios cuantitativos reproducibles; sin embargo, en traducción de lenguas originarias esa evidencia no basta por sí sola para afirmar que una salida será aceptable para la comunidad de uso. Por ello, este capítulo contrasta las métricas automáticas con juicios humanos sobre sentido, naturalidad y decisión práctica de uso.

El resultado de este capítulo es metodológico, operativo y empírico: se define el protocolo, se documenta el instrumento de revisión y se reporta su primera ejecución completa. Dicha ejecución se realizó con Fidel Lomas Chota, uno de los principales exponentes y preservadores contemporáneos del shiwilu vinculados al proyecto, sobre una muestra balanceada de 100 traducciones del modelo seleccionado. El alcance corresponde a R5 y a sus medios de verificación MV5/IOV5: métricas automáticas reportadas, muestra acotada revisada, rúbrica de evaluación, planilla de captura completada y resultados humanos agregados. Los detalles técnicos del instrumento se consignan en el [Anexo C.12](#); la síntesis metodológica y los resultados de la ejecución participativa se presentan como [Anexo E](#).

6.2 Resultados alcanzados

El protocolo alcanzado articula dos niveles de evidencia. El primero es la evaluación automática ya ejecutada sobre el conjunto de prueba. En esta etapa se tradujeron las 892 filas direccionales del *test* de la variante x1, distribuidas en 446 ejemplos shiwilu→castellano y 446 ejemplos castellano→shiwilu. Sobre esas salidas se calcularon BLEU, chrF++ y COMET para cada variante del sistema. BLEU se conserva como indicador comparativo estándar basado en coincidencias de n-gramas; chrF++ se adopta como métrica primaria por su sensibilidad a formas morfológicas y coincidencias parciales; y COMET se reporta como señal semántica complementaria. En la lectura por dirección, BLEU funciona como indicador de cabecera hacia el castellano y chrF++ hacia el shiwilu, criterio coherente con el análisis cualitativo estratificado de la sección 5.2.7. Además, el reranking semántico se evalúa de forma explícita porque reordena las cinco mejores hipótesis del decodificador combinando probabilidad de traducción y similitud semántica.

La validación automática no se limita a una tabla agregada. Primero, las métricas se reportan por dirección para evitar que el promedio oculte diferencias entre traducir hacia castellano y traducir hacia shiwilu. Segundo, se compara el modelo base, el modelo aumentado y las ablaciones posteriores bajo el mismo conjunto de prueba. Tercero, se estiman intervalos bootstrap para chrF++, lo que permite interpretar si las diferencias observadas son consistentes y no solo variación muestral. Esta base cuantitativa permite seleccionar una variante candidata bajo criterios reproducibles; en este caso, $v_{2.1b}$ LoRA+ con reranking semántico. Los resultados se observan en los Cuadros 5.4, 5.5 y 5.6.

El segundo nivel es la validación participativa aplicada con un revisor competente. La muestra contiene 100 ítems en total: 50 en la dirección shiwilu→castellano y 50 en la dirección castellano→shiwilu, extraídos del conjunto de prueba del modelo seleccionado $v_{2.1b}$ LoRA+ con reranking semántico. La selección se planteó como una muestra dirigida y balanceada por dirección, apoyada en criterios automáticos de calidad y usabilidad. Además, se buscó que la muestra incluyera traducciones con distintos niveles de desempeño: algunas claramente logradas, otras razonables pero revisables, y otras con errores visibles. Esta variedad permite que el

revisor no evalúe solo casos favorables, sino un repertorio amplio del comportamiento real del traductor, manteniendo al mismo tiempo una carga de trabajo razonable.

Tabla 6.1: Estado de los componentes del protocolo de validación.

Componente	Estado	Evidencia generada	Uso previsto
Evaluación automática	Ejecutada	Métricas BLEU, chrF++, Selección del modelo COMET, resultados por dirección e intervalos bootstrap	
Modelo para revisión	Seleccionado	Variante $v_{2.1b}$ LoRA+ con reranking semántico	Generar la muestra participativa
Muestra de revisión	Aplicada	100 ítems balanceados: 50 por dirección	Presentar casos revisables a hablantes
Rúbrica	Definida	Sentido, naturalidad, decisión y comentarios	Registrar juicios lingüísticos y culturales
Planilla de captura	Completada	Archivo validacion_participativa_100.xlsx	Recoger puntajes y observaciones
Resultados humanos	Consolidados	Promedios por dirección, decisiones y comentarios de corrección	Contrastar métricas automáticas con juicio experto
Preferencia pareada	Generada	Archivo pairwise_preference.xlsx con clave anónima aparte	Elegir el modelo cuando las métricas empatan

La construcción del archivo sigue un flujo reproducible. Primero, el script toma las predicciones reranked del modelo seleccionado. Segundo, calcula indicadores automáticos de calidad para ordenar y controlar la muestra dentro del conjunto de prueba. Tercero, descarta automáticamente casos no aptos para revisión, como salidas vacías, texto con codificación defectuosa o repeticiones severas. Cuarto, selecciona la cuota de ejemplos por dirección. Quinto, genera un libro Excel único, reports/05_nmt/evaluation_xl/human_validation_100.xlsx, con una hoja de instrucciones y dos hojas de revisión. La ejecución completada queda preservada como anexo digital externo en https://docs.google.com/spreadsheets/d/1dYJ_4qstg76dHtDs6qaIICG5aBeiG7kL/edit?usp=sharing&ouid=110915706047387486036&rtpof=true&sd=true, como anexo local de entrega en anexos_digitales/Anexo_E_validacion_participativa_100.xlsx y como copia reproducible del repositorio en reports/05_nmt/evaluation_xl/validacion_participativa_100.xlsx. Fi-

nalmente, la validación programática confirma que cada dirección tiene exactamente 50 filas, que los puntajes 1–5 están completos, que las decisiones se normalizan en aceptar/corregir/rechazar y que todos los casos marcados como corregibles incluyen comentario.

La planilla se diseña como un instrumento simple de revisión por hablantes. Cada fila presenta el texto fuente y la traducción generada por el modelo, junto con campos vacíos para registrar puntajes y observaciones. El archivo contiene una hoja de instrucciones y dos hojas de evaluación, una por dirección. Los encabezados son deliberadamente legibles para usuarios no técnicos: *N*, *Texto fuente*, *Traducción del modelo*, *Sentido (1–5)*, *Naturalidad (1–5)*, *Decisión* y *Comentarios*. Con ello, el instrumento prioriza la comprensión del hablante y evita exponer metadatos internos del experimento.

La rúbrica propuesta usa escala 1–5 en dos dimensiones principales, más una decisión global:

Sentido (1–5). Evalúa si la traducción conserva el significado del texto fuente; 5 indica que el sentido se mantiene bien y 1 que cambia el sentido o falta información importante.

Naturalidad (1–5). Evalúa si la traducción suena natural en la lengua de llegada; 5 indica una formulación natural y 1 una salida rara, forzada o difícil de entender.

Decisión. Permite clasificar cada caso como *aceptar*, *corregir* o *rechazar*, acompañado opcionalmente de comentarios.

Estas dimensiones responden a criterios que las métricas automáticas no separan por sí solas. El sentido se vincula con la preservación del contenido; la naturalidad, con la aceptabilidad lingüística de la salida; y la decisión global permite distinguir traducciones listas para uso de aquellas que requieren corrección o rechazo. Con ello, R5 queda documentado y aplicado en una primera ronda: existe una base automática de comparación, una muestra participativa acotada, una rúbrica de evaluación, una planilla de captura completada y resultados humanos agregados.

6.2.1 Primera ejecución de la validación participativa

La primera ejecución se realizó con Fidel Lomas Chota, hablante/revisor competente y actor central en la preservación del shiwilu dentro del trabajo con el Grupo Chana. Su participación

no se trata como una revisión menor o preliminar, sino como una evaluación lingüística especialmente calificada por su dominio del idioma, su producción de relatos y su colaboración directa en la documentación de materiales. El mismo instrumento podría aplicarse a nuevos revisores sin cambiar la muestra, la rúbrica ni el formato de captura; sin embargo, en una lengua con disponibilidad muy restringida de hablantes, esa ampliación depende de condiciones logísticas y comunitarias complejas. Por ello, la posibilidad de repetir la validación se plantea como una vía de ampliación metodológica, no como una debilidad de la evidencia obtenida.

El Cuadro 6.2 resume los resultados agregados. La dirección shiwilu→castellano fue la más sólida: obtuvo promedio de Sentido = 4,74, Naturalidad = 4,76 y 82 % de traducciones aceptadas. La dirección castellano→shiwilu también fue favorable, con Sentido = 4,58, Naturalidad = 4,68 y 78 % de aceptadas, aunque concentró más correcciones. En conjunto, el 80 % de las traducciones fue aceptado, el 20 % fue marcado como corregible y no hubo rechazos.

Tabla 6.2: Resultados agregados de la primera validación participativa.

Dirección	n	Sentido	Naturalidad	Aceptar	Corregir / Rechazar
shw→spa	50	4,74	4,76	41 (82 %)	9 (18 %) / 0 (0 %)
spa→shw	50	4,58	4,68	39 (78 %)	11 (22 %) / 0 (0 %)
Global	100	4,66	4,72	80 (80 %)	20 (20 %) / 0 (0 %)

Los comentarios del revisor indican que los errores detectados fueron recuperables mediante correcciones puntuales. En shiwilu→castellano predominan ajustes de precisión semántica, como distinguir “quiero ganar” de “quiero ganarle”, corregir persona o número, o evitar agregados léxicos. En castellano→shiwilu aparecen con mayor frecuencia problemas de selección léxica, concordancia y forma morfológica, por ejemplo al traducir imperativos, plurales o expresiones largas. El Cuadro 6.3 muestra ejemplos representativos; el Excel anexo conserva la revisión completa.

La lectura académica de estos resultados confirma la asimetría observada en la evaluación automática. Traducir desde shiwilu hacia castellano resultó más estable porque el sistema produce una lengua destino de mayor cobertura en los modelos multilingües y con menor exigencia morfológica generativa. La dirección castellano→shiwilu, aun con promedios altos, exige ma-

Tabla 6.3: Ejemplos representativos de correcciones en la validación participativa.

Dirección	Fuente	Traducción del modelo	Observación del revisor
shw→spa	<i>yakana'lek</i>	quiero ganar.	Más precisamente dice “quiero ganarle”.
shw→spa	<i>dei'techek</i>	me mataré.	La forma esperada es “lo mataré”.
shw→spa	<i>¿luwer'chapadekla?</i>	¿me conoces?	Más preciso: “¿los conoces?”.
spa→shw	te mostraré.	<i>alli'echek</i>	<i>A'lli'echen</i> corresponde a “te mostraré”; <i>a'lli'echek</i> a “le mostraré”.
spa→shw	lean esto.	<i>luntuker'asu'</i>	La oración en castellano está en plural; debería ser <i>luntuku'</i> .
spa→shw	¿estás cansado?	<i>¿iker'su' ñapala?</i>	Se propone <i>Saka'tusu' ñapala?</i> .

yor control de morfología, concordancia y selección léxica; por ello acumula más comentarios de corrección. El hecho de que no haya rechazos es metodológicamente relevante: la muestra revisada no revela salidas inutilizables, sino traducciones mayoritariamente aceptables o corregibles.

6.2.2 Instrumento complementario de preferencia pareada

La rúbrica anterior mide cada traducción de forma absoluta, pero hay decisiones que conviene resolver por comparación directa. Cuando dos variantes del sistema obtienen métricas estadísticamente indistinguibles —como ocurre con $v_{2.1}$ y $v_{2.1b}$, cuyos intervalos de confianza se traslapan—, los promedios automáticos no bastan para elegir entre ellas. Para ese caso se preparó un instrumento de preferencia pareada de elección forzada: en cada ítem se muestran la referencia y dos traducciones, etiquetadas como Opción A y Opción B, y el evaluador indica cuál se acerca más a la referencia.

El diseño sigue tres principios. Primero, es ciego: el orden A/B se aleatoriza por fila y oculta qué sistema produjo cada salida, de modo que la elección no se contamina con preferencias previas; la correspondencia entre etiqueta y sistema se guarda en una clave aparte. Segundo, admite

empates explícitos, porque dos salidas pueden ser igual de cercanas —o igual de deficientes— y forzar una elección introduciría ruido. Tercero, se aplica sobre la dirección shw→spa, cuya salida en castellano puede juzgarse sin requerir un hablante de shiwilu, lo que permite emplearlo como contraste rápido previo a la validación con hablantes.

El instrumento se generó como un libro de cálculo con 60 pares, extraídos de las salidas reranked y limitados a los casos en que ambos sistemas difieren (cuando coinciden no hay preferencia que expresar). Su uso previsto es doble: permitir una decisión de selección entre modelos empatados y, más adelante, recoger preferencias de hablantes de forma sencilla. Los detalles de reproducción se consignan en el Anexo C, sección A.

La revisión participativa aplicada permite resumir los puntajes de sentido y naturalidad por dirección y por tipo de decisión. Las respuestas *aceptar*, *corregir* y *rechazar* estiman qué proporción de salidas puede considerarse utilizable sin edición, qué proporción requiere intervención y qué casos revelarían errores fuertes. Los comentarios abiertos identifican patrones que las métricas no muestran directamente, como problemas de registro, elección léxica, omisiones, exceso de literalidad o formulaciones poco naturales.

6.3 Discusión

Contar con este protocolo y con una primera ejecución resuelve una brecha metodológica importante para lenguas de muy bajo recurso: evita que la calidad del traductor se interprete únicamente desde indicadores automáticos e incorpora juicio lingüístico y cultural. BLEU permite mantener comparabilidad con literatura previa, chrF++ ofrece una señal más robusta ante variación morfológica y COMET aporta una estimación semántica complementaria; sin embargo, ninguna de estas métricas sustituye la revisión de hablantes. BLEU es sensible a coincidencias superficiales, chrF++ captura semejanza formal sin agotar el juicio lingüístico, y COMET no fue entrenado específicamente para shiwilu.

La validación participativa aplicada complementa esa base automática porque separa criterios que las métricas tienden a mezclar: preservación del sentido, naturalidad de la salida y decisión práctica de aceptación, corrección o rechazo. Esta separación es especialmente relevante en

traducción de lenguas originarias, donde una salida puede parecer cercana formalmente pero fallar en registro, cortesía, uso idiomático o elección léxica culturalmente marcada. La planilla también fortalece el diseño al presentar solo los campos necesarios para el juicio del hablante, sin sobrecargar la revisión con metadatos técnicos.

El tamaño de la validación debe interpretarse desde las condiciones sociolingüísticas del shiwilu. En una lengua con muy pocos hablantes disponibles, una revisión completa de 100 ítems por un revisor de la trayectoria de Fidel Lomas Chota aporta evidencia valiosa, trazable y metodológicamente pertinente, especialmente porque cubre ambas direcciones y conserva comentarios cualitativos en los casos corregibles. Si en el futuro se logra coordinar con más hablantes, el instrumento permitiría calcular acuerdo interevaluador y contrastar discrepancias; no obstante, esa ampliación debe entenderse como fortalecimiento adicional y no como requisito para reconocer el valor de la validación ya ejecutada. En términos de trazabilidad, el OE3 queda cumplido en su componente protocolar, documental y de primera ejecución participativa.

6.4 Conclusión del capítulo

El capítulo establece y aplica el protocolo de validación automática y participativa asociado al OE3. La contribución consiste en fijar una ruta de evaluación y ejecutar una primera revisión completa que permite interpretar las métricas automáticas junto con juicios lingüísticos y culturales. Esta combinación es metodológicamente necesaria: en un par de muy bajo recurso como shiwilu–castellano, las métricas automáticas permiten comparar modelos, pero la aceptabilidad final de las traducciones requiere revisión por hablantes o evaluadores competentes.

Con ello, R5 queda cerrado como protocolo documentado y aplicado inicialmente, y R8 queda respaldado por una primera ejecución participativa con resultados agregados: 80 % de traducciones aceptadas, 20 % corregibles y 0 % rechazadas. La aplicación del mismo instrumento con más revisores, si las condiciones de disponibilidad de hablantes lo permiten, queda como una continuidad metodológica posible para ampliar el análisis, calcular acuerdo interevaluador y estudiar discrepancias entre juicios humanos.

Capítulo 7

Prototipo funcional del traductor automático

7.1 Introducción

Los capítulos anteriores dejaron seleccionado un modelo de traducción bajo criterios cuantitativos reproducibles (Capítulo 5) y un protocolo para contrastar esas métricas con el juicio de hablantes (Capítulo 6). Sin embargo, mientras el sistema solo pueda ejecutarse desde la línea de comandos del entorno de experimentación, su uso queda restringido al propio desarrollo y no resulta accesible para docentes, miembros de la comunidad ni evaluadores no técnicos. Este capítulo desarrolla el cuarto objetivo específico: diseñar e implementar un prototipo funcional de traductor automático neuronal que integre el modelo entrenado y facilite su uso y prueba.

El resultado de este capítulo es un componente de software, no un nuevo modelo. El prototipo no reentrena ni modifica el sistema SA-BiNLLB; reutiliza el modelo campeón $v_{2.1b}$ LoRA+ y el modelo de *embeddings* v3 ya congelados, y los orquesta detrás de una interfaz web sencilla que permite escribir una oración, elegir la dirección de traducción y obtener la salida en ambos sentidos. El alcance corresponde a R6 y a sus medios de verificación MV6/IOV6: un prototipo operativo ejecutable localmente, una guía breve de uso, la demostración de traducción de ejemplos y un registro estructurado de los casos de prueba. La organización del capítulo sigue el mismo orden que los enunciados del objetivo: primero la arquitectura que reutiliza el modelo, luego la funcionalidad de la interfaz, después el registro de uso y la integración ejecutable, y finalmente la demostración con casos reales. El [Anexo D](#) reúne la evidencia funcional del prototipo y deja la trazabilidad técnica como respaldo.


7.2 Resultados alcanzados

Este capítulo reporta el resultado asociado al cuarto objetivo específico: un prototipo funcional que integra el sistema NMT y habilita su uso y prueba. El entregable central es R6, el prototipo ejecutable localmente, acompañado de su guía de uso y de un registro estructurado de entradas y salidas que sustenta el medio de verificación. El [Anexo D](#) funciona como medio de verificación de la funcionalidad, los casos registrados y la trazabilidad técnica mínima.

7.2.1 Arquitectura del prototipo

El prototipo se implementa como una aplicación web ligera construida sobre la biblioteca Gradio, que expone la interfaz en el navegador sin requerir que el usuario interactúe con la línea de comandos. Su diseño reutiliza, sin alterarlos, los tres bloques del sistema SA-BiNLLB descritos en el Capítulo 5, de modo que el prototipo actúa como una capa de orquestación e interacción por encima de artefactos ya validados.

Figura 7.1: Arquitectura del prototipo funcional: capa de interfaz sobre el sistema SA-BiNLLB $v_{2.1b}$ congelado.



El primer bloque es el modelo de traducción: el prototipo carga una sola vez, al arrancar, el *checkpoint* del modelo seleccionado $v_{2.1b}$ LoRA+ junto con su *tokenizer* extendido y su configuración de generación. La carga única en memoria evita reinicializar el modelo en cada solicitud y mantiene la latencia de cada traducción dentro de un rango interactivo. El segundo bloque

es el componente de apoyo semántico: el mismo modelo de *embeddings* bilingüe v3 congelado en el Capítulo 4, que el prototipo emplea para reordenar las hipótesis del decodificador. El reordenamiento usa exactamente la combinación lineal definida en el Capítulo 5 y detallada en el Anexo C, sección C.5: una mezcla convexa entre la probabilidad de traducción del decodificador y la similitud coseno fuente–candidato del modelo de *embeddings*, con el coeficiente $\alpha = 0,7$ que resultó óptimo para el modelo campeón. El tercer bloque es la propia capa de interfaz, que recibe la oración del usuario, dispara la decodificación por búsqueda en haz ($k = 5$), aplica el reranking semántico cuando está activado y devuelve la traducción elegida junto con sus alternativas.

Conviene subrayar que el prototipo no introduce ningún parámetro entrenable nuevo ni vuelve a ejecutar el *pipeline* de entrenamiento: reutiliza las mismas funciones de inferencia y reranking validadas en el Capítulo 5, de modo que la calidad de las traducciones es, por construcción, la del modelo campeón ya evaluado. La evidencia funcional y la mecánica general de carga se resumen en el Anexo D.

7.2.2 Funcionalidad de la interfaz

La interfaz se diseñó priorizando la funcionalidad mínima exigida por el objetivo, es decir, el ingreso de texto y la visualización de resultados de forma simple y accesible, y siguiendo convenciones de uso ampliamente conocidas en traductores en línea, de manera que un usuario no técnico pueda operarla sin instrucciones extensas. La vista principal presenta dos áreas de texto contiguas: a la izquierda, el cuadro donde el usuario escribe la oración fuente; a la derecha, el cuadro donde aparece la traducción. Entre ambas, un control de intercambio ($\rightleftharpoons$) invierte la dirección de traducción y reutiliza la salida previa como nueva entrada, lo que facilita comparar ambos sentidos. La salida incluye un botón para copiar el resultado y un conjunto de sugerencias con las siguientes mejores hipótesis del modelo, que el usuario puede seleccionar con un clic para reemplazar la traducción mostrada.

Las opciones más técnicas se mantienen ocultas tras un panel de *Opciones avanzadas* para no recargar la vista de un usuario ocasional, siguiendo un criterio de divulgación progresiva: allí se exponen el interruptor del reranking semántico, el control del coeficiente α y la tabla completa

Figura 7.2: Interfaz del prototipo funcional: traducción castellano→shiwilu con el modelo $v_{2.1b}$ y reranking semántico.

Traductor Castellano – Shiwilu

Traduce oraciones en ambos sentidos

Castellano

↔

Shiwilu

Dame eso

enka'u nana

☐ Traducir mientras escribo

Otras opciones

enka'ker' nana

enka'u nanek

enka'uler' nana

Limpiar

Traducir

Opciones avanzadas

Ejemplos

yo exageré. · ES→SHW

me gusta el caldo de gallina. · ES→SHW

sólo el pueblo de ellos se reproduci... · ES→SHW

kua a'nadalek · SHW→ES

iyatulek wa'dante' dek · SHW→ES

madettanna' a'ullinerku. · SHW→ES

Prototipo experimental (SA-BiNLLB) · NLLB-200 + LoRA+ (v2.1b, xl) · reranker E5-base (v3, xl) · chrF++ 44.99 · las traducciones pueden contener errores

de hipótesis con sus puntajes. Por defecto, la aplicación arranca en modo claro, con el reranking activado y con la traducción automática mientras se escribe desactivada, de modo que cada traducción responde a una acción explícita del usuario. La interfaz incluye además ejemplos cargables con un clic, etiquetas en castellano legible (*Castellano* y *Shiwilu* en lugar de los códigos internos del modelo) y un conmutador de modo claro u oscuro. Con ello, la funcionalidad mínima del objetivo queda cubierta y ampliada con comodidades que no comprometen la simplicidad de la vista principal.

7.2.3 Registro estructurado de uso

Para habilitar el análisis posterior de las pruebas, cada traducción se registra en un archivo de bitácora con formato JSON por líneas, en el que cada línea es un objeto independiente que documenta una traducción completa. El registro guarda la marca temporal, la dirección, el texto fuente, la salida elegida, si el reranking estuvo activo, el valor de α , la lista de hipótesis candidatas con su puntaje final y la latencia de la operación en milisegundos. El Cuadro 7.1 resume la información que se conserva en cada traducción; la ubicación del archivo y los nombres exactos de los campos se documentan en el Anexo D, sección D.4.

Tabla 7.1: Información que el prototipo conserva en el registro de uso por cada traducción.

Información registrada	Contenido
Marca temporal	Fecha y hora de la traducción
Dirección	Sentido de la traducción (castellano→shiwilu o shiwilu→castellano)
Texto fuente	Oración ingresada por el usuario
Traducción	Salida finalmente mostrada
Reranking	Si el reordenamiento semántico estuvo activo y con qué coeficiente α
Candidatos	Lista de hipótesis del decodificador con su puntaje final
Latencia	Tiempo de cómputo de la traducción en milisegundos

Este registro responde directamente al medio de verificación del objetivo, que exige habilitar pruebas básicas y un registro estructurado de entradas y salidas para análisis. La bitácora permite, por ejemplo, recuperar los casos efectivamente probados, comparar latencias por dirección

o auditar qué hipótesis alternativas ofreció el sistema en cada consulta. El esquema completo del registro se desarrolla en el Anexo D, sección D.4.

7.2.4 Integración y despliegue

El prototipo se empaqueta junto con el resto del sistema NMT, de modo que no introduce dependencias nuevas más allá de la biblioteca de interfaz, y se ejecuta sobre la GPU disponible. Para facilitar su puesta en marcha sin conocimientos técnicos, se proveen dos lanzadores equivalentes para Windows que abren la aplicación con un doble clic. Por defecto, la interfaz queda disponible de forma local en el navegador y, de forma opcional, genera un enlace público temporal que permite compartir la demostración con colaboradores remotos durante una sesión, sin desplegar un servidor permanente. Esta última posibilidad es coherente con el alcance del proyecto, que reserva el despliegue web de acceso público como trabajo futuro y delimita el entregable a un prototipo local de demostración. La forma de uso y la trazabilidad mínima se resumen en el Anexo D.

7.2.5 Demostración y casos de prueba

Para verificar el funcionamiento de extremo a extremo se ejecutaron, a través de la interfaz, traducciones de demostración en ambas direcciones tomadas del conjunto de prueba, cuya traducción de referencia es conocida. El Cuadro 7.2 reúne una muestra de casos en los que la salida del prototipo coincide con esa referencia, registrados además en la bitácora del prototipo. Las traducciones reproducen el comportamiento del modelo campeón evaluado en el Capítulo 5: oraciones cortas y frecuentes se resuelven de forma directa, y la latencia se mantiene en el rango interactivo (del orden de décimas de segundo por traducción), lo que confirma que la carga única del modelo es suficiente para un uso fluido.

Conviene señalar una limitación operativa observada durante las pruebas: cuando se activa la opción de traducir mientras se escribe, el sistema produce traducciones de oraciones aún incompletas, que pueden resultar erráticas hasta que la frase se termina. Por ese motivo dicha opción permanece desactivada por defecto y la traducción responde, salvo que el usuario indique lo contrario, a una acción explícita. El Cuadro 7.3 resume el estado de los componentes del prototipo

Tabla 7.2: Casos de prueba de demostración en ambas direcciones, tomados del conjunto de prueba de la variante x1, en los que la salida del prototipo coincide con la traducción de referencia (modelo $v_{2.1b}$ con reranking, $\alpha = 0,7$).

Dirección	Texto fuente	Traducción del prototipo	Latencia
shw→spa	werampalek	estoy comiendo.	$\approx 0,14$ s
shw→spa	yakana'lek	quiero ganar.	$\approx 0,08$ s
shw→spa	enka'u nana	dame eso.	$\approx 0,27$ s
spa→shw	dame eso.	enka'u nana	$\approx 0,25$ s
spa→shw	olvídenlo.	pinaner'ku'	$\approx 0,27$ s

y la evidencia que respalda cada uno.

Tabla 7.3: Estado de los componentes del prototipo funcional.

Componente	Estado	Evidencia generada	Uso previsto
Interfaz web	Implementada	Aplicación web (Gradio) con en- trada bidireccional y opciones avanzadas	Traducir y probar el modelo sin línea de comandos
Integración del modelo	Operativa	Carga única del campeón $v_{2.1b}$ y del reranker v3 congelados	Reutilizar el sistema evaluado sin reentrenarlo
Registro de uso	Generado	Bitácora por sesión con entradas, salidas y latencias	Auditar y analizar los casos probados
Lanzadores	Provisionados	Dos lanzadores para Windows	Ejecutar el prototipo en local
Despliegue público	Acotado	Enlace temporal opcional por sesión	Demostración remota puntual

Con ello, R6 queda cumplido como prototipo funcional ejecutable localmente: existe una interfaz operativa que integra el modelo seleccionado, una guía breve de uso y unos lanzadores que simplifican su puesta en marcha, una demostración de traducción de ejemplos en ambas direcciones y un registro estructurado de los casos de prueba.

7.3 Discusión

El prototipo cierra el recorrido técnico de la tesis al convertir un sistema que hasta ahora solo vivía en el entorno de experimentación en una herramienta que cualquier usuario puede operar

desde el navegador. Su aporte no es un avance de calidad de traducción, que quedó fijada y medida en el Capítulo 5, sino de accesibilidad y verificabilidad: hace tangible el resultado del proyecto, habilita pruebas por parte de personas ajenas al desarrollo y produce un registro que documenta cómo se comporta el sistema ante entradas reales. En el contexto de una lengua de muy bajo recurso, contar con una interfaz sencilla y un mecanismo de registro es relevante porque facilita la futura recolección de retroalimentación de hablantes y docentes sobre casos de uso concretos.

La lectura del alcance debe ser prudente. El prototipo es deliberadamente local y de demostración: no constituye un servicio web de acceso público ni una aplicación móvil, opciones que el propio alcance del proyecto reserva como trabajo futuro. Su calidad de traducción está acotada por la del modelo subyacente, con las asimetrías por dirección y las limitaciones de cobertura de vocabulario ya discutidas; la opción de traducción en tiempo real evidencia esa frontera al exponer salidas parciales sobre frases incompletas. Finalmente, el prototipo habilita la prueba del sistema, mientras que la valoración lingüística y cultural de sus salidas se articula con el protocolo participativo del Capítulo 6, cuya primera ejecución ya fue aplicada sobre 100 ítems. En conjunto, el prototipo satisface el objetivo de facilitar el uso y la prueba del modelo sin sobrepasar el alcance académico definido para esta versión del trabajo.

7.4 Conclusión del capítulo

El capítulo cumple el cuarto objetivo específico al entregar un prototipo funcional que integra el modelo seleccionado $v_{2.1b}$ LoRA+ con reranking semántico y lo expone a través de una interfaz web sencilla, ejecutable localmente y acompañada de lanzadores para su puesta en marcha. El prototipo reutiliza los artefactos congelados del sistema SA-BiNLLB sin reentrenarlos, ofrece traducción bidireccional con visualización clara y opciones avanzadas opcionales, y persiste un registro estructurado de cada traducción que sirve como medio de verificación de las pruebas. Con ello, R6 queda cumplido como prototipo funcional ejecutable localmente que integra el modelo NMT y permite pruebas básicas con registro estructurado de entradas y salidas. La evidencia funcional y la trazabilidad mínima del prototipo se consignan en el Anexo D.

Capítulo 8

Conclusiones y trabajos futuros

8.1 Conclusiones

Esta tesis avanzó sobre cuatro componentes del sistema de traducción automática neuronal shiwilu–castellano: la construcción del corpus y recurso de representación semántica, la implementación del modelo NMT bidireccional SA-BiNLLB, la validación automática y participativa, y la integración de un prototipo funcional. El primer resultado fue un corpus paralelo consolidado de 4814 pares útiles, procedentes de ocho fuentes bilingües, con normalización no destructiva, auditoría de duplicados, trazabilidad por origen y particiones reproducibles. Este resultado responde al OE1 y queda verificado por las tablas, manifiestos y reportes del [Anexo B](#).

El segundo resultado del OE1 fue un modelo de *embeddings* bilingüe preparado y evaluado. La variante v3 de E5-base bidireccional con minería iterativa de negativos alcanzó R@1 de 0,8080 en castellano→shiwilu y 0,7857 en shiwilu→castellano sobre oraciones completas de prueba, además de valores R@5 y R@10 superiores a 0,93 en ambas direcciones. Este recurso no se presentó como traductor final, sino como medio semántico auxiliar para recuperar equivalencias, filtrar pares y apoyar el pipeline NMT.

Respecto del OE2, se implementó y evaluó un sistema NMT bidireccional basado en NLLB-200 distilled, adaptación LoRA, aumentación controlada, reranking semántico y ablaciones de optimización. El mejor resultado fue $v_{2.1b}$ con LoRA+ y reranking, que alcanzó avg chrF++ = 44,99 con IC 95 % [43,17, 46,96]. Para una lengua de muy bajo recurso, con corpus reducido y alta complejidad morfológica, este resultado constituye un baseline sólido para continuar el desarrollo. Las pruebas muestran que la mejora depende tanto del corpus x1 como de la calidad

de los datos sintéticos y del optimizador; también muestran que la backtranslation fuera de dominio puede degradar el modelo aun cuando aumente el volumen de entrenamiento.

Respecto del OE3, se definió y aplicó una primera ejecución de un protocolo que combina evaluación automática y validación participativa. El componente automático quedó respaldado por *leaderboard*, métricas por dirección, reranking, análisis bootstrap y comparación de variantes sobre el conjunto de prueba. El componente participativo se aplicó sobre una muestra balanceada de 100 ítems, 50 por dirección, organizada en una planilla orientada a hablantes con campos legibles para evaluar sentido, naturalidad, decisión y comentarios. La revisión con Fidel Lomas Chota produjo promedios altos en ambas direcciones: shiwilu→castellano alcanzó Sentido = 4,74, Naturalidad = 4,76 y 82 % de aceptadas; castellano→shiwilu alcanzó Sentido = 4,58, Naturalidad = 4,68 y 78 % de aceptadas. Globalmente, el 80 % de las traducciones fue aceptado, el 20 % quedó como corregible y no hubo rechazos. Este resultado corresponde a R5 como protocolo documentado y aplicado inicialmente, y a R8 como primera validación participativa ejecutada.

Respecto del OE4, se diseñó e implementó un prototipo funcional que integra el modelo seleccionado *v2.1b* LoRA+ con reranking semántico en una interfaz web sencilla, ejecutable localmente y acompañada de lanzadores para su puesta en marcha. El prototipo reutiliza los artefactos congelados del sistema SA-BiNLLB sin reentrenarlos, ofrece traducción bidireccional con visualización clara y opciones avanzadas opcionales, y persiste un registro estructurado de cada traducción. Este resultado corresponde a R6 como prototipo funcional ejecutable localmente que permite pruebas básicas con registro estructurado de entradas y salidas, y queda documentado en el Capítulo 7 y en el [Anexo D](#).

La investigación confirma que, para una lengua originaria de muy bajo recurso como el shiwilu, la contribución técnica más defendible es un pipeline reproducible y auditable antes que una afirmación de cobertura general. El sistema obtenido constituye un baseline sólido para continuar el trabajo y sus resultados deben leerse dentro del marco experimental definido: corpus pequeño, dominio concentrado en flashcards y narrativas, baja recuperación de tokens OOV y uso de métricas automáticas complementadas por una primera validación participativa.

La planilla de evaluación humana queda preservada como instrumento reproducible y como evidencia digital de la primera ejecución. La ausencia de rechazos sugiere que los errores observados son corregibles mediante ajustes puntuales, no fallas irreparables del sistema. Además, la revisión fue realizada por un hablante/revisor de alta relevancia para la preservación del shiwilu, lo que fortalece su valor cualitativo. Si más adelante se cuenta con disponibilidad de otros hablantes, el mismo instrumento podría ampliarse para estimar acuerdo interevaluador y analizar discrepancias, aunque dicha ampliación es compleja por la escasez real de hablantes.

8.2 Trabajos futuros

Las siguientes líneas quedan documentadas como ampliación natural de SA-BiNLLB. Las primeras se derivan directamente de las ablaciones, el análisis automático y la primera validación participativa ejecutada; las últimas corresponden a mejoras de alcance que no forman parte de esta versión del sistema.

Arquitectura *Two-Adapter* LoRA+ con rangos asimétricos. La opción más prometedora identificada después de las ablaciones, y la que se cita explícitamente como continuación inmediata. Consiste en entrenar dos adaptadores LoRA+ independientes, uno por dirección, con rangos asimétricos: $\text{spa} \rightarrow \text{shw}$ con $r = 64$ y $\alpha = 128$ (la dirección morfológicamente más difícil recibe más capacidad) y $\text{shw} \rightarrow \text{spa}$ con $r = 32$ y $\alpha = 64$. El soporte de código está integrado (`30_train_lora.py --direction {spa2shw,shw2spa}`; `40_evaluate.py --checkpoint-spa2shw ...--checkpoint-shw2spa ...`), de modo que la inversión adicional es exclusivamente computacional ($\approx 5\text{--}6$ h sobre el hardware actual). La hipótesis a validar es que la separación por dirección reduce la interferencia entre ambas tareas y cierra la brecha residual entre las dos direcciones que se observa en el Cuadro 5.4; su fundamento técnico se apoya en la adaptación eficiente por adaptadores y LoRA (Houlsby et al., 2019; Hu et al., 2022), mientras que la asimetría de tasas sigue la mejora propuesta por LoRA+ (Hayou et al., 2024).

***Stochastic Weight Averaging* sobre el modelo seleccionado.** Promediar los pesos de los últimos 3 a 5 *checkpoints* del modelo seleccionado (Izmailov et al., 2018) suele aportar entre +0,3 y +0,8 chrF++ adicionales en regímenes de bajos recursos a través de regularización implícita.

Es barato (≈ 30 min, sin entrenamiento adicional), ortogonal a la arquitectura del adaptador, y aplicable tanto a $v_{2.1b}$ como al mejor resultado del experimento Two-Adapter.

Iterative backtranslation con corpus monolingüe controlado por dominio. La regresión observada en $v_{2.2}$ (Wikipedia) confirma que en *low-resource* la calidad del pool monolingüe se rige por la coincidencia de dominio, no por su tamaño. La línea futura es curar un pool combinado de Tatoeba, *News-commentary* hispanoamericano y narrativas comunitarias (10–30 k frases), filtrarlo con el SBERT v_3 congelado contra el Shiwilu existente para preservar la distribución del corpus original, y aplicar iteraciones sucesivas de *round-trip backtranslation* (Edunov et al., 2018; Hoang et al., 2018) con criterio de detención sobre validación.

Corpus monolingüe español controlado por dominio. El sistema actual omite la dirección $\text{spa} \rightarrow \text{shw}$ en *backtranslation* clásica precisamente para no contaminar el *target* con Shiwilu sintético generado por un modelo aún imperfecto en esa dirección. Curar 10–30 k frases en Español cercanas al dominio de *flashcards* y textos comunitarios, filtrarlas con el SBERT v_3 congelado contra el Shiwilu existente y usarlas como *seeds* para BT $\text{spa} \rightarrow \text{shw}$ con un $v_{2.1b}$ ya estable es la línea natural complementaria a la iteración descrita arriba.

Focal loss para preservación de rare-tokens. El análisis morfológicamente sensible documentado en el Anexo C, sección A, muestra que la *OOV recovery rate* es uniformemente baja: el decoder casi no copia palabras shiwilu OOV cuando aparecen en la fuente. *Focal loss* con $\gamma \approx 2$ sobre los *token-ids* más raros sesgaría al modelo a preservarlos. Es ortogonal al pesado por origen documentado en el Anexo C, sección A, y se puede combinar con él, pero requiere reescribir `compute_loss` para conocer la frecuencia de cada *token-target* en *train*.

Ampliación opcional multi-revisor de la validación participativa. La primera ejecución del instrumento ya fue completada con 100 ítems revisados por un hablante/revisor especialmente calificado. Si la disponibilidad de hablantes lo permite, el mismo instrumento podría aplicarse a más hablantes nativos o revisores competentes, sin cambiar muestra ni rúbrica, para calcular acuerdo interevaluador, analizar desacuerdos y contrastar con mayor detalle los juicios humanos frente a las métricas automáticas. Esta línea se plantea como extensión deseable, no como requisito para considerar válida la primera ejecución.

Evolución del prototipo funcional hacia un servicio de acceso público. El prototipo local ya fue implementado y se documenta en el Capítulo 7: integra el modelo seleccionado, traduce en ambas direcciones y registra entradas y salidas de forma estructurada. Su continuación natural, explícitamente fuera del alcance de la presente versión, es desplegarlo como servicio web de acceso público o aplicación móvil, incorporar la recolección controlada de retroalimentación de hablantes desde la propia interfaz y exponer de manera más visible los niveles de confianza por predicción ya calculados en el sistema (Anexo C, sección C.9).

Referencias

- Artetxe, M., & Schwenk, H. (2019). Massively Multilingual Sentence Embeddings for Zero-Shot Cross-Lingual Transfer and Beyond. *Transactions of the Association for Computational Linguistics*, 7, 597-610. https://doi.org/10.1162/tacl_a_00288
- Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural Machine Translation by Jointly Learning to Align and Translate. *3rd International Conference on Learning Representations (ICLR 2015)*. <https://arxiv.org/abs/1409.0473>
- Baladón, A., Lucas, A., & Pardiñas, V. (2024). *Generación de datos sintéticos para traducción automática entre español y guaraní* [Tesis de grado]. Universidad de la República.
- Chaudhary, V., Tang, Y., Guzmán, F., Schwenk, H., & Koehn, P. (2019). Low-Resource Corpus Filtering Using Multilingual Sentence Embeddings. *Proceedings of the Fourth Conference on Machine Translation (Volume 3: Shared Task Papers, Day 2)*, 261-266. <https://doi.org/10.18653/v1/W19-5435>
- Chowdhury, G. G. (2003). Natural Language Processing. *Annual Review of Information Science and Technology*, 37(1), 51-89. <https://doi.org/10.1002/aris.1440370103>
- Chronopoulou, A., Stojanovski, D., Fraser, A., & Birch, A. (2023). Language Family Adapters for Low-Resource Machine Translation with a Large-Scale Multilingual Model. *Findings of the Association for Computational Linguistics: ACL 2023*.
- Chuquimamani, M. (2021). *Minería web de textos en quechua sureño para traducción automática* [Tesis de licenciatura]. Pontificia Universidad Católica del Perú.
- De Silva, D. I., & Hansadi, D. G. P. (2024). Advancing Machine Translation: A Comparative Analysis of Evolving Technologies. *Proceedings of the 15th International Conference on Computing Communication and Networking Technologies (ICCCNT)*.
- Edunov, S., Ott, M., Auli, M., & Grangier, D. (2018). Understanding Back-Translation at Scale. *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 489-500. <https://doi.org/10.18653/v1/D18-1045>

- Fadaee, M., Bisazza, A., & Monz, C. (2017). Data Augmentation for Low-Resource Neural Machine Translation. En R. Barzilay & M.-Y. Kan (Eds.), *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)* (pp. 567-573). Association for Computational Linguistics. <https://doi.org/10.18653/v1/P17-2090>
- Freitag, M., Foster, G., Grangier, D., Ratnakar, V., Tan, Q., & Macherey, W. (2021). Experts, Errors, and Context: A Large-Scale Study of Human Evaluation for Machine Translation. *Transactions of the Association for Computational Linguistics*, 9, 1460-1474.
- Galarreta, A.-P. (2017). *Generación de corpus paralelos para un traductor estadístico entre shipibo-konibo y español* [Tesis de maestría]. Pontificia Universidad Católica del Perú.
- Gale, W. A., & Church, K. W. (1993). A Program for Aligning Sentences in Bilingual Corpora. *Computational Linguistics*, 19(1), 75-102. <https://aclanthology.org/J93-1004/>
- Hayou, S., Ghosh, N., & Yu, B. (2024). LoRA+: Efficient Low Rank Adaptation of Large Models. <https://arxiv.org/abs/2402.12354>
- Hoang, V. C. D., Koehn, P., Haffari, G., & Cohn, T. (2018). Iterative Back-Translation for Neural Machine Translation. *Proceedings of the 2nd Workshop on Neural Machine Translation and Generation*, 18-24. <https://doi.org/10.18653/v1/W18-2703>
- Houlsby, N., Giurgiu, A., Jastrzębski, S., Morrone, B., De Laroussilhe, Q., Gesmundo, A., Attariyan, M., & Gelly, S. (2019). Parameter-Efficient Transfer Learning for NLP. *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-Rank Adaptation of Large Language Models. *Proceedings of the International Conference on Learning Representations (ICLR 2022)*. <https://arxiv.org/abs/2106.09685>
- Izmailov, P., Podoprikin, D., Garipov, T., Vetrov, D., & Wilson, A. G. (2018). Averaging Weights Leads to Wider Optima and Better Generalization. *Proceedings of the Thirty-Fourth Conference on Uncertainty in Artificial Intelligence (UAI)*. <http://auai.org/uai2018/proceedings/papers/313.pdf>
- Johnson, J., Douze, M., & Jégou, H. (2019). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3), 535-547. <https://doi.org/10.1109/TBDATA.2019.2921572>

Kocmi, T., & Bojar, O. (2018). Trivial Transfer Learning for Low-Resource Neural Machine Translation. En O. Bojar, R. Chatterjee, C. Federmann, M. Fishel, Y. Graham, B. Haddow, M. Huck, A. J. Yepes, P. Koehn, C. Monz, M. Negri, A. N  v  l, M. Neves, M. Post, L. Specia, M. Turchi & K. Verspoor (Eds.), *Proceedings of the Third Conference on Machine Translation: Research Papers* (pp. 244-252). Association for Computational Linguistics. <https://doi.org/10.18653/v1/W18-6325>

Koehn, P., & Knowles, R. (2017). Six Challenges for Neural Machine Translation. *Proceedings of the First Workshop on Neural Machine Translation*, 28-39. <https://doi.org/10.18653/v1/W17-3204>

Kudo, T., & Richardson, J. (2018). SentencePiece: A Simple and Language Independent Subword Tokenizer and Detokenizer for Neural Text Processing. *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 66-71. <https://doi.org/10.18653/v1/D18-2012>

Lee, S., Lee, J., Moon, H., Park, C., Seo, J., & Lim, H. (2023). A Survey on Evaluation Metrics for Machine Translation. *Mathematics*, 11(4), 1006.

Li, F., Shao, M., Yan, H., & Chi, C. (2025). A Clause-Based Data Augmentation Method for Low-Resource Neural Machine Translation. *IEEE Access*, 13, 62567-62576. <https://doi.org/10.1109/ACCESS.2025.3555742>

Liu, S.-Y., Wang, C.-Y., Yin, H., Molchanov, P., Wang, Y.-C. F., Cheng, K.-T., & Chen, M.-H. (2024). DoRA: Weight-Decomposed Low-Rank Adaptation. *Proceedings of the 41st International Conference on Machine Learning (ICML)*. <https://arxiv.org/abs/2402.09353>

Liu, Y., Gu, J., Goyal, N., Li, X., Edunov, S., Ghazvininejad, M., Lewis, M., & Zettlemoyer, L. (2020). Multilingual Denoising Pre-training for Neural Machine Translation. *Transactions of the Association for Computational Linguistics*, 8, 726-742. https://doi.org/10.1162/tacL_a_00343

Luo, D., Shi, S., Su, R., & Huang, H. (2019). Data Augmentation Under Scarce Condition for Neural Machine Translation. *Proceedings of the 2019 IEEE 6th International Conference on Cloud Computing and Intelligence Systems (CCIS)*, 36-40. <https://doi.org/10.1109/CCIS48116.2019.9073698>

- Madalengoitia Barúa, M. G. (2014). *Bosquejo fonológico de la lengua Jebero (shiwilu)* [Tesis de licenciatura]. Pontificia Universidad Católica del Perú. <http://hdl.handle.net/20.500.12404/5251>
- Mager, J. M., & Meza, I. V. (2018). Hacia la traducción automática de las lenguas indígenas de México. *Proceedings of Digital Humanities 2018*.
- Maimaiti, M., Liu, Y., Luan, H., & Sun, M. (2022). Enriching the Transfer Learning with Pre-trained Lexicon Embedding for Low-Resource Neural Machine Translation. *Tsinghua Science and Technology*, 27(1), 150-163. <https://doi.org/10.26599/TST.2020.9010029>
- Meque, A. G. M., Angel, J., Sidorov, G., & Gelbukh, A. (2023). Traducción automática entre lenguas indígenas de México y el español. *Research in Computing Science*, 152(9), 329-337.
- Ministerio de Cultura del Perú. (2016). Resolución Viceministerial N.º 073-2016-VMPCIC-MC: Declaran Patrimonio Cultural de la Nación a la lengua shiwilu.
- Montoya, H. E. G., Rojas, K. D. R., & Oncevay, A. (2019). A Continuous Improvement Framework of Machine Translation for Shipibo-Konibo. En A. Karakanta, A. K. Ojha, C.-H. Liu, J. Washington, N. Oco, S. M. Lakew, V. Malykh & X. Zhao (Eds.), *Proceedings of the 2nd Workshop on Technologies for MT of Low Resource Languages* (pp. 17-23). European Association for Machine Translation. <https://aclanthology.org/W19-6804/>
- Ning, T., Xie, X., & Zhang, J. (2024). Research on Low-Resource Neural Machine Translation Methods Based on Explicit Sparse Attention and Pre-trained Language Model. *Proceedings of the 2024 IEEE 12th International Conference on Computer Science and Network Technology (ICCSNT)*, 103-107. <https://doi.org/10.1109/ICCSNT62291.2024.10776704>
- NLLB Team, Costa-jussà, M. R., Cross, J., Çelebi, O., Elbayad, M., Heafield, K., Heffernan, K., Kalbassi, E., Lam, J., Licht, D., Maillard, J., Sun, A., Wang, S., Wenzek, G., Youngblood, A., Akula, B., Barrault, L., Mejia Gonzalez, G., Hansanti, P., ... Wang, J. (2022). No Language Left Behind: Scaling Human-Centered Machine Translation. *arXiv preprint arXiv:2207.04672*. <https://arxiv.org/abs/2207.04672>
- Nzeyimana, A. (2024). Low-Resource Neural Machine Translation with Morphological Modeling. *arXiv preprint arXiv:2404.02392*. <https://doi.org/10.48550/arXiv.2404.02392>

- Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: A Method for Automatic Evaluation of Machine Translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL 2002)*, 311-318. <https://aclanthology.org/P02-1040.pdf>
- Popović, M. (2015). chrF: Character N-gram F-Score for Automatic MT Evaluation. *Proceedings of the Tenth Workshop on Statistical Machine Translation (WMT 2015)*. <https://aclanthology.org/W15-3049.pdf>
- Post, M. (2018). A Call for Clarity in Reporting BLEU Scores. *Proceedings of the Third Conference on Machine Translation (WMT 2018)*, 186-191.
- Qorbani, A., Ramezani, R., Baraani, A., & Kazemi, A. (2025). Multilingual Neural Machine Translation for Low-Resource Languages by Twinning Important Nodes. *Neurocomputing*, 634, 129890. <https://doi.org/10.1016/j.neucom.2025.129890>
- Rei, R., Stewart, C., Farinha, A., & Lavie, A. (2020). COMET: A Neural Framework for MT Evaluation. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP 2020)*, 2685-2702. <https://doi.org/10.48550/arXiv.2009.09025>
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing*, 3982-3992. <https://doi.org/10.18653/v1/D19-1410>
- Ríos, J. C. (2019). *Traducción automática náhuatl-español: variables que influyen en la calidad de la traducción* [Tesis de maestría]. Universidad Nacional Autónoma de México.
- Roy, A., Purkayastha, B. S., Devi, C. S., & Paul, S. (2024). A Neural Based Bidirectional MT System to Investigate the Performance of the Low Resource Language Pair English-Nepali. *INFOCOMP Journal of Computer Science*, 23(1). <https://infocomp.dcc.ufla.br/index.php/infocomp/article/view/3361>
- Sai, A. B., Dixit, T., Nagarajan, V., Kunchukuttan, A., Kumar, P., Khapra, M. M., & Dabre, R. (2023). IndicMT Eval: A Dataset to Meta-Evaluate Machine Translation Metrics for Indian Languages. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL 2023), Long Papers*, 14210-14228.

- Sellam, T., Das, D., & Parikh, A. (2020). BLEURT: Learning Robust Metrics for Text Generation. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL 2020)*, 7881-7892. <https://doi.org/10.48550/arXiv.2004.04696>
- Sennrich, R., Haddow, B., & Birch, A. (2016). Improving Neural Machine Translation Models with Monolingual Data. En K. Erk & N. A. Smith (Eds.), *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 86-96). Association for Computational Linguistics. <https://doi.org/10.18653/v1/P16-1009>
- Socher, R., & Manning, C. D. (2013). Deep Learning for NLP (Without Magic). En J. Lin & K. Erk (Eds.), *NAACL HLT 2013 Tutorial Abstracts* (pp. 1-3). Association for Computational Linguistics. <https://aclanthology.org/N13-4001/>
- Talwar, A., & Laasri, J. (2025). Pivot Language for Low-Resource Machine Translation. <https://doi.org/10.48550/arXiv.2505.14553>
- UNESCO. (2023). El empoderamiento digital impulsa el Decenio Internacional de las Lenguas Indígenas. <https://www.unesco.org/es/articles/el-empoderamiento-digital-impulsa-el-decenio-internacional-de-las-lenguas-indigenas>
- Valenzuela, P. M. (2018). Shiwilu (Jebero). *International Journal of American Linguistics*, 84(S1), S19-S24.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*. <https://arxiv.org/abs/1706.03762>
- Wang, J., Adelani, D. I., Agrawal, S., Masiak, M., Rei, R., et al. (2024). AfriMTE and AfriCOMET: Enhancing COMET to Embrace Under-Resourced African Languages. *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL 2024), Long Papers*.
- Wang, L., Yang, N., Huang, X., Jiao, B., Yang, L., Jiang, D., Majumder, R., & Wei, F. (2022). Text Embeddings by Weakly-Supervised Contrastive Pre-training. <https://arxiv.org/abs/2212.03533>

- Wei, J., & Zou, K. (2019). EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 6382-6388. <https://doi.org/10.18653/v1/D19-1670>
- Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A., & Raffel, C. (2021). mT5: A Massively Multilingual Pre-trained Text-to-Text Transformer. *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 483-498. <https://doi.org/10.18653/v1/2021.naacl-main.41>
- Yamamoto, Y., Akiba, T., & Tsukada, H. (2023). Training Neural Machine Translation Models by Using an Entire Comparable Corpus. *Proceedings of the 2023 10th International Conference on Advanced Informatics: Concept, Theory and Application (ICAICTA)*, 1-5. <https://doi.org/10.1109/ICAICTA59291.2023.10390174>
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). BERTScore: Evaluating Text Generation with BERT. *International Conference on Learning Representations (ICLR 2020)*. <https://doi.org/10.48550/arXiv.1904.09675>
- Zoph, B., Yuret, D., May, J., & Knight, K. (2016). Transfer Learning for Low-Resource Neural Machine Translation. *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1568-1575. <https://doi.org/10.18653/v1/D16-1163>

Apéndice A

Anexos

Los anexos reúnen información complementaria citada desde el cuerpo de la tesis. El Anexo A presenta el plan de proyecto, el Anexo B documenta aspectos adicionales del sistema de embeddings bilingües, el Anexo C consolida la evidencia reproducible del sistema de traducción automática neuronal, el Anexo D documenta la reproducción técnica del prototipo funcional y el Anexo E sintetiza la primera validación participativa del sistema.

Anexo A: Plan de Proyecto

Justificación

El presente proyecto surge de la necesidad urgente de crear soluciones tecnológicas que ayuden a preservar, enseñar y usar de forma cotidiana las lenguas originarias en peligro de extinción, en particular el shiwilu. Esta lengua enfrenta una seria amenaza debido a la escasez de recursos digitales, corpus lingüísticos y herramientas de traducción automática, lo que limita su documentación, aprendizaje y revitalización. Frente a ello, la investigación busca cerrar la brecha entre el conocimiento existente y su aplicación práctica en entornos educativos y tecnológicos.

El objetivo central es diseñar e implementar un sistema de traducción automática neuronal bidireccional entre shiwilu y castellano, basado en la creación de un corpus paralelo depurado y en protocolos de evaluación que combinan métricas automáticas con validación por hablantes. Este enfoque se apoya en los avances del aprendizaje profundo y del procesamiento del lenguaje natural en contextos de bajo recurso, adaptando modelos y arquitecturas a las particularidades lingüísticas del shiwilu para garantizar resultados técnicamente sólidos y culturalmente pertinentes.

El proyecto tendrá impacto en tres niveles: académico, al generar recursos reproducibles para futuras investigaciones; tecnológico, al demostrar la viabilidad de un traductor neuronal en escenarios con pocos datos; y social, al fortalecer los esfuerzos de revitalización lingüística mediante una herramienta accesible para docentes y comunidades. En conjunto, esta propuesta representa un aporte técnico y humano que une la innovación con el compromiso cultural, reafirmando el papel de la ingeniería al servicio de la diversidad lingüística.

Viabilidad

El presente proyecto es viable desde los puntos de vista técnico, metodológico, institucional y económico, dado que se sustenta en recursos accesibles, herramientas de libre uso y un plan de ejecución compatible con los plazos y capacidades de un proyecto académico universitario. La naturaleza tecnológica, documental y experimental de la investigación permite alcanzar los objetivos propuestos mediante procedimientos reproducibles y verificables, sin requerir infraestructura especializada ni financiamiento externo significativo. En otras palabras, es una iniciativa que se sostiene sobre bases sólidas y realistas, donde la precisión técnica y la sensatez operativa caminan de la mano.

Desde la perspectiva técnica, la viabilidad se respalda en el uso de plataformas y librerías de código abierto ampliamente reconocidas en el ámbito del aprendizaje profundo y el procesamiento del lenguaje natural. Cada experimento puede documentarse, replicarse y compararse, lo que refuerza la confiabilidad del proceso. Además, la implementación puede realizarse en entornos locales o en plataformas de cómputo en la nube de bajo costo, demostrando que la innovación no siempre requiere grandes presupuestos, sino ingenio y método. El flujo de trabajo, desde la construcción del corpus hasta la evaluación del modelo y la integración del prototipo, ha sido cuidadosamente diseñado para ser completamente reproducible y versionado, garantizando transparencia y continuidad.

En el plano metodológico, la investigación sigue un enfoque estructurado que combina ingeniería de datos, aprendizaje automático y evaluación lingüística. Las fases avanzan con orden lógico: recopilación y alineación del corpus paralelo shiwilu–castellano, entrenamiento y comparación de modelos neuronales bidireccionales, validación automática y participativa, e inte-

gración del prototipo funcional de traducción. Cada etapa cuenta con indicadores objetivos y entregables definidos, asegurando coherencia entre los objetivos y los resultados. El registro sistemático de parámetros e hiperparámetros no solo aporta rigor científico, sino también una brújula para futuras réplicas y mejoras.

La viabilidad institucional del proyecto se ve reforzada por su alineación con las competencias formativas del programa de Ingeniería Informática y con los lineamientos de investigación aplicada de la Facultad de Ciencias e Ingeniería. Además, cuenta con la guía de un asesor especializado en inteligencia artificial y procesamiento de lenguaje natural, y con acompañamiento metodológico institucional. A ello se suma el apoyo del Grupo Chana, comprometido con la revitalización del idioma shiwilu, y del señor Fidel Lomas Chota, hablante nativo y colaborador en proyectos lingüísticos, cuya participación garantiza la pertinencia cultural y la autenticidad del enfoque. La colaboración entre el conocimiento técnico y la sabiduría viva de la lengua convierte este proyecto en un puente entre la academia y la comunidad.

Finalmente, desde una perspectiva económica y temporal, el proyecto resulta plenamente realizable dentro del periodo académico establecido. El software principal empleado en el pipeline es libre o de código abierto, mientras que los servicios auxiliares y herramientas de oficina usados para cómputo, documentación y validación se valorizan como costos operativos atribuibles al proyecto. Los requerimientos de equipamiento se cubren con equipos personales de desarrollo, cuyo costo se reconoce por depreciación durante el periodo de uso. Los gastos asociados a la validación lingüística son acotados y responden a la logística de coordinación con los colaboradores. El cronograma actualizado contempla tiempos razonables y mecanismos de control de avance que aseguran el cumplimiento integral de los objetivos. En conjunto, todos estos factores confirman que la propuesta no solo es viable en teoría, sino también en práctica: un ejemplo concreto de cómo la tecnología, bien dirigida, puede ponerse al servicio del conocimiento y la preservación cultural.

Alcance

El presente proyecto comprende el diseño, desarrollo y validación progresiva de un sistema de traducción automática neuronal bidireccional entre el idioma shiwilu y el castellano, orientado a

fortalecer el aprendizaje y la preservación de la lengua. El trabajo abarca desde la recopilación y preparación de datos lingüísticos hasta la implementación de un prototipo funcional que permite realizar pruebas básicas de traducción. Esta versión del plan recoge la formulación inicial del curso *Proyecto de Fin de Carrera I* y la actualiza con las actividades efectivamente ejecutadas de gestión, modelado y validación lingüística en colaboración con hablantes nativos.

El alcance técnico incluye la construcción de un corpus paralelo shiwilu–castellano alineado y depurado, el desarrollo de modelos neuronales de traducción bajo un esquema reproducible y la elaboración de un prototipo local ejecutable para la demostración del sistema. Asimismo, incluye la definición y primera ejecución de un protocolo de validación participativa, que combina métricas automáticas con la evaluación cualitativa de hablantes, asegurando tanto la calidad lingüística como la pertinencia cultural del modelo. Durante el proceso, también se incorporó la recolección paralela de *flashcards* junto al Grupo Chana y el señor Fidel Lomas Chota, con el fin de fortalecer el acervo léxico y los ejemplos de uso del idioma, sin que dicha actividad altere las particiones experimentales del corpus principal.

Quedan fuera del alcance del presente proyecto la implementación de una interfaz web o aplicación móvil de acceso público, la integración con servicios en línea de traducción, el entrenamiento de modelos multilingües a gran escala y la evaluación extendida en dominios distintos al educativo y comunitario. Estos aspectos se consideran líneas futuras de trabajo, una vez concluida la validación del prototipo y la consolidación del corpus paralelo.

Limitaciones

Las limitaciones del proyecto constituyen los condicionantes que restringen su planificación, ejecución y alcance operativo. Estas se derivan tanto del contexto académico en el que se desarrolla la investigación como de los recursos y alcances definidos para el periodo de tesis. Su reconocimiento permite establecer expectativas realistas respecto de los resultados y definir futuras líneas de mejora.

En primer lugar, el proyecto presenta **limitaciones temporales** propias del marco académico en el que se ejecuta. El cronograma se encuentra delimitado por la duración de un semestre uni-

versitario, lo que restringe la posibilidad de realizar múltiples iteraciones de entrenamiento y evaluación del modelo. En consecuencia, el tiempo disponible para afinar los hiperparámetros, optimizar el rendimiento y explorar variantes arquitectónicas del modelo de traducción automática es limitado, priorizándose la obtención de un sistema funcional y evaluado dentro del periodo establecido.

Asimismo, se identifican **limitaciones técnicas y de recursos** vinculadas al uso de equipamiento personal y entornos gratuitos de cómputo en la nube, como Google Colab o Kaggle. Estas plataformas, si bien son adecuadas para fines experimentales, imponen restricciones en capacidad de procesamiento, memoria y tiempo de ejecución, lo que puede afectar la cantidad de experimentos concurrentes o la profundidad de los entrenamientos. Pese a ello, el diseño modular y reproducible del proyecto permite mitigar estos efectos dentro del alcance académico propuesto.

En cuanto a los **datos disponibles**, el corpus paralelo shiwilu–castellano presenta un tamaño moderado y una diversidad temática acotada, derivada de la limitada disponibilidad de materiales bilingües y de la complejidad del proceso de alineación. Esto condiciona la generalización del modelo a dominios no representados y refuerza la necesidad de considerar esta versión como una base inicial susceptible de ampliación en futuros trabajos.

El proyecto también enfrenta **limitaciones de alcance funcional**, dado que el producto final consiste en un prototipo ejecutable localmente, orientado a la demostración de la viabilidad técnica y lingüística del sistema. No se contempla el despliegue web ni la integración con plataformas externas, ya que el objetivo principal es validar la factibilidad del enfoque propuesto. De igual modo, las limitaciones de validación participativa derivan de la disponibilidad restringida de hablantes shiwilu; aunque se contó con la revisión de Fidel Lomas Chota, hablante/revisor competente, la muestra de evaluación lingüística es representativa pero acotada, centrada en garantizar pertinencia cultural más que amplitud estadística.

Estas limitaciones, resumidas en la tabla siguiente, no comprometen la validez del proyecto, sino que definen su marco operativo y orientan las posibilidades de mejora y expansión futura.

Tabla A.1: Limitaciones del proyecto

Tipo de limitación	Descripción	Impacto en el proyecto
Tiempo	El plazo de ejecución está restringido al semestre académico, lo que limita el número de iteraciones de prueba, ajuste y validación del modelo.	Menor margen para el <i>fine-tuning</i> progresivo y la experimentación con múltiples configuraciones de red.
Recursos técnicos	El desarrollo se realiza con equipos personales y entornos gratuitos/ <i>low cost</i> de cómputo (Google Colab, Kaggle)	Entrenamientos más lentos y reducción en la cantidad de experimentos simultáneos.
Corpus	El corpus paralelo shiwilu–castellano posee volumen y variedad temática limitados, dependientes de fuentes disponibles y validación lingüística.	Restricción en la capacidad del modelo para generalizar a otros dominios o estilos discursivos.
Herramientas	Se emplean únicamente librerías y herramientas de código abierto, sin uso de software comercial especializado.	Limitación en la integración con sistemas avanzados de evaluación o despliegue profesional.
Alcance funcional	El entregable final es un prototipo local de traducción automática, sin despliegue web ni integración con servicios externos.	Enfoca los resultados en validación académica, no en uso público o masivo.
Validación participativa	La evaluación lingüística depende de la disponibilidad de hablantes shiwilu y se apoya en la revisión cualificada del señor Fidel Lomas Chota.	Muestra acotada pero altamente cualificada, centrada en la adecuación cultural y lingüística más que en la cobertura estadística amplia.

Identificación de los riesgos del proyecto

En la presente sección se identifican los riesgos que podrían afectar el desarrollo del proyecto de tesis. Para ello, se emplea el umbral de riesgo mostrado en la Tabla A.2, que permite medir la probabilidad, el impacto y la severidad como el producto de ambos.

A continuación, la Tabla A.3 presenta la matriz de riesgos con la calificación de severidad correspondiente.

Tabla A.2: Umbral de riesgo (probabilidad e impacto)

Probabilidad	Impacto Bajo (1)	Impacto Moderado (2)	Impacto Alto (3)
Si ocurre (5)	5	10	15
Probable (4)	4	8	12

Tabla A.2 (continuación)

Probabilidad	Impacto Bajo (1)	Impacto Moderado (2)	Impacto Alto (3)
Posible (3)	3	6	9
Improbable (2)	2	4	6
No ocurre (1)	1	2	3

Tabla A.3: Matriz de riesgos del proyecto

Descripción del riesgo	Síntomas	P	I	S	Mitigación	Contingencia
Interrupción o limitación del acceso a entornos de cómputo (Colab/Kaggle) durante el entrenamiento.	Sesiones finalizadas abruptamente, pérdida de progreso o tiempo de cómputo.	4	3	12	Guardar checkpoints automáticos y dividir los entrenamientos por etapas.	Reentrenar con subconjuntos reducidos o migrar temporalmente a otra plataforma gratuita.
Corpus paralelo reducido o con ruido en las alineaciones shiwilu–castellano.	Resultados inconsistentes, bajo puntaje BLEU o traducciones inestables.	3	3	9	Aplicar filtros automáticos de similitud, revisión muestral y limpieza manual.	Reprocesar corpus y ajustar criterios de alineación.
Resultados del modelo inferiores a los baselines esperados.	Estancamiento de métricas, sobreajuste o traducciones incoherentes.	3	2	6	Realizar <i>fine-tuning</i> gradual, control de semillas y ajuste de hiperparámetros.	Revertir al baseline y analizar logs para reajustar parámetros.
Disponibilidad limitada de hablantes para validación participativa.	Retrasos en sesiones de validación o muestra reducida.	3	3	9	Coordinar con anticipación con el Grupo Chana y el señor Fidel Lomas Chota; emplear instrumentos asincrónicos.	Sustituir por revisión lingüística parcial o sesiones virtuales.
Falta de tiempo para afinar y mejorar el modelo (<i>fine-tuning</i>).	Cronograma ajustado, tareas de entrenamiento solapadas con documentación.	4	3	12	Priorizar configuraciones reproducibles y registrar resultados intermedios.	Reducir variantes de modelo y enfocar esfuerzos en documentación y análisis.

Tabla A.3 (continuación)

Descripción del riesgo	Síntomas	P	I	S	Mitigación	Contingencia
Pérdida o inconsistencia de datos durante el preprocesamiento o entrenamiento.	Archivos corruptos o datos desalineados.	2	3	6	Implementar control de versiones y respaldos en la nube.	Restaurar desde <i>backups</i> verificados y repetir el procesamiento afectado.
Desviación del alcance del proyecto o incorporación de tareas no previstas.	Retrasos o sobrecarga de trabajo académico.	3	2	6	Control semanal de avance y revisión de cambios con el asesor.	Replanificar cronograma priorizando entregables críticos.


En la siguiente matriz se describen los riesgos identificados, sus síntomas, probabilidad (P), impacto (I) y severidad (S). Las medidas de mitigación corresponden a acciones preventivas destinadas a reducir la probabilidad de ocurrencia, mientras que las contingencias establecen las estrategias de respuesta planificadas para asegurar la continuidad del proyecto en caso de que alguno de los riesgos se materialice.

Estructura de descomposición del trabajo (EDT)

La Estructura de Descomposición del Trabajo (EDT) constituye una representación jerárquica que organiza las actividades del proyecto en componentes manejables y verificables. En el caso del presente trabajo, la EDT se divide en dos secciones principales: la Gestión del Proyecto, que comprende las tareas administrativas, académicas y de seguimiento vinculadas al curso de Proyecto de Fin de Carrera 1, y la Gestión del Producto, que abarca las fases técnicas orientadas al desarrollo del sistema de traducción automática neuronal bidireccional shiwilu–castellano.

La primera sección contempla los entregables establecidos en el curso (E1, E2 y E3), las reuniones periódicas con el asesor, el control de riesgos y avances, así como la composición final del documento de tesis. Por su parte, la gestión del producto comprende la recolección y preparación del corpus bilingüe, el modelado y entrenamiento del sistema de traducción, la validación lingüística participativa con hablantes nativos y el desarrollo del prototipo funcional. De manera complementaria, se incluye la recolección paralela de *flashcards* junto al señor Fidel Lomas

Figura A.1: Estructura de descomposición del trabajo



Chota, orientada al fortalecimiento del vocabulario y la base de datos lingüística.

El EDT permite visualizar de forma clara la relación entre los objetivos específicos, las fases técnicas y los entregables académicos del proyecto, garantizando la trazabilidad entre las actividades, el cronograma y los resultados esperados.

Lista de tareas

Tabla A.4: Lista de tareas (EDT)

EDT	Nombre de la tarea	Duración (días)	Esfuerzo (h-persona)	Costo estimado (S/.)	Método de verificación y validación
1.1.1	Avance del cronograma y envío inicial	7	8	80	Revisión del cronograma inicial y validación con asesor
1.1.2	E1 – Plan de Proyecto	19	20	200	Entrega revisada y aprobada / asesor
1.1.3	E2 – Marco conceptual y estado del arte	27	28	280	Retroalimentación del asesor y validación del profesor del curso

Tabla A.4 (continuación)

EDT	Nombre de la tarea	Duración (días)	Esfuerzo (h-persona)	Costo estimado (S/.)	Método de verificación y validación
1.1.4	E3 – Plan de proyecto y correcciones finales	36	32	320	Revisión del asesor y calificación final del curso
1.2	Reuniones con asesor de tesis	84	13	130	Correos de confirmación de reunión semanal
1.3	Control y seguimiento del proyecto	60	25	90	Bitácora de avances y reportes de progreso
1.4	Composición del documento de tesis	45	40	400	Revisión de formato PUCP y observaciones resueltas
2.1.1	Definición de fuentes y criterios de inclusión	10	12	100	Lista validada y aprobada por asesor
2.1.2	Limpieza y alineación del corpus	20	28	6	Comparación con corpus original y bitácora de preprocesamiento
2.1.3	Generación de particiones reproducibles	5	10	20	Scripts reproducibles y revisión de semillas
2.1.4	Recolección paralela con hablante (flashcards)	84	25	250	Validación lingüística con hablante (Grupo Chana / Fidel Lomas Chota)
2.2.1	Definición de arquitectura y tokenización	10	20	45	Configuración aprobada y reproducible
2.2.2	Implementación y análisis de <i>embeddings</i>	6	20	45	Reporte técnico y comparación de resultados
2.2.3	Entrenamiento y pruebas del modelo	12	60	220	Registro de métricas y logs de entrenamiento
2.2.4	Optimización final del sistema	5	25	50	Evaluación de desempeño final del modelo
2.3.1	Diseño de instrumentos de validación	3	12	25	Aprobación del instrumento por asesor
2.3.2	Sesiones con hablantes y revisión lingüística	5	15	30	Rúbricas completadas y observaciones registradas
2.3.3	Análisis de resultados y observaciones	4	15	30	Informe consolidado con tablas y conclusiones

Tabla A.4 (continuación)

EDT	Nombre de la tarea	Duración (días)	Esfuerzo (h-persona)	Costo estimado (S/.)	Método de verificación y validación
2.4.1	Diseño de la interfaz local	10	18	80	Prueba funcional en entorno local
2.4.2	Integración del modelo al prototipo	6	25	50	Verificación de inferencias correctas
2.4.3	Pruebas de funcionamiento y registro de resultados	5	20	40	Registro de casos de prueba y evidencias
2.4.4	Documentación final y demo	4	15	30	Presentación y revisión del prototipo

Cronograma del proyecto

Tabla A.5: Cronograma del proyecto

EDT	Nombre de la tarea	Fecha de inicio	Fecha de fin	Duración planificada (días)	Dependencias
1	Gestión del proyecto	19/08/2025	19/11/2025	—	—
1.1	Entregables del curso de Tesis 1 (PFC1)	19/08/2025	19/11/2025	—	—
	Avance del cronograma y envío inicial	19/08/2025	25/08/2025	7	—
	E1 – Plan de Proyecto	27/08/2025	15/09/2025	20	1.1
	E2 – Marco conceptual y estado del arte	17/09/2025	13/10/2025	27	1.1
	E3 – Plan de proyecto y correcciones finales	15/10/2025	19/11/2025	36	1.1
1.2	Reuniones con el asesor de tesis	23/08/2025	15/11/2025	84	Paralelo a todas las tareas
1.4	Composición y edición del documento de tesis	19/08/2025	19/11/2025	93	Paralelo a todo el proyecto
2	Gestión del producto	17/02/2026	05/07/2026	—	—
2.1	Recolección y preparación del corpus	17/02/2026	27/03/2026	—	—
2.1.1	Definición de fuentes y criterios de inclusión	17/02/2026	28/02/2026	10	—

Tabla A.5 (continuación)

EDT	Nombre de la tarea	Fecha de inicio	Fecha de fin	Duración planificada (días)	Dependencias
2.1.2	Limpieza y alineación del corpus	02/03/2026	20/03/2026	20	2.1.1
2.1.3	Generación de particiones reproducibles	23/03/2026	27/03/2026	5	2.1.2
2.1.4	Recolección paralela con hablante (flashcards)	17/02/2026	10/05/2026	84	Paralela
2.2	Desarrollo del modelo de traducción	30/03/2026	13/05/2026	—	2.1.3
2.2.1	Definición de arquitectura y tokenización	30/03/2026	10/04/2026	10	2.1.3
2.2.2	Implementación y análisis de embeddings	13/04/2026	20/04/2026	6	2.2.1
2.2.3	Entrenamiento y pruebas del modelo	21/04/2026	06/05/2026	12	2.2.2
2.2.4	Optimización final del sistema	07/05/2026	13/05/2026	5	2.2.3
2.3	Validación lingüística participativa	14/05/2026	30/05/2026	—	2.2.4
2.3.1	Diseño de instrumentos de validación	14/05/2026	16/05/2026	3	2.2.4
2.3.2	Sesiones con hablantes y revisión lingüística	18/05/2026	24/05/2026	5	2.3.1
2.3.3	Análisis de resultados y observaciones	25/05/2026	30/05/2026	4	2.3.2
2.4	Desarrollo del prototipo funcional	01/06/2026	05/07/2026	—	2.3.3
2.4.1	Diseño de la interfaz local	01/06/2026	12/06/2026	10	2.3.3
2.4.2	Integración del modelo al prototipo	15/06/2026	22/06/2026	6	2.4.1
2.4.3	Pruebas de funcionamiento y registro de resultados	23/06/2026	29/06/2026	5	2.4.2
2.4.4	Documentación final y demo	30/06/2026	05/07/2026	4	2.4.3

- Lista de recursos

- Personas involucradas y necesidades de capacitación
 - * Tesista: Fabian Fernando Prado Infanson
 - * Asesor: Mg. Héctor Erasmo Gomez Montoya
 - * Colaboradores:
 - Fidel Lomas Chota: hablante nativo shiwilu, colaborador en la elaboración de flashcards y validación participativa.
 - * Necesidad de Capacitación:
 - Las actividades realizadas en el proyecto de fin de carrera se encuentran dentro del ámbito de la Ingeniería Informática y están respaldadas por los conocimientos adquiridos en cursos electivos de la especialización en Inteligencia Artificial. No se requiere capacitación adicional, aunque se reforzó el aprendizaje autodirigido mediante la revisión bibliográfica técnica actualizada sobre NMT.
- Materiales requeridos para el proyecto
 - * Electricidad
 - * Servicio de internet
 - * Acceso a bibliografía y repositorios digitales (IEEXplore, arXiv, Github).
- Estándares utilizados en el proyecto
 - * ISO/IEC 29110-5-1-2 – Gestión de proyectos para Very Small Entities (VSE).
 - * Directrices éticas para la recolección y tratamiento de datos lingüísticos (basadas en ACL Ethics 2023).
 - * Normas institucionales PUCP para la elaboración de trabajos de fin de carrera.
 - * Principios FAIR de gestión y reutilización de datos (Findable, Accessible, Interoperable, Reusable).
- Equipamiento requerido
 - * Computadora personal con procesador Intel i7, 32 GB RAM y GPU RTX 5060 TI 16GB.

– Herramientas requeridas

* Python, PyTorch, Hugging Face Transformers y SentencePiece.

* Google Colab Pro / Kaggle como entornos de cómputo.

• Costeo del Proyecto

El presupuesto se formula como valorización económica del proyecto, no únicamente como registro de desembolsos. En este sentido, el costo representa el valor de los recursos consumidos o asignados para ejecutar la investigación, aunque parte de ellos no haya implicado un pago directo durante el periodo; el gasto, en cambio, corresponde al desembolso efectivo realizado. Por ello, las horas del tesista, del asesor y del colaborador lingüístico se valorizan como costo de equipo humano; el equipamiento personal se reconoce por depreciación atribuible al periodo de uso del proyecto; y el software o los servicios auxiliares se registran según su costo operativo, TCO o amortización aplicable.

El software principal del pipeline técnico (Python, PyTorch, Hugging Face Transformers, SentencePiece, FAISS y librerías asociadas) es libre o de código abierto, por lo que no genera licencias directas. No obstante, Google Colab Pro se mantiene como costo operativo de cómputo cuando fue utilizado para acelerar entrenamientos o pruebas, y Microsoft Office se considera herramienta auxiliar para documentación, revisión y manejo de planillas. En el caso de la computadora personal, no se imputa el valor total de compra, sino la depreciación lineal correspondiente a nueve meses de uso sobre una vida útil referencial de cuarenta y ocho meses.

A continuación, se presenta el presupuesto actualizado del proyecto con partidas de equipo humano, materiales, servicios operativos, equipamiento y herramientas auxiliares.

Tabla A.6: Presupuesto del proyecto

Ítem	Descripción	Unidad	Cantidad	Valor unidad (S/.)	Monto parcial (S/.)	Monto total (S/.)
0	Costo total del proyecto	-	-	-	-	9602.50
1	Tesista	-	-	-	-	4600.00

Tabla A.6 (continuación)

Ítem	Descripción	Unidad	Cantidad	Valor unidad (S/.)	Monto parcial (S/.)	Monto total (S/.)
1.1	Fabian Prado Infanson	Hora	460	10	4600	-
2	Otros participantes	-	-	-	-	2240.00
2.1	Mg. H. Erasmo Gómez Montoya (Asesor académico)	Hora	37	20	740	-
2.2	Fidel Lomas Chota	Hora	100	15	1500	-
3	Materiales e insumos	-	-	-	-	1625.00
3.1	Electricidad	Mes	9	25	225	-
3.2	Servicio de internet	Mes	9	100	900	-
3.3	Google Colab Pro	Mes	5	100	500	-
4	Equipamiento y software	-	-	-	-	1137.50
4.1	Computadora personal (depreciación atribuible: 9/48 de S/. 5000)	Mes	9	104.17	937.50	-
4.2	Microsoft Office Suite	Anual	1	200	200	-

Anexo B: Documento reproducible del proceso de corpus y embeddings

Este anexo reúne la documentación operativa que respalda los medios de verificación del primer objetivo específico. En particular, funciona como informe reproducible de criterios de selección, normalización y alineación aplicadas, y como referencia del entregable del modelo de *embeddings*. El propósito no es reemplazar la explicación metodológica del capítulo 4, sino dejar trazabilidad suficiente para revisar, replicar o auditar el proceso.

B.1 Alcance del documento

El proceso documentado comprende dos entregables:

- Corpus paralelo shiwilu–castellano depurado, alineado y particionado.
- Modelo de *embeddings* preparado y evaluado en ambas direcciones.

La fuente de verdad para los conteos y decisiones corresponde a los archivos generados por el pipeline del repositorio. Los valores principales (variante x1, ocho fuentes habilitadas) son: 4894 registros unificados, 4814 registros incluidos en las particiones canónicas, 80 duplicados exactos excluidos, 4523 grupos totales y 257 grupos multi-par.

B.2 Pipeline reproducible del corpus

La Tabla A.7 resume el proceso por decisiones documentales: qué se hizo, qué evidencia deja y por qué esa etapa era necesaria. Las rutas internas se mantienen después de la tabla como respaldo técnico, no como lectura principal.

Tabla A.7: Evidencia documental de construcción del corpus

Etapas	Qué se hizo	Evidencia que deja	Uso en la tesis
00	Se extrajeron pares bilingües desde el material narrativo en PDF	Resumen de extracción y pares recuperados	Incorporar la fuente narrativa publicada

Tabla A.7 (continuación)

Etapas	Qué se hizo	Evidencia que deja	Uso en la tesis
01	Se filtraron registros incompletos o no utilizables por fuente	Listado de exclusiones y conteo de filas conservadas	Evitar ejemplos incompletos en el corpus
01b	Se unificaron las ocho fuentes habilitadas	Corpus integrado con metadatos de procedencia	Mantener trazabilidad por origen
02	Se aplicó normalización no destructiva	Versiones originales y normalizadas de cada par	Reducir ruido sin perder forma original
03	Se auditó el corpus normalizado	Reporte de duplicados, alertas y casos revisables	Controlar calidad antes de modelar
04	Se generaron particiones reproducibles	Separación estable de entrenamiento, validación y prueba	Entrenar y evaluar sin fuga de datos

Para auditoría, estas etapas se respaldan en los scripts `scripts/00_extraer_dataset_pdf.py`, `scripts/01_filtrar_dataset.py`, `scripts/01b_unificar_fuentes.py`, `scripts/02_depurar_dataset.py`, `scripts/03_auditar_dataset.py` y `src/embeddings/preprocess_embeddings.py`, junto con sus reportes en los directorios `reports/00_pdf`, `reports/01_filtrado`, `reports/01b_unificado`, `reports/02_normalizacion`, `reports/03_auditoria` y `reports/04_embeddings/preprocessing`.

B.3 Criterios de selección y normalización

Los criterios aplicados fueron conservadores para evitar eliminar información lingüística útil del shiwilu. La selección mantuvo únicamente pares bilingües completos, preservó la fuente de cada registro y excluyó solo duplicados exactos en el cierre canónico. La normalización se aplicó de forma no destructiva: las columnas originales se conservaron y las versiones procesadas se almacenaron por separado.

Tabla A.8: Criterios documentados para selección y normalización

Criterio	Aplicación	Justificación
Par bilingüe completo	Se conservaron registros con español y shiwilu válidos	Evitar ejemplos incompletos en entrenamiento y evaluación
Trazabilidad por fuente	Se mantuvo el origen flashcards o PDF	Permitir análisis por procedencia del dato

Tabla A.8 (continuación)

Criterio	Aplicación	Justificación
Normalización Unicode NFC	Se estandarizó la representación de caracteres	Reducir variación técnica no lingüística
Espacios y formato	Se aplicaron <i>trim</i> , colapso de espacios y ajuste de coma-espacio	Homogeneizar superficie textual sin alterar contenido
Minúsculas	Se redujo variación por capitalización	Estabilizar vocabulario en un corpus pequeño
Apóstrofes internos	Se preservaron en shiwilu	Evitar romper formas potencialmente relevantes
Puntuación	No se eliminó agresivamente	Reducir riesgo de pérdida morfológica o funcional
Agrupación por <code>group_id</code>	Se agruparon variantes equivalentes antes del split	Evitar fuga de datos entre entrenamiento y prueba

B.4 Particiones canónicas

Las particiones canónicas separan el corpus en entrenamiento, validación y prueba con una semilla fija. Esta decisión evita que ejemplos equivalentes aparezcan simultáneamente en entrenamiento y evaluación, y permite que los resultados del modelo se comparen sobre la misma base. La semilla usada fue 42 y las proporciones fueron 80% entrenamiento, 10% validación y 10% prueba. El hash SHA-256 del insumo canónico fue:

1f6f8f252c47add44d47eee96570c3db2199dc94522dd04f2e8cb88075654a9

Tabla A.9: Función de las particiones canónicas

Partición	Función	Qué permite verificar
Entrenamiento	Ajustar modelos y aprender patrones del corpus disponible	Que el modelo se entrena solo con datos permitidos para aprendizaje
Validación	Seleccionar configuraciones e identificar sobreajuste durante el desarrollo	Que las decisiones de ajuste no usan el conjunto de prueba
Prueba	Medir el rendimiento final y comparar variantes	Que las métricas finales se calculan sobre ejemplos no usados para entrenar

Para auditoría técnica, las particiones se conservan en formatos tabulares y JSONL bajo

data/processed/04_splits/. También se generó un corpus textual consolidado para procesos posteriores de tokenización o segmentación sub-palabra.

B.5 Entregable del modelo de embeddings

El modelo de *embeddings* preparado quedó registrado como:

models/sentence_transformers/v3_iterative_hn_e5_base_bidirectional

La selección se realizó mediante una progresión experimental. Se partió de modelos E5 sin ajuste fino, que sirvieron como baselines. Luego se adaptaron al corpus shiwilu–castellano con una pérdida contrastiva. Posteriormente se incorporaron negativos duros y medios para mejorar la discriminación entre pares cercanos, se migró de E5-small a E5-base, se probó entrenamiento bidireccional y finalmente se aplicó una iteración adicional de minería sobre el mejor candidato previo. La Tabla A.10 resume esta secuencia, indicando la hipótesis de cada variante y la decisión tomada a partir de sus resultados.

Tabla A.10: Evolución experimental del modelo de embeddings


Variante	Hipótesis o motivo	Resultado observado	Decisión
E5-small sin ajuste	Medir el desempeño de un modelo multilingüe preentrenado sin adaptación al corpus	R@1=0.0966; recuperación insuficiente	Aplicar fine-tuning contrastivo
v1 E5-small	Verificar si los pares positivos adaptan el espacio semántico	R@1=0.5109; mejora fuerte frente al baseline	Explorar negativos difíciles
v2 hard-only	Probar si solo los negativos duros mejoran la discriminación	R@1=0.5421; mejora moderada	Combinar negativos duros y medios
v2 hard/medium	Evaluar si los negativos medios estabilizan el aprendizaje	R@1=0.5670; mejora mayor que hard-only	Migrar a una base de mayor capacidad
E5-base sin ajuste	Comprobar si una base más grande mejora sin ajuste	R@1=0.1059; sigue bajo sin adaptación	Ajustar E5-base con el corpus
v1 E5-base	Repetir fine-tuning contrastivo con mayor capacidad	R@1=0.6480; supera a E5-small	Usar E5-base como línea principal
v1 E5-base bidireccional	Evitar favorecer una sola dirección de recuperación	R@1=0.6573 / 0.6760	Mantener evaluación bidireccional

Tabla A.10 (continuación)

Variante	Hipótesis o motivo	Resultado observado	Decisión
v2 E5-base	Combinar E5-base con negativos controlados	R@1=0.7134 / 0.7165	Probar entrenamiento bidireccional con negativos
v2 E5-base bidireccional	Unir hard/medium negatives y entrenamiento bidireccional	R@1=0.7508 / 0.7788	Usarlo como base para minería iterativa
v3 iterativo bidireccional	Minar nuevos negativos desde el mejor candidato previo	R@1=0.7882 / 0.7913	Seleccionarlo como modelo preparado

El entrenamiento final partió del candidato anterior `models/sentence_transformers/v2_hn_controlled_e5_base_bidirectional`, se ejecutó durante 2 épocas, con *batch size* 16, tasa de aprendizaje 5×10^{-6} , temperatura 0.05 y entrenamiento bidireccional. La pérdida registrada fue una entropía cruzada estilo MNRL con negativos explícitos. La minería de negativos produjo 3997 filas negativas, con 2526 casos medios y 1471 casos duros. La Figura A.2 muestra la composición de estos negativos.

Figura A.2: Composición de negativos usados en la iteración v3



Las figuras anteriores representan la evolución del desempeño de recuperación entre candidatos ya entrenados. No corresponden a curvas internas de pérdida de entrenamiento, porque los experimentos de Sentence Transformers no conservaron una serie histórica de pérdida por época o paso. Para futuras corridas, se recomienda habilitar logging a TensorBoard o persistir un archivo CSV o `trainer_state.json` con pérdida de entrenamiento y validación por época.

Tabla A.11: Reportes del modelo de embeddings preparado

Reporte	Ruta	Contenido
Entrenamiento	reports/04_embeddings/v3_iterative_hn_e5_base_bidirectional/v3_iterative_hn_e5_base_bidirectional_training.json	Configuración, minería y métricas finales
Recuperación castellano–shiwilu	reports/04_embeddings/experiments/v3_iterative_hn_e5_base_bidirectional/v3_iterative_hn_e5_base_bidirectional_esp_to_shi_retrieval.json	R@1, R@5, R@10, MRR y distribución de rangos
Recuperación shiwilu–castellano	reports/04_embeddings/experiments/v3_iterative_hn_e5_base_bidirectional/v3_iterative_hn_e5_base_bidirectional_shi_to_esp_retrieval.json	R@1, R@5, R@10, MRR y distribución de rangos
Congelamiento del candidato	reports/04_embeddings/experiments/v3_iterative_hn_e5_base_bidirectional/v3_iterative_hn_e5_base_bidirectional_freeze_metadata.json	Rutas finales, manifiesto y decisión de cierre
Script de figuras	scripts/generate_embedding_figures.py	Generación reproducible de gráficas desde reportes JSON
Resumen tabular de métricas	thesis/latex/figuras/generated/embedding_metrics_summary.csv	Métricas, hipótesis, resultados y decisiones por variante

La decisión registrada para este candidato fue `candidate_final_embedding_model`. Por tanto, el modelo queda como entregable del resultado R2 y como insumo listo para integración o evaluación con etapas posteriores de traducción automática neuronal.

Anexo C: Documento reproducible del sistema NMT SA-BiNLLB

Este anexo documenta los detalles técnicos, hiperparámetros, fórmulas y rutas de configuración del sistema de traducción neuronal SA-BiNLLB descrito en el Capítulo 5. Su organización es paralela a la del Anexo B: cada subsección amplía un aspecto que en el cuerpo del capítulo se mantiene en tono narrativo, de modo que el lector que requiera reproducir o auditar el sistema

disponga aquí de la especificación operativa completa.

C.1 Hiperparámetros del modelo y del entrenamiento

El modelo base es facebook/nllb-200-distilled-600M. La adaptación al par shiwilu–castellano se realiza con un único *adapter* LoRA bidireccional cuyos hiperparámetros se resumen en el Cuadro A.12.

Tabla A.12: Hiperparámetros del adaptador LoRA y del entrenamiento.

Parámetro	v_0	v_{1bt}	Comentario
LoRA r	16	32	Aumentado en v_{1bt} para absorber el corpus aumentado sin saturación
LoRA α	32	64	Mantiene la razón $\alpha/r = 2$
LoRA <i>dropout</i>	0,05	0,05	—
<i>Target modules</i>	q_proj, v_proj	ídem	Foco en proyecciones de atención
<i>Bias</i>	none	none	—
<i>Task type</i>	SEQ_2_SEQ_LM	ídem	—
Parámetros entrenables	$\sim 2,36$ M ($\sim 0,38\%$)	$\sim 4,72$ M ($\sim 0,76\%$)	Sobre 619 M de parámetros totales
<i>Learning rate</i>	2×10^{-4}	ídem	AdamW, programación cosenoidal
<i>Warm-up ratio</i>	0,1	0,1	—
<i>Weight decay</i>	0,01	0,01	—
Label smoothing	0,1	0,1	Reformulado por fila cuando hay pesos (ver C.7)
<i>Batch</i> entrenamiento	8	8	Por dispositivo
<i>Gradient accumulation</i>	4	4	<i>Batch</i> efectivo: 32
<i>Batch</i> validación	8	8	—
Épocas	20	20	Selección por mejor <i>eval_avg_chrf</i>
Precisión	fp16 (CUDA)	fp16 / bf16	bf16 disponible vía <code>--bf16</code>
Longitud máx. fuente	128 <i>tokens</i>	128	—
Longitud máx. destino	128 <i>tokens</i>	128	—
Generación intra-loop	beam=4	beam=4	Costo acotado
Generación final	beam=5	beam=5	Para inferencia y <i>reranking</i>

C.2 Extensión del tokenizer NLLB para Shiwilu

NLLB-200 no incluye Shiwilu en su inventario de lenguas (NLLB Team et al., 2022). La extensión del *tokenizer* registra shw_Latn como un *special token* adicional, actualiza los mapas lang_code_to_id e id_to_lang_code, y, por compatibilidad con tareas multitarea, registra también las etiquetas estilo T5 <2shw> y <2spa>. La fila de *embeddings* correspondiente al nuevo identificador se inicializa como la media (en float32) de las filas asociadas a tres lenguas indígenas sudamericanas que NLLB sí soporta: quy_Latn (Quechua de Ayacucho), ayr_Latn (Aymara) y grn_Latn (Guarani). Esta elección se usa como heurística de ingeniería: prioriza lenguas sudamericanas disponibles en NLLB y evita presentar la inicialización como una equivalencia lingüística fuerte entre familias no emparentadas.

La actualización se realiza in-place sobre el modelo redimensionado (model.resize_token_embeddings), respetando el atado de pesos entre *input embeddings* y *lm head* cuando aplica. La rutina se encuentra en src/nmt/training/model_setup.py.

C.3 Filtrado semántico: configuración y umbrales

El filtro semántico utiliza el modelo congelado v3_iterative_hn_e5_base_bidirectional_xl para puntuar la similitud coseno entre fuente y destino de cada par paralelo. Por convención de E5, los textos se prefijan con query: y passage: respectivamente antes de la codificación. La normalización L2 se aplica antes de calcular el coseno, equivalente a producto interno con vectores unitarios.

Los umbrales se declaran en config/nmt/filter.yaml: score < 0,45 descarta la pareja, $0,45 \leq \text{score} \leq 0,60$ la marca como *flagged* (queda en el corpus pero se reporta), score > 0,60 la acepta sin marca. La decisión se calcula a nivel de pair_id (no por dirección) para garantizar que ambas filas direccionales de un mismo par compartan etiqueta. El filtro se aplica únicamente al *train*; *valid* y *test* reciben el puntaje pero no se modifican.

C.4 Construcción de los índices FAISS

Sobre los pares aceptados se construyen dos índices FAISS (Johnson et al., 2019) de tipo `IndexFlatIP` con dimensión 768 (uno por idioma) y vectores L2-normalizados, lo que vuelve el producto interno equivalente al coseno. Cada índice se acompaña de un parquet de metadatos con `pair_id`, `group_id`, `texto` y `posición`. Los índices se utilizan en (a) la fase de aumentación por minería bilingüe (Sección C.6, ítem 3) y (b) la detección opcional de duplicados cercanos: pares con $IP \geq 0,98$ se reportan como casi-duplicados pero no se eliminan automáticamente.

C.5 Reranking semántico: fórmula y ablación

El *reranker* opera sobre las $K = 5$ hipótesis del decodificador con haz de cinco. Para cada candidato c_i se calcula:

- $p_{\text{trad}}(c_i) = \text{softmax}_K(\text{sequence_score}(c_i))$: probabilidad relativa entre los K candidatos.
- $\cos(s, c_i) = \langle \mathbf{e}(s), \mathbf{e}(c_i) \rangle$, con $\mathbf{e}$ producido por el modelo de *embeddings* congelado y normalizado L2.

El puntaje final es la combinación lineal $\text{final}(c_i) = \alpha \cdot p_{\text{trad}}(c_i) + (1 - \alpha) \cdot \cos(s, c_i)$ y la hipótesis seleccionada es $\arg \max_i \text{final}(c_i)$. El barrido de ablación se efectúa sobre $\alpha \in \{0, 0,3, 0,5, 0,7, 1,0\}$ usando chrF++ promediada entre direcciones como métrica de selección. El Cuadro A.13 consolida la ablación para los modelos v_0 y v_{1bt} sobre la variante x1.

Tabla A.13: Ablación de α en el *reranker* semántico (modelos v_0 y v_{1bt} , variante x1, conjunto de *test*, métrica de selección: chrF++ promedio).

α (translation)	avg chrF++	avg BLEU
0.00	26.44	6.67
0.30	26.54	6.84
0.50	26.52	6.93
0.70	26.61	7.17
1.00	25.01	6.49

Tabla A.14: Ablación de α para el modelo aumentado v_{1bt} (variante x1).

α (translation)	avg chrF++	avg BLEU
0.00	31.87	9.29
0.30	32.26	9.66
0.50	32.20	9.65
0.70	32.14	9.57
1.00	30.85	8.80

El óptimo observado es $\alpha = 0,5$ para v_0 y $\alpha = 0,7$ para v_{1bt} . La forma de U invertida de las curvas indica que ambas señales (p_{trad} y $\cos$) aportan información complementaria sin redundancia destructiva.

C.6 Augmentación: especificación matemática de cada fuente

(1) Backtranslation desde monolingüe Shiwilu. Sea M_{shw} el conjunto de oraciones shiwilu sin par paralelo (extraídas del PDF de *VOCES SHIWILU*). Para cada $t \in M_{\text{shw}}$ se genera $\hat{s} = v_0^{\text{shw} \rightarrow \text{spa}}(t)$ con haz de cinco. Se calcula $\cos(t, \hat{s})$ usando el modelo de *embeddings* congelado y se aceptan las parejas con $\cos \geq 0,60$. El conjunto aceptado se acota al doble del tamaño del corpus paralelo ($\text{cap_x} = 2$). Cada par aceptado produce dos filas direccionales con $\text{origin_source} = \text{backtranslation_v0}$.

(2) Round-trip backtranslation desde monolingüe Español. Sea M_{spa} un conjunto de oraciones españolas (FLORES-101 spa_Latn, OPUS-100, Wikipedia es). Para cada $s \in M_{\text{spa}}$ se calcula $\hat{t} = v_0^{\text{spa} \rightarrow \text{shw}}(s)$ y luego $\hat{s} = v_0^{\text{shw} \rightarrow \text{spa}}(\hat{t})$. Se mide $\cos(s, \hat{s})$ (consistencia *monolingüe* en español) con el modelo de *embeddings* congelado y se aceptan parejas con $\cos \geq 0,70$ (umbral más estricto que el cross-lingual del ítem 1, justificado por la naturaleza intra-lengua de la comparación). Cada par aceptado $(s, \hat{t})$ produce dos filas direccionales con $\text{origin_source} = \text{backtranslation_roundtrip_v0}$, almacenadas en `train_bt_roundtrip[_iterN].csv`. El esquema soporta iteraciones sucesivas: a partir de iteración 1 el modelo generador deja de ser v_0 y pasa a ser el último v_{kbt} entrenado.

(3) Minería bilingüe basada en embeddings. Sobre los índices FAISS de la Sección C.4, para cada oración shiwilu del corpus aceptado se obtienen los $k = 5$ vecinos más cercanos en el espa-

cio español, y viceversa. Se conservan únicamente las parejas con vecindad recíproca (mutual top- k) y producto interno $IP > 0,65$. Esta fuente captura paráfrasis cruzadas que el corpus paralelo no había emparejado explícitamente. Cada par aceptado produce dos filas direccionales con `origin_source = mined_v3_sbert`.

(4) Variantes morfológicas controladas. Sobre el inventario de sufijos minado en la fase de *embeddings*, se generan variantes morfológicas (sustitución de sufijos compatibles) para revisión por lingüista. Sin validación humana, estas filas se marcan como `manual_review_required` y se mantienen fuera del entrenamiento por defecto. La activación es opcional vía `--include-morph` y `--emit-csv-anyway`.

C.7 Pesado por origen de la pérdida (Enhancement #4)

Las filas sintéticas tienen confiabilidad heterogénea respecto del paralelo real. Se introduce un mapa de pesos por origen, `DEFAULT_WEIGHT_MAP`:

Origen	Peso w
flashcards (paralelo real)	1,0
pdf_textos (paralelo real)	1,0
mined_v3_sbert (minería bilingüe)	0,5
backtranslation_v0 (BT shiwillu)	0,3
backtranslation_roundtrip_v0 (BT round-trip español)	0,3
morphological_variant (morfología)	0,3

El *collator* extrae el peso de cada *feature* antes del `DataCollatorForSeq2Seq` y lo re-attacha al *batch* como tensor $[B]$. La pérdida se calcula con una variante de *label-smoothing* replicada a nivel *per-row*: para logits $\ell \in \mathbb{R}^{B \times T \times V}$, *labels* $y \in \{1, \dots, V, -100\}^{B \times T}$ y suavizado ϵ ,

$$\mathcal{L} = \frac{\sum_{b,t} w_b \cdot [(1 - \epsilon) \text{NLL}(\ell_{b,t}, y_{b,t}) + \epsilon - \overline{\log p}(\ell_{b,t})] \mathbb{I}[y_{b,t} \neq -100]}{\sum_{b,t} w_b \cdot \mathbb{I}[y_{b,t} \neq -100]}$$

Una fila con $w = 0,3$ contribuye así el 30 % de sus *tokens* válidos al promedio. Esta ruta se activa exclusivamente en v_{1bt} y subsecuentes; el modelo v_0 original mantiene la pérdida estándar de Hugging Face. Implementación en `src/nmt/training/train_lora.py::_weighted_smoothed_ce`.

C.8 Configuración de inferencia

La inferencia (script `scripts/nmt/40_evaluate.py`) usa los siguientes parámetros, declarados en `config/nmt/inference.yaml`:

- `num_beams = 5`
- `num_return_sequences = 5` (necesario para *reranking* y top-K JSONL)
- `length_penalty` y `no_repeat_ngram_size` con valores por defecto del *generation config* de NLLB
- `generation_max_length = 128`
- `forced_bos_token_id` establecido al *lang code* del idioma destino antes de cada llamada

C.9 Bandas de confianza por predicción

Cada predicción persiste tres campos adicionales en `*_predictions.jsonl`: `confidence_score`, `confidence` $\in \{\text{low}, \text{medium}, \text{high}\}$, `confidence_components`.

- **Sin reranker:** `confidence_score` = $\exp(\text{top-1 sequence_score})$, una probabilidad geométrica por *token* sobre la mejor hipótesis.
- **Con reranker:** `confidence_score` = puntaje *final* combinado descrito en C.5.

Los umbrales se calibraron sobre el conjunto de *test* de v_0 : rango observado $[0,20, 0,79]$, mediana 0,41 en *baseline*; rango $[0,10, 0,48]$, mediana 0,28 con *reranker* $\alpha = 0,7$. Se fija `low_to_med` = 0,40, `med_to_high` = 0,55 para la familia *baseline*. La distribución resultante por banda se persiste en `meta.confidence` de cada `*_metrics.json`. Esta señal no pretende ser una

probabilidad calibrada sino un indicador suave para consumidores aguas abajo (por ejemplo, herramientas de pre-llenado de *flashcards*).

C.10 Análisis morfológicamente sensible (rare-token y OOV)

Para complementar la métrica corpus-level se reporta chrF^{++} por *bucket* de fracción de palabras raras en la referencia (frecuencia en *train* < 5) y la tasa de recuperación de palabras OOV (jamás vistas en *train*) que aparecen verbatim en la hipótesis. El *bucket* de mayor interés es “ $\geq 20\%$ raras”, que aísla las oraciones morfológicamente densas. El Cuadro A.15 resume el comportamiento de las seis variantes reranked evaluadas sobre la versión x1; el mejor resultado corresponde a $v_{2.1b}$ LoRA+, aunque la *OOV recovery rate* se mantiene baja en términos absolutos. Esta observación motiva la línea de trabajo futuro sobre *focal loss* (Sección 8.2).

Tabla A.15: Análisis rare-token / OOV sobre el bucket de referencias con $\geq 20\%$ palabras raras para las variantes reranked (variante x1).

Variante (reranked)	shw→spa		spa→shw	
	chrF^{++} raras $\geq 20\%$	OOV rec.	chrF^{++} raras $\geq 20\%$	OOV rec.
v_0	21.46	0.025	25.62	0.011
v_{1bt} (+BT OPUS)	26.97	0.062	33.33	0.034
$v_{2.0}$ DoRA	27.00	0.070	33.84	0.027
$v_{2.1}$ DoRA+LoRA+	37.61	0.117	47.27	0.073
$v_{2.1b}$ LoRA+ ★	39.10	0.122	47.24	0.085
$v_{2.2}$ +BT iter1 (Wikipedia)	26.98	0.056	33.40	0.036

C.11 SentencePiece como artefacto analítico

El *tokenizer* de tiempo de ejecución es siempre el de NLLB. No obstante, el plan de trabajo prescribe entrenar un *SentencePiece Unigram* sobre el corpus consolidado (vocab = 8000, *character coverage* = 1,0) como artefacto analítico para (i) sustentar la elección de un *tokenizer* compatible con la morfología aglutinante del shiwilu, y (ii) compararlo con la tokenización de NLLB sobre el mismo conjunto (Kudo & Richardson, 2018; Sennrich et al., 2016). Con ~ 5 k oraciones de entrenamiento, la cobertura efectiva del vocabulario es de 5276 piezas. El comportamiento sobre shiwilu se resume en el Cuadro A.16: SP unigram produce 9,78 *tokens*

promedio por frase frente a 12,48 de NLLB, lo cual confirma que la tokenización entrenada localmente es más compacta para shiwilu. Esta evidencia respalda la elección *conceptual* de un *tokenizer* aglutinante-amigable, aunque en runtime se conserve el de NLLB por compatibilidad con los pesos pre-entrenados.

Tabla A.16: Tokens promedio por oración de shiwilu: SP Unigram entrenado en este trabajo vs. el *tokenizer* multilingüe de NLLB-200 (variante x1).

Tokenizador	Tokens / frase	Tokens / palabra	Vocab efectivo	Frases más cortas
SP Unigram (este trabajo)	9.78	3.18	5276	42/50
NLLB-200	12.48	4.05	256 000	1/50
Empate		No aplica		7/50

C.12 Protocolo de evaluación humana

Esta sección documenta el instrumento usado para pasar de la evaluación automática a una revisión lingüística comprensible para un hablante/revisor. La evidencia principal no es el nombre del archivo ni el comando usado para generarlo, sino la existencia de una muestra balanceada, una rúbrica clara, una planilla completada y resultados humanos agregados que permiten contrastar las métricas automáticas con juicio lingüístico.

La muestra contiene 100 traducciones del modelo seleccionado: 50 en la dirección shiwilu→castellano y 50 en la dirección castellano→shiwilu. La selección se balanceó por dirección y se controló para evitar casos no revisables, como salidas vacías, texto con codificación defectuosa o repeticiones severas. Cada fila presenta únicamente la información necesaria para la revisión: texto fuente, traducción del modelo, puntajes de sentido y naturalidad, decisión global y comentarios.

Tabla A.17: Evidencias del protocolo de evaluación humana

Evidencia	Qué demuestra	Contenido verificable
Plantilla de revisión	Que el instrumento fue preparado antes de la revisión humana	100 ítems balanceados por dirección, instrucciones y campos de evaluación

Tabla A.17 (continuación)

Evidencia	Qué demuestra	Contenido verificable
Planilla completada	Que la primera ejecución participativa fue realizada	Puntajes de sentido y naturalidad, decisiones aceptar/corregir/rechazar y comentarios
Resultados agregados	Que la revisión produjo evidencia interpretable	Promedios por dirección, proporciones de aceptación y ejemplos de corrección
Constancias complementarias	Que la interacción con el revisor quedó respaldada	Registro oral y capturas de coordinación/conformidad disponibles como anexos digitales

La planilla contiene, por fila, el texto fuente, la traducción del modelo y campos para que el revisor consigne puntajes en las dimensiones *Sentido (1–5)* y *Naturalidad (1–5)*, además de una *Decisión (aceptar, corregir o rechazar)* y *Comentarios*. En la primera ejecución se completaron 50 filas por dirección; los promedios humanos, decisiones y ejemplos de corrección se sintetizan en el [Anexo E](#). La aplicación a revisores adicionales puede reutilizar la misma muestra y rúbrica para calcular acuerdo interevaluador.

Como instrumentos complementarios, se conservan un análisis cualitativo estratificado y una plantilla de preferencia pareada. El primero organiza ejemplos por niveles de calidad para interpretar los tipos de acierto y error; el segundo permite comparar dos variantes de modelo cuando las métricas automáticas resultan cercanas. Estos instrumentos no sustituyen la validación participativa completada, sino que amplían la capacidad de auditoría del sistema.

Para fines de reproducción técnica, la plantilla base se conserva en `reports/05_nmt/evaluation_xl/human_validation_100.xlsx`; la ejecución completada se conserva como anexo digital en `anexos_digitales/Anexo_E_validacion_participativa_100.xlsx` y como copia interna en `reports/05_nmt/evaluation_xl/validacion_participativa_100.xlsx`. El generador reproducible del instrumento es `scripts/nmt/75_human_validation_workbook.py`; las predicciones usadas para armar la muestra provienen del modelo $v_{2.1b}$ con reranking semántico.

C.13 Reproducibilidad y desviaciones documentadas

Para reproducibilidad técnica, las dependencias del sistema NMT quedaron fijadas en un entorno controlado y documentadas en `requirements/nmt.txt`. Las desviaciones formales respecto del plan original son:

- Python 3.12 (no 3.11) para alinearse con `pyproject.toml`.
- PyTorch 2.7.1 con *wheels* cu128 (no 2.5.1) por el soporte de la arquitectura Blackwell (*compute capability* 12.0) presente en la GPU disponible (RTX 5060 Ti).
- Subida coordinada de `transformers` 4.55.0, `accelerate` 1.8.1, `peft` 0.16.0 para mantener compatibilidad con la versión de PyTorch.
- `sentence-transformers` $\geq 5.4.1$ (no 4.1.0): el *checkpoint* congelado del capítulo anterior se serializó con las rutas de módulo introducidas en 5.4.x y no es cargable por la familia 4.x.
- Cota superior `numpy` < 2 requerida por COMET 2.2.4.
- Cota `setuptools` < 81 requerida porque `torchmetrics` (dependencia transitiva de COMET) aún importa `pkg_resources`, removido en 81+.

Adicionalmente, `torch.compile` no se utiliza en este pipeline porque depende de Triton, sólo disponible en Linux. Cada desviación se justifica por una restricción concreta de *hardware* o de cadena de dependencias y se ha registrado en el encabezado de `requirements/nmt.txt` y en el archivo `plan.md` de seguimiento.

C.14 Ablaciones del optimizador y arquitectura del adaptador

Sobre la base v_{1bt} descrita en el Capítulo 5, sección 5.2.6, la fase final de experimentación incorporó cuatro ablaciones que aíslan la contribución de tres familias de mejoras: una arquitectura alternativa del adaptador PEFT (DoRA), una modificación del optimizador (LoRA+), su combinación, y una ronda adicional de *round-trip backtranslation* con *pool* monolingüe extra-dominio.

DoRA (Decomposed Low-Rank Adaptation). En lugar del producto $\Delta W = BA$ clásico de LoRA, DoRA descompone la actualización del peso adaptado como $\Delta W = m \cdot \frac{V+BA}{\|V+BA\|_c}$, donde el factor de magnitud m y la dirección normalizada se entrenan por separado (S.-Y. Liu et al., 2024). La hipótesis de DoRA es que separar magnitud y dirección produce dinámicas de aprendizaje más cercanas al *full fine-tuning*. Implementación: PEFT 0.16.0 nativa vía `LoraConfig(use_dora=True)`; conmutador CLI `--use-dora` en `30_train_lora.py`.

LoRA+. Aplica una tasa de aprendizaje asimétrica a las dos matrices del producto BA : $\eta_B = \lambda \cdot \eta_A$ con $\lambda = 16$ según el valor recomendado por los autores para modelos pre-entrenados grandes (Hayou et al., 2024). La justificación es que, dado que B se inicializa en cero y A sigue una distribución no trivial, mantener tasas iguales mantiene a B en un régimen efectivamente inactivo durante demasiados pasos. Implementación: optimizador construido vía `peft.optimizers.create_loraplus_optimizer`; conmutador CLI `--loraplus-lr-ratio 16.0`.

Round-trip backtranslation iterativa (iter 1). La extensión natural de la *backtranslation* de v_{1bt} usando $v_{2.1b}$ como generador, sobre un *pool* monolingüe español tomado de Wikipedia en español (corpus extraído con `60b_roundtrip_bt.py --source wikipedia`). El criterio de admisión sintética es el mismo del Anexo A: filtro cosenoidal monolingüe contra el SBERT v_3 congelado con umbral $\tau = 0,70$.

El Cuadro 5.4 consolida las seis variantes ordenadas por avg chrF++ reranked; el Cuadro 5.6 reporta los intervalos de confianza bootstrap del 95 % con $n = 1000$ re-muestreos por dirección, computados sobre las predicciones reranked. Las lecturas operativas son:

La Figura A.3 complementa los resultados finales porque permite ver la evolución del entrenamiento, no sólo el valor alcanzado en prueba. En esa comparación, $v_{2.1b}$ mantiene una trayectoria de validación superior a las variantes previas, lo que respalda su selección como modelo final bajo el criterio primario de chrF++.

- **LoRA+ aislado obtiene el mejor desempeño.** $v_{2.1b}$ alcanza avg chrF++ = 44,99 con IC 95 % [43,17, 46,96], sin solapamiento con el IC de v_{1bt} ([30,63, 33,80]). El salto de $\approx 12,8$ puntos es la mejora más grande del conjunto de ablaciones y es estadísticamente clara.




Figura A.3: Comparación de chrF++ promedio en validación durante el entrenamiento de v_0 , v_{1bt} y $v_{2.1b}$ LoRA+.

- **DoRA aislado no se distingue de v_{1bt} .** $v_{2.0}$ reporta $\text{avg chrF++} = 32,58$ con IC $[31,02, 34,25]$, que se traslapa con $[30,63, 33,80]$. En este tamaño de corpus DoRA no paga su sobrecarga computacional.
- **DoRA+LoRA+ no mejora sobre LoRA+ aislado.** $v_{2.1}$ reporta 44,30 con IC $[42,49, 46,12]$, cuyo IC se traslapa fuertemente con el de $v_{2.1b}$. La señal dominante proviene del optimizador, no de la descomposición del adaptador.
- **La calidad del *pool* monolingüe rige sobre su volumen.** $v_{2.2}$ regresa a ≈ 32 chrF++, eliminando casi por completo la ganancia de LoRA+. El cambio de *pool* (de OPUS-100, registro conversacional/web alineado con el corpus paralelo, a Wikipedia, registro enciclopédico) introduce vocabulario y longitudes ajenas que el filtro semántico no logra absorber porque el evaluador SBERT v_3 está calibrado sobre la distribución del corpus original; el resultado es coherente con la literatura de *domain-aware backtranslation* y se cita como justificación para el ítem de trabajo futuro sobre corpus monolingüe controlado por dominio.

Los hiperparámetros finales adoptados en $v_{2.1b}$ son los listados en la Sección A, con dos diferencias respecto del entrenamiento de v_{1bt} : (i) el optimizador es construido vía

`create_loraplus_optimizer` con $\lambda = 16$, y (ii) la precisión es bf16 (no fp16) por su mayor estabilidad numérica en presencia de tasas de aprendizaje asimétricas. El rango LoRA permanece en $r = 32$, $\alpha = 64$; el resto de la configuración es idéntico.

C.15 Tabla de scripts y reportes generados

El Cuadro A.18 enumera los scripts del pipeline NMT, las salidas principales y los reportes de control que permiten reproducir o auditar cada fase.

Tabla A.18: Pipeline reproducible del sistema NMT SA-BiNLLB.

Fase	Script base	Salida principal	Reporte de control
10	<code>scripts/nmt/10_canonicalize_dataset.py</code>	<code>data/processed/05_nmt_canonical[_xl]/^{train,valid,test\}.csv</code>	<code>reports/05_nmt/preprocessing[_xl]/canonical_manifest.json</code>
20	<code>scripts/nmt/20_semantic_filter.py</code>	<code>data/processed/06_nmt_filtered[_xl]/train_{accepted,flagged,removed\}.csv</code>	<code>reports/05_nmt/preprocessing[_xl]/semantic_filter.json</code>
21	<code>scripts/nmt/21_build_faiss.py</code>	<code>data/processed/06_nmt_filtered[_xl]/faiss_{shw,spa\}.index + meta parquet</code>	<code>reports/05_nmt/preprocessing[_xl]/faiss_index.json</code>
22	<code>scripts/nmt/22_train_sentencepiece.py</code>	<code>models/nmt/sentencepiece/sp_unigram_8k.model</code>	<code>reports/05_nmt/preprocessing[_xl]/sentencepiece_stats.json</code>
30	<code>scripts/nmt/30_train_lora.py</code>	<code>models/nmt/nllb_bidi_lora_v0[_xl]/</code>	<code>reports/05_nmt/training[_xl]/<run>^{summary,training_log\}.json</code>
40	<code>scripts/nmt/40_evaluate.py</code>	<code>reports/05_nmt/evaluation[_xl]/<run>/test_predictions[_topk].jsonl</code>	<code>reports/05_nmt/evaluation[_xl]/<run>/test_metrics.json</code>
41	<code>scripts/nmt/41_rare_token_eval.py</code>	—	<code>reports/05_nmt/evaluation[_xl]/<run>/rare_token_analysis[_reranked].json</code>
42	<code>scripts/nmt/42_qualitative_analysis.py</code>	<code>reports/05_nmt/evaluation[_xl]/<run>/qualitative^{sampled_examples.csv,qualitative_report.md\}</code>	<code>.../qualitative/bucket_summary.json</code>

Tabla A.18 (continuación)

Fase	Script base	Salida principal	Reporte de control
50	scripts/nmt/50_rerank.py	reports/05_nmt/ reranking[_xl]/<run>/test_ predictions_reranked.jsonl	reports/05_nmt/ reranking[_xl]/<run>/\{test_ metrics_reranked,ablation\}. json
60	scripts/nmt/60_backtranslate.py	data/processed/07_nmt_ augmented[_xl]/\{mono_ shw.txt,train_bt.csv\}	reports/05_nmt/ augmentation[_xl]/\{mono_ extraction,backtranslation\}. json
60b	scripts/nmt/60b_roundtrip_bt. py	data/processed/07_nmt_ augmented[_xl]/train_bt_ roundtrip[_iterN].csv	reports/05_nmt/ augmentation[_xl] /backtranslation_roundtrip. json
61	scripts/nmt/61_mine_pairs.py	data/processed/07_nmt_ augmented[_xl]/train_mined. csv	reports/05_nmt/ augmentation[_xl]/mining. json
62	scripts/nmt/62_morph_variants. py	data/processed/07_nmt_ augmented[_xl]/train_morph. csv (opcional)	reports/05_nmt/ augmentation[_xl]/morph_ variants.json
63	scripts/nmt/63_train_with_ augmented.py	models/nmt/nllb_bidi_lora_ v1_bt[_xl]/	reports/05_nmt/training[_xl] /<run>/\{summary,training_ log\}.json
70	scripts/nmt/70_compare_runs. py	reports/05_nmt/ evaluation[_xl]/comparison_ <v0>_vs_<v1>.md	ídem
71	scripts/nmt/71_human_eval_ template.py	reports/05_nmt/ evaluation[_xl]/human_eval_ template.csv	human_eval_anon_key.json
72	scripts/nmt/72_leaderboard.py	reports/05_nmt/ evaluation[_xl]/leaderboard. \{md,json\}	—
73	scripts/nmt/73_bootstrap_ci.py	reports/05_nmt/ evaluation[_xl]/<run> /bootstrap_ci.json	reports/05_nmt/ evaluation[_xl]/bootstrap_ ci_summary.md
74	scripts/nmt/74_thesis_tables_ phase6.py	thesis/latex/figuras/ generated/nmt_ \{leaderboard,directional_ metrics,bootstrap_ci,rare_ token_full,qualitative_ buckets\}[_xl].tex	—
75	scripts/nmt/75_human_ validation_workbook.py	reports/05_nmt/ evaluation[_xl]/human_ validation_100.xlsx	—

Tabla A.18 (continuación)

Fase	Script base	Salida principal	Reporte de control
76	scripts/nmt/76_pairwise_preference.py	reports/05_nmt/evaluation[_xl]/pairwise_preference.xlsx	pairwise_preference_anon_key.json
—	scripts/generate_nmt_tables.py	thesis/latex/figuras/generated/nmt_*.tex	—

Anexo D: Prototipo funcional de traducción

Este anexo documenta el prototipo descrito en el Capítulo 7 como evidencia funcional del sistema. Su propósito es mostrar que el modelo seleccionado puede usarse desde una interfaz local, recibir texto en cualquiera de las dos direcciones, devolver una traducción y registrar cada prueba para revisión posterior. El prototipo no reentrena ni modifica SA-BiNLLB; reutiliza el modelo campeón *v2.1b* LoRA+ y el modelo de *embeddings* *v3* para ofrecer una demostración operativa del sistema.

D.1 Componentes funcionales

El Cuadro A.19 resume los componentes del prototipo desde el punto de vista del lector: qué parte del sistema existe, qué función cumple y qué evidencia deja.

Tabla A.19: Componentes funcionales del prototipo

Componente	Función en el prototipo	Evidencia que aporta
Interfaz local	Permite escribir texto, elegir dirección de traducción y visualizar la salida	Captura de pantalla y demostraciones de uso en ambas direcciones
Modelo de traducción	Genera traducciones shiwilu↔castellano con el modelo seleccionado	Salidas observables en la interfaz y casos de prueba registrados
Reordenamiento semántico	Reevalúa las hipótesis candidatas con una señal semántica auxiliar	Traducción final y alternativas comparables cuando se activa el reranking
Registro de uso	Guarda cada prueba realizada con entrada, salida, configuración y latencia	Bitácora auditable de los casos ejecutados durante la demostración

D.2 Carga única en el arranque

Al iniciarse, la aplicación carga una sola vez el modelo campeón con `load_checkpoint`, su `tokenizer` extendido y la configuración de generación (`GenerationConfig`), y los conserva en un estado en memoria (`RUNTIME`). El modelo de *embeddings* v3 se carga de forma perezosa la primera vez que se activa el reranking. Esta carga única evita reinicializar los modelos en cada solicitud y mantiene la latencia de cada traducción en el rango interactivo. La inferencia se realiza sobre la GPU disponible cuando existe (`device = cuda`).

D.3 Reranking en la interfaz

El reordenamiento de hipótesis usa la misma combinación lineal documentada en el Anexo C, sección C.5: se generan cinco hipótesis por búsqueda en haz ($k = 5$), se normaliza la probabilidad de traducción del decodificador con *softmax* sobre los *sequence scores*, se calcula la similitud coseno entre la fuente y cada candidato con el modelo de *embeddings* v3, y se combina ambos términos con $\alpha = 0,7$ (el valor óptimo del modelo campeón). La hipótesis con mayor puntaje final se muestra como traducción y las restantes se ofrecen como alternativas. Cuando el reranking está desactivado, el prototipo devuelve directamente la mejor hipótesis del decodificador.

D.4 Esquema del registro estructurado

Cada traducción queda registrada en una bitácora estructurada. El registro conserva la fecha y hora de la prueba, la dirección de traducción, el texto ingresado, la salida elegida, si se usó reranking, las hipótesis candidatas y la latencia de respuesta. Esta información permite reconstruir una sesión de prueba sin depender de memoria del evaluador ni de capturas aisladas. El Cuadro 7.1 del Capítulo 7 resume estos campos.

D.5 Ejecución y despliegue

El prototipo se ejecuta localmente y abre una interfaz web en el navegador del equipo de prueba. Por diseño, no constituye un despliegue público ni una aplicación móvil: su función es demos-

trar la integración del modelo, habilitar pruebas controladas y registrar los casos usados en la evaluación. Puede habilitarse un enlace temporal para demostraciones puntuales, pero ese enlace no forma parte del producto final ni cambia el alcance local del sistema.

D.6 Casos de prueba registrados

Las traducciones de demostración resumidas en el Cuadro 7.2 provienen de la bitácora del prototipo. Cada ejecución acumula sus casos en el archivo de sesión correspondiente, de modo que el registro puede auditarse para recuperar las entradas probadas, las salidas devueltas, las hipótesis alternativas y las latencias por dirección. Esta evidencia respalda el medio de verificación del cuarto objetivo específico (demostración de traducción de ejemplos y registro de casos de prueba).

D.7 Trazabilidad técnica

Para reproducir o auditar la implementación, los componentes técnicos se conservan en el repositorio del proyecto. La aplicación principal está en `app.py`; el modelo campeón en `models/nmt/nllb_bidi_lora_v2_1b_loraplus_xl/`; el modelo de *embeddings* para reranking en `models/sentence_transformers/v3_iterative_hn_e5_base_bidirectional_xl/`; las funciones de inferencia en `src/nmt/inference/generate.py`; la configuración de generación en `config/nmt/inference.yaml`; y las bitácoras de prueba en `reports/05_nmt/frontend_logs/session_<fecha>.jsonl`. Esta información se incluye solo como respaldo reproducible; la evidencia principal del anexo es la funcionalidad demostrada y los casos registrados.

Anexo E: Validación participativa del sistema

Este anexo documenta la primera ejecución completa del protocolo de validación participativa aplicado al sistema SA-BiNLLB. Su objetivo es dejar evidencia entendible y trazable de la revisión humana de una muestra balanceada de traducciones, sin obligar al lector a revisar archivos internos del repositorio ni duplicar las 100 filas completas dentro del PDF.

E.1 Objetivo y alcance

La validación busca contrastar las métricas automáticas con juicio lingüístico sobre dos dimensiones: preservación del sentido y naturalidad de la salida. La muestra contiene 100 traducciones: 50 shiwilu→castellano y 50 castellano→shiwilu. La primera ejecución se realizó con Fidel Lomas Chota, hablante/revisor competente y uno de los principales exponentes y preservadores contemporáneos del shiwilu vinculados al proyecto. Este alcance aporta evidencia humana valiosa y trazable para una lengua con disponibilidad muy limitada de hablantes. El instrumento podría repetirse con otros revisores si las condiciones comunitarias lo permiten, pero esa ampliación se entiende como una posibilidad de fortalecimiento, no como una carencia de la revisión realizada.

La evidencia principal del anexo es la planilla de validación completada: allí se encuentran los 100 ítems revisados, los puntajes, las decisiones y los comentarios del revisor. Como respaldo complementario se conserva una constancia oral del revisor y dos registros visuales de coordinación/conformidad. Por contener elementos identificables propios de una comunicación privada, estos respaldos no se reproducen como figuras dentro del PDF; su función es acreditar la trazabilidad del proceso, mientras que la evidencia sustantiva permanece en la matriz de validación y en los resultados agregados.

Tabla A.20: Evidencias digitales de la validación participativa

Evidencia	Qué demuestra	Disponibilidad para consulta
Planilla de validación completada	Revisión de 100 traducciones con puntajes, decisiones y comentarios	Anexo digital local y hoja de cálculo externa indicada en E.2

Tabla A.20 (continuación)

Evidencia	Qué demuestra	Disponibilidad para consulta
Constancia oral del revisor	Confirmación de que el revisor revisó las traducciones y entregó observaciones	Enlace externo complementario
Registro de interacción	Respaldo visual de la coordinación de la revisión	Enlace externo complementario
Constancia visual de conformidad	Respaldo complementario posterior a la revisión	Enlace externo complementario

Los enlaces externos complementarios son:

[Constancia oral del revisor](#)

[Registro de interacción de la revisión](#)

[Constancia visual de conformidad](#)

E.2 Estructura del instrumento

La planilla de revisión contiene una hoja de instrucciones y dos hojas de evaluación, una por dirección de traducción. Cada fila incluye *N*, *Texto fuente*, *Traducción del modelo*, *Sentido* (1–5), *Naturalidad* (1–5), *Decisión* y *Comentarios*. El archivo completo no se inserta en el PDF para evitar duplicar las 100 filas en papel. Para lectores externos, se encuentra disponible en:

[Planilla completa de validación participativa](#)

La rúbrica interpreta *Sentido* como conservación del significado de la fuente y *Naturalidad* como aceptabilidad lingüística en la lengua destino. La *Decisión* clasifica cada salida como *aceptar*, *corregir* o *rechazar*. Antes de consolidar los resultados se verificó que hubiera 50 filas por dirección, que los puntajes estuvieran completos en escala 1–5, que las decisiones fueran interpretables y que todos los casos corregibles incluyeran comentario.

E.3 Resultados agregados

Los resultados respaldan al modelo en ambas direcciones. La dirección shiwilu→castellano aparece como la más estable, tanto en promedios como en proporción de aceptación. La dirección

Tabla A.21: Síntesis de la validación participativa del sistema.

Dirección	n	Sentido	Naturalidad	Aceptar	Corregir / Rechazar
shw→spa	50	4,74	4,76	41 (82 %)	9 (18 %) / 0 (0 %)
spa→shw	50	4,58	4,68	39 (78 %)	11 (22 %) / 0 (0 %)
Global	100	4,66	4,72	80 (80 %)	20 (20 %) / 0 (0 %)

castellano→shiwilu mantiene evaluación favorable, pero concentra más correcciones por exigencias de morfología, concordancia y selección léxica. La ausencia de rechazos indica que los errores observados fueron recuperables mediante edición puntual.

E.4 Ejemplos representativos

Tabla A.22: Correcciones representativas registradas por el revisor.

Dirección	Fuente	Traducción del modelo	Corrección u observación
shw→spa	<i>yakana'lek</i>	quiero ganar.	Más precisamente dice “quiero ganarle”.
shw→spa	<i>dei'techek</i>	me mataré.	La forma esperada es “lo mataré”.
shw→spa	<i>shiwilu la'la'wek nap'i' mudinupawiñi</i>	mi lengua shiwilu antiguamente era barro	El revisor propone “mi lengua shiwilu antiguamente estaba sano”.
spa→shw	te mostraré.	<i>alli'echek</i>	<i>A'lli'echen</i> corresponde a “te mostraré”; <i>a'lli'echek</i> a “le mostraré”.
spa→shw	lean esto.	<i>luntuker'asu'</i>	La oración en castellano está en plural; debería ser <i>luntuku'</i> .
spa→shw	eres nervioso.	<i>watensu'nuka'ma</i>	El revisor indica “eres duro”.

E.5 Uso futuro del instrumento

El valor metodológico del instrumento es que puede repetirse sin alterar la muestra, la rúbrica ni el formato. Una ampliación con más hablantes permitiría calcular acuerdo interevaluador y revisar discrepancias por dirección, siempre que la disponibilidad real de hablantes haga viable

esa coordinación. En el contexto del shiwilu, esta posibilidad no debe leerse como una falta del estudio, sino como una ruta de ampliación para un instrumento que ya produjo una primera evidencia humana sólida y reproducible.

E.6 Trazabilidad técnica

Para auditoría interna, la planilla completada se entrega como anexo digital local en anexos_digitales/Anexo_E_validacion_participativa_100.xlsx. También se conserva una copia reproducible en reports/05_nmt/evaluation_xl/validacion_participativa_100.xlsx. La plantilla base usada para preparar la revisión está en reports/05_nmt/evaluation_xl/human_validation_100.xlsx. Estas rutas no son necesarias para comprender los resultados del anexo; se incluyen para permitir auditoría y reproducción del proceso.