

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

FACULTAD DE CIENCIAS E INGENIERÍA



“Traducción automática neuronal Shiwilu–Castellano”

Tesis para obtener el título profesional de Ingeniería Informática

AUTOR:

Fabian Prado Infanson

ASESOR:

Hector Gómez

Lima, 26 de Julio del 2025

Resumen

Índice general

Resumen	1
1 Generalidades	6
1.1 Problemática	6
1.1.1 Árbol de Problemas	9
1.1.2 Descripción	9
1.1.3 Causas	9
1.1.4 Consecuencias	10
1.1.5 Problema seleccionado	11
1.2 Objetivos	11
1.2.1 Objetivo general	11
1.2.2 Objetivos específicos	12
1.2.3 Resultados esperados	13
1.2.4 Mapeo de objetivos, resultados y verificación	14
1.3 Métodos y Procedimientos	15
1.3.1 Herramientas:	15
1.3.2 Justificación	15
1.3.3 Detalle	16
1.3.4 Métodos	17
1.3.5 Procedimientos	18
2 Marco Conceptual	19
2.1 Introducción	19
2.2 Desarrollo del marco	19

2.2.1	Procesamiento de Lenguaje Natural (NLP)	20
2.2.2	Lenguas de bajo recursos (LRL)	20
2.2.3	Alineación oración a oración	21
2.2.4	Preprocesamiento y tokenización sub-palabra	21
2.2.5	Aumento de datos (<i>data augmentation</i>)	22
2.2.6	Transfer learning y modelos multilingües	23
2.2.7	Adaptación eficiente (adapters/LoRA)	24
2.2.8	Representaciones vectoriales (embeddings) y minería/filtrado	24
2.2.9	BLEU (Bilingual Evaluation Understudy)	25
2.2.10	chrF (carácter n-gram F-score)	25
2.2.11	BERTScore y COMET	26
3	Estado del Arte	27
3.1	Introducción	27
3.2	Objetivos de revisión	27
3.3	Preguntas de revisión	28
3.4	Estrategia de búsqueda	28
3.4.1	Motores de búsqueda a usar	28
3.4.2	Cadenas de búsqueda a usar	29
3.4.3	Documentos encontrados	31
3.4.4	Criterios de inclusión/exclusión	32
3.5	Formulario de extracción de datos	33
3.6	Resultados de la revisión	34
3.6.1	¿Qué técnicas de generación y ampliación de datos (back-translation, mutación semántica, paraphrasing, pivoting, filtrado por embeddings, etc.) producen mejoras reproducibles en NMT para pares de muy bajos recursos?	34

3.6.2	¿Qué arquitecturas y estrategias de entrenamiento (multilingüe, transfer learning, fine-tuning bidireccional, adapters, few/zero-shot) ofrecen el mejor balance entre rendimiento y coste computacional para un modelo shiwilu↔castellano, y qué baselines son apropiados para la comparación?	37
3.6.3	¿Qué métricas automáticas (BLEU, ChrF++, TER, ¿etc.) y procedimientos de validación combinada (evaluación automática + pruebas participativas con hablantes) son más adecuados y fiables para medir adecuación lingüística y pertinencia cultural en traducciones de lenguas originarias con corpus escaso?	39
3.7	Conclusiones	41
4	Recopilación y preparación inicial del corpus bilingüe	43
4.1	Introducción	43
4.2	Materiales textuales bilingüe recopilados	43
4.3	Elaboración del corpus de flashcards shiwilu – castellano	44
4.4	Distribución temática del corpus generado	45
4.5	Proceso de preprocesamiento del corpus bilingüe	45
4.6	Preparación del corpus consolidado para modelo de embeddings	47
5	Conclusiones y trabajos futuros	49
5.1	Conclusiones	49
5.2	Trabajos futuros	49
	Referencias	50
A	Anexos	56

Índice de cuadros

1.1	Resultados esperados (mapeo de objetivos, MV e IOV)	14
1.2	Herramientas, métodos y procedimientos a utilizar	15
3.1	Resultados de búsqueda de las cadenas	32
3.2	Resultados luego de aplicar criterios de exclusión	32
3.3	Formulario de extracción de datos	33
4.1	Resumen de materiales textuales bilingües recopilados	44
4.2	Distribución temática del corpus generado	45
4.3	Etapas del preprocesamiento del corpus bilingüe	47
4.4	Corpus consolidado para modelo de embeddings	48
A.1	Limitaciones del proyecto	60
A.2	Umbral de riesgo (probabilidad e impacto)	61
A.3	Matriz de riesgos del proyecto	62
A.4	Lista de tareas (EDT)	65
A.5	Cronograma del proyecto	67
A.6	Presupuesto del proyecto	70

Capítulo 1

Generalidades

1.1 Problemática

El shiwilu, también llamado jebero, es una lengua amazónica peruana de la familia cahuapana que atraviesa un estado crítico de amenaza. El número de hablantes es muy reducido, en su mayoría personas adultas mayores, y la transmisión intergeneracional se encuentra quebrada (Valenzuela, 2018). Aunque en 2016 fue declarada Patrimonio Cultural de la Nación, su presencia en el ecosistema digital sigue siendo mínima, lo que incrementa el riesgo de desplazamiento. Cuando una lengua no encuentra espacios de uso en entornos digitales, su marginación se acelera y disminuye la posibilidad de su aprendizaje y uso cotidiano (Ministerio de Cultura, 2016; UNESCO, 2023).

En este escenario, un sistema de traducción automática neuronal entre shiwilu y castellano podría convertirse en una herramienta estratégica para documentar, acceder y circular conocimiento bilingüe. No obstante, el desarrollo de un traductor de este tipo enfrenta un cuello de botella inmediato: no existe un corpus paralelo shiwilu–castellano con volumen y diversidad suficientes para entrenar y evaluar modelos con criterios reproducibles. La traducción automática, tanto en su vertiente estadística como neuronal, depende de colecciones amplias de oraciones alineadas; cuando el paralelo es mínimo, la calidad de los modelos cae y los resultados no son comparables entre estudios (Mager & Meza, 2018). En shiwilu, más allá de aportes de documentación, como el diccionario bilingüe con ejemplos de uso, los datos disponibles siguen siendo escasos y dispersos, de modo que no hay baselines ni conjuntos de prueba estables contra los cuales contrastar avances (Valenzuela, 2018). Esta situación contrasta con pares mejor

documentados en la región, como quechua–español o shipibo–español, donde ya existen corpus iniciales y evaluaciones básicas que permiten organizar la investigación (Galarreta, 2017; Chuquimamani, 2021).

El problema abarca también la calidad y la representatividad de los datos. En ausencia de textos variados, el material disponible tiende a concentrarse en narrativas tradicionales o léxico especializado, lo que sesga el dominio temático y deja fuera construcciones frecuentes del uso cotidiano. Con pocos ejemplos, los modelos neuronales sobreajustan y generalizan mal, fenómeno documentado en lenguas indígenas con corpus de apenas miles de oraciones (Mager & Meza, 2018). A ello se suma la distancia tipológica entre shiwilu y castellano: la morfología aglutinante, ciertos patrones estructurales y los alineamientos semánticos no uno a uno complica la alineación y la traducción literal de términos culturalmente marcados; en varios casos no hay equivalencias directas, lo que exige una curación cuidadosa y verificación contextual de las parejas de oración (Ministerio de Cultura, 2016). Incluso si se reúne un primer conjunto paralelo, la calidad del dato y su adecuación semántica y cultural se vuelven el desafío central.

La dimensión sociolingüística es igualmente ineludible, ya que la construcción de recursos depende del trabajo con hablantes. Dada la escala de la comunidad y la edad de sus miembros, la obtención y validación de paralelos requiere colaboración cercana. En este proyecto, el Grupo Chana ha articulado la recolección de materiales con apoyo del señor Fidel Lomas Chota, hablante competente y autor de relatos en shiwilu, quien ha contribuido con traducciones y validaciones. Su participación garantiza datos de primera mano y criterio cultural para juzgar la aceptabilidad de equivalencias, un aspecto que las métricas automáticas no capturan por sí solas (UNESCO, 2023). La experiencia comparada en náhuatl y guaraní sugiere, además, que sin esta mediación humana los modelos tienden a aprender artefactos del corpus y fallan en variedades o géneros no cubiertos por los datos de entrenamiento (Ríos, 2019; Baladón, Lucas & Pardiñas, 2024).

El panorama regional confirma que la base del problema en lenguas de muy bajos recursos es doble: escasez de corpus y ausencia de referencias evaluativas. En quechua sureño, la creación de nuevos conjuntos bilingües a partir de fuentes dispersas fue condición previa para evaluar con métricas estándar y establecer comparaciones significativas; sin ese piso de

datos, no era posible justificar avances ni orientar mejoras (Chuquimamani, 2021). En shipibo–español, un esfuerzo temprano desde el enfoque estadístico mostró el mismo patrón: antes de buscar la mejor arquitectura, era imprescindible contar con un corpus alineado utilizable y un procedimiento reproducible para entrenar y medir (Galarreta, 2017). Estas lecciones sugieren que, en shiwilu, no hay atajos de ingeniería: sin un primer corpus paralelo confiable y criterios de evaluación claros, cualquier intento de traducción neuronal carecerá de base metodológica y relevancia práctica (Meque, Angel, Sidorov & Gelbukh, 2023).

En síntesis, la problemática que aborda esta tesis es multidimensional. En el plano técnico, falta el insumo esencial, el cual es un corpus paralelo validado y por arrastre, faltan líneas de base y protocolos de evaluación adaptados al par shiwilu–castellano. En el plano lingüístico, la asimetría tipológica y la carga cultural de numerosos términos exigen datos cuidadosamente curados y verificación contextual. En el plano social, la escala pequeña y envejecida de la comunidad obliga a que la construcción de recursos sea participativa, pues solo así se asegura que las traducciones sean útiles y respetuosas (UNESCO, 2023). Mantener este conjunto de factores sin atender mantiene al shiwilu fuera del ecosistema digital y limita su aprendizaje, su circulación escrita y su presencia simbólica en la esfera pública.

Este diagnóstico delimita con precisión el núcleo del problema: sin corpus paralelo validado, sin líneas de base y sin un esquema de verificación que combine métricas automáticas con revisión por hablantes, no es posible avanzar con rigor hacia un traductor neuronal shiwilu↔castellano. Por ello, esta investigación asume como punto de partida la construcción y depuración de datos bilingües con apoyo comunitario, junto con la definición de criterios evaluativos reproducibles que permitan situar cualquier resultado en una línea cero clara. Solo sobre ese cimiento será razonable explorar y comparar arquitecturas, estrategias de transferencia y futuros incrementos de datos. Atender esta problemática no solo llena un vacío científico en la traducción automática de lenguas peruanas de muy bajo recurso; también supone un paso concreto para que el shiwilu tenga presencia en la esfera tecnológica contemporánea (Valenzuela, 2018; UNESCO, 2023).

1.1.1 Árbol de Problemas

En la figura 1 se muestra un panorama claro para observar la problemática central, las causas consideradas y consecuencias que generan estas mismas.




Figura 1: Árbol de Problemas

1.1.2 Descripción

1.1.3 Causas

- Inexistencia de un corpus paralelo shiwilu–castellano adecuado.

Los textos disponibles son escasos, dispersos y con variaciones ortográficas y de dominio que dificultan su aprovechamiento. Falta alineación fiable a nivel de oración, hay ruido (traducciones parciales, glosas, duplicados) y metadatos incompletos. Además, no existen particiones estandarizadas de entrenamiento/validación/prueba que permitan comparaciones justas y reproducibles.

- Investigación limitada y falta de baselines adaptados al par shiwilu–castellano.

Hay pocos estudios específicos y no se cuenta con líneas base consensuadas (configuraciones mínimas, tokenización/segmentación apropiada o variantes multilingües razonables). Esta carencia impide medir avances con rigor, aislar el impacto de cada técnica y evitar conclusiones sesgadas por configuraciones ad-hoc.

- Falta de métodos comparativos en línea para probar y contrastar modelos NMT.

No existe una interfaz accesible que permita evaluar modelos lado a lado, registrar métricas y recopilar ejemplos de uso real de forma ágil. Sin pruebas comparativas en un entorno web, se ralentiza el ciclo de retroalimentación, se dificulta la trazabilidad de cambios y se limita la participación de docentes e integrantes de la comunidad.

- Protocolos combinados de validación automatizada y participativa insuficientes.

Predomina el uso de métricas automáticas generales que no capturan adecuación, naturalidad ni pertinencia cultural. Faltan guías, instrumentos y criterios para integrar la revisión de hablantes (escalas, rúbricas, taxonomías de error, control de acuerdo inter-anotador), lo que genera evaluaciones incompletas y poco accionables.

1.1.4 Consecuencias

- Modelos con precisión insuficiente en usos reales.

Las salidas presentan errores léxicos y morfosintácticos, inestabilidad ante variantes ortográficas y pérdida de sentido en dominios no vistos. Esto reduce la confianza de usuarios y docentes, eleva el costo de posesición y limita la adopción del traductor en tareas cotidianas (material educativo, comunicaciones comunitarias, trámites), dejando el sistema como un prototipo poco útil fuera del laboratorio.

- Escasez de materiales bilingües para enseñanza y uso práctico.

La falta de recursos paralelos limpios y actualizados impide generar textos, ejercicios y guías bilingües con progresión pedagógica. Se restringen las oportunidades de lectura y escritura en shiwilu con apoyo del castellano, y se dificulta producir contenidos para contextos

reales (salud, servicios públicos, señalética), perpetuando la dependencia de materiales aislados o desactualizados.

- Menor visibilidad digital y dificultad en la revitalización.

La baja disponibilidad de herramientas y contenidos en línea reduce la presencia del shiwilu en buscadores, plataformas y aplicaciones, desincentivando la participación de jóvenes y hablantes potenciales. Esto crea un círculo vicioso: menor uso genera menos datos y menos innovación, lo que a su vez limita el apoyo institucional y la colaboración con otras comunidades y actores tecnológicos.

- Problema seleccionado – Problema central

Dificultad para que nuevos hablantes aprendan, interioricen y usen cotidianamente la lengua shiwilu, por la limitada disponibilidad de recursos bilingües, herramientas y evaluaciones pertinentes.

1.1.5 Problema seleccionado

Dificultad para que nuevos hablantes aprendan, interioricen y usen cotidianamente la lengua shiwilu, por la limitada disponibilidad de recursos bilingües, herramientas y evaluaciones pertinentes.

1.2 Objetivos

1.2.1 Objetivo general

Mejorar la capacidad de nuevos hablantes para aprender e interiorizar la lengua shiwilu mediante el desarrollo de un sistema de traducción automática neuronal shiwilu↔castellano, sustentado en un corpus paralelo, protocolos de evaluación automática-participativa y un prototipo funcional para su uso en contextos reales.

1.2.2 Objetivos específicos

1. **Recopilar y alinear un corpus paralelo shiwilu–castellano y producir particiones reproducibles para entrenamiento, validación y prueba.**
 - **Alcance de fuentes:** delimitar criterios de inclusión y priorizar materiales comunitarios, educativos y documentales.
 - **Alineación a nivel de oración:** segmentar, normalizar variantes ortográficas y sincronizar pares con apoyo de herramientas.
 - **Reproducibilidad:** definir reglas para train/valid/test, con bitácora del preprocesamiento.
2. **Implementar y validar un modelo de traducción automática neuronal bidireccional (shiwilu↔castellano).**
 - **Arquitectura y tokenización:** seleccionar un esquema adecuado a bajo recurso y fijar parámetros de segmentación.
 - **Control experimental:** documentar configuraciones e hiperparámetros para asegurar replicabilidad.
3. **Definir un protocolo de validación que combine evaluación automática y validación participativa con hablantes para medir adecuación lingüística y pertinencia cultural.**
 - **Métricas automáticas:** seleccionar indicadores (p. ej., BLEU/chrF/COMET) y su procedimiento de cálculo.
 - **Evaluación con hablantes:** diseñar instrumentos con rúbricas de adecuación, fluidez y pertinencia cultural.
 - **Confiabilidad:** establecer muestreo, instrucciones de anotación y medición de consistencia entre evaluadores.
4. **Diseñar e implementar un prototipo funcional de traductor automático neuronal que integre el modelo entrenado y facilite su uso y prueba.**

- **Funcionalidad mínima:** ingreso de texto y visualización de resultados de forma simple y accesible.
- **Pruebas y registro:** habilitar pruebas básicas y registro estructurado de entradas/salidas para análisis.
- **Integración y despliegue:** empaquetar el modelo y la interfaz en un entorno ejecutable

1.2.3 Resultados esperados

- O1:
 - R1: Corpus paralelo shiwilu–castello ambos correctamente preprocesado y con las características relevantes cantidad de palabras, de sustantivos, etc.
 - R2: Modelo de *embeddings* preparado.
- O2:
 - R3: Modelo de traducción automático shiwilu->castellano entrenado.
 - R4: Modelo de traducción automático castellano->shiwilu entrenado.
- O3:
 - R5: Protocolo de validación documentado (métricas automáticas, instrumentos y rúbricas para hablantes).
- O4:
 - R6: Prototipo funcional ejecutable localmente que integre el modelo NMT y permita pruebas básicas.
 - R7: Documento de proceso para la validación con pruebas de experto.
 - R8: Ejecución del proceso de validación con expertos.

1.2.4 Mapeo de objetivos, resultados y verificación

Para cada uno de los objetivos planteados, se plantearon los siguientes resultados esperados en esta Tabla 1.

Tabla 1.1: Resultados esperados (mapeo de objetivos, MV e IOV)

Objetivo	Resultados asociados	Medio de verificación (MV)	Indicador objetivamente verificable (IOV)
O1: Recopilar y alinear un corpus paralelo shiwilu–castellano y producir particiones reproducibles.	R1: Corpus depurado y alineado. R2: Modelo de <i>embeddings</i> preparado.	MV1: Informe breve de criterios de selección, normalización y alineación aplicadas. MV2: Entregable del modelo de <i>embeddings</i>	IOV1: Procedimiento descrito y aplicado. IOV2: Datos obtenidos del modelo de <i>embeddings</i>
O2: Implementar y validar un modelo NMT bidireccional (shiwilu↔castellano).	R3: Modelo shiwilu→castellano R4: Modelo castellano→shiwilu.	MV3: Descripción del pipeline de entrenamiento y configuraciones probadas. MV4: Reporte de evaluación automática en valid/test. MV5: Protocolo que prioriza la evaluación automática (métricas) e incluye una sesión acotada con hablantes.	IOV3: Entrenamientos completados en ambas direcciones. IOV4: Métricas BLEU/chrF presentadas.
O3: Definir un protocolo de validación que combine evaluación automática y participativa.	R4: Protocolo de validación documentado (métricas, instrumentos y rúbricas).	MV6: Prototipo operativo con guía breve de uso y video corto de demostración.	IOV5: Métricas automáticas reportadas y muestra acotada con hablantes registrada.
O4: Diseñar e implementar un prototipo funcional de traductor NMT que facilite su uso y prueba.	R5: Prototipo funcional ejecutable localmente que integre el modelo NMT y permita pruebas básicas. R7: Documento de proceso para pruebas de experto R8: Proceso de validación con expertos ejecutado.		IOV6: Demostración de traducción de ejemplos y registro de casos de prueba ejecutada (expertos).

1.3 Métodos y Procedimientos

Se describirán las herramientas, métodos, enfoques y procedimientos para lograr los resultados previstos. Todo ello se plantea en la tabla 2.

Tabla 1.2: Herramientas, métodos y procedimientos a utilizar

Resultados Esperados	Herramientas (H), Métodos (M) y Procedimientos (P)
R1: Corpus shiwilu–castellano preprocesado y alineado.	H: Python, regex, tokenizador. M: Limpieza, segmentación, alineación. P: Criterios→limpieza/segmentación→alineación→bitácora.
R2: Modelo de embeddings preparado.	H: Python, E5/Sentence-Transformers (o LASER), FAISS/índice vectorial. M: Embeddings oracionales; similitud y umbral.
R3: NMT shiwilu→castellano entrenado.	H: Python, PyTorch (Transformers) o TensorFlow; SentencePiece. M: Entrenamiento supervisado NMT; subword; evaluación BLEU/chrF. P: Particionar→entrenar→validar→métricas.
R4: NMT castellano→shiwilu entrenado.	H: Python, PyTorch (Transformers) o TensorFlow; SentencePiece. M: Mismo esquema que R3 en dirección inversa. P: Repetir pipeline→consolidar métricas.
R5: Protocolo de validación documentado.	H: Procesador de texto; formularios/hojas. M: Rúbricas (adecuación, fluidez, pertinencia); muestreo.
R6: Prototipo local funcional (UI simple).	H: Python, PyTorch/TensorFlow; Gradio/Streamlit; logs. P: UI→cargar checkpoint→traducir→registrar.
R7: Documento de proceso para pruebas de experto.	M: Plantilla de acta y checklist; versionado. P: Formato→checklist→evidencias→archivo.
R8: Validación con expertos ejecutada (actas).	M: Aplicación del protocolo; consolidación. P: Sesiones→consolidado→síntesis→mejoras.

1.3.1 Herramientas:

1.3.2 Justificación

La selección de herramientas responde a la necesidad de implementar un pipeline compacto y reproducible para traducción automática shiwilu↔castellano en un contexto de bajo recurso. Python se adopta como lenguaje de orquestación por su ecosistema maduro y la facili-

dad para controlar versiones, semillas y configuraciones a lo largo de todo el proceso.

En la preparación del corpus (R1) se emplean expresiones regulares y un tokenizador básico para limpieza, segmentación y alineación con reglas simples de longitud y puntuación, manteniendo una bitácora que documenta criterios y transformaciones. Para la representación semántica y el filtrado (R2) se utilizan embeddings oracionales generados con E5/SentenceTransformers (o LASER) y un índice vectorial FAISS, lo que permite estimar similitudes, fijar umbrales operativos, detectar *outliers* y priorizar pares útiles antes del modelado.

El modelado NMT bidireccional (R3–R4) se realiza con PyTorch o TensorFlow (familia Transformers) y segmentación en subpalabras mediante SentencePiece, a fin de reducir OOV y estabilizar el vocabulario en ambas direcciones. El entrenamiento se conduce bajo control experimental (semillas, *checkpoints* y configuraciones registradas) y se evalúa con métricas reproducibles (BLEU y chrF++), garantizando comparabilidad entre modelos y corridas.

Para la verificación práctica (R6) se implementa un prototipo local con Gradio o Streamlit, con interfaz mínima de entrada, traducción y salida, y registro estructurado de entradas y salidas para análisis posterior. La validación participativa (R5, R7–R8) se instrumenta con formularios y hojas de cálculo, apoyada en rúbricas de adecuación, fluidez y pertinencia cultural, y consolidada mediante actas y resúmenes que facilitan la trazabilidad de hallazgos y acciones de mejora.

En conjunto, estas herramientas sostienen cuatro principios operativos: calidad de datos (regex, tokenizador, embeddings e índice), robustez del modelo (SentencePiece y marcos de Deep learning), evaluación reproducible (BLEU/chrF++) y transferencia a la práctica (prototipo local y validación experta).

1.3.3 Detalle

- **Python:** Orquestación del pipeline de preprocesamiento, entrenamiento, evaluación y prototipado; control de semillas, versiones y configuraciones.

- **Expresiones regulares (regex):** Limpieza y normalización de texto (tildes, signos, espacios, duplicados) previas a la segmentación y alineación; soporte a la bitácora de decisiones.

- **Tokenizer:** Segmentación inicial de oraciones y palabras; generación de conteos

(tokens, tipos, OOV) para trazabilidad del corpus paralelo.

- **E5 / Sentence-Transformers (o LASER)**: Embeddings oracionales para medir similitud semántica, detectar outliers y priorizar material útil en bajo recurso.
- **FAISS / índice vectorial**: Búsqueda eficiente en el espacio de embeddings y aplicación de umbrales para filtrado y control de calidad.
- **SentencePiece**: Segmentación en subpalabras (BPE/unigram) para reducir OOV y estabilizar el vocabulario en shiwilu↔castellano.
- **PyTorch / TensorFlow (Transformers)**: Entrenamiento NMT bidireccional con registro de hiperparámetros, checkpoints y configuraciones reproducibles.
- **sacreBLEU**: Cálculo estandarizado de BLEU en validación y prueba con parámetros fijados para asegurar comparabilidad.
- **chrF++**: Métrica complementaria basada en caracteres y palabras, adecuada para morfología rica en escenarios de bajo recurso.
- **Gradio / Streamlit**: Prototipo local con interfaz mínima (entrada → traducción → salida) y registro estructurado de casos para análisis posterior.
- **Formularios y hojas de cálculo**: Instrumentos para rúbricas, actas y consolidación de resultados en la validación con expertos (componentes cuantitativos y cualitativos).

1.3.4 Métodos

• Data augmentation

Generación de datos sintéticos (p. ej., sinónimos controlados, back-translation, interpolación en el espacio latente) para robustecer el entrenamiento, mejorar la cobertura y mitigar el sobreajuste en bajo recurso.

• Proceso KDD

Marco de descubrimiento de conocimiento que estructura el pipeline en selección, preprocesamiento, transformación y análisis exploratorio, asegurando orden, trazabilidad y criterios reproducibles.

• Tokenización subword (BPE/unigram)

Segmentación en subpalabras con SentencePiece para estabilizar el vocabulario y re-

ducir OOV en lenguas de bajo recurso, manteniendo compatibilidad en ambas direcciones de traducción.

- **Alineación paralela**

Uso combinado de herramientas automáticas (p. ej., *awesome-align*) y reglas lingüísticas simples (longitud, puntuación) para obtener alineaciones consistentes entre textos fuente y destino.

- **Evaluación A/B con bootstrapping**

Contraste de métricas automáticas (p. ej., BLEU, chrF++) mediante re-muestreo para estimar variabilidad y significancia de diferencias entre configuraciones o modelos.

- **Automatización de pipelines**

Orquestación de entrenamientos, evaluaciones y registros con scripts o DAG ligeros, fijando semillas y configuraciones para garantizar reproducibilidad y auditoría de experimentos.

1.3.5 Procedimientos

- **Revisión humana y refinamiento**

Evaluación muestral por hablantes nativos en coherencia, fluidez y fidelidad; consolidación de medidas descriptivas y ajuste iterativo de reglas de limpieza, alineación y generación sintética.

- **Verificación de calidad léxica (OOV)**

Comparación de vocabularios del corpus original y del sintético para estimar la proporción de tokens fuera de vocabulario; si se supera el umbral definido, se reajustan tokenización, filtrado y estrategias de expansión de datos.

- **Selección de checkpoint y control experimental**

Registro de configuraciones e hiperparámetros; elección del mejor checkpoint según validación; almacenamiento de bitácoras y métricas para comparación entre corridas.

- **Registro estructurado y trazabilidad**

Conservación de entradas y salidas, versiones de datos, semillas y resultados en repositorio organizado, facilitando replicación, auditoría y análisis posterior.

Capítulo 2

Marco Conceptual

2.1 Introducción

A continuación se presenta una síntesis de los fundamentos teóricos necesarios para clarificar los distintos aspectos de la problemática. En este capítulo se incluyen definiciones (por ejemplo, procesamiento de lenguaje natural), los algoritmos principales del aprendizaje automático y las técnicas concretas que se emplearán en la investigación (por ejemplo, back-translation), además de otros conceptos clave que sustentan el estudio. El propósito es ofrecer al lector un marco conceptual claro y coherente que facilite la comprensión de las decisiones metodológicas y la interpretación de los resultados.

2.2 Desarrollo del marco

El objetivo principal del marco conceptual es reunir y definir de forma precisa los conceptos, técnicas y herramientas que se utilizarán en la tesis, de modo que quede explícito el conocimiento necesario para comprender el problema y las soluciones propuestas. Este bloque conceptual proporciona el vocabulario técnico común para el trabajo, articula las nociones que sustentan los procedimientos experimentales y sirve de referencia para la interpretación de los resultados.

2.2.1 Procesamiento de Lenguaje Natural (NLP)

El Procesamiento de Lenguaje Natural (PLN) es la disciplina interdisciplinaria que combina informática, inteligencia artificial y lingüística para permitir que las máquinas analicen, interpreten y generen lenguaje humano de forma automática; abarca tareas que van desde la segmentación y el etiquetado morfosintáctico hasta la representación semántica y la generación de texto (Chowdhury, 2005).

A nivel conceptual, el PLN transforma texto bruto en representaciones manipulables (tokens, sub-palabras, vectores/embeddings) y aplica modelos estadísticos o neuronales para aprender patrones lingüísticos: las etapas típicas son preprocesamiento → representación → modelado → evaluación. En la última década, los enfoques basados en aprendizaje profundo (p. ej. redes neuronales profundas y arquitecturas de atención) han pasado a ser el centro del PLN por su capacidad para aprender jerarquías de representaciones directamente de los datos (Socher & Manning, 2013).

2.2.2 Lenguas de bajo recursos (LRL)

Las lenguas de muy bajos recursos (Low-Resource Languages, LRL) son aquellas para las cuales existe una cantidad muy limitada de datos digitales, y en particular de corpus paralelos (fuente–meta) suficientes para entrenar modelos estadísticos o neuronales con buen desempeño. Esta condición incluye no solo la escasez numérica de ejemplos paralelos, sino también problemas asociados como dominio sesgado, variación ortográfica, ausencia de anotaciones lingüísticas y poca disponibilidad de textos monolingües de calidad (Zoph et al., 2016; Koehn & Knowles, 2017).

La escasez de datos reduce la capacidad de aprendizaje y la generalización de modelos NMT, incrementa el riesgo de overfitting y disminuye la cobertura léxica y contextual del sistema. Conceptualmente, las LRL requieren estrategias que compensen la falta de paralelo, por ejemplo, transferencia desde modelos preentrenados, aumento de datos o minería de paralelo comparable y una mayor atención a la normalización y validación lingüística para asegurar que los ejemplos disponibles representen adecuadamente las variantes del habla. (Artetxe & Schwenk, 2019).

2.2.3 Alineación oración a oración

La alineación oración a oración consiste en emparejar oraciones equivalentes en dos lenguas para convertir colecciones comparables en pares fuente y meta utilizables por sistemas de traducción. En la práctica, este proceso combina heurísticas simples, por ejemplo reglas basadas en la longitud relativa de los segmentos, con métodos estadísticos o neuronales que explotan señales léxicas, sintácticas y contextuales; asimismo, es habitual complementar las salidas automáticas con reglas lingüísticas o validación humana para reducir el ruido. Las correspondencias resultantes pueden ser uno a uno, uno a muchos o muchos a uno. La calidad de estas alineaciones puede medirse mediante indicadores como la precisión y la tasa de pares falsos, y condiciona directamente la utilidad del corpus: las alineaciones defectuosas introducen ruido que degrada el aprendizaje del modelo, mientras que las alineaciones limpias incrementan la señal supervisada disponible, lo cual es especialmente crítico en pares de muy bajos recursos. Las herramientas automáticas modernas, como los alineadores neuronales que emplean representaciones contextualizadas, facilitan la extracción de paralelo; aun así, en todos los casos es necesario aplicar criterios de filtrado y verificación para garantizar la coherencia temática y la trazabilidad de los pares.

2.2.4 Preprocesamiento y tokenización sub-palabra

El preprocesamiento agrupa las operaciones de limpieza y normalización del texto que convierten el material bruto en unidades coherentes y comparables para el modelado. Conceptualmente incluye la normalización de codificación (por ejemplo, normalización Unicode), la limpieza de ruido (eliminación o corrección de caracteres inválidos, marcas de formato o duplicados), la segmentación en oraciones y la normalización ortográfica mínima (p. ej., manejo de mayúsculas/minúsculas, tratamiento de signos de puntuación y variantes tipográficas). Estas transformaciones tienen por objeto reducir la varianza superficial del corpus y hacer que las señales lingüísticas que aprenden los modelos sean más estables y comparables entre fuentes heterogéneas.

La tokenización sub-palabra es una estrategia que divide las unidades léxicas en fragmentos más pequeños aprendidos a partir del propio corpus, con el fin de reducir el problema

de palabras fuera de vocabulario y capturar elementos morfológicos productivos. Técnicamente, los métodos más usados son BPE (Byte Pair Encoding) y los modelos de unigram / SentencePiece, que construyen vocabularios de sub-unidades optimizando una medida de compactación o probabilidad sobre el corpus (Sennrich et al., 2016; Kudo & Richardson, 2018). A nivel conceptual, elegir una tokenización sub-palabra implica un compromiso entre tamaño del vocabulario y granularidad de las piezas: vocabularios más grandes reducen la fragmentación pero aumentan la dimensionalidad; vocabularios más pequeños incrementan la capacidad de representar formas novedosas mediante composiciones de sub-unidades.

Para pares con variación ortográfica o riqueza morfológica, como el caso shiwilu–castellano, la tokenización sub-palabra facilita que las formas derivadas y las variantes ortográficas compartan representaciones parciales, mejorando la generalización del modelo frente a formas raras. Asimismo, la práctica conceptual aconseja documentar las decisiones de tokenización (tipo de algoritmo y tamaño del vocabulario) porque influyen en la distribución de los tokens y, por ende, en el comportamiento de las métricas de evaluación. (Sennrich et al., 2016; Kudo & Richardson, 2018).

2.2.5 Aumento de datos (*data augmentation*)

El aumento de datos agrupa técnicas destinadas a generar ejemplos sintéticos a partir del material disponible para ampliar la cobertura léxica y contextual del conjunto de entrenamiento. Conceptualmente, estas técnicas buscan introducir variación útil que actúe como regularizador del modelo y que permita que patrones raros o formas morfológicas poco frecuentes sean vistos durante el aprendizaje. Entre los métodos más usados en traducción automática se encuentran la retrotraducción (back-translation), el parafraseo, y las operaciones de modificación léxica sencillas como la sustitución de sinónimos o la técnica EDA (Easy Data Augmentation). (Sennrich, Haddow & Birch, 2016; Wei & Zou, 2019).

La retrotraducción consiste en entrenar un sistema de traducción en la dirección meta→fuente con datos disponibles y luego traducir grandes cantidades de texto monolingüe en la lengua meta para producir pares sintéticos fuente–meta que se incorporan al entrenamiento. El parafraseo y las operaciones basadas en sinónimos generan alternativas al mismo significado en la lengua

fuelle o meta, aumentando la diversidad léxica sin requerir nueva anotación humana. Desde un punto de vista teórico, estos procedimientos incrementan la densidad de la señal de entrenamiento y reducen el sobreajuste en escenarios con poco paralelo, aunque su efectividad depende de la calidad del modelo que genera los ejemplos sintéticos y del control del ruido introducido.

No obstante, el aumento de datos implica riesgos conceptuales importantes: la introducción de pares sintéticos de baja calidad puede sesgar al modelo hacia errores sistemáticos, producir efectos de dominio no deseados o reforzar traducciones incorrectas si el generador es débil. Por ello, conceptualmente es crucial aplicar criterios de filtrado y estimación de confianza sobre los ejemplos sintéticos, por ejemplo mediante puntuaciones de calidad automáticas o umbrales de similitud semántica, y considerar la composición equilibrada entre datos auténticos y sintéticos para evitar diluir la señal real.

2.2.6 Transfer learning y modelos multilingües

El *transfer learning* en PLN se refiere al uso de modelos preentrenados o a la transferencia de parámetros aprendidos en una tarea o idioma fuente para mejorar el rendimiento en otra tarea o en un idioma con pocos datos. En el contexto de NMT esto puede materializarse como preentrenamiento en grandes colecciones monolingües o paralelas en idiomas con abundante recurso y posterior ajuste fino (*fine-tuning*) sobre el par objetivo, o bien como entrenamiento multilingüe conjunto donde un único modelo aprende a traducir múltiples idiomas compartiendo representaciones (Zoph et al., 2016). Los modelos multilingües preentrenados (p. ej. mBART, NLLB) explotan señales cruzadas entre lenguas para aprender embeddings y transformaciones transferibles que benefician a los pares de muy bajos recursos al proporcionar una representación inicial más informativa que el entrenamiento desde cero.

Conceptualmente, las ventajas de estas estrategias son que reducen la dependencia de grandes *corpus* paralelos para el par objetivo y permiten aprovechar patrones tipológicos o léxico-semánticos compartidos entre idiomas. Sin embargo, la transferencia puede introducir sesgos si los idiomas de preentrenamiento dominan al par objetivo (efecto de *interferencia*), o si los dominios y estilos difieren notablemente; por ello, a nivel conceptual se distingue entre transferencias beneficiosa, cuando hay suficiente semejanza tipológica o forma lingüística

compartida y transferencias nocivas, que requieren técnicas de mitigación como muestreo balanceado, re-pesado de idiomas o adaptación focalizada. En resumen, transfer learning y modelos multilingües constituyen una palanca teórica y práctica central para abordar la escasez de datos en shiwilu–castellano, siempre que se consideren cuidadosamente las condiciones de similitud lingüística y las estrategias para evitar la dominancia de idiomas mayoritarios. (Zoph et al., 2016).

2.2.7 Adaptación eficiente (adapters/LoRA)

Las técnicas de adaptación eficiente buscan ajustar modelos preentrenados grandes añadiendo o entrenando un número reducido de parámetros en lugar de actualizar la totalidad del modelo. Los adapters incorporan módulos pequeños entre capas del modelo que se entrenan para la tarea objetivo, manteniendo fijos los pesos base; de este modo se conservan las representaciones generales del preentrenamiento y se reduce el costo de almacenamiento y cómputo para cada adaptación específica (Houlsby et al., 2019). LoRA propone una idea afín desde la perspectiva de factorización de parámetros: en lugar de modificar matrices completas, se aprenden componentes de bajo rango que se suman a las matrices originales, lo que permite una adaptación eficaz con un número significativamente menor de parámetros entrenables (Hu et al., 2021). Conceptualmente, estas técnicas permiten experimentar y desplegar adaptaciones para pares de muy bajos recursos sin incurrir en el coste de reentrenar o almacenar copias completas de modelos muy grandes.

2.2.8 Representaciones vectoriales (embeddings) y minería/filtrado

Los embeddings son vectores numéricos que codifican propiedades léxicas y contextuales de palabras, subpalabras, oraciones o documentos, y sirven como base para medir similitud semántica en espacios continuos. En la práctica se usan embeddings de oraciones (por ejemplo SBERT o modelos E5) para representar segmentos lingüísticos y comparar su proximidad mediante similitud coseno u otras métricas; la minería de paralelo comparable consiste en buscar en grandes colecciones aquellos pares de segmentos cuya proximidad vectorial sugiere traducción o equivalencia, y la indexación mediante motores de búsqueda vectorial como FAISS permite

escalar esta operación a corpus extensos. El filtrado posterior con umbrales de similitud o clasificadores de calidad reduce el ruido y mejora la precisión del paralelo extraído, de modo que conceptualmente la combinación embedding+índice vectorial actúa como puente entre textos no alineados y pares útiles para NMT.

2.2.9 BLEU (Bilingual Evaluation Understudy)

BLEU es una métrica automática de evaluación de traducción basada en la coincidencia de n-gramas entre la hipótesis de traducción y una o más referencias. Calcula precisiones modificadas de n-gramas para varios valores de n y combina esas precisiones mediante la media geométrica, aplicando además una penalidad por brevedad para evitar sobrevaloraciones de hipótesis excesivamente cortas; su fórmula formal resume estas componentes en una puntuación entre 0 y 1 generalmente expresada como porcentaje (Papineni et al., 2002). Conceptualmente, BLEU cuantifica la coincidencia léxica y local del orden de tokens, por lo que es sensible a la elección de referencias y no captura directamente sinonimia ni equivalencias reordenadas que no comparten n-gramas con la referencia.

2.2.10 chrF (carácter n-gram F-score)

chrF evalúa la similitud entre hipótesis y referencia a nivel de caracteres mediante n-gramas de caracteres; calcula precisión y recall sobre esos n-gramas y reporta una F-score agregada, pudiendo ponderar recall frente a precisión mediante el parámetro β . Al operar sobre caracteres en lugar de palabras, chrF resulta especialmente sensible a semejanzas morfológicas, variaciones ortográficas y segmentos parciales compartidos entre formas derivadas, aspectos que suelen ser relevantes en lenguas con morfología productiva o en corpus con variación ortográfica; por ello, conceptualmente ofrece ventajas sobre métricas puramente basadas en palabras cuando la coincidencia léxica exacta es una medida limitada (Popović, 2015).

2.2.11 BERTScore y COMET

BERTScore compara tokens de hipótesis y referencia usando embeddings contextuales extraídos de modelos como BERT: para cada token calcula la máxima similitud con tokens de la otra secuencia y a partir de esas similitudes construye medidas de precisión, recall y F1 que reflejan correspondencia semántica token-a-token. COMET, por su parte, es un marco neuronal que entrena un regresor para predecir una puntuación de calidad en correlación con juicios humanos, utilizando como entradas la fuente, la hipótesis y opcionalmente la referencia y aprovechando representaciones contextualizadas; conceptualmente estas métricas representan una transición desde medidas de coincidencia léxica hacia evaluadores que capturan similitud contextual y correlación humana, aunque su fiabilidad depende de los datos con que fueron entrenadas y del dominio al que se aplican (Zhang et al., 2019; Rei et al., 2020).

Capítulo 3

Estado del Arte

3.1 Introducción

En este capítulo se presenta la revisión sistemática de la literatura relacionada con la traducción automática neuronal (NMT) aplicada a lenguas de bajos recursos. Se abordan enfoques, técnicas y experiencias previas en escenarios similares, con el fin de identificar avances, limitaciones y oportunidades de investigación que sean pertinentes para el caso de estudio de la lengua shiwilu.

3.2 Objetivos de revisión

- Identificación de métodos y estrategias: clasificar y comparar las técnicas más utilizadas en traducción automática neural para lenguas de bajo recursos (back-transition, transfer learning, sistemas encoder-decoder, data augmentation, zero-shot, few-shot, etc.
- Integración de bases de conocimiento externas: revisar modelos híbridos que incorporan ontologías, WordNets o Knowledge Base (KB) en los flujos de pre- y post-procesamiento de MT/NMT, midiendo mejoras en cobertura léxica, desambiguación y coherencia semántica para lenguas indígenas.
- Análisis de métricas de evaluación: sintetizar el funcionamiento de BLEU, ChrF++ y evaluar su sensibilidad a la variabilidad introducida por datos sintéticos, así como protocolos de adaptación y comparación con evaluaciones humanas.

3.3 Preguntas de revisión

- P1. ¿Qué técnicas de generación y ampliación de datos (back-translation, mutación semántica, paraphrasing, pivoting, filtrado por embeddings, etc.) producen mejoras reproducibles en NMT para pares de muy bajos recursos?
- P2. ¿Qué arquitecturas y estrategias de entrenamiento (multilingüe, transfer learning, fine-tuning bidireccional, adapters, few/zero-shot) ofrecen el mejor balance entre rendimiento y coste computacional para un modelo shiwilu↔castellano, y qué baselines son apropiados para la comparación?
- P3. ¿Qué métricas automáticas (BLEU, ChrF++, TER, ¿etc.) y procedimientos de validación combinada (evaluación automática + pruebas participativas con hablantes) son más adecuados y fiables para medir adecuación lingüística y pertinencia cultural en traducciones de lenguas originarias con corpus escaso?

3.4 Estrategia de búsqueda

3.4.1 Motores de búsqueda a usar

Scopus

- Es una base bibliográfica multidisciplinaria que agrega resúmenes y citas de artículos, actas y capítulos revisados por pares.
- Su cobertura y metadatos permiten identificar tendencias, estudios empíricos y comparativas relevantes en NMT y técnicas de aumento de datos.
- Proporciona métricas bibliométricas útiles para priorizar lecturas y fundamentar la selección de trabajos clave.

IEEE Xplore

- Es una biblioteca digital orientada a la ingeniería y las ciencias de la computación con énfasis en documentación experimental y detalles implementaciones.

- Incluye artículos y actas que describen configuraciones experimentales, métricas de rendimiento y optimizaciones prácticas aplicables a sistemas de traducción.
- Ofrece evidencia técnica valiosa para la definición de parámetros experimentales y criterios de evaluación reproducibles.

ACL Anthology

- Es un repositorio especializado en lingüística computacional y procesamiento de lenguaje natural que reúne actas y trabajos de la comunidad NLP (ACL, EMNLP, WMT, LREC, workshops).
- Es importante recalcar que en este repositorio no se puede realizar búsqueda en cadena, entonces amerita ajustarse la búsqueda similar. Entonces esta fuente se usará como un respaldo técnico de las principales dos.
- Contiene investigaciones de vanguardia en NMT, evaluación y recursos para lenguas de bajos recursos, con frecuencia acompañadas de código y datos.

3.4.2 Cadenas de búsqueda a usar

Cadena 1 (C1) – Generación y ampliación de datos sintéticos

El objetivo de esta cadena es recuperar trabajos sobre técnicas de data augmentation aplicadas a NMT (back-translation, paraphrasing, synthetic data, filtering) y estudios que midan su efecto en pares de muy bajo recursos.

- Scopus:

TITLE-ABS-KEY(("data augmentation" OR "synthetic data" OR "back-translation" OR backtranslation OR "paraphrase" OR "paraphrasing" OR "synthetic pivot" OR "data synthesis" OR "data augmentation techniques") AND ("neural machine translation" OR "NMT" OR "machine translation") AND ("low-resource" OR "low resource" OR "under-resourced" OR "minority language" OR "indigenous" OR "endangered language")) AND NOT("image" OR "images" OR "computer vision")

OR "audio" OR "speech") AND (PUBYEAR > 2018 AND PUBYEAR < 2026)
AND SUBJAREA(COMP)

- IEEE Xplore:

("data augmentation" OR "synthetic data" OR "back-translation" OR backtranslation OR "paraphrase" OR "paraphrasing" OR "synthetic pivot" OR "data synthesis") AND ("neural machine translation" OR "NMT" OR "machine translation") AND ("low-resource" OR "low resource" OR "under-resourced" OR "minority language" OR "indigenous" OR "endangered language")

Cadena 2 (C2) – Arquitecturas y estrategias de entrenamiento para pares muy escasos

El objetivo de esta cadena es recuperar trabajos sobre arquitecturas y estrategias de entrenamiento adecuadas para pares con datos mínimos (transfer learning, fine-tuning bidireccional, modelos multilingües y preentrenados, adapters, enfoques few/zero-shot y técnicas de ajuste de parámetros).

- Scopus:

TITLE-ABS-KEY(("transfer learning" OR "fine-tuning" OR "fine tuning" OR "adapters" OR "adapter modules" OR "multilingual" OR "multilingual models" OR "few-shot" OR "few shot" OR "zero-shot" OR "zero shot" OR "pre-trained" OR "pretrained" OR "transformer" OR "mBART" OR "mT5") AND ("neural machine translation" OR "NMT" OR "machine translation") AND ("low-resource" OR "low resource" OR "small dataset" OR "under-resourced" OR "minority language")) AND NOT("image" OR "images" OR "computer vision" OR "audio" OR "speech") AND (PUBYEAR > 2018 AND PUBYEAR < 2026) AND SUBJAREA(COMP)

- IEEE Xplore

("transfer learning" OR "fine-tuning" OR "fine tuning" OR "adapters" OR "multilingual" OR "few-shot" OR "few shot" OR "zero-shot" OR "zero shot" OR "pre-trained" OR "pretrained" OR "transformer") AND ("neural machine translation"

OR "NMT" OR "machine translation") AND ("low-resource" OR "low resource"
OR "small dataset" OR "under-resourced") AND NOT ("image" OR "images" OR
"computer vision" OR "audio" OR "speech")

Cadena 3 (C3) – Evaluación automática y participativa; métricas y protocolos

El objetivo de esta cadena es identificar métricas automáticas y protocolos de evaluación, así como estudios sobre evaluación participativa (human evaluation, adequacy, acceptability, community/participatory evaluation), y trabajos que analicen la sensibilidad de métricas a la presencia de datos sintéticos.

- Scopus

TITLE-ABS-KEY (("BLEU" OR "ChrF" OR "ChrF++" OR "TER" OR "METEOR"
OR "automatic evaluation" OR "evaluation metric" OR "evaluation metrics" OR
"human evaluation" OR "participatory evaluation" OR "community evaluation"
OR "adequacy" OR "acceptability") AND ("machine translation" OR "neural ma-
chine translation" OR "NMT") AND ("low-resource" OR "low resource" OR "in-
digenous" OR "small dataset")) AND NOT ("image" OR "audio" OR "speech")
AND (PUBYEAR > 2018 AND PUBYEAR < 2026) AND SUBJAREA(COMP)

- IEEE Xplore

("BLEU" OR "ChrF" OR "ChrF++" OR "TER" OR "METEOR" OR "automa-
tic evaluation" OR "evaluation metric" OR "human evaluation" OR "participa-
tory evaluation" OR "community evaluation" OR "adequacy" OR "acceptability")
AND ("machine translation" OR "neural machine translation" OR "NMT") AND
("low-resource" OR "low resource" OR "indigenous" OR "small dataset") AND
NOT ("image" OR "audio" OR "speech")

3.4.3 Documentos encontrados

Los resultados encontrados con las cadenas de búsquedas usadas se presentan a conti-
nuación en la Tabla 1. Dado que las cadenas devolvían una gran cantidad de artículos, realizó

una revisión preliminar de los títulos y resúmenes para filtrar y reducir la muestra utilizando los criterios de inclusión/exclusión, estos resultados son visibles en la Tabla 2.

Tabla 3.1: Resultados de búsqueda de las cadenas

Fuente	C1	C2	C3	Cantidad documentos duplicados
Scopus	225	617	425	340
IEEE Xplore	90	352	123	
Total	315	969	548	

Tabla 3.2: Resultados luego de aplicar criterios de exclusión

Preguntas	Artículos por pregunta
P1	50
P2	45
P3	63

3.4.4 Criterios de inclusión/exclusión

- Para inclusión:
 - Se revisaron artículos publicados entre 2018 y 2025 para asegurar información vigente y actual
 - Investigaciones que detallen el tratamiento de data sintética y otras alternativas para poco corpus de datos
 - Artículos exclusivamente revisados por pares
- Para la exclusión:
 - Artículos que solo tienen resumen, es decir con acceso restringido
 - Artículos que no se enfoquen en lenguas de bajos recursos o de corpus limitados
 - Estudios que hablen de las lenguas de pocos recursos fuera de punto de vista de NMT, sino más enfocado en lingüística

- Publicaciones que podrían ser redundantes, reportes cortos o position papers.

3.5 Formulario de extracción de datos

Se desarrolló un formulario de extracción de datos con campos a evaluar detallado en la Tabla 3, en este caso si el artículo analizado cumplía con responder las preguntas de investigación según los criterios de inclusión y exclusión que se detalló previamente. Para esta tarea si el estudio a analizarse contribuía con el desarrollo de la pregunta, se respondía con un “Sí”, caso contrario “No”.

Tabla 3.3: Formulario de extracción de datos

Campo	Descripción
DOI	Identificador único del documento
Document Title	Título del estudio
Publication Year	Año de publicación
Abstract	Abstracción del documento
Link	Link referencial del DOI para obtener la fuente
Fuente	De qué cadena y de qué motor viene, ej. C1-Scopus, C4-IEEE
¿Qué métodos y protocolos han demostrado ser más efectivos para construir y alinear un corpus paralelo cuando solo se dispone de corpus monolingüe muy limitado (p. ej. textos de un solo autor en shiwilu) y recursos en castellano?	¿El artículo responde a esta pregunta? ¿Sí o No?
¿Qué arquitecturas y estrategias de entrenamiento (multilingüe, transfer learning, fine-tuning bidireccional, adapters, few/zero-shot) ofrecen el mejor balance entre rendimiento y coste computacional para un modelo shiwilu↔castellano, y qué baselines son apropiados para la comparación?	¿El artículo responde a esta pregunta? ¿Sí o no?

Tabla 3.3 (continuación)

Campo	Descripción
¿Qué métricas automáticas (BLEU, ChrF++, TER, ¿etc.) y procedimientos de validación combinada (evaluación automática + pruebas participativas con hablantes) son más adecuados y fiables para medir adecuación lingüística y pertinencia cultural en traducciones de lenguas originarias con corpus escaso?	¿El artículo responde a esta pregunta? ¿ Sí o no?

3.6 Resultados de la revisión

3.6.1 ¿Qué técnicas de generación y ampliación de datos (back-translation, mutación semántica, paraphrasing, pivoting, filtrado por embeddings, etc.) producen mejoras reproducibles en NMT para pares de muy bajos recursos?

El principal desafío de la traducción automática neuronal (NMT) en escenarios de muy bajos recursos es la escasez de datos paralelos. Sin suficientes ejemplos de entrenamiento, la calidad de las traducciones se ve seriamente afectada, al punto de que la NMT pura puede ser superada por métodos estadísticos tradicionales. Para enfrentar esta limitación, la literatura reciente ha propuesto múltiples técnicas de generación y ampliación de datos que han demostrado mejoras reproducibles en lenguas con escasa disponibilidad digital. Entre ellas destacan la retrotraducción, la mutación semántica y el parafraseo, el uso de idiomas pivote y la transferencia multilingüe, el filtrado mediante embeddings, así como la augmentación sintáctica y la obtención activa de nuevos datos. Todas estas aproximaciones buscan enriquecer el entrenamiento con datos adicionales tanto reales como sintéticos y han mostrado un impacto consistente en la mejora de la calidad de la traducción.

Una de las técnicas más efectivas es la retrotraducción (back-translation), introducida por Sennrich et al. (2016). El procedimiento consiste en entrenar un modelo inverso con el

corpus paralelo reducido y utilizarlo para traducir datos monolingües del idioma meta hacia el idioma fuente, generando pares sintéticos que se incorporan al entrenamiento. Esta estrategia ha reportado mejoras significativas en métricas como BLEU y se ha convertido en práctica estándar en NMT de bajos recursos. Existen variantes más refinadas, como la retrotraducción selectiva de Luo et al. (2019), que prioriza oraciones con vocabulario poco frecuente, logrando incrementos notables en BLEU y reduciendo el tiempo de entrenamiento.

Otra línea de trabajo es el parafraseo y la mutación semántica del corpus. Fadaee et al. (2017) propusieron insertar palabras raras en contextos nuevos, generando ejemplos adicionales para mejorar la cobertura léxica del modelo. El parafraseo automático, ya sea mediante sinónimos, reformulaciones o traducciones de ida y vuelta, también ha demostrado beneficios. Al exponer al sistema a distintas variantes de una misma oración, se fortalece su capacidad de generalización. Aunque los resultados suelen ser más modestos que los obtenidos con retrotraducción, contribuyen de manera consistente a mejorar la robustez de los modelos.

El uso de idiomas pivote y la transferencia multilingüe constituyen otra estrategia importante. Un idioma pivote permite entrenar con corpus paralelo de terceros idiomas o bien realizar traducción en cascada. Talwar y Laasri (2025) mostraron que el hindi como pivote para la traducción nepalí-inglés duplicó el puntaje BLEU frente a un modelo entrenado solo con corpus directo. En un enfoque complementario, la transferencia multilingüe aprovecha modelos previamente entrenados en pares de mayor recurso para inicializar la traducción en lenguas minoritarias. Montoya et al. experimentaron con español-shipibo utilizando inicializaciones desde diferentes pares de idiomas y alcanzaron mejoras de hasta 12 puntos BLEU, incluso con pivotes tipológicamente distantes. Estos resultados confirman que el tamaño y la calidad del corpus pivot influyen más que la cercanía lingüística, como también señalaron Kocmi y Bojar (2018).

Las técnicas de filtrado y minería de datos basadas en embeddings han mostrado gran utilidad cuando existen corpus comparables o bilingües ruidosos. Herramientas como LASER permiten identificar oraciones semánticamente equivalentes en diferentes idiomas y extraer corpus paralelo oculto (Artetxe & Schwenk, 2019). Chaudhary et al. (2019) demostraron en el Shared Task de WMT que este enfoque elevó significativamente los resultados en nepalí-inglés y cingalés-inglés al filtrar millones de pares web, conservando únicamente los más consistentes.

Además de extraer datos, los embeddings también sirven para depurar traducciones sintéticas, eliminando ejemplos de baja calidad y reforzando la fiabilidad del corpus de entrenamiento.

Otra vertiente prometedora es la augmentación sintáctica. Li et al. (2025) propusieron segmentar oraciones complejas en cláusulas y generar pares adicionales mediante traducción inversa, lo que enriqueció el corpus con ejemplos de menor tamaño pero mayor diversidad estructural. Con este enfoque se lograron mejoras constantes frente a baselines y a otros métodos de augmentación. Estrategias similares como el intercambio de subárboles sintácticos o la recombinación de sujetos y predicados también han demostrado ampliar la cobertura gramatical en lenguas con recursos escasos.

Finalmente, en escenarios de extrema limitación, la recopilación activa de datos se vuelve fundamental. Gómez Montoya et al. (2019) ampliaron el corpus español–shipibo con un conjunto de flashcards bilingües que aportó vocabulario diverso y mejoró la cobertura léxica. También implementaron esquemas de aprendizaje activo y crowdsourcing, presentando oraciones en español a hablantes nativos para obtener traducciones verificadas. De manera paralela, Yamamoto et al. (2023) mostraron cómo aprovechar corpus comparables no paralelos mediante un ciclo iterativo de traducción automática y filtrado, generando datos sintéticos útiles incluso sin disponer de textos monolingües extensos en la lengua meta. Estos enfoques resaltan la importancia de combinar la generación de datos con la incorporación de material real recopilado en colaboración con la comunidad.

En conjunto, la evidencia señala que no existe una única solución, sino un conjunto de técnicas complementarias. La retrotraducción explota datos monolingües, el parafraseo introduce variabilidad semántica, los idiomas pivote y la transferencia multilingüe aportan conocimiento desde pares más ricos, los embeddings permiten extraer y filtrar corpus adicionales, y la recopilación activa añade datos verificados por hablantes. La integración de estas estrategias ha demostrado mejorar sustancialmente la calidad de la traducción, incluso en contextos con recursos extremadamente limitados.

3.6.2 ¿Qué arquitecturas y estrategias de entrenamiento (multilingüe, transfer learning, fine-tuning bidireccional, adapters, few/zero-shot) ofrecen el mejor balance entre rendimiento y coste computacional para un modelo shiwilu↔castellano, y qué baselines son apropiados para la comparación?

La evidencia reciente en traducción de muy bajos recursos indica que el mejor compromiso entre rendimiento y coste no proviene de entrenar modelos desde cero, sino de reutilizar modelos multilingües preentrenados y adaptarlos con técnicas de transferencia eficientes, complementadas por un entrenamiento bilingüe bidireccional y módulos de adaptación livianos. Liu et al. (2019) y trabajos posteriores muestran que, frente a corpus mínimos, la reutilización de representaciones previas y la compartición de parámetros entre lenguas elevan la calidad y reducen el coste computacional. De Silva y Hansadi (2024) aportan análisis comparativos recientes que corroboran este patrón; Sun et al. (2025) ofrecen evidencia adicional sobre la fragilidad y el coste de entrenar transformadores bilingües desde cero con datos escasos.

En la práctica, el equipo NLLB (2022) y otros grupos documentan que la adaptación de modelos multilingües preentrenados (p. ej., mBART, mT5 o NLLB) con unas pocas centenas o miles de pares paralelos suele superar claramente a los modelos bilingües entrenados desde cero, porque se aprovechan representaciones de alto nivel y patrones de traducción ya aprendidos en múltiples lenguas. Este enfoque evita el coste del preentrenamiento completo si se limita a un fine-tuning supervisado, aunque puede aparecer interferencia negativa entre idiomas alejados. Para mitigar esa interferencia, Chronopoulou et al. (2023) y Houlsby et al. (2019) han mostrado la eficacia de los adapters basados en familias lingüísticas: estos insertan pequeños bloques entrenables y dejan congelado el resto del modelo, aislando la adaptación por grupos de lenguas. Hu et al. (2022) añade que, con igual cantidad de datos, esta estrategia suele mejorar la adaptación plena, reduce el cómputo y facilita escenarios zero-/few-shot.

El aprendizaje por transferencia continúa siendo el pilar metodológico cuando los datos del par objetivo son exigüos. Kocmi y Bojar (2018) describen el “transfer trivial”, que consiste en inicializar con un par rico y afinar en el par escaso, pero los avances recientes muestran

que enriquecer la transferencia con señales léxicas o lingüísticas específicas del idioma minoritario incrementa la ganancia sin elevar en exceso el coste. Maimaiti et al. (2022) destacan que embeddings léxicos preentrenados compartidos entre una lengua padre y la hija mejoran la cobertura de vocabulario poco frecuente sin recurrir a aumentaciones costosas; por su parte, estudios sobre modelado morfológico (Nzeyimana, 2024) indican que la incorporación explícita de información morfológica aporta robustez en lenguas con rica morfología, con ganancias comparables a modelos multilingües a gran escala cuando el paralelo es mínimo.

En contextos como Shiwilu↔Castellano, donde el monolingüe objetivo es casi inexistente y predominan pares paralelos cortos (p. ej., flashcards), esta transferencia “guiada” resulta especialmente ventajosa: permite explotar el español como lengua pivote de alto recurso, añadir conocimiento léxico/morfológico del Shiwilu y evitar ciclos de entrenamiento prolongados (Montoya et al., 2019).

Asimismo, el entrenamiento bilingüe bidireccional con un único modelo (Shiwilu↔Castellano) se ha consolidado como una práctica robusta. Liu et al. (2019) y De Silva y Hansadi (2024) muestran que al mezclar ambas direcciones y señalar el idioma objetivo con un token, cada par paralelo se aprovecha “dos veces”, actuando como regularizador y mejorando la consistencia bilingüe con un coste marginal respecto a mantener dos modelos unidireccionales. Por esto, el bilingüe bidireccional constituye una baseline fuerte y reproducible en pares muy escasos, sobre todo cuando se combina con transferencia o con un preentrenado multilingüe.

Dentro de las estrategias paramétricas y eficientes en cómputo, Houlsby et al. (2019), Hu et al. (2022) y Chronopoulou et al. (2023) han mostrado que los adapters y técnicas afines (p. ej., LoRA) reducen drásticamente los parámetros entrenables y el uso de GPU sin pérdida apreciable de rendimiento frente al fine-tuning completo. Ning, Xie y Zhang (2024) proponen además enfoques con atención dispersa explícita y PLMs integrados que concentran la capacidad del modelo en componentes informativos, rebajando el coste de inferencia y entrenamiento sin sacrificar calidad. Recientemente, Qorbani et al. (2025) han explorado la especialización por par, por ejemplo, la duplicación y ajuste de neuronas críticas para el par escaso, siendo vía para elevar el rendimiento del par minoritario sin reentrenar el modelo completo ni perjudicar pares ajenos, con un sobre coste computacional controlado. Para Shiwilu, estas técnicas de especialización

son prácticas cuando se dispone de un conjunto de validación por par y se busca exprimir un multilingüe grande sin aumentar su huella computacional.

En escenarios few/zero-shot, la evidencia sugiere que una adaptación breve de un modelo grande con muy pocos pares paralelos curados (cientos) puede cerrar gran parte de la brecha a coste mínimo; sin embargo, el zero-shot puro hacia una lengua no vista tiende a ser frágil y normalmente requiere inyección léxica o validación humana para ser utilizable (Liu et al., 2019; NLLB Team, 2022). Para Shiwilu, el few-shot fine-tuning sobre mBART/mT5/NLLB con adapters y entrenamiento bidireccional aparece como un punto dulce entre calidad y coste, especialmente si se integra un léxico Shiwilu–español y señales morfológicas.

A la luz de esta evidencia, un diseño recomendado para Shiwilu↔Castellano que maximice rendimiento y minimice costes sería: partir de un baseline bilingüe bidireccional (Transformer base) entrenado con el paralelo disponible; comparar dicho baseline contra un SMT frase-a-frase como línea histórica de mínima; y pasar luego a fine-tuning de un modelo multilingüe preentrenado (mBART/mT5/NLLB) con adapters específicos. En este último paso conviene incorporar transferencia léxica y morfológica y, cuando proceda, aplicar técnicas de especialización por par (twinning) para afinar sin reentrenar el total. Esta propuesta recoge las prácticas más respaldadas y reproducibles en LRLs: ofrece mejoras significativas frente a los baselines con un coste computacional moderado y controlado.

3.6.3 ¿Qué métricas automáticas (BLEU, ChrF++, TER, ¿etc.) y procedimientos de validación combinada (evaluación automática + pruebas participativas con hablantes) son más adecuados y fiables para medir adecuación lingüística y pertinencia cultural en traducciones de lenguas originarias con corpus escaso?

En traducción automática para lenguas originarias con datos escasos, la evaluación ha ido desplazándose desde el uso exclusivo de métricas clásicas hacia esquemas mixtos que combinan indicadores automáticos y validación humana. BLEU sigue empleándose como referencia comparativa entre sistemas, pero la literatura reciente muestra que su énfasis en coincidencias

de n-gramas lo vuelve poco sensible a variación morfológica, paráfrasis y sinónimos, especialmente en contextos de bajo recurso; además, sus valores absolutos pueden resultar poco informativos cuando el conjunto de prueba es pequeño o el dominio es muy específico (Post, 2018; Roy, Purkayastha y Paul, 2024). Por ello, se ha vuelto habitual reportarlo junto con otras métricas que ofrecen señales complementarias sobre la calidad.

Para lenguas con morfología rica, se han privilegiado indicadores a nivel de subcadena y representaciones, pues capturan mejor coincidencias parciales y variación formal. Entre las alternativas contemporáneas, BERTScore aproxima similitud semántica mediante embeddings y suele reflejar mejor la adecuación cuando la traducción válida no coincide palabra por palabra con la referencia (Zhang et al., 2020). En la misma línea, BLEURT aprende a imitar juicios humanos y reduce la dependencia de coincidencias superficiales (Sellam, Das y Parikh, 2020), mientras que COMET integra información de la fuente y la hipótesis para predecir calidad con correlaciones superiores a las métricas n-gram en múltiples escenarios (Rei et al., 2020). Ahora bien, los estudios en lenguas de muy bajo recurso advierten que estas métricas neuronales, usadas en modo generalista, no siempre generalizan de forma óptima a idiomas poco representados; su desempeño mejora cuando se ajustan con anotaciones humanas del mismo entorno lingüístico (Sai et al., 2023; Singh et al., 2024; Wang et al., 2024).

La práctica contemporánea en evaluación de bajos recursos favorece, por tanto, un conjunto curado de métricas automáticas y no una sola cifra. Un protocolo razonable incluye BLEU como línea de base comparativa, indicadores sensibles a variación formal o semántica como BERTScore y BLEURT, y, cuando sea viable, una versión adaptada por familia o región lingüística de COMET u otra métrica aprendida para elevar la concordancia con juicios nativos (Sai et al., 2023; Wang et al., 2024). Conjuntos de prueba multilingües recientes, como FLORES, han impulsado además prácticas de reporte más cuidadosas en LRLs y variantes de cómputo que respetan particularidades de segmentación y escritura; aun así, persiste la recomendación de interpretar con cautela cualquier puntaje aislado y buscar convergencia entre métricas (NLLB Team, 2022; Post, 2018).

Debido a que ninguna métrica automática captura por sí sola matices de pertinencia cultural, la validación combinada con hablantes nativos se consolida como componente indis-

pensable. En evaluaciones a gran escala con expertos se ha visto que marcos sistemáticos de anotación como MQM permiten diagnosticar errores por categorías y que el ranking de sistemas puede diferir sustancialmente del inferido con encuestas rápidas o métricas superficiales; además, ciertas métricas modernas se alinean mejor con juicios expertos cuando han sido contrastadas y afinadas con datos del mismo dominio (Freitag et al., 2021). Para lenguas originarias, diversos proyectos han optado por guías simplificadas inspiradas en MQM o por rúbricas de adecuación, fluidez y sensibilidad cultural acordadas con la comunidad, de modo que la evaluación humana sea sostenible y pertinente al uso real (Sai et al., 2023; Wang et al., 2024).

En el contexto peruano, se dispone de evidencia aplicada en Shipibo-Konibo que ilustra este enfoque iterativo: Montoya, Rojas y Oncevay presentan un marco de mejora continua que combina ampliación incremental de datos, transferencia y aprendizaje activo, evaluando el avance con BLEU a nivel palabra y a nivel subpalabra mediante segmentación BPE; paralelamente, incorporan retroalimentación de hablantes a través de un agente conversacional para recolectar nuevas traducciones y ajustar el sistema (Montoya, Rojas y Oncevay, 2019). Esta experiencia coincide con la pauta observada en LRLs: usar métricas automáticas para seguimiento y comparación controlada, y sostener decisiones de despliegue con revisión humana participativa que verifique adecuación lingüística y pertinencia cultural en los dominios objetivo. En suma, para medir de manera más fiable la calidad en traducciones hacia lenguas originarias de corpus escaso, conviene priorizar un conjunto de métricas que incluya al menos un indicador semántico moderno junto con la línea base clásica, y articularlo con procedimientos de evaluación con hablantes que garanticen que la traducción diga lo correcto y lo haga como corresponde en su comunidad.

3.7 Conclusiones

El análisis del estado del arte indica que la limitación principal para el desarrollo de un sistema de traducción automática shiwilu↔castellano es la escasez de un corpus paralelo amplio, diverso y con metadatos adecuados. Las mejoras metodológicas, como la adaptación de modelos multilingües preentrenados (por ejemplo, mBART, mT5, NLLB) mediante técnicas

de afinamiento eficientes (adapters, LoRA), y el uso controlado de aumento de datos (back-translation, parafraseo), aportan ganancias apreciables en la relación rendimiento-coste, pero no sustituyen la necesidad de datos verificados por hablantes. De igual forma, los métodos de minería y filtrado basados en representaciones (por ejemplo, SBERT o LASER) son herramientas valiosas para extraer pares paralelos de corpus comparables siempre que se apliquen criterios de calidad rigurosos y mecanismos de depuración.

Para la tesis se derivan implicaciones metodológicas claras. En primer lugar, resulta prioritario consolidar y curar un corpus paralelo reproducible con metadatos y trazabilidad que permitan documentación y replicabilidad experimental. En segundo lugar, se recomienda establecer líneas base experimentales reproducibles y aplicar una estrategia combinada que incluya adaptación de modelos multilingües, aumento selectivo de datos y filtrado por embeddings. La evaluación debe integrar métricas automáticas establecidas (por ejemplo, BLEU, ChrF, COMET) y estudios de validación con hablantes mediante rúbricas que midan adecuación, fluidez y pertinencia cultural. Finalmente, todas las etapas experimentales deben acompañarse de prácticas de reproducibilidad que son recomendables para lograr resultados consistentes en distintos entornos de desarrollo.

Capítulo 4

Recopilación y preparación inicial del corpus bilingüe

4.1 Introducción

El presente capítulo expone los avances en la construcción del corpus bilingüe shiwilu–castellano que sustenta el desarrollo del sistema de traducción automática neuronal. Esta etapa se ha orientado a la recopilación, organización y análisis lingüístico de materiales textuales en ambas lenguas, así como a la elaboración de un conjunto amplio de frases paralelas creadas especialmente para el proyecto. La combinación de fuentes narrativas bilingües y datos sintéticos validados con hablante nativo responde a las recomendaciones revisadas en el marco teórico para la construcción de corpus en lenguas de bajo recurso, priorizando la autenticidad lingüística, la coherencia semántica y la representatividad funcional del idioma.

4.2 Materiales textuales bilingüe recopilados

Como parte de la recopilación de corpus, se han incorporado dos obras bilingües fundamentales que aportan contenido narrativo estructurado en formato paralelo shiwilu–castellano:

- *Pidir Llinsercha'su – Los relatos de Fidel*

Recopilada por Fidel Lomas Chota, hablante nativo shiwilu, esta obra presenta relatos contemporáneos con traducción directa al castellano. Sus textos se caracterizan por la claridad estructural y el uso de oraciones cortas, lo cual resulta especialmente favorable para procesos

posteriores de alineación y normalización. Esta fuente añade diversidad estilística y contribuye a capturar una parte representativa del uso actual del idioma.

En total, esta obra comprende **24 cuentos breves** y aporta **957 oraciones** en formato bilingüe paralelo, constituyéndose en la principal fuente textual complementaria al corpus de flashcards empleado en esta investigación.

Tabla 4.1: Resumen de materiales textuales bilingües recopilados

Fuente	Tipo de contenido	Nº de relatos	Promedio de oraciones por relato	Oraciones estimadas	Formato paralelo
<i>Pidir Llinsercha'su</i>	Relatos contemporáneos	24	40	957	Shiwilu–Castellano

4.3 Elaboración del corpus de flashcards shiwilu – castellano

Además de los materiales textuales, se desarrolló un corpus propio de **2,301 pares de frases shiwilu–castellano**, construido específicamente para este proyecto en coordinación directa con el señor **Fidel Lomas Chota**. Las frases fueron generadas, revisadas y validadas conjuntamente, asegurando la idoneidad lingüística, la equivalencia semántica y la coherencia morfológica entre ambas lenguas.

Este corpus presenta frases cortas y de estructura controlada, con extensiones que oscilan entre una y seis palabras en castellano y entre una y cinco palabras en shiwilu. Esta configuración es especialmente útil para entrenar modelos neuronales en escenarios de bajo recurso, dado que favorece la identificación de correspondencias morfológicas y la construcción de representaciones subléxicas consistentes con un total de **2252 frases** paralelas shiwilu – castellano.

El análisis morfológico inicial revela patrones regulares en la lengua shiwilu, incluyendo sufijos frecuentes como **-LEK, -EK, -ER', -LLI, -DEK, -SU', -NEK** y prefijos como **ÑAP-, NU-, NUK-, LU-, MU-**, los cuales se alinean con la caracterización de la lengua como sistema aglutinante, aspecto ampliamente documentado en la literatura lingüística amazónica revisada en el marco teórico.

Además el desarrollo conjunto con hablante de la lengua, nos brinda la seguridad que la data obtenida está validada por un experto.

4.4 Distribución temática del corpus generado

Las 2,252 frases elaboradas se distribuyen en una variedad de categorías funcionales que permiten cubrir diferentes actos de habla y contextos comunicativos. La clasificación semántica evidencia la presencia de interrogativas, descripciones personales, comandos, expresiones de ubicación, referencias temporales y otros tipos de contenido frecuente en el uso cotidiano del idioma.

Tabla 4.2: Distribución temática del corpus generado

Categoría	Cantidad	Porcentaje
Expresiones generales	1,720	76.4 %
Estados, descripciones personales y acciones	320	14.2 %
Ubicación, direcciones y referencias temporales	140	6.2 %
Comandos, emergencias y situaciones funcionales	72	3.2 %

Esta distribución demuestra que el corpus no solo cubre vocabulario básico, sino también expresiones asociadas a situaciones comunicativas reales, alineándose con los enfoques de corpus funcionales para lenguas originarias discutidos en el marco conceptual.

4.5 Proceso de preprocesamiento del corpus bilingüe

Luego de recopilar las fuentes principales del corpus, se implementó un proceso de preprocesamiento orientado a transformar los datos en un recurso bilingüe estructurado, consistente y apto para su uso dentro del pipeline experimental de la investigación. Este proceso fue especialmente importante debido a la heterogeneidad de las fuentes empleadas: por un lado, el corpus de flashcards ya se encontraba en formato tabular; por otro, el material textual de *Pidir*

Llinsercha'su tuvo que ser extraído desde un archivo PDF antes de poder integrarse con el resto del corpus.

El flujo de trabajo aplicado se organizó en cuatro etapas principales: 00 extraer PDF, 01 filtrar, 01b unificar y 02 depurar. Cada una de estas etapas permitió reducir ruido, asegurar correspondencia entre las dos lenguas y consolidar una versión progresivamente más limpia del corpus bilingüe.

En la etapa 00 extraer PDF, se procesó el archivo de textos narrativos en formato PDF para recuperar pares bilingües en shiwilu y castellano y convertirlos a un archivo CSV estructurado. Para ello, se empleó un parser con heurísticas conservadoras que permitió identificar ítems numerados, separar bloques bilingües y registrar casos ambiguos para revisión posterior, sin eliminar información lingüística relevante del documento original. El resultado de esta etapa fue un dataset inicial extraído desde PDF en formato tabular, junto con un resumen de trazabilidad del proceso

En la etapa 01 filtrar, se trabajó sobre el archivo de flashcards para conservar únicamente aquellas filas que contaban con valores válidos en ambas columnas, es decir, tanto en castellano como en shiwilu. En este punto se descartaron explícitamente las filas que no tenían su correspondiente traducción en una de las dos lenguas, así como registros vacíos o placeholders. Esta decisión permitió asegurar que el corpus paralelo estuviera compuesto únicamente por pares bilingües utilizables y coherentes para las etapas siguientes

La etapa 01b unificar tuvo como objetivo integrar en un único dataset las diferentes fuentes disponibles, manteniendo trazabilidad de origen. Para ello, se combinaron el dataset filtrado de flashcards y el dataset extraído desde PDF, registrando para cada fila su fuente correspondiente y su identificador interno. Adicionalmente, se realizó una detección de duplicados entre fuentes para identificar pares que pudieran repetirse en más de un recurso, preservando así mayor control sobre la composición final del corpus

Finalmente, en la etapa 02 depurar, se aplicó una normalización no destructiva al corpus unificado. Este procedimiento mantuvo las columnas originales y generó versiones normalizadas de los textos, incorporando reglas como normalización Unicode, eliminación de espacios redundantes, estandarización básica del formato textual y registro detallado de las transforma-

ciones realizadas. De este modo, se obtuvo un corpus depurado y trazable, sin perder acceso a las versiones originales de cada segmento bilingüe

En conjunto, este proceso permitió pasar de fuentes heterogéneas y parcialmente ruidosas a un corpus bilingüe consolidado, filtrado y depurado, listo para ser utilizado en las siguientes fases metodológicas de la investigación.

Tabla 4.3: Etapas del preprocesamiento del corpus bilingüe

Etapas	Nombre	Descripción	Resultado principal
00	Extraer PDF	Extracción de oraciones bilingües desde el archivo PDF de textos narrativos y conversión a formato CSV estructurado	Dataset inicial extraído desde PDF
01	Filtrar	Eliminación de filas sin correspondencia bilingüe válida en castellano o shiwilu, así como registros vacíos o placeholders	Dataset de flashcards filtrado
01b	Unificar	Integración de las distintas fuentes en un único dataset con trazabilidad de origen y revisión de duplicados entre fuentes	Dataset unificado
02	Depurar	Normalización no destructiva del corpus, conservando versiones originales y generando versiones depuradas	Dataset normalizado y trazable

4.6 Preparación del corpus consolidado para modelo de embeddings

Una vez completadas las etapas de extracción, filtrado, unificación y depuración, se obtuvo una versión consolidada del corpus bilingüe español–shiwilu, preparada para su uso en las siguientes fases del proyecto. Esta consolidación permitió disponer de un recurso homogéneo en cuanto a formato, estructura y trazabilidad, lo cual era necesario para trabajar de manera consistente con datos provenientes de fuentes distintas.

La preparación del corpus no se limitó a la limpieza básica de texto, sino que implicó también una reorganización metodológica del recurso. En particular, se aseguró que cada

registro bilingüe contara con una estructura uniforme, con identificadores claros, fuente de procedencia y versiones tratadas del texto que facilitaran su manipulación computacional. Esto resultó fundamental para garantizar que las distintas etapas posteriores del trabajo se apoyaran en un mismo insumo validado y reproducible.

Asimismo, la conversión del material narrativo desde PDF hacia CSV permitió homogeneizar el formato de los relatos con el de las flashcards, de modo que ambas fuentes pudieran ser trabajadas bajo una lógica común. Esta homogeneización fue una condición necesaria para consolidar un corpus paralelo único, evitando que las diferencias de formato entre fuentes dificultaran el análisis posterior.

Por otro lado, el descarte de filas sin traducción correspondiente en castellano o shiwilu fortaleció la calidad paralela del recurso final. En un escenario de muy bajo recurso, conservar únicamente pares bilingües completos constituye una decisión metodológica importante, ya que reduce ruido y evita incorporar ejemplos incompletos que puedan afectar la consistencia del corpus.

Como resultado de este proceso, el proyecto pasó a contar con un corpus bilingüe consolidado y depurado, compuesto por el conjunto de flashcards paralelas y las oraciones narrativas extraídas de *Pidir Llinsercha'su*, todo ello integrado en una misma estructura tabular. Esta base constituye el insumo central preparado para las siguientes etapas de trabajo de la tesis.

Tabla 4.4: Corpus consolidado para modelo de embeddings

Fuente	Unidad de análisis	Cantidad	Tratamiento aplicado
Flashcards español–shiwilu	Par paralelo	2,252	Filtrado, unificación y depuración
Pidir Llinsercha'su	Oración bilingüe	957	Extracción desde PDF, unificación y depuración
Corpus consolidado	Registro bilingüe estructurado	3,209	Integración total en formato tabular

Capítulo 5

Conclusiones y trabajos futuros

5.1 Conclusiones

5.2 Trabajos futuros

Referencias

Aguilar, M., Zapata, C. (2017). Integrating UCD and an Agile Methodology in the Development of a Mobile Catalog of Plants. In: Soares, M., Falcão, C., Ahram, T. (eds) *Advances in Ergonomics Modeling, Usability & Special Populations. Advances in Intelligent Systems and Computing*, vol 486. Springer, Cham. https://doi.org/10.1007/978-3-319-41685-4_8

Hernández Sampieri, R., Fernández Collado, C., & Baptista, M. (2014). *Metodología de la investigación* (6ta ed.). México D.F.: McGraw-Hill.

Krusche, S., & Bruegge, B. (2014). User feedback in mobile development. En *Mobile-DeLi 2014 - Proceedings of the 2nd International Workshop on Mobile Development Lifecycle, Part of SPLASH 2014* (pp. 25–26). Recuperado de <http://www.scopus.com/inward/record.url?eid=2-s2.0-84921489617&partnerID=40&md5=0198a5715bec4bf6608454ce82f098d2>

Artetxe, M., & Schwenk, H. (2019). Massively Multilingual Sentence Embeddings for Zero-Shot Cross-Lingual Transfer and Beyond. *Transactions of the Association for Computational Linguistics*, 7, 597–610. https://doi.org/10.1162/tacl_a_00288

Chaudhary, V., Tang, Y., Guzmán, F., Schwenk, H., & Koehn, P. (2019). Low-Resource Corpus Filtering Using Multilingual Sentence Embeddings. En O. Bojar, R. Chatterjee, C. Federmann, M. Fishel, Y. Graham, B. Haddow, M. Huck, A. J. Yepes, P. Koehn, A. Martins, C. Monz, M. Negri, A. Névél, M. Neves, M. Post, M. Turchi, & K. Verspoor (Eds.), *Proceedings of the Fourth Conference on Machine Translation (Volume 3: Shared Task Papers, Day 2)* (pp. 261–266). Association for Computational Linguistics. <https://doi.org/10.18653/v1/W19-5435>

F. Li, M. Shao, H. Yan, & C. Chi. (2025). A Clause-Based Data Augmentation Method for Low-Resource Neural Machine Translation. *IEEE Access*, 13, 62567–62576. <https://doi.org/10.1109/ACCE>

Fadaee, M., Bisazza, A., & Monz, C. (2017). Data Augmentation for Low-Resource Neural Machine Translation. En R. Barzilay & M.-Y. Kan (Eds.), *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)* (pp.

567–573). Association for Computational Linguistics. <https://doi.org/10.18653/v1/P17-2090>

Kocmi, T., & Bojar, O. (2018). Trivial Transfer Learning for Low-Resource Neural Machine Translation. En O. Bojar, R. Chatterjee, C. Federmann, M. Fishel, Y. Graham, B. Haddow, M. Huck, A. J. Yepes, P. Koehn, C. Monz, M. Negri, A. Névél, M. Neves, M. Post, L. Specia, M. Turchi, & K. Verspoor (Eds.), *Proceedings of the Third Conference on Machine Translation: Research Papers* (pp. 244–252). Association for Computational Linguistics. <https://doi.org/10.18653/v1/W18-6325>

Luo, D., Shi, S., Su, R., & Huang, H. (2019). Data Augmentation Under Scarce Condition for Neural Machine Translation. *2019 IEEE 6th International Conference on Cloud Computing and Intelligence Systems (CCIS)*, 36–40. <https://doi.org/10.1109/CCIS48116.2019.9073698>

Montoya, H. E. G., Rojas, K. D. R., & Oncevay, A. (2019). A Continuous Improvement Framework of Machine Translation for Shipibo-Konibo. En A. Karakanta, A. Kr. Ojha, C.-H. Liu, J. Washington, N. Oco, S. M. Lakew, V. Malykh, & X. Zhao (Eds.), *Proceedings of the 2nd Workshop on Technologies for MT of Low Resource Languages* (pp. 17–23). European Association for Machine Translation. <https://aclanthology.org/W19-6804/>

Nzeyimana, A. (2024). *Low-resource neural machine translation with morphological modeling* (No. arXiv:2404.02392). arXiv. <https://doi.org/10.48550/arXiv.2404.02392>

Sennrich, R., Haddow, B., & Birch, A. (2016). Improving Neural Machine Translation Models with Monolingual Data. En K. Erk & N. A. Smith (Eds.), *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 86–96). Association for Computational Linguistics. <https://doi.org/10.18653/v1/P16-1009>

Talwar, A., & Laasri, J. (2025). *Pivot Language for Low-Resource Machine Translation* (No. arXiv:2505.14553). arXiv. <https://doi.org/10.48550/arXiv.2505.14553>

Y. Yamamoto, T. Akiba, & H. Tsukada. (2023). Training Neural Machine Translation Models by Using an Entire Comparable Corpus. *2023 10th International Conference on Advanced Informatics: Concept, Theory and Application (ICAICTA)*, 1–5. <https://doi.org/10.1109/ICAICTA59291.2023>

Chronopoulou, A., Stojanovski, D., Fraser, A., & Birch, A. (2023). Language family adapters for low-resource machine translation with a large-scale multilingual model. *Findings of the Association for Computational Linguistics (ACL 2023)*.

Houlsby, N., Giurgiu, A., Jastrzębski, S., Morrone, B., De Laroussilhe, Q., Gesmundo, A., Attariyan, M., & Gelly, S. (2019). Parameter-efficient transfer learning for NLP. *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*.

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., & Chen, W. (2022). LoRA: Low-rank adaptation of large language models. *Proceedings of the International Conference on Learning Representations (ICLR 2022)*.

Maimaiti, M., Liu, Y., Luan, H., & Sun, M. (2022). Enriching the transfer learning with pre-trained lexicon embedding for low-resource neural machine translation. *Tsinghua Science and Technology*, 27(1), 150–163. <https://doi.org/10.26599/TST.2020.9010029>

Ning, T., Xie, X., & Zhang, J. (2024). Research on low-resource neural machine translation methods based on explicit sparse attention and pre-trained language model. *Proceedings of the 2024 IEEE 12th International Conference on Computer Science and Network Technology (ICCSNT 2024)*, 103–107. <https://doi.org/10.1109/ICCSNT62291.2024.10776704>

NLLB Team. (2022). No Language Left Behind: Scaling human-centered machine translation. *Transactions of the Association for Computational Linguistics*, 10, 92–109.

Qorbani, A., Ramezani, R., Baraani, A., & Kazemi, A. (2025). Multilingual neural machine translation for low-resource languages by twinning important nodes. *Neurocomputing*, 634, 129890. <https://doi.org/10.1016/j.neucom.2025.129890>

Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., & Raffel, C. (2021). mT5: A massively multilingual pre-trained text-to-text transformer. *Proceedings of NAACL 2021*.

Post, M. (2018). A Call for Clarity in Reporting BLEU Scores. En *Proceedings of the Third Conference on Machine Translation (WMT 2018)* (pp. 186–191). Association for Computational Linguistics.

Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). BERTScore: Evaluating Text Generation with BERT. *International Conference on Learning Representations (ICLR 2020)*. <https://doi.org/10.48550/arXiv.1904.09675>

Sellam, T., Das, D., & Parikh, A. (2020). BLEURT: Learning Robust Metrics for Text Generation. En *Proceedings of the 58th Annual Meeting of the Association for Computational*

Linguistics (ACL 2020) (pp. 7881–7892). Association for Computational Linguistics. <https://doi.org/10.48550/a>

Rei, R., Stewart, C., Farinha, A., & Lavie, A. (2020). COMET: A Neural Framework for MT Evaluation. En *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP 2020)* (pp. 2685–2702). Association for Computational Linguistics. <https://doi.org/10.48550/arXiv.2009.09025>

Freitag, M., Foster, G., Grangier, D., Ratnakar, V., Tan, Q., & Macherey, W. (2021). Experts, Errors, and Context: A Large-Scale Study of Human Evaluation for Machine Translation. *Transactions of the Association for Computational Linguistics*, 9, 1460–1474.

Lee, S., Lee, J., Moon, H., Park, C., Seo, J., & Lim, H. (2023). A Survey on Evaluation Metrics for Machine Translation. *Mathematics*, 11(4), 1006.

Sai, A. B., Dixit, T., Nagarajan, V., Kunchukuttan, A., Kumar, P., Khapra, M. M., & Dabre, R. (2023). IndicMT Eval: A Dataset to Meta-Evaluate Machine Translation Metrics for Indian Languages. En *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL 2023), Long Papers* (pp. 14210–14228). Association for Computational Linguistics.

Singh, A., Sai, A. B., Dabre, R., Puduppully, R., Kunchukuttan, A., & Khapra, M. M. (2024). How Good is Zero-Shot MT Evaluation for Low Resource Indian Languages? En *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL 2024), Short Papers* (pp. 640–649). Association for Computational Linguistics.

Wang, J., Adelani, D. I., Agrawal, S., Masiak, M., Rei, R., et al. (2024). AfriMTE and AfriCOMET: Enhancing COMET to Embrace Under-Resourced African Languages. En *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL 2024), Long Papers*. Association for Computational Linguistics.

Baladón, A., Lucas, A., & Pardiñas, V. (2024). Generación de datos sintéticos para traducción automática entre español y guaraní. Tesis de grado, Universidad de la República.

Chuquimamani, M. (2021). Minería web de textos en quechua sureño para traducción automática. Tesis de licenciatura, Pontificia Universidad Católica del Perú.

Galarreta, A. P. (2017). Generación de corpus paralelos para un traductor estadístico entre shipibo-konibo y español. Tesis de maestría, Pontificia Universidad Católica del Perú.

Mager, J. M., & Meza, I. V. (2018). Hacia la traducción automática de las lenguas indígenas de México. En *Proceedings of Digital Humanities 2018*.

Meque, A. G. M., Angel, J., Sidorov, G., & Gelbukh, A. (2023). Traducción automática entre lenguas indígenas de México y el español. *Research in Computing Science*, 152(9), 329–337.

Ministerio de Cultura. (2016). Resolución Viceministerial N.º 073-2016-VMPCIC-MC: Declaran Patrimonio Cultural de la Nación a la lengua shiwilu. El Peruano.

Ríos, J. C. (2019). Traducción automática náhuatl–español: variables que influyen en la calidad de la traducción. Tesis de maestría, Universidad Nacional Autónoma de México.

UNESCO. (2023). El empoderamiento digital impulsa el Decenio Internacional de las Lenguas Indígenas. UNESCO.

Valenzuela, P. M. (2018). Shiwilu (Jebero). *International Journal of American Linguistics*, 84(S1), S19–S24.

Chowdhury, G. G. (2003). Natural language processing. *Annual Review of Information Science and Technology*, 37(1), 51–89. <https://doi.org/10.1002/aris.1440370103>

Socher, R., & Manning, C. D. (2013). Deep learning for NLP (without magic). In J. Lin & K. Erk (Eds.), *NAACL HLT 2013 Tutorial Abstracts* (pp. 1–3). Association for Computational Linguistics. <https://aclanthology.org/N13-4001/>

Zoph, B., Yuret, D., May, J., & Knight, K. (2016). Transfer learning for low-resource neural machine translation. *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1568–1575. <https://doi.org/10.18653/v1/D16-1163>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30. <https://arxiv.org/abs/1706.03762>

Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: a method for automatic evaluation of machine translation. *Proceedings of ACL 2002*, 311–318. <https://aclanthology.org/P02-1040.pdf>

Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. *International Conference on Learning Representations (ICLR)*.

<https://arxiv.org/abs/1409.0473>

Popović, M. (2015). chrF: character n-gram F-score for automatic MT evaluation. Proceedings of the Tenth Workshop on Statistical Machine Translation (WMT 2015). <https://aclanthology.org/W15-3049.pdf>

Apéndice A

Anexos

Los anexos deben ser referenciados desde el documento. Por ejemplo, debe existir un párrafo donde se diga que determinada información puede ser vista en el Anexo X

Los anexos pueden numerarse con letras o número de acuerdo con su preferencia.

Anexo A: Plan de Proyecto

- Justificación

El presente proyecto surge de la necesidad urgente de crear soluciones tecnológicas que ayuden a preservar, enseñar y usar de forma cotidiana las lenguas originarias en peligro de extinción, en particular el shiwilu. Esta lengua enfrenta una seria amenaza debido a la escasez de recursos digitales, corpus lingüísticos y herramientas de traducción automática, lo que limita su documentación, aprendizaje y revitalización. Frente a ello, la investigación busca cerrar la brecha entre el conocimiento existente y su aplicación práctica en entornos educativos y tecnológicos.

El objetivo central es diseñar e implementar un sistema de traducción automática neuronal bidireccional entre shiwilu y castellano, basado en la creación de un corpus paralelo depurado y en protocolos de evaluación que combinan métricas automáticas con validación por hablantes. Este enfoque se apoya en los avances del aprendizaje profundo y del procesamiento del lenguaje natural en contextos de bajo recurso, adaptando modelos y arquitecturas a las particularidades lingüísticas del shiwilu para garantizar resultados técnicamente sólidos y culturalmente pertinentes.

El proyecto tendrá impacto en tres niveles: académico, al generar recursos reproducibles para futuras investigaciones; tecnológico, al demostrar la viabilidad de un traductor neuronal en escenarios con pocos datos; y social, al fortalecer los esfuerzos de revitalización lingüística mediante una herramienta accesible para docentes y comunidades. En conjunto, esta propuesta representa un aporte técnico y humano que une la innovación con el compromiso cultural, reafirmando el papel de la ingeniería al servicio de la diversidad lingüística.

- Viabilidad

El presente proyecto es viable desde los puntos de vista técnico, metodológico, institucional y económico, dado que se sustenta en recursos accesibles, herramientas de libre uso y un plan de ejecución compatible con los plazos y capacidades de un proyecto académico universitario. La naturaleza tecnológica, documental y experimental de la investigación permite alcanzar los objetivos propuestos mediante procedimientos reproducibles y verificables, sin requerir infraestructura especializada ni financiamiento externo significativo. En otras palabras, es una iniciativa que se sostiene sobre bases sólidas y realistas, donde la precisión técnica y la sensatez operativa caminan de la mano.

Desde la perspectiva técnica, la viabilidad se respalda en el uso de plataformas y librerías de código abierto ampliamente reconocidas en el ámbito del aprendizaje profundo y el procesamiento del lenguaje natural. Cada experimento puede documentarse, replicarse y compararse, lo que refuerza la confiabilidad del proceso. Además, la implementación puede realizarse en entornos locales o en plataformas de cómputo en la nube de bajo costo, demostrando que la innovación no siempre requiere grandes presupuestos, sino ingenio y método. El flujo de trabajo, desde la construcción del corpus hasta la evaluación del modelo y la integración del prototipo, ha sido cuidadosamente diseñado para ser completamente reproducible y versionado, garantizando transparencia y continuidad.

En el plano metodológico, la investigación sigue un enfoque estructurado que combina ingeniería de datos, aprendizaje automático y evaluación lingüística. Las fases avanzan con orden lógico: recopilación y alineación del corpus paralelo shiwilu–castellano, entrenamiento y comparación de modelos neuronales bidireccionales, validación automática y participativa, e integración del prototipo funcional de traducción. Cada etapa cuenta con indicadores objetivos

y entregables definidos, asegurando coherencia entre los objetivos y los resultados. El registro sistemático de parámetros e hiperparámetros no solo aporta rigor científico, sino también una brújula para futuras réplicas y mejoras.

La viabilidad institucional del proyecto se ve reforzada por su alineación con las competencias formativas del programa de Ingeniería Informática y con los lineamientos de investigación aplicada de la Facultad de Ciencias e Ingeniería. Además, cuenta con la guía de un asesor especializado en inteligencia artificial y procesamiento de lenguaje natural, y con el respaldo metodológico del curso de tesis. A ello se suma el apoyo del Grupo Chana, comprometido con la revitalización del idioma shiwilu, y del señor Fidel Lomas Chota, hablante nativo y colaborador en proyectos lingüísticos, cuya participación garantiza la pertinencia cultural y la autenticidad del enfoque. La colaboración entre el conocimiento técnico y la sabiduría viva de la lengua convierte este proyecto en un puente entre la academia y la comunidad.

Finalmente, desde una perspectiva económica y temporal, el proyecto resulta plenamente realizable dentro del periodo académico establecido. El uso exclusivo de software libre elimina costos por licencias, y los requerimientos de equipamiento se limitan a equipos personales de desarrollo. Los gastos asociados a la validación lingüística son mínimos y responden a la logística de coordinación con los colaboradores. El cronograma propuesto contempla tiempos razonables y mecanismos de control de avance que aseguran el cumplimiento integral de los objetivos en el marco del semestre. En conjunto, todos estos factores confirman que la propuesta no solo es viable en teoría, sino también en práctica: un ejemplo concreto de cómo la tecnología, bien dirigida, puede ponerse al servicio del conocimiento y la preservación cultural.

- Alcance

El presente proyecto comprende el diseño, desarrollo y validación de un sistema de traducción automática neuronal bidireccional entre el idioma shiwilu y el castellano, orientado a fortalecer el aprendizaje y la preservación de la lengua. El trabajo abarca desde la recopilación y preparación de datos lingüísticos hasta la implementación de un prototipo funcional que permita realizar pruebas básicas de traducción. La ejecución se enmarca dentro del curso *Proyecto de Fin de Carrera I*, con una planificación que incluye actividades de gestión, modelado y validación lingüística en colaboración con hablantes nativos.

El alcance técnico incluye la construcción de un corpus paralelo shiwilu–castellano alineado y depurado, el desarrollo de modelos neuronales de traducción bajo un esquema reproducible y la elaboración de un prototipo local ejecutable para la demostración del sistema. Asimismo, se contempla la definición de un protocolo de validación participativa, que combina métricas automáticas con la evaluación cualitativa de hablantes, asegurando tanto la calidad lingüística como la pertinencia cultural del modelo. Durante el proceso, se llevará a cabo también la recolección paralela de *flashcards* junto al Grupo Chana y el señor Fidel Lomas Chota, con el fin de fortalecer el acervo léxico y los ejemplos de uso del idioma, sin que dicha actividad altere las particiones experimentales del corpus principal.

Quedan fuera del alcance del presente proyecto la implementación de una interfaz web o aplicación móvil de acceso público, la integración con servicios en línea de traducción, el entrenamiento de modelos multilingües a gran escala y la evaluación extendida en dominios distintos al educativo y comunitario. Estos aspectos se consideran líneas futuras de trabajo, una vez concluida la validación del prototipo y la consolidación del corpus paralelo.

- Limitaciones

Las limitaciones del proyecto constituyen los condicionantes que restringen su planificación, ejecución y alcance operativo. Estas se derivan tanto del contexto académico en el que se desarrolla la investigación como de los recursos y alcances definidos para el periodo de tesis. Su reconocimiento permite establecer expectativas realistas respecto de los resultados y definir futuras líneas de mejora.

En primer lugar, el proyecto presenta **limitaciones temporales** propias del marco académico en el que se ejecuta. El cronograma se encuentra delimitado por la duración de un semestre universitario, lo que restringe la posibilidad de realizar múltiples iteraciones de entrenamiento y evaluación del modelo. En consecuencia, el tiempo disponible para afinar los hiperparámetros, optimizar el rendimiento y explorar variantes arquitectónicas del modelo de traducción automática es limitado, priorizándose la obtención de un sistema funcional y evaluado dentro del periodo establecido.

Asimismo, se identifican **limitaciones técnicas y de recursos** vinculadas al uso de equipamiento personal y entornos gratuitos de cómputo en la nube, como Google Colab o Kaggle.

Estas plataformas, si bien son adecuadas para fines experimentales, imponen restricciones en capacidad de procesamiento, memoria y tiempo de ejecución, lo que puede afectar la cantidad de experimentos concurrentes o la profundidad de los entrenamientos. Pese a ello, el diseño modular y reproducible del proyecto permite mitigar estos efectos dentro del alcance académico propuesto.

En cuanto a los **datos disponibles**, el corpus paralelo shiwilu–castellano presenta un tamaño moderado y una diversidad temática acotada, derivada de la limitada disponibilidad de materiales bilingües y de la complejidad del proceso de alineación. Esto condiciona la generalización del modelo a dominios no representados y refuerza la necesidad de considerar esta versión como una base inicial susceptible de ampliación en futuros trabajos.

El proyecto también enfrenta **limitaciones de alcance funcional**, dado que el producto final consistirá en un prototipo ejecutable localmente, orientado a la demostración de la viabilidad técnica y lingüística del sistema. No se contempla el despliegue web ni la integración con plataformas externas, ya que el objetivo principal es validar la factibilidad del enfoque propuesto. De igual modo, las limitaciones de validación participativa derivan de la disponibilidad restringida de hablantes shiwilu; si bien se cuenta con la colaboración del Grupo Chana y del señor Fidel Lomas Chota, hablante nativo, la muestra para la evaluación lingüística será representativa pero acotada, centrada en garantizar pertinencia cultural más que amplitud estadística.

Estas limitaciones, resumidas en la tabla siguiente, no comprometen la validez del proyecto, sino que definen su marco operativo y orientan las posibilidades de mejora y expansión futura.

Tabla A.1: Limitaciones del proyecto

Tipo de limitación	Descripción	Impacto en el proyecto
Tiempo	El plazo de ejecución está restringido al semestre académico, lo que limita el número de iteraciones de prueba, ajuste y validación del modelo.	Menor margen para el <i>fine-tuning</i> progresivo y la experimentación con múltiples configuraciones de red.

Tabla A.1 (continuación)

Tipo de limitación	Descripción	Impacto en el proyecto
Recursos técnicos	El desarrollo se realiza con equipos personales y entornos gratuitos/ <i>low cost</i> de cómputo (Google Colab, Kaggle)	Entrenamientos más lentos y reducción en la cantidad de experimentos simultáneos.
Corpus	El corpus paralelo shiwilu–castellano posee volumen y variedad temática limitados, dependientes de fuentes disponibles y validación lingüística.	Restricción en la capacidad del modelo para generalizar a otros dominios o estilos discursivos.
Herramientas	Se emplean únicamente librerías y herramientas de código abierto, sin uso de software comercial especializado.	Limitación en la integración con sistemas avanzados de evaluación o despliegue profesional.
Alcance funcional	El entregable final es un prototipo local de traducción automática, sin despliegue web ni integración con servicios externos.	Enfoca los resultados en validación académica, no en uso público o masivo.
Validación participativa	La evaluación lingüística depende de la disponibilidad del Grupo Chana y del señor Fidel Lomas Chota, hablante nativo colaborador.	Muestra limitada de validación, centrada en la adecuación cultural más que en la cobertura estadística.

- Identificación de los riesgos del proyecto

En la presente sección se identifican los riesgos que podrían afectar el desarrollo del proyecto de tesis. Para ello, se emplea el umbral de riesgo mostrado en la Tabla X Anexo A, que permite medir la probabilidad, el impacto y la severidad como el producto de ambos.

A continuación del mismo, la Tabla X2 Anexo A presenta la matriz de riesgos con la calificación de severidad correspondiente.

Tabla A.2: Umbral de riesgo (probabilidad e impacto)

Probabilidad	Impacto Bajo (1)	Impacto Moderado (2)	Impacto Alto (3)
Si ocurre (5)	5	10	15
Probable (4)	4	8	12
Posible (3)	3	6	9

Tabla A.2 (continuación)

Probabilidad	Impacto Bajo (1)	Impacto Moderado (2)	Impacto Alto (3)
Improbable (2)	2	4	6
No ocurre (1)	1	2	3


Tabla A.3: Matriz de riesgos del proyecto

Descripción del riesgo	Síntomas	P	I	S	Mitigación	Contingencia
Interrupción o limitación del acceso a entornos de cómputo (Colab/Kaggle) durante el entrenamiento.	Sesiones finalizadas abruptamente, pérdida de progreso o tiempo de cómputo.	4	3	12	Guardar checkpoints automáticos y dividir los entrenamientos por etapas.	Reentrenar con subconjuntos reducidos o migrar temporalmente a otra plataforma gratuita.
Corpus paralelo reducido o con ruido en las alineaciones shiwilu–castellano.	Resultados inconsistentes, bajo puntaje BLEU o traducciones inestables.	3	3	9	Aplicar filtros automáticos de similitud, revisión muestral y limpieza manual.	Reprocesar corpus y ajustar criterios de alineación.
Resultados del modelo inferiores a los baselines esperados.	Estancamiento de métricas, sobreajuste o traducciones incoherentes.	3	2	6	Realizar <i>fine-tuning</i> gradual, control de semillas y ajuste de hiperparámetros.	Revertir al baseline y analizar logs para reajustar parámetros.
Disponibilidad limitada de hablantes para validación participativa.	Retrasos en sesiones de validación o muestra reducida.	3	3	9	Coordinar con anticipación con el Grupo Chana y el señor Fidel Lomas Chota; emplear instrumentos asincrónicos.	Sustituir por revisión lingüística parcial o sesiones virtuales.

Tabla A.3 (continuación)

Descripción del riesgo	Síntomas	P	I	S	Mitigación	Contingencia
Falta de tiempo para afinar y mejorar el modelo (<i>fine-tuning</i>).	Cronograma ajustado, tareas de entrenamiento solapadas con documentación.	4	3	12	Priorizar configuraciones reproducibles y registrar resultados intermedios.	Reducir variantes de modelo y enfocar esfuerzos en documentación y análisis.
Pérdida o inconsistencia de datos durante el preprocesamiento o entrenamiento.	Archivos corruptos o datos desalineados.	2	3	6	Implementar control de versiones y respaldos en la nube.	Restaurar desde <i>backups</i> verificados y repetir el procesamiento afectado.
Desviación del alcance del proyecto o incorporación de tareas no previstas.	Retrasos o sobrecarga de trabajo académico.	3	2	6	Control semanal de avance y revisión de cambios con el asesor.	Replanificar cronograma priorizando entregables críticos.

En la siguiente matriz se describen los riesgos identificados, sus síntomas, probabilidad (P), impacto (I) y severidad (S). Las medidas de mitigación corresponden a acciones preventivas destinadas a reducir la probabilidad de ocurrencia, mientras que las contingencias establecen las estrategias de respuesta planificadas para asegurar la continuidad del proyecto en caso de que alguno de los riesgos se materialice.



La Estructura de Descomposición del Trabajo (EDT) constituye una representación jerárquica que organiza las actividades del proyecto en componentes manejables y verificables. En el caso del presente trabajo, la EDT se divide en dos secciones principales: la Gestión del Proyecto, que comprende las tareas administrativas, académicas y de seguimiento vinculadas al curso de Proyecto de Fin de Carrera 1, y la Gestión del Producto, que abarca las fases técnicas orientadas al desarrollo del sistema de traducción automática neuronal bidireccional shiwilu–castellano.

La primera sección contempla los entregables establecidos en el curso (E1, E2 y E3), las reuniones periódicas con el asesor, el control de riesgos y avances, así como la composición final del documento de tesis. Por su parte, la gestión del producto comprende la recolección y preparación del corpus bilingüe, el modelado y entrenamiento del sistema de traducción, la validación lingüística participativa con hablantes nativos y el desarrollo del prototipo funcional. De manera complementaria, se incluye la recolección paralela de *flashcards* junto al señor Fidel Lomas, orientada al fortalecimiento del vocabulario y la base de datos lingüística.

El EDT permite visualizar de forma clara la relación entre los objetivos específicos, las fases técnicas y los entregables académicos del proyecto, garantizando la trazabilidad entre las actividades, el cronograma y los resultados esperados.

- Lista de tareas

Tabla A.4: Lista de tareas (EDT)

EDT	Nombre de la tarea	Duración (días)	Esfuerzo (h-persona)	Costo estimado (S/.)	Método de verificación y validación
1.1.1	Avance del cronograma y envío inicial	7	8	80	Revisión del cronograma inicial y validación con asesor
1.1.2	E1 – Plan de Proyecto	19	20	200	Entrega revisada y aprobada / asesor
1.1.3	E2 – Marco conceptual y estado del arte	27	28	280	Retroalimentación del asesor y validación del profesor del curso
1.1.4	E3 – Plan de proyecto y correcciones finales	36	32	320	Revisión del asesor y calificación final del curso
1.2	Reuniones con asesor de tesis	84	13	130	Correos de confirmación de reunión semanal
1.3	Control y seguimiento del proyecto	60	25	90	Bitácora de avances y reportes de progreso
1.4	Composición del documento de tesis	45	40	400	Revisión de formato PUCP y observaciones resueltas
2.1.1	Definición de fuentes y criterios de inclusión	10	12	100	Lista validada y aprobada por asesor
2.1.2	Limpieza y alineación del corpus	20	28	6	Comparación con corpus original y bitácora de preprocesamiento
2.1.3	Generación de particiones reproducibles	5	10	20	Scripts reproducibles y revisión de semillas
2.1.4	Recolección paralela con hablante (flashcards)	84	25	250	Validación lingüística con hablante (Grupo Chana / Fidel Lomas Chota)

Tabla A.4 (continuación)

EDT	Nombre de la tarea	Duración (días)	Esfuerzo (h-persona)	Costo estimado (S/.)	Método de verificación y validación
2.2.1	Definición de arquitectura y tokenización	10	20	45	Configuración aprobada y reproducible
2.2.2	Implementación y análisis de <i>embeddings</i>	6	20	45	Reporte técnico y comparación de resultados
2.2.3	Entrenamiento y pruebas del modelo	12	60	220	Registro de métricas y logs de entrenamiento
2.2.4	Optimización final del sistema	5	25	50	Evaluación de desempeño final del modelo
2.3.1	Diseño de instrumentos de validación	3	12	25	Aprobación del instrumento por asesor
2.3.2	Sesiones con hablantes y revisión lingüística	5	15	30	Rúbricas completadas y observaciones registradas
2.3.3	Análisis de resultados y observaciones	4	15	30	Informe consolidado con tablas y conclusiones
2.4.1	Diseño de la interfaz local	10	18	80	Prueba funcional en entorno local
2.4.2	Integración del modelo al prototipo	6	25	50	Verificación de inferencias correctas
2.4.3	Pruebas de funcionamiento y registro de resultados	5	20	40	Registro de casos de prueba y evidencias
2.4.4	Documentación final y demo	4	15	30	Presentación y revisión del prototipo

- Cronograma del proyecto

Tabla A.5: Cronograma del proyecto

EDT	Nombre de la tarea	Fecha de inicio	Fecha de fin	Duración planificada (días)	Dependencias
1	Gestión del proyecto	19/08/2025	19/11/2025	—	—
1.1	Entregables del curso de Tesis 1 (PFC1)	19/08/2025	19/11/2025	—	—
	Avance del cronograma y envío inicial	19/08/2025	25/08/2025	7	—
	E1 – Plan de Proyecto	27/08/2025	15/09/2025	20	1.1
	E2 – Marco conceptual y estado del arte	17/09/2025	13/10/2025	27	1.1
	E3 – Plan de proyecto y correcciones finales	15/10/2025	19/11/2025	36	1.1
1.2	Reuniones con el asesor de tesis	23/08/2025	15/11/2025	84	Paralelo a todas las tareas
1.4	Composición y edición del documento de tesis	19/08/2025	19/11/2025	93	Paralelo a todo el proyecto
2	Gestión del producto	17/02/2026	05/07/2026	—	—
2.1	Recolección y preparación del corpus	17/02/2026	27/03/2026	—	—
2.1.1	Definición de fuentes y criterios de inclusión	17/02/2026	28/02/2026	10	—
2.1.2	Limpieza y alineación del corpus	02/03/2026	20/03/2026	20	2.1.1
2.1.3	Generación de particiones reproducibles	23/03/2026	27/03/2026	5	2.1.2

Tabla A.5 (continuación)

EDT	Nombre de la tarea	Fecha de inicio	Fecha de fin	Duración planificada (días)	Dependencias
2.1.4	Recolección paralela con hablante (flashcards)	17/02/2026	10/05/2026	84	Paralela
2.2	Desarrollo del modelo de traducción	30/03/2026	13/05/2026	—	2.1.3
2.2.1	Definición de arquitectura y tokenización	30/03/2026	10/04/2026	10	2.1.3
2.2.2	Implementación y análisis de embeddings	13/04/2026	20/04/2026	6	2.2.1
2.2.3	Entrenamiento y pruebas del modelo	21/04/2026	06/05/2026	12	2.2.2
2.2.4	Optimización final del sistema	07/05/2026	13/05/2026	5	2.2.3
2.3	Validación lingüística participativa	14/05/2026	30/05/2026	—	2.2.4
2.3.1	Diseño de instrumentos de validación	14/05/2026	16/05/2026	3	2.2.4
2.3.2	Sesiones con hablantes y revisión lingüística	18/05/2026	24/05/2026	5	2.3.1
2.3.3	Análisis de resultados y observaciones	25/05/2026	30/05/2026	4	2.3.2
2.4	Desarrollo del prototipo funcional	01/06/2026	05/07/2026	—	2.3.3
2.4.1	Diseño de la interfaz local	01/06/2026	12/06/2026	10	2.3.3
2.4.2	Integración del modelo al prototipo	15/06/2026	22/06/2026	6	2.4.1
2.4.3	Pruebas de funcionamiento y registro de resultados	23/06/2026	29/06/2026	5	2.4.2

Tabla A.5 (continuación)

EDT	Nombre de la tarea	Fecha de inicio	Fecha de fin	Duración planificada (días)	Dependencias
2.4.4	Documentación final y demo	30/06/2026	05/07/2026	4	2.4.3

- Lista de recursos

- Personas involucradas y necesidades de capacitación

- * Tesista: Fabian Fernando Prado Infanson
- * Asesor: Mg. Héctor Erasmo Gomez Montoya
- * Colaboradores:
 - Fidel Lomas Chota: hablante nativo shiwilu, colaborador en la elaboración de flashcards y validación participativa.
- * Necesidad de Capacitación:
 - Las actividades a realizar el proyecto en el proyecto de fin de carrera se encuentran dentro del ámbito de la Ingeniería Informática y están respaldadas por los conocimientos adquiridas en cursos electivos de la especialización en Inteligencia Artificial. No se requiere capacitación adicional, aunque se reforzará el aprendizaje autodirigido mediante la revisión bibliográfica técnica actualizada sobre NMT.

- Materiales requeridos para el proyecto

- * Electricidad
- * Servicio de internet
- * Acceso a bibliografía y repositorios digitales (IEEXplore, arXiv, Github).

- Estándares utilizados en el proyecto

- * ISO/IEC 29110-5-1-2 – Gestión de proyectos para Very Small Entities (VSE).
- * Directrices éticas para la recolección y tratamiento de datos lingüísticos (basadas en ACL Ethics 2023).

- * Normas institucionales PUCP para la elaboración de trabajos de fin de carrera.
- * Principios FAIR de gestión y reutilización de datos (Findable, Accessible, Interoperable, Reusable).
- Equipamiento requerido
 - * Computadora personal con procesador Intel i7, 32 GB RAM y GPU RTX 5060 TI 16GB.
- Herramientas requeridas
 - * Python, PyTorch, Hugging Face Transformers y SentencePiece.
 - * Google Colab Pro / Kaggle como entornos de cómputo.
- Costeo del Proyecto
 - « Debe desarrollar un análisis de costos que incluya siempre:
 - costos por el equipo humano
 - costos por utilización de equipamiento (usar el concepto de depreciación)
 - costos por utilización de software, usar el concepto de TCO (Total cost of ownership) o amortización
 - Debe tener claro que costo es un concepto distinto al de gasto

A continuación, se presenta una plantilla mínima genérica que puede ser usada de base para establecer un presupuesto. Para los proyectos de curso es suficiente un solo nivel de partida.

Tabla A.6: Presupuesto del proyecto

Ítem	Descripción	Unidad	Cantidad	Valor unidad (S/.)	Monto parcial (S/.)	Monto total (S/.)
0	Costo total del proyecto	-	-	-	-	13665.00
1	Tesista	-	-	-	-	4600.00

Tabla A.6 (continuación)

Ítem	Descripción	Unidad	Cantidad	Valor unidad (S/.)	Monto parcial (S/.)	Monto total (S/.)
1.1	Fabian Prado Infanson	Hora	460	10	4600	-
2	Otros participantes	-	-	-	-	2240.00
2.1	Mg. H. Erasmo Gómez Montoya (Asesor académico)	Hora	37	20	740	-
2.2	Fidel Lomas Chota	Hora	100	15	1500	-
3	Materiales e insumos	-	-	-	-	1625.00
3.1	Electricidad	Mes	9	25	225	-
3.2	Servicio de internet	Mes	9	100	900	-
3.3	Google Colab Pro	Mes	5	100	500	-
4	Equipamiento y software	-	-	-	-	5200.00
4.1	Computadora personal	Unidad	1	5000	5000	-
4.2	Microsoft Office Suite	Anual	1	200	200	-